

Imię i nazwisko studenta: Aleksandra Sobecka

Nr albumu: 127585

Poziom kształcenia: studia pierwszego stopnia

Forma studiów: niestacjonarne

Kierunek studiów: Informatyka

Specjalność/profil: -

Imię i nazwisko studenta: Mateusz Naklicki

Nr albumu: 188578

Poziom kształcenia: studia pierwszego stopnia

Forma studiów: stacjonarne

Kierunek studiów: Informatyka

Profil: Algorytmy i modelowanie systemów

Imię i nazwisko studenta: Krystian Nowakowski

Nr albumu: 188728

Poziom kształcenia: studia pierwszego stopnia

Forma studiów: stacjonarne

Kierunek studiów: Informatyka

Profil: Algorytmy i modelowanie systemów

Imię i nazwisko studenta: Julia Młynarczyk

Nr albumu: 188719

Poziom kształcenia: studia pierwszego stopnia

Forma studiów: stacjonarne

Międzywydziałowy kierunek studiów: Inżynieria biomedyczna

prowadzony przez: Wydział Elektroniki, Telekomunikacji i Informatyki; Wydział Chemiczny; Wydział Fizyki Technicznej i Matematyki Stosowanej

Specjalność/profil: -

PROJEKT DYPLOMOWY INŻYNIERSKI

Tytuł projektu w języku polskim: Klasyfikacja sygnałów EEG do detekcji stanów uwagi

Tytuł projektu w języku angielskim: Classification of EEG signals for the detection of attention states

Opiekun pracy: dr hab. inż. Julian Szymański

STRESZCZENIE

Niniejsza praca koncentruje się na problemie klasyfikacji sygnałów EEG w celu detekcji stanów uwagi, takich jak relaks i skupienie. Zagadnienie to łączy elementy neurobiologii, przetwarzania danych oraz algorytmów uczenia maszynowego, znajdując zastosowanie zarówno w diagnostyce medycznej, jak i technologii interfejsów mózg-komputer (BCI).

Celem pracy było opracowanie skutecznych metod analizy i klasyfikacji sygnałów EEG, umożliwiających identyfikację stanów uwagi z wykorzystaniem wielokanałowej elektroencefalografii. Zakres badań obejmował wstępną obróbkę i filtrację danych EEG, ekstrakcję cech oraz zastosowanie zaawansowanych algorytmów klasyfikacyjnych, takich jak K-Nearest Neighbors (KNN), Support Vector Machines (SVM) oraz sieci neuronowe typu long short-term memory (LSTM).

Badania przeprowadzono z wykorzystaniem publicznego zbioru danych (LEMON) oraz własnych nagrań wykonanych przy użyciu czterech elektrod. Eksperymenty obejmowały analizę klasyfikacji stanu oczu otwartych i zamkniętych z elektrodami umieszczonymi w płacie potylicznym oraz analizę stanu relaksu i skupienia z elektrodami umieszczonymi w płacie centralnym. Zbadano wpływ różnych metod agregacji danych na skuteczność klasyfikatorów zarówno w środowisku offline, jak i na żywo. Zastosowane metody obejmowały m.in. redukcję artefaktów, analizę czasowo-częstotliwościową oraz optymalizację parametrów klasyfikatorów.

Wyniki eksperymentów wykazały wysoką skuteczność algorytmów w detekcji stanów uwagi, osiągając dokładność do 86% w warunkach rzeczywistych podczas eksperymentów z udziałem uczestnika. Potwierdzono korelację pomiędzy częstotliwościami fal EEG a poziomem koncentracji i relaksu, co podkreśla potencjał elektroencefalografii w precyzyjnym rozpoznawaniu stanów uwagi.

Praca wskazuje na możliwość zastosowania opracowanych metod w praktyce, w tym w systemach interfejsów mózg-komputer (BCI) oraz w aplikacjach wspierających terapię neuropsychologiczną i trening umysłowy.

Słowa kluczowe: EEG, klasyfikacja, stany uwagi, przetwarzanie danych, BCI

Dziedzina nauki i techniki, zgodnie z wymogami OECD: nauki inżynierskie i techniczne, inżynieria medyczna

ABSTRACT

This study focuses on the problem of EEG signal classification for detecting attention states, such as relaxation and focus. This topic combines elements of neurobiology, data processing, and machine learning algorithms, finding applications in both medical diagnostics and brain-computer interface (BCI) technologies.

The aim of this work was to develop effective methods for analyzing and classifying EEG signals to identify attention states using multi-channel electroencephalography. The scope of the research included the preprocessing and filtering of EEG data, feature extraction, and the application of advanced classification algorithms such as K-Nearest Neighbors (KNN), Support Vector Machines (SVM), and Long Short-Term Memory (LSTM) neural networks.

The study utilized both a public dataset (LEMON) and custom recordings conducted with four electrodes. The experiments included an analysis of the classification of open and closed eye states using electrodes placed in the occipital lobe, as well as the analysis of relaxation and focus states using electrodes located in the central lobe. The impact of various data aggregation methods on the classifiers' effectiveness was investigated in both offline and real-time environments. The methods applied included artifact reduction, time-frequency analysis, and classifier parameter optimization.

The results demonstrated the high effectiveness of the algorithms in detecting attention states, achieving an accuracy of up to 86% in real-time scenarios during participant testing. A correlation was confirmed between EEG frequency bands and levels of concentration and relaxation, emphasizing the potential of electroencephalography for the precise recognition of attention states.

This work highlights the practical applicability of the developed methods, including in brain-computer interface (BCI) systems and applications supporting neuropsychological therapy and cognitive training.

Keywords: EEG, classification, attention states, data processing, BCI

Field of science and technology according to OECD classification: engineering and technology, medical engineering

SPIS TREŚCI

Wykaz ważniejszych oznaczeń i skrótów	6
1. WSTĘP I CEL PRACY (<i>JULIA MŁYNARCZYK</i>)	7
2. WSTĘP TEORETYCZNY	8
2.1. Neurologiczne podstawy badania EEG (<i>Julia Młynarczyk</i>)	8
2.1.1. Czym jest badanie EEG	8
2.1.2. Historia EEG	9
2.1.3. Artefakty w sygnałach EEG	10
2.1.4. Potencjały wywołane	12
2.1.5. Wpływ impedancji oraz elektrod na sygnał EEG	12
2.2. Stany uwagi i ich biologiczne podstawy (<i>Julia Młynarczyk</i>)	14
2.2.1. Co to jest uwaga?	14
2.2.2. Neurobiologia uwagi	15
2.2.3. Zastosowanie badania uwagi	17
2.3. Przetwarzanie i filtracja danych (<i>Aleksandra Sobecka</i>)	17
2.3.1. Wstępna obróbka danych	18
2.3.2. Filtracja	18
2.3.3. Analiza czasowo-częstotliwościowa	19
2.3.4. Redukcja wymiarowości danych	21
2.3.5. Tworzenie modelu teoretycznego	22
2.3.6. Zbieranie danych EEG	22
2.3.7. Przetwarzanie sygnału EEG i filtracja danych	22
2.3.8. Porównanie metod filtracji	23
2.3.9. Wnioski	24
2.4. Wydobywanie cech (<i>Mateusz Naklicki</i>)	24
2.5. Algorytmy klasyfikujące (<i>Krystian Nowakowski</i>)	25
2.5.1. K-Nearest Neighbors	25
2.5.2. Support Vector Machines	26
2.5.3. Long short-term memory	27
3. WARSZTAT BADAWCZY	29
3.1. Środowisko pracy (<i>Mateusz Naklicki</i>)	29
3.1.1. Cyton	29
3.1.2. OpenBCI GUI	30
3.1.3. MNE	30
3.1.4. Brainflow	31
3.2. Zbieranie sygnału (<i>Mateusz Naklicki</i>)	31
3.2.1. Podłączanie elektrod	31
3.2.2. Lokalizacja elektrod	32
3.2.3. Weryfikacja jakości podłączenia	32
3.2.4. Stworzona aplikacja	32

3.3. Przetwarzanie sygnału	34
3.3.1. Filtracja sygnału (<i>Aleksandra Sobecka</i>)	34
3.3.2. Wybrane metody analizy i oczyszczania sygnału EEG w bibliotece MNE (<i>Aleksandra Sobecka</i>)	34
3.3.3. Agregacja sygnału EEG (<i>Krystian Nowakowski</i>)	36
3.4. Klasyfikacja	37
3.4.1. Narzędzia (<i>Krystian Nowakowski</i>)	37
3.4.2. KNN (<i>Krystian Nowakowski</i>)	38
3.4.3. SVM (<i>Krystian Nowakowski</i>)	39
3.4.4. LSTM (<i>Krystian Nowakowski</i>)	41
3.4.5. Klasyfikacja w czasie rzeczywistym (<i>Mateusz Naklicki</i>)	41
4. EKSPERYMENTY	43
4.1. Klasyfikacja stanu oczu otwartych i zamkniętych na zbiorze danych LEMON	43
4.1.1. Cel eksperymentu (<i>Mateusz Naklicki</i>)	43
4.1.2. Dane (<i>Mateusz Naklicki</i>)	43
4.1.3. Filtracja i pre-processing sygnału (<i>Aleksandra Sobecka</i>)	43
4.1.4. Eksploracja danych (<i>Mateusz Naklicki</i>)	55
4.1.5. Eksperyment (<i>Krystian Nowakowski</i>)	57
4.1.6. Wyniki (<i>Krystian Nowakowski</i>)	57
4.1.7. Wnioski (<i>Krystian Nowakowski</i>)	59
4.1.8. Dyskusja (<i>Krystian Nowakowski</i>)	59
4.2. Klasyfikacja stanu oczu otwartych i zamkniętych przy użyciu urządzenia Cyton	59
4.2.1. Cel eksperymentu (<i>Mateusz Naklicki</i>)	59
4.2.2. Zbieranie danych (<i>Mateusz Naklicki</i>)	60
4.2.3. Eksploracja danych (<i>Mateusz Naklicki</i>)	61
4.2.4. Eksperyment (<i>Krystian Nowakowski</i>)	63
4.2.5. Wyniki (<i>Krystian Nowakowski</i>)	63
4.2.6. Wnioski (<i>Krystian Nowakowski</i>)	66
4.2.7. Dyskusja (<i>Krystian Nowakowski Mateusz Naklicki</i>)	67
4.3. Klasyfikacja stanu relaksu i skupienia przy użyciu urządzenia Cyton	68
4.3.1. Cel eksperymentu (<i>Mateusz Naklicki</i>)	68
4.3.2. Zbieranie danych (<i>Mateusz Naklicki</i>)	68
4.3.3. Filtracja i pre-processing sygnału (<i>Aleksandra Sobecka</i>)	69
4.3.4. Eksploracja danych (<i>Mateusz Naklicki</i>)	73
4.3.5. Eksperyment (<i>Krystian Nowakowski Mateusz Naklicki</i>)	73
4.3.6. Wyniki (<i>Krystian Nowakowski Mateusz Naklicki Aleksandra Sobecka</i>)	75
4.3.7. Wnioski (<i>Krystian Nowakowski Mateusz Naklicki</i>)	89
4.3.8. Dyskusja (<i>Krystian Nowakowski Mateusz Naklicki</i>)	90
5. PODSUMOWANIE (<i>MATEUSZ NAKLICKI</i>)	92
Wykaz literatury	92
Wykaz rysunków	97
Wykaz tabel	99

WYKAZ WAŻNIEJSZYCH OZNACZEŃ I SKRÓTÓW

EEG – Electroencephalography (pol. elektroencefalografia)
MEG – Magnetoencephalography (pol. magnetoencefalografia)
MRI – Magnetic resonance imaging (pol. rezonans magnetyczny)
KNN – K-nearest neighbors (pol. k-najbliższych sąsiadów)
SVM – Support vector machines (pol. maszyna wektorów nośnych)
LSTM – Long short-term memory (pol. długa pamięć krótkotrwała)
MLP – Multi-layer perceptron (pol. perceptron wielowarstwowy)
PSD – Power spectral density (pol. gęstość widmowa mocy)
ERP – Event-related potential (pol. potencjały wywołane)
ICA – Independent component analysis (pol. analiza składowych niezależnych)
PCA – Principal component analysis (pol. analiza głównych składowych)
EO – Eyes Open, stan oczu otwartych
EC – Eyes Closed, stan oczu zamkniętych

1. WSTĘP I CEL PRACY

Julia Młynarczyk

Niniejsza praca inżynierska poświęcona jest zagadnieniom dotyczącym analizy sygnałów pozyskanych dzięki wielokanałowej elektroencefalografii (EEG) oraz ich klasyfikacji w celu detekcji stanów uwagi u osób badanych. Rozważane zagadnienie podejmuje aspekty pochodzące z wielu dziedzin nauk takich jak informatyka, inżynieria biomedyczna oraz analiza sygnałów

Aby lepiej rozumieć procesy zachodzące w ludzkim mózgu stosuje się liczne techniki obrazowania medycznego oraz analizowania aktywności tego narządu. Niemal każda działalność ciała człowieka generuje sygnał elektryczny. Dzięki technologii badań EEG jesteśmy w stanie określić bioelektryczną aktywność mózgu oraz powiązać ją z konkretnymi stanami uwagi. Możliwa jest także obserwacja procesów zachodzących w mózgu w stanie rzeczywistym. W celach klinicznych EEG stosowane jest głównie przy diagnozowaniu padaczki, zaburzeń snu oraz śpiączki czy śmierci mózgu [1].

Technologia elektroencefalografii znana jest już od 1929 roku i została zaproponowana przez Hansa Bergera. Duży skok technologiczny od tamtego momentu spowodował znaczne ulepszenie tej metody, wciąż jednak istnieją pewne trudności związane z rejestrowaniem zapisu aktywności mózgu w ten sposób. Wynikają one z małej amplitudy otrzymywanego sygnału ($10\div 100\ \mu\text{V}$), co spowodowane jest istnieniem lokalnej aktywności niewielkich obszarów mózgu oraz wpływem tkanek otaczających ten organ. Pomimo niskiej rozdzielczości przestrzennej badania możliwe jest jednak uzyskanie wielu cennych danych przy zastosowaniu technik przetwarzania sygnałów zarówno w dziedzinie czasu jak i częstotliwości, a także uczenia maszynowego. Wśród powszechnie stosowanych metod wyróżnić można filtrację sygnału, stosowanie algorytmów SVM oraz analizę spektralną [2, 3].

Metoda EEG, która dostarcza najwięcej informacji w zakresie rozpoznawania stanów uwagi oraz potencjałów wywołanych to elektroencefalografia wielokanałowa. Specyficzne ułożenie elektrod odgrywa istotną rolę w pozyskiwaniu danych do analizy przestrzennej potencjałów, a także ich zmienności w czasie. Obecnie uważa się, że proces poznawczy oraz myślowy nie mają linearnego przebiegu, a pojęcie uwagi jest bardzo zniuansowane i dzielące się na wiele kategorii, w ramach których można je rozpatrywać [4].

Celem pracy było przeprowadzenie badania EEG, przeanalizowania wyników pod kątem występowania różnych stanów uwagi takich jak skupienie czy relaks. Ważnym aspektem było także stworzenie odpowiedniego oprogramowania, które umożliwi wyżej wspomnianą analizę.

2. WSTĘP TEORETYCZNY

2.1. *Neurologiczne podstawy badania EEG*

Julia Młynarczyk

2.1.1. *Czym jest badanie EEG*

Badanie EEG (elektroencefalograficzne) stanowi nieinwazyjną metodę badania aktywności w mózgu za pośrednictwem elektrod umieszczonych na skądzie, za pomocą aparatury nazwanej elektroencefalografem. Wśród zasobów pozwalających na śledzenie czynności mózgowych EEG stanowi jedno z wiodących badań z uwagi na swoją wysoką rozdzielczość czasową, bezpieczeństwo, a także stosunkowo niskie koszty wymaganego sprzętu [5] [6].

Sygnał elektryczny wędrujący wzdłuż aksonów charakteryzuje się pewnymi cechami trudnymi do modelowania przez układy elektroniczne, a także do zarejestrowania przez techniki obrazowania. Do czynników utrudniających wyżej wspomniane działania należy fakt istnienia zarówno opóźnień globalnych, jak i lokalnych sygnału. Podczas procesów poznawczych wymagana jest komunikacja różnorodnych, często od siebie oddalonych, regionów mózgu, co sprawia, że czas tego procesu może się mieścić w zakresie 10÷30 ms. Pozyskanie informacji o tym, w którym obszarze mózgu, a także kiedy zaczęła się aktywność, a zatem zlokalizowanie grup neuronów odpowiedzialnych za dany proces poznawczy stanowi jedno z pól zainteresowań badań EEG [7]. Podsumowując, badanie EEG jest makroskopową metodą pozwalającą w sposób nieinwazyjny zbadać synchroniczną aktywność grup neuronów [8].

Rozważając temat EEG warto przeanalizować zjawiska biologiczne, które są podstawą do przeprowadzania tego badania. Ludzki mózg, najważniejszy z organów, składa się z połączonych ze sobą neuronów, które decydują o ludzkim zachowaniu [9]. Sygnał, który uzyskujemy podczas badania EEG to potencjały postsynaptyczne, powstałe w wyniku wiązania się neurotransmitera z receptorami na membranie postsynaptycznej [5]. Sygnały te przeważają nad krótkotrwałymi potencjałami czynnościowymi, czyli impulsami elektrycznymi przemieszczającymi się wzdłuż aksonów. Potencjały czynnościowe z uwagi na swoją losową naturę oraz generowanie dość małej aktywności są zasadniczo gubione w szumie tła i nie są rejestrowane przez elektrody [10]. Powstawanie prądu jonowego jest wynikiem ciągłego ruchu jonów takich jak Na⁺, K⁺, Cl⁻, a które wytwarzają różnicę potencjałów między wnętrzem komórki neuronu a jej otoczeniem. Właśnie ta różnica ładunków jest mierzona na powierzchni czaszki podczas badania EEG [7].

Podczas badania EEG mierzy się różnicę napięcia pomiędzy dwoma punktami na czaszce, natomiast w celu otrzymania lepszego sygnału stosuje się specjalny żel przewodzący (Ag-Cl) nakładany pomiędzy skórę głowy, a elektrody [8] [9]. Podczas rejestrowania aktywności elektrycznej mózgu wymagane jest zastosowanie wzmacniacza napięcia. Sygnały rejestrowane podczas badań EEG cechują się stosunkowo niską rozdzielczością przestrzenną oraz dużym stosunkiem szumu do sygnału, co bezpośrednio związane jest z obecnością czaszki [5]. Dodatkowo stosuje się także konwerter analogowo cyfrowy [9].

Przy wyborze elektrod do badania EEG powinno kierować się dwoma najważniejszymi czynnikami - rozmiarem oraz impedancją [8]. Sygnał pozyskiwany tylko z jednego neuronu jest zbyt mały do zarejestrowania, jednak gdy dochodzi do synchronicznej pracy ich ogromnej ilości moż-

liwa jest rejestracja sygnału na poziomie mikrowoltów. Standardowo stosowaną praktyką przy badaniach EEG stosuje się umiejscowienie elektrod według systemu 10-20 [9].

Surowy sygnał zebrany przez elektrody ze skóry głowy poddaje się filtracji oraz usuwa się z niego wszystkie artefakty. Następnie poddawany jest ekstrakcji cech, do której wykonania wykorzystuje się wiele technik przetwarzania sygnału. Niektóre z nich to transformacja Fouriera, transformacja falkowa, analiza głównych składowych (PCA) i wyodrębnienie znaczących cech. Końcowym etapem jest klasyfikacja sygnału, którą wykorzystuje się do docelowych obserwacji i wniosków [9].

2.1.2. Historia EEG

Historię badania EEG można datować od roku 1924, w którym to niemiecki psychiatra Hans Berger przy użyciu czułego, dwucewkowego galwanometru Simensa [11] po raz pierwszy dokonał zarejestrowania elektrycznego sygnału mózgu, a także jako pierwszy użył nazwy elektroencefalografia [12] [11]. Początkowe eksperymenty wykonywane były na osobach z defektami czaszki [12]. W latach 1926-1929 udało się ze sporym sukcesem zarejestrować rytm alpha oraz beta, a także prowadzić badania analizujące zmiany sygnału podczas otwierania oczu [11].

W późniejszych latach odkrycia te zostały potwierdzone przez badaczy takich jak Edgar Adrian i Brian Matthews, którzy w latach 30. nie tylko rozwijali tę technologię [12] [11], lecz także doprowadzili do zapisania się jej na stałe w świecie medycyny oraz powiązali sygnały EEG ze stanami uwagi, chorobami takimi jak epilepsja czy uszkodzeniami kory mózgowej.

Wraz z nastaniem technologii cyfrowej badanie EEG na stałe zagościło oddziałach intensywnej terapii. W późniejszych latach badanie stosowano głównie przy wykrywaniu aktywności padaczkowej oraz lokalizowania epileptogennych obszarów mózgu. Technologia ta przyczyniła się do rozpoznania wielu charakterystycznych dla epilepsji aktywności mózgu oraz pozwoliła właściwie postawić diagnozę chorym pacjentom. W dzisiejszych czasach technologia EEG wciąż pozostaje wiodącym narzędziem do diagnozowania epilepsji. [12].

Fale mózgowe pełnią istotną rolę w funkcjonowaniu mózgu, a także pozwalają na lepsze zrozumienie różnych funkcji fizjologicznych oraz stanów behawioralnych.

W skutek porozumiewania się ze sobą neuronów w ośrodkowym układzie nerwowym za pomocą sygnałów elektronicznych dochodzi do przepływu prądu jonowego w mózgu [7] [13] [14]. Gdy aktywność neuronalna jest ze sobą zsynchronizowana, np. podczas wykonywania różnorodnych czynności, prąd ten wykazuje stałe, rytmiczne zmiany napięcia, które określane są jako fale mózgowe lub oscylacje neuronalne [14].

Wyróżnić można dwa główne stany, które występują podczas wyżej wspomnianych zmian napięcia. Stany górne ("up states"), skojarzone z wyładowaniami potencjałów czynnościowych i depolaryzacją neuronów, a także stany dolne ("down states"), podczas których dochodzi do hiperpolaryzacji błon komórkowych oraz stanów spoczynkowych [14]. Występowanie tych stanów jest bardzo mocno związane z procesami sensorycznymi, motorycznymi, a także poznawczymi, co czyni je istotnym źródłem wiedzy o funkcjonowaniu mózgu.

Wraz z rozwojem technologii ustalono, że fale mózgowe można podzielić na określone pasma częstotliwości, które powiązać można w sposób bezpośredni ze stanami uwagi takimi jak stan relaksu czy skupienia [15], a także odpowiednimi obszarami mózgu [14]. Warto wspomnieć także, że charakterystyka fal mózgowych ulega zmianie wraz z wiekiem [15] [9].

Powszechny podział zakłada pięć różnych pasm – alpha, beta, theta, delta oraz gamma [13]. Dodatkowo, oprócz wyżej wspomnianych zakresów można także zdefiniować pasma takie

jak: infra niskie oscylacje (*infra slow oscillations (ISO)*) oraz oscylacje wysokich częstotliwości (*high-frequency oscillations (HFOs)*). Nie uznaje się ich jednak w typowych, klinicznych badaniach EEG z uwagi na generowanie przez zwiększony zakres częstotliwości większych kosztów sprzętu oraz potrzebnego miejsca na jego użytkowanie [15].

Pasmo	Zakres [Hz] [13]	Specyfika [13]
Delta	0,5 - 4	Głęboki, nieświadomy sen
Theta	4 - 8	Lekki sen, relaks
Alpha	8 - 14	Świadomy stan relaksu, oczy zamknięte
Beta	14 - 30	Normalna świadomość, aktywna koncentracja
Gamma	>30	Aktywna koncentracja, reakcja na bodźce wzrokowe

Tabela 2.1. Klasyfikacja fal mózgowych

Jak wynika z powyższej tabeli każde z pasm jest silnie skojarzone ze stanem uwagi w jakim w danej chwili znajduje się ludzki mózg. Podczas gdy fale o niższych częstotliwościach występują w znacznej mierze przy stanach relaksu i odpoczynku, te o częstotliwościach większych mają miejsce podczas aktywnego działania. Zaburzone występowanie któregośkolwiek z rytmów może wskazywać na nieprawidłową pracę mózgu oraz choroby [15].

- Delta (0,5 - 4 [Hz]): Rytm delta wykazuje się najwyższą amplitudą [9], a także najmniejszymi częstotliwościami. Jest on skojarzony ze stanem głębokiego snu [9] [15]. Stanowi wiodący rytm u dzieci. U dorosłych, którzy są w pełni obudzeni, ich występowanie stanowi anomalię [9].
- Theta (4 - 8 [Hz]): Rytm ten pojawia się we wczesnych stadiach snu [15], a także podczas głębokiej medytacji [9] czy relaksu [13]. Występuje głównie w czołowo-centralnych częściach głowy.[15]. Stanowi anomalię u obudzonych dorosłych, jednak jego występowanie jest normalne u dzieci do 13. roku życia [9].
- Alpha (8 - 14 [Hz]): Rytm alpha występuje powszechnie u ludzi w każdym wieku. U dorosłych pojawia się głównie podczas stanu zrelaksowania, a także przy zamkniętych oczach [9] [15]. Amplituda tego rytmu jest inna u różnych osób, a także różni się w różnych momentach u tej samej osoby [15]. Występuje po obu stronach głowy i stanowi rodzaj przejścia pomiędzy stanem nieświadomym oraz świadomym, rozbudzonym [9].
- Beta (14 - 30 [Hz]): Rytm beta stanowi najczęściej występujący rytm u dorosłych oraz u dzieci [15]. Rytm ten jest bardzo mocno skojarzony z odczuwaniem zmysłów, a także ze stanami takimi jak rozmowa, rozwiązywanie problemów oraz podejmowaniem decyzji [9]. Jest najbardziej zauważalny w czołowych oraz centralnych obszarach głowy i słabnie w kierunku tylnym [15].
- Gamma (>30 [Hz]): Badania tego rytmu możliwe były dopiero po wkroczeniu sprzętu EEG w erę cyfrową z uwagi na to, że analogowe sprzęty rejestrowały sygnały tylko do 25 Hz. Fale gamma są charakterystyczne dla stanu wzmożonego skupienia oraz integracji bodźców sensorycznych [9].

2.1.3. Artefakty w sygnałach EEG

W swoim założeniu badanie EEG powinno rejestrować elektryczną aktywność mózgu. Niestety nie istnieje sposób, aby podczas pomiarów pozyskać ten sygnał w niezakłóconej formie. Zapis EEG obarczony jest występowaniem elektrycznej aktywności, nazwanej artefaktami, ze źródeł

innych niż mózg [16]. W celu zapewnienia poprawności interpretacji wyników, należy uzyskane dane oczyścić ze wszystkich artefaktów [9]. Wyróżnia się dwie główne przyczyny powstawania artefaktów: biologiczne oraz niefizjologiczne [16] [17].

Do przyczyn fizjologicznych występowania artefaktów uwzględnia się ruchy gałek ocznych, mruganie czy aktywność mięśniową, w tym aktywność serca [16]. Do przyczyn niefizjologicznych artefaktów należą natomiast czynniki takie jak wady sprzętowe, które obejmują między innymi wadliwe elektrody, szумы linii elektrycznych czy zbyt wysoką impedancję połączenia elektroda-skóra [16].


Podczas gdy przyczyny niefizjologiczne są znacznie prostsze do wyeliminowania poprzez poprawę warunków przeprowadzania badania, a także dostosowanie aparatury, te drugie stanowią większy problem. Istnieje spore ryzyko, że przegapione, zostaną potraktowane jak normalna aktywność mózgu [17], a co za tym idzie mogą doprowadzić do błędnej diagnozy w przypadkach takich jak problemy ze snem czy choroba Alzheimera [16]. W celu wyeliminowania zanieczyszczonych fragmentów stosuje się ręczne przetwarzanie sygnału i odrzucanie segmentów, które negatywnie wpłynęłyby na wyniki badań [16].

Wśród biologicznych artefaktów można wyróżnić kilka głównych kategorii:

1. Artefakty oczne (*Ocular Artifacts*): Spowodowane ruchem gałek ocznych, a także mruganiem, których sygnał rozprzestrzenia się po skądzie i wpływa na zapis EEG [17] [16]. Zmiany spowodowane są zjawiskiem Bella (*Bell's Phenomenon*) obecnym podczas mrugania, gdy gałka oczna unosi się ku górze [18], w wyniku którego zmienia się orientacja dipola pomiędzy siatkówką a rogówką. Podczas mrugania zmienia się także konduktancja pomiędzy rogówką a powieką, co także znajduje swoje odzwierciedlenie w sygnale [17] [16]. Artefakty te są zauważalne głównie z zapisie z elektrod czołowych [18] [16] jako krótkie, gwałtowne odchylenia sygnału
2. Artefakty mięśniowe (*Muscle Artifacts*): Mogą być spowodowane zmianami napięcia mięśniowego w pobliżu miejsc rejestracji sygnału, a także czynnościami takimi jak wachanie, mówienie czy przełykanie [17] [16]. Posiadają dość szeroko rozłożone częstotliwości od 0 Hz do >200 Hz [16]. W przeciwieństwie do artefaktów ocznych nie ograniczają się one do jednego kanału rejestrującego, co sprawia, że są wyjątkowo trudne do usunięcia [16].
3. Artefakty sercowe (*Cardiac Artifacts*): Pojawiają się w przypadkach, gdy elektrody umiejscowione są w pobliżu naczynia krwionośnego, a ich częstotliwość wynosi około 1,2 Hz [16]. Wynikają z kurczenia i rozszerzenia się naczyń krwionośnych w wyniku pracy mięśnia sercowego. Ich kształt w zapisie przypomina fale mózgowe co sprawia, że stają się wyjątkowo trudne do usunięcia z zapisu EEG [17] [16]. Mają tendencję do pojawiania się w zapisie uzyskanym z elektrod po lewej stronie [18]. Objawiają się jako regularne, okresowe wzorce w sygnale, podobne do kompleksów QRS widocznych w elektrokardiogramie (EKG).

Wśród artefaktów pochodzących ze środowiska badawczego wyróżniamy natomiast [16]:

1. Zakłócenia pochodzące z sieci elektrycznej, które występują zazwyczaj na częstotliwościach 50 Hz (w Europie) lub 60 Hz (w Ameryce Północnej). Charakterystykę takiego artefaktu zaobserwować można na rysunku 2.1.
2. Chwilowe zakłócenia sygnału wynikające z drgań otoczenia, spowodowanych gwałtownymi ruchami w budynku (np. zamknięcie drzwi z dużą siłą). Zdarzenia takie skutkować mogą przejściowymi artefaktami widocznymi w rejestrowanym sygnale EEG.
3. Zakłócenia sygnału spowodowane przez zewnętrzne źródła promieniowania elektromagnetycznego, takie jak urządzenia elektroniczne (np. telefony komórkowe), instalacje mecha-



Rys. 2.1. Artefakt pochodzący z sieci elektrycznej

niczne (np. windy) oraz naturalne pola magnetyczne Ziemi, które mogą wprowadzać szумы i artefakty do rejestrowanego sygnału EEG.

4. Artefakty wynikające z działania aparatury pomiarowej, na przykład nieprawidłowe działanie czujnika, takie jak uszkodzona elektroda czy niewłaściwy jej kontakt z powierzchnią skóry głowy. Takie wydarzenie powodować może nagle i nieprzewidywalne skoki sygnału o dużej amplitudzie lub brak sygnału. Typ wykorzystywanej aparatury podczas badania oraz dodatkowe sprzęty mogą być źródłem dodatkowych zakłóceń powodujących zaszumienie sygnału.

2.1.4. Potencjały wywołane

Potencjały wywołane stanowią uśrednioną odpowiedź mózgu na krótkotrwałe bodźce wzrokowe, słuchowe czy dotykowe. W celu zarejestrowania takiej odpowiedzi istotne jest, aby sygnał został poddany odpowiedniemu przetwarzaniu, ponieważ posiada on zwykle bardzo małą amplitudę w porównaniu do szumu tła. Przy badaniach potencjałów wywołanych stosuje się wielokrotne powtarzanie bodźca stymulującego, następnie sygnał zostaje nagrany i uśredniony przez komputer [19] [20].

Obecnie wyróżnić możemy następujące rodzaje potencjałów wywołanych [20]:

1. Wzrokowe potencjały wywołane - reakcja mózgu na bodźce wizualne,
2. Słuchowe potencjały wywołane - reakcja mózgu na bodźce słuchowe,
3. Sensoryczne potencjały wywołane - reakcja na stymulację somatosensoryczną np. bodźce elektryczne.

Technologia badania potencjałów wywoływanych jest szeroko wykorzystywana w dziedzinach takich jak neurologia czy psychologia. Znajdują także zastosowanie w interfejsach-mózg komputer [19].

2.1.5. Wpływ impedancji oraz elektrod na sygnał EEG

Aby badanie EEG przyniosło satysfakcjonujące rezultaty bardzo istotne jest zadbanie o odpowiednie wartości impedancji pomiędzy elektrodami a skórą [21]. W kontekście EEG impedancja mierzona jest zwykle poprzez przepuszczanie niewielkiego prądu o częstotliwości 10 Hz pomiędzy dwiema elektrodami i pomiar oporu przepływu tego prądu [22]. Żywa skóra głowy pokryta jest warstwą martwego naskórka, która powoduje stosunkowo wysokie wartości impedancji bariery elektroda-skóra. Podczas pomiaru impedancji w ten sposób zmierzona wartość stanowi odzwierciedlenie impedancji wszystkiego, co znajduje się pomiędzy dwoma elektrodami, a tym samym pomiędzy każdą elektrodą a tkanką pod nią. Istnieją także metody, które pozwalają na uzyskanie wartości impedancji dla każdej elektrody z osobna [22].


Podczas przepływu prądu przez impedancję następuje spadek potencjału. Z tego powodu bardzo istotne jest utrzymywanie niskich wartości impedancji skalpowej. Jej wyższe wartości powodować by mogły większe spadki potencjału, co z kolei daje rezultat w postaci niższej amplitudy sygnału [23]. Niestety, w przypadkach, gdy badanie przeprowadzane jest z dużą ilością elektrod minimalizacja impedancji może okazać się kłopotliwa [22]. Standardowo, w badaniach EEG stosowany jest żel przewodzący w celu zredukowania wartości impedancji dla połączenia elektroda-skóra [21]. Większość wytycznych klinicznych dotyczących rejestrowania EEG przy użyciu nowoczesnych wzmacniaczy zawiera następujące ustalenia: impedancja powinna być mniejsza niż 10 k Ω , aby zapewnić wysoką jakość sygnału, ale większa niż 100 Ω , aby mieć pewność, że elektrody nie będą się zwierać ani tworzyć mostka przewodzącego [24].

Z uwagi na charakterystykę sygnałów EEG, tj. niestacjonarność, losowość, a także duży szum, bardzo istotne jest także stosowanie elektrod wytworzonych z odpowiednich materiałów zapewniających jak najwyższą jakość pobieranych danych [21]. Złoty standard stanowią obecnie elektrody typu Ag/AgCl połączone z żelem przewodzącym (elektroda pozbawiona jest bezpośredniego kontaktu ze skórą), co spowodowane jest głównie ich niezawodnymi właściwościami elektrochemicznymi oraz niskim poziomem szumu wewnętrznego [21] [25]. Nie jest to jednak rozwiązanie pozbawione wad, wśród których wymienić można między innymi potencjalne reakcje alergiczne pacjentów na żel [21] oraz ograniczony czas na przeprowadzenie badania z uwagi na wysychanie żelu czy długi czas wymagany do przygotowania do badania [25]. Z uwagi na przytoczone problemy badacze starają się obecnie wprowadzić rozwiązania, które zapewnią bardziej komfortowe dla pacjentów warunki oraz bardziej efektywne przeprowadzanie badania EEG. Jednym z proponowanych oraz testowanych rozwiązań są tzw. suche elektrody, nie posiadające one bezpośredniego kontaktu z elektrolitem jakim jest żel przewodzący, a dobre przewodnictwo zapewniają mikro-igły [21] [25]. Nie jest to jednak szeroko przetestowane rozwiązanie.

Bardzo istotnym aspektem badań EEG są systemy montażu elektrod, które dzielą się na dwie główne kategorie: bipolarny oraz referencyjny [26]. Montaż określa sposób umiejscowienia elektrod w wielokanałowym EEG. Każda ze wspomnianych kategorii charakteryzuje się innymi założeniami oraz realizacją. Istotnym jest jednak, że w przypadku użycia takich samych elektrod każdy z układów powinien zapewnić równoważne informacje [27].

- System bipolarny: Jest jednym z najprostszych i najszerzej stosowanych systemów montażowych [28]. Zakłada, że napięcie każdej elektrody jest porównywane z napięciem elektrody sąsiedniej, tworząc pewnego rodzaju łańcuch elektrod - "łańcuch bipolarny" [26] [28]. Najbardziej popularnym typem połączenia elektrod w montażu bipolarnym jest porównywanie elektrody do tej, która znajduje się tuż za nią [26]. W porównaniu do montażu referencyjnych, montaż bipolarne uznawane są za oferujące lepsze odrzucanie artefaktów, posiadające bardziej dokładną lokalizację przestrzenną, a także reprezentację zjawisk, która pozostaje niezależna od odniesienia [28]. W montażu bipolarnym kluczową rolę odgrywa odwrócenie fazy dzięki czemu ten typ montażu dobrze ilustruje lokalne nieprawidłowości. Wyjątek stanowi pojawienie się maksymalnego wyładowania na początku lub końca łańcucha [27].
- System referencyjny: W montażach referencyjnych wszystkie wartości napięcia na elektrodach porównywane są z jednym punktem odniesienia, który w praktyce stanowi najczęściej średnią napięcia wszystkich elektrod (wspólna średnia odniesienia) lub punkt na małżowinie usznej [26] [27]. Z uwagi na brak występowania odwrócenia fazy [26] wartość amplitudy może zostać wykorzystana do ustalenia największego napięcia - najbardziej aktywnego

obszaru. Montaż referencyjny oferuje także lepszą identyfikację rozproszonych wyładowań [27].



Rys. 2.2. Rozmieszczenie elektrod według międzynarodowego systemu 10-20 dla badań EEG.

Położenie elektrod na czaszce jest ściśle określone przez ustandaryzowany i szeroko stosowany system 10-20 [24] [26]. Wizualizację rozmieszczenia elektrod w tym systemie zaprezentowano na rysunku 2.2. System ten opiera się na zależności pomiędzy położeniem elektrody, a obszarem mózgu, który zlokalizowany jest tuż pod nią. Nazwa "10-20" odnosi się do faktu, że elektrody powinny być rozmieszczone w interwałach wynoszących 10-20% czaszki. System odnosi się zatem do proporcji na czaszce, a nie do jej wielkości. Umieszczenie elektrod opiera się zwykle na anatomicznie charakterystycznych punktach czaszki takich jak punkty przedusznej, nasion czy inion [29] [26]. System 10-20 w ścisły sposób określa nazwy elektrod, które oznaczone są literą oraz cyfrą. Litery w nazwie nawiązują do regionu mózgu, przy którym umieszczona jest elektroda - T dla obszaru czołowego (temporal), P dla obszaru ciemieniowego (parietal), natomiast O dla obszaru potylicznego (occipital). Cyfry parzyste wykorzystywane są do oznaczania prawej strony czaszki, natomiast nieparzyste do lewej [26]. Istnieją także inne systemy rozmieszczenia elektrod takie jak rozszerzony system 10-20, system 10-10 czy 10-5, nie są jednak tak powszechnie stosowane [30].

2.2. Stany uwagi i ich biologiczne podstawy

Julia Młynarczyk

2.2.1. Co to jest uwaga?

Pojęcie uwagi jest bardzo trudne do zdefiniowania i postrzegane różnie w zależności od rozważanej dziedziny. Inaczej definiowana jest uwaga z punktu widzenia psychologii, neurobiologii czy codziennego życia. W najbardziej ogólnym znaczeniu uwagę można zdefiniować jako poziom podwyższonej czujności lub zdolność do zaangażowania się w otoczenie [4]. Badania pokazują, że sen jest bardzo ściśle powiązany z uwagą. Osoby w różnych cyklach snu lub pozbawione go przez długi czas, a także pod wpływem środków nasennych, wykazują mniejsze zdolności do skupiania uwagi i podwyższonej czujności. W przypadku wykonywania zdań odbieranych jako nudne czy monotonne poziom uwagi także ulega zmniejszeniu. Jest możliwe jednak manipulowanie po-

ziomem uwagi poprzez wprowadzenie nowych bodźców takich jak stres, obiecana nagroda czy urozmaicenie wykonywanych zadań [31].

Oprócz ogólnego wzmożonego poziomu czujności uwagi może być także definiowana jako świadoma odpowiedź na konkretny bodziec sensoryczny [4]. Znakomita część badań nad uwagą w dziedzinach takich jak psychologia czy neurobiologia skupia się na reakcjach na bodźce wzrokowe [32]. Uwagę wzrokową podzielić można na przestrzenną oraz opartą na cechach. Definiowanie tej pierwszej opiera się na założeniu, że umiejscowienie spojrzenia na konkretnym miejscu w przestrzeni stanowi przeznaczenie pewnego zasobu uwagi. Próbuując skategoryzować uwagę według drugiego kryterium zakłada się, że można ją kierować jedynie na określonych cechach wizualnych na przykład na kolorze czy określonym kształcie [4]. Inne zmysły, takie jak słuch czy dotyk, także są w stanie generować stan uwagi. Jednym z przykładów poruszających problem selektywnej uwagi podczas słuchania jest zagadnienie zwane "problem imprezy koktajlowej", które polega na trudności w skupieniu się na wypowiedzi jednej osoby w tłumie ludzi i panującym hałasie [33].

W przypadku występowania wielu równoczesnych i konkurujących ze sobą zadań wymagane jest istnienie swojego rodzaju centralnego zarządzania, które pozwoli na decydowanie o działaniach, które należy podjąć. Łącząc dane sensoryczne oraz wiedzę pozyskaną w przeszłości możliwe jest skoordynowanie tzw. kontroli wykonawczej pozwalającej na dokonywanie efektywnych wyborów. Kontrola ta związana jest zwykle z korą przedczołową i również stanowi pewną reprezentację uwagi [34]. System kontroli wykonawczej odpowiedzialny jest za wybieranie celów skupienia uwagi i przekazywanie ich do realizacji. Należy podkreślić, że podczas decydowania i uruchamiania mechanizmów kontroli wykonawczej bardzo istotną rolę odgrywają mechanizmy pamięci, które również mogą w pewien sposób kumulować uwagę [4].

2.2.2. *Neurobiologia uwagi*

Istnieje wiele badań neurologicznych, które badały obszary mózgowie odpowiedzialne za selektywne kierowanie uwagi, w tym uwagi wzrokowej, poprzez monitorowanie odpowiedzi kory mózgowej na zadane bodźce. Wykazano, że obszary czołowe oraz ciemieniowe są silnie związane z tym procesem, jednak badania te nie były całkowicie wolne od występowania innych procesów poznawczych, co sprawia, że jednoznaczne określenie obszaru mózgu odpowiedzialnego za uwagę staje się zadaniem niemożliwym do wykonania.

Biorąc pod uwagę budowę mózgu wyróżnić możemy następujące obszary, które z pewnością odgrywają ważną rolę w powstawaniu uwagi.

- Kora przedczołowa (PFC)- Odpowiada za zarządzanie funkcjami poznawczymi, w tym za kontrolę uwagi, a także za przenoszenie jej pomiędzy wykonywanymi zadaniami. Warto wyróżnić kluczowe obszary, które mają wpływ na kierowanie uwagi, Jednym z nich jest obszar grzbietowo-boczny (DLPFC), który odpowiada za uwagę skierowaną na cele, oraz przedni zakręt obręczy (ACC), którego zadaniem jest uczestniczenie w wykrywaniu konfliktów, a także kontrolowaniu impulsywności [35].
- Układ siatkowaty pnia mózgu - Jego głównym zadaniem jest utrzymanie poziomu pobudzenia, które jak już wcześniej zauważono w tej pracy, jest niezwykle istotnym czynnikiem wpływającym na zdolność skupiania uwagi. Aktywność tego obszaru jest w głównej mierze regulowana przez system noradrenergiczny, który zaopatruje mózg w norepinefrynę [36].
- Kora ciemieniowa - stanowi kolejny bardzo istotny obszar w mózgu przy analizowaniu zjawiska uwagi. Jej udział jest szczególnie istotny przy zintegrowaniu bodźców sensorycznych.

Obszar ten pozwala na postrzeganie kontrastów podczas obserwowania wizualnego oraz pozwala priorytetyzować bodźce, na których skupiana jest uwaga. Jest szczególnie istotny dla orientacji, jednak jego rola nie ogranicza się jedynie do tego zadania. Obejmuje także inne procesy, w tym procesy motoryczne [35] [37].

- Ciało migdałowe, hipokamp - Obszary te odpowiadają za pamięć oraz reakcje emocjonalne. Połączenia tych obszarów z korą przedczołową zapewniają odpowiedni kontekst emocjonalny, który odgrywa bardzo ważną rolę w przetwarzaniu informacji, a co za tym idzie podejmowaniu skutecznych decyzji [35].

Oprócz odpowiednich obszarów w mózgu bardzo istotne są także reakcje chemiczne i jego biologia biorące udział w kierowaniu selektywnej uwagi. Opierają się na działaniu kilku podstawowych neuroprzekaźników.

- Acetylocholina (ACh) - Jest to kluczowy neuroprzekaźnik, który moduluje uwagę. Aktywność tego neuroprzekaźnika w obszarach kory ciemieniowej i przedczołowej wpływa na poprawę selektywności uwagi, szczególnie podczas przetwarzania bodźców sensorycznych [38].
- Dopamina - System dopaminergiczny reguluje motywację oraz zdolność do utrzymywania uwagi. W przypadku dysfunkcji związanych z dopaminą mogą występować zjawiska takie jak deficyt uwagi, znany jako ADHD [37].
- Norepinefryna - Za jej wytwarzanie odpowiedzialne jest miejsce sinawe (LC), a sama jej obecność wspomaga pobudzenie oraz gotowość do reagowania na bodźce. Ten neuroprzekaźnik jest także odpowiedzialny za zdolność przenoszenia uwagi pomiędzy różnymi bodźcami [36].
- Serotonina - Reguluje impulsywność oraz emocjonalne aspekty zjawiska uwagi. Jej działanie skupione jest głównie na poziomie układów limbicznych oraz kory przedczołowej [39].
- Glutaminian - Jeden z najważniejszych neuroprzekaźników. Zaangażowany jest w proces szybkiej transmisji sygnałów w obrębie sieci uwagi [38].

Badania nad lokalizacją oraz mechanizmami neurologicznymi uwagi korzystają z zaawansowanych technik obrazowania dostępnych dzięki współczesnej medycynie. Ważną rolę w lokalizowaniu uwagi odgrywa także badanie EEG. Wśród tych technik można wyróżnić:

- Funkcjonalny rezonans magnetyczny (fMRI) - Jest to technologia, która umożliwia obserwację mózgu podczas wykonywania zadań. Obserwowanie aktywności mózgowej w czasie rzeczywistym za pomocą tej metody umożliwiło powiązanie aktywacji kory ciemieniowej z uwagą przestrzenną [37].
- Pozytonowa tomografia emisyjna (PET) - To nieinwazyjne badanie obrazowe, które wykorzystuje techniki radioizotopowe, wykazało, że zwiększona aktywność dopaminergiczna w korze przedczołowej i prążkowi jest powiązana z efektywnością selektywnej uwagi [37].
- Elektroencefalografia (EEG) - Dzięki rejestrowaniu fal mózgowych możliwa jest detekcja stanów uwagi, gdyż fale te stanowią swego rodzaju wskaźniki uwagi. Wysokie amplitudy fal beta oraz gamma wskazują na intensywne zaangażowanie uwagi. Przy obecności fal alfa wnioskować można, że mózg znajduje się w stanie relaksu oraz braku skupienia [39].

Neurobiologia uwagi jest procesem niezwykle złożonym, który niewątpliwie angażuje wiele struktur mózgowych, mechanizmów biologicznych oraz chemicznych. Dzięki możliwościom oferowanym przez współczesną medycynę możliwe jest lepsze rozumienie tych mechanizmów.

2.2.3. Zastosowanie badania uwagi

Badania nad uwagą pozwalają na diagnozowanie oraz monitorowanie wielorakich zaburzeń uwagi, a także na opracowywanie różnych technologii, których zadaniem jest wspomagać medycynę, edukację czy inżynierię. W kontekście pracy nad klasyfikacją sygnałów EEG istotne jest omówienie, jakie zaburzenia uwagi mogą być diagnozowane za pomocą analizy sygnałów EEG oraz w jaki sposób technologie opierające się na EEG wspierają badania.

Obecnie sygnały EEG używane są w diagnostyce zaburzeń uwagi takich jak:

- Zespół nadpobudliwości psychoruchowej z deficytem uwagi (ADHD) – W przypadku tego zaburzenia można mówić o zwiększonym stosunku fal theta do fal beta w sygnałach EEG. Występowanie takiego zjawiska jest jednym z biomarkerów diagnostycznych. Przy tym zaburzeniu charakterystyczne są problemy z przełączaniem uwagi pomiędzy wykonywanymi zadaniami [40].
- Deficyty poznawcze w depresji – Wśród osób objętych depresją zauważalna jest zmniejszona aktywność fal beta oraz alfa. Stan taki koreluje z problemami z koncentracją oraz mniejszym pobudzeniem. Podczas badań zauważalna jest niezdolność do długotrwałego zaangażowania poznawczego w zadania o niskiej stymulacji bodźcowej [41].
- Uszkodzenia mózgu – Badanie EEG umożliwia monitorowanie zmian aktywności elektrycznej mózgu po różnorodnych urazach. Możliwa jest w ten sposób ocena zdolności pacjenta do ponownego odzyskania pełnej lub częściowej zdolności koncentracji [42].

Dzięki temu, że badania EEG umożliwiają obserwację sygnału w czasie rzeczywistym, wraz z postępem technologicznym, zaczęły pojawiać się rozwiązania takie jak urządzenia przenośne. Analiza sygnałów pozwala na wykrywanie stanów obniżonej koncentracji, a także ostrzegania użytkownika o konieczności przerwania wykonywanego zadania lub podjęcia działań zwiększających czujność [43]. Wśród przykładowych zastosowań takiej technologii wyróżnić można lotnictwo i motoryzację, gdzie detekcja uwagi u kierowców stanowi istotną rolę. Inne zastosowanie to różnego rodzaju rehabilitacja neurologiczna, gdzie monitorowanie postępu pacjentów w treningu poznawczym stanowi ważny aspekt prawidłowo przeprowadzonej terapii. Wykazano, że treningi neurofeedback okazały się niezwykle pomocne w poprawianiu zdolności poznawczych pacjentów [40] [42].

2.3. Przetwarzanie i filtracja danych

Aleksandra Sobecka

Najistotniejszym celem filtracji i przetwarzania jest oczyszczenie otrzymanego z badania sygnału EEG z szumów i artefaktów. Zadanie to jest niezbędne, aby w sposób poprawny móc interpretować wyniki pomiarów. Jest to również zadanie dość wymagające, ponieważ trzeba mieć na uwadze, że w przypadku zbyt agresywnego odfiltrowania można utracić również zapis z aktywności mózgowej, który jest istotny. W związku z tym, że sama aktywność mózgowa charakteryzuje się dość niską amplitudą, odfiltrowanie drobnych artefaktów związanych z m.in. aktywnością mięśniową, szumami sprzętowymi czy zakłóceniami sieciowymi, może być bardzo trudna do odseparowania od aktywności mózgowej [44]. Proces przetwarzania sygnału EEG składa się z etapów, które m.in. obejmują proces filtrowania sygnału, redukcję wymiarowości danych oraz analizę czasowo-częstotliwościową. Poniżej zostaną wymienione i opisane metody, które są kluczowe dla dalszej analizy.

2.3.1. Wstępna obróbka danych

Resampling (przepróbkowanie)

Sygnaly EEG są zazwyczaj rejestrowane z wysoką częstotliwością próbkowania, na przykład 500 Hz lub 1000 Hz. Taka duża ilość danych może prowadzić do niepotrzebnego, zwiększonego zapotrzebowania na zasoby obliczeniowe i pamięciowe podczas przetwarzania oraz analizy. Próbkowanie zbyt dużą częstotliwością może skutkować rejestrowaniem nadmiaru informacji, które nie mają wpływu na wykrywanie istotnych sygnałów, związanych z aktywnością mózgu. *Resampling* zbioru danych z wyższej do niższej częstotliwości (np. z 1000 Hz do 250 Hz) pozwala na zmniejszenie ilości danych bez wpływu na ich informatywność tj. utratę istotnych informacji w zakresie częstotliwości związanych z aktywnością mózgu (w typowym zakresie 1-45 Hz) [44]. *Resampling* jest również pomocny podczas prac z nagraniami pochodzącymi z różnych sesji, bowiem w takich nagraniach mogą wystąpić różnice w częstotliwościach próbkowania. Zastosowanie *resampling*-u prowadzi do ujednolicenia częstotliwości próbkowania, dzięki czemu dalszy proces analizy staje się bardziej spójny, a porównywanie danych z różnych nagrań jest bardziej wiarygodne. Matematycznie, *resampling* można zrealizować za pomocą interpolacji, czyli aproksymacji nowego sygnału na podstawie istniejących próbek. Interpolacja zakłada aproksymację nowej wartości na podstawie wartości sygnału w określonej liczbie próbek. Zaś decymacja polega na zmniejszeniu liczby próbek, poprzez zachowanie co n -tej próbki (np. co 10 próbek), co pozwala obniżyć częstotliwość próbkowania. Przed zmniejszeniem częstotliwości próbkowania należy przefiltrować sygnał za pomocą filtra dolnoprzepustowego o częstotliwości, która jest równa połowie docelowej częstotliwości próbkowania (czyli nowej częstotliwości Nyquista) [45]

Uśrednianie odniesienia (average referencing)

Metoda uśredniania polega na przeliczeniu sygnału z elektrod względem ich średniego potencjału. Pozwala to na eliminację globalnych zakłóceń (np. szumu sprzętowego). Ten krok w analizie danych EEG jest stosowany często jako standardowy etap poprawiający jakość danych [46]. Nie wpływa on bowiem na informatywność sygnału.

2.3.2. Filtracja

Filtry górnoprzepustowe i dolnoprzepustowe

Filtracja dolno- i górnoprzepustowa jest stosowana, aby ograniczyć analizowany sygnał do wybranego zakresu częstotliwości. W przypadku sygnału EEG często stosuje się filtr pasmowy w zakresie 1-45 Hz, co pozwala wyeliminować składowe niskiej częstotliwości (artefakty ruchowe) oraz składowe wysokiej częstotliwości (szumy elektromagnetyczne). Filtry górnoprzepustowe i dolnoprzepustowe to jedno z podstawowych narzędzi stosowanych w filtracji sygnałów. Pozwalają one na selektywne przepuszczanie określonych częstotliwości, jednocześnie tłumiąc inne. Filtr dolnoprzepustowy (low-pass filter) przepuszcza sygnały o częstotliwościach niższych niż określona częstotliwość graniczna (częstotliwość odcięcia) i tłumi częstotliwości wyższe od tej wartości. Celem stosowania tego filtra jest eliminacja szumów o wyższych częstotliwościach, które mogą być nieistotne dla analizy danego sygnału. Filtr górnoprzepustowy (high-pass filter) działa odwrotnie do dolnoprzepustowego – przepuszcza sygnały o częstotliwościach wyższych niż częstotliwość graniczna (częstotliwość odcięcia) i tłumi składowe częstotliwości poniżej tej wartości. Celem tego filtra jest usunięcie niskoczęstotliwościowych zakłóceń, takich jak np. artefakty ruchowe, które mogą zakłócać analizę [47].

Połączenie filtra górnoprzepustowego z dolnoprzepustowym pozwala utworzyć filtr pasmowoprzepustowy, który przepuszcza sygnały w określonym zakresie częstotliwości.

Filtr Notch

Filtr Notch, nazywany także filtrem pasmowozaporowym, służy do tłumienia określonego, wąskiego zakresu częstotliwości, przepuszczając jednocześnie wszystkie inne częstotliwości. Matematycznie, odpowiedź filtra Notch można wyrazić za pomocą funkcji:

$$H_{\text{notch}}(f) = \frac{f^2 + f_0^2}{f^2 + \frac{f_0}{Q}f + f_0^2}$$

Gdzie:

- f – Częstotliwość sygnału wejściowego (Hz).
- f_0 – Częstotliwość, którą chcemy stłumić (np. 50 Hz).
- Q – Współczynnik jakości filtra, określający szerokość pasma tłumienia:
 - Wyższa wartość Q oznacza węższe pasmo tłumienia.
 - Niższa wartość Q oznacza szersze pasmo tłumienia.

W przypadku zakłóceń na poziomie 50Hz (czyli takich jakie mogą być spowodowane przez sieć energetyczną w większości krajów Europy) za częstotliwość odcięcia przyjmiemy 50Hz, natomiast współczynnik Q określa jak selektywne ma być tłumienie tej częstotliwości.

2.3.3. Analiza czasowo-częstotliwościowa

Transformata Fouriera (FT)

Transformata Fouriera to podstawowe narzędzie służące do analizy częstotliwościowej sygnałów EEG. Polega na rozłożeniu analizowanego sygnału w dziedzinie czasu na składowe sinusoidalne o różnych częstotliwościach. Dla sygnału ciągłego zdefiniowana jest jako [48]:

$$F(\omega) = \int_{-\infty}^{\infty} f(t)e^{-j\omega t} dt \quad (2.1)$$

Gdzie:

- $F(\omega)$ – widmo częstotliwości sygnału w dziedzinie częstotliwości kątowej ω [rad/s],
- $f(t)$ – sygnał w dziedzinie czasu,
- ω – częstość kątowa, związana z częstotliwością f poprzez $\omega = 2\pi f$,
- $e^{-j\omega t}$ – funkcja wykładnicza opisująca oscylacje (jądro transformaty),
- j – jednostka urojona ($j = \sqrt{-1}$).

[49]

Dla sygnałów dyskretnych stosowana jest Dyskretna Transformata Fouriera (DFT):

$$X[k] = \sum_{n=0}^{N-1} x[n]e^{-j\frac{2\pi}{N}kn} \quad (2.2)$$

Gdzie:

- $X[k]$ – współczynniki DFT, reprezentujące widmo dyskretne sygnału,
- $x[n]$ – sygnał wejściowy w dziedzinie czasu, składający się z N próbek ($n = 0, 1, \dots, N-1$),
- N – liczba próbek sygnału (długość sygnału),
- k – indeks częstotliwości ($k = 0, 1, \dots, N-1$),

- $e^{-j\frac{2\pi}{N}kn}$ – jądro transformaty, opisujące oscylacje dla częstotliwości k ,
- j – jednostka urojona ($j = \sqrt{-1}$).

Szybka transformata Fouriera (algorytm obliczający DFT) pozwala m.in. na detekcję zakłóceń na określonych częstotliwościach (np. szum sieciowy), oraz umożliwia analizę aktywności mózgu w określonych pasmach częstotliwości (delta, theta, alpha, beta, gamma).

Transformata Falkowa (WT)

Transformata falkowa w porównaniu do transformaty Fouriera pozwala na bardziej zaawansowaną analizę sygnału, ponieważ analizuje sygnał w sposób lokalny, w dziedzinie czasu i częstotliwości jednocześnie. Pozwala to na detekcję artefaktów występujących w określonych przedziałach czasu (np. mrugnięcie oczu, przetykanie śliny) oraz na analizę zmiennej częstotliwości w różnym czasie.

$$W(a, b) = \int_{-\infty}^{\infty} f(t) \psi^* \left(\frac{t-b}{a} \right) dt \quad (2.3)$$

Gdzie:

- $W(a, b)$ – współczynniki transformaty falkowej dla skali a i przesunięcia b ,
- $f(t)$ – sygnał w dziedzinie czasu,
- $\psi(t)$ – funkcja falkowa (fala podstawowa, ang. wavelet), która jest przeskalowana i przesunięta,
- $\psi^*(t)$ – sprzężenie zespolone funkcji falkowej $\psi(t)$,
- a – skala, odpowiadająca rozciągnięciu lub skurczeniu funkcji falkowej,
- b – przesunięcie w czasie,
- $\frac{t-b}{a}$ – argument funkcji falkowej, wskazujący jej skalowanie i przesunięcie,
- dt – element całkowania w dziedzinie czasu.

[50]

Porównanie FT i WT

W tabeli 2.2 zestawiono różnice w cechach między transformatą Fouriera a falkową.

Tabela 2.2. Porównanie cech transformaty Fouriera (FT) i transformaty Falkowej (WT).

Cechy	Transformata Fouriera (FT)	Transformata Falkowa (WT)
Zakres analizy	Cały sygnał jednocześnie (globalna analiza częstotliwości).	Analiza lokalna (czasowo-częstotliwościowa).
Precyzja w lokalizacji artefaktów	Trudna do lokalizowania krótkotrwałych zakłóceń w czasie.	Pozwala na precyzyjną lokalizację zakłóceń w czasie i częstotliwości.
Przykładowe zastosowanie w EEG	Usuwanie zakłóceń o stałej częstotliwości, wyliczanie gęstości widmowej mocy (Power Spectral Density, PSD).	Usuwanie krótkotrwałych artefaktów, analiza zmiennych wzorców.
Reprezentacja częstotliwości	Jedynie w dziedzinie częstotliwości.	Czasowo-częstotliwościowa (lokalna analiza).
Przystosowanie do sygnałów niestacjonarnych	Nieefektywna – wymaga dodatkowego przetwarzania.	Dobrze przystosowana do sygnałów niestacjonarnych.

2.3.4. Redukcja wymiarowości danych

PCA (Principal Component Analysis)

Analiza głównych składowych (PCA, ang. Principal Component Analysis) jest statystyczną metodą analizy czynnikowej, której głównym celem jest redukcja wymiarowości danych przy jednoczesnym zachowaniu jak największej ilości istotnych informacji (tzw. informatywność). W praktyce PCA wykonuje rotację układu współrzędnych, aby uzyskać maksymalizację wariancji pierwszej współrzędnej (pierwszej głównej składowej), a następnie kolejnych. PCA opiera się na obliczeniu wartości własnych i wektorów własnych macierzy kowariancji danych. Przekształcenie danych wejściowych można wyrazić jako:

$$\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \quad (2.4)$$

Gdzie:

- $\mathbf{X}$: macierz danych wejściowych o wymiarach $N \times M$, gdzie:
 - N : liczba obserwacji (np. próbek czasowych),
 - M : liczba zmiennych (np. kanałów EEG),
- $\mathbf{U}$: macierz wektorów własnych (ortogonalna baza w nowej przestrzeni),
- $\mathbf{\Sigma}$: macierz wartości własnych (diagonalna macierz określająca wariancję wzdłuż nowych osi),
- $\mathbf{V}^T$: transponowana macierz wektorów własnych.

Dzięki temu przekształceniu dane są przedstawiane w nowym układzie współrzędnych, w którym pierwsza główna składowa opisuje największą możliwą wariancję w danych, druga składowa – drugą co do wielkości, trzecia kolejną itd.

Zastosowanie metody PCA względem danych pozyskanych z EEG pozwala m.in. na:

- redukcję wymiarowości poprzez zmniejszenie liczby głównych składowych,
- detekcję składowych, które mogą być odpowiedzialne za określone artefakty (np. mięśniowe).

[51]

ICA (Independent Component Analysis)

Analiza składowych niezależnych (ICA, Independent Component Analysis) to metoda, która pozwala na rozdzielenie sygnałów mieszanych na zbiór niezależnych sygnałów składowych. W kontekście EEG ICA jest używana do identyfikacji i usuwania niechcianych artefaktów, takich jak mrugnięcia oczu czy zakłócenia mięśniowe.

ICA zakłada, że sygnały rejestrowane są liniową mieszaniną niezależnych źródeł:

$$\mathbf{X} = \mathbf{A}\mathbf{S} \quad (2.5)$$

Gdzie:

- $\mathbf{X}$: macierz danych wejściowych (sygnałów zmierzonych na elektrodach EEG),
- $\mathbf{A}$: macierz mieszania, która opisuje, jak sygnały źródłowe są mieszane na kanałach EEG,
- $\mathbf{S}$: macierz niezależnych źródeł (odpowiadająca rzeczywistym sygnałom mózgowym i artefaktom).

Celem ICA jest obliczenie macierzy S , która reprezentuje niezależne źródła (np. sygnały mózgowe i artefakty), na podstawie zmierzonych danych X . Proces ten wymaga oszacowania macierzy odwrotnej W , gdzie:

$$S = WX \quad (2.6)$$

Gdzie:

- W : macierz odwrotna do A .

Metoda ICA w analizie sygnału EEG jest stosowana głównie do rozróżnienia artefaktów od faktycznej aktywności mózgowej. W zależności od rodzaju badania może również posłużyć jako metoda do analizy konkretnych źródeł aktywności związanej z wywołanymi bodźcami [52].

Porównanie PCA i ICA

W tabeli 2.3 zestawiono różnice między metodami analizy sygnału. Obie techniki są często stosowane razem, gdzie PCA służy jako wstępna redukcja wymiarowości przed bardziej szczegółową analizą przy użyciu ICA. [51] [52]

Tabela 2.3. Porównanie cech PCA i ICA.

Cecha	PCA	ICA
Cel	Redukcja wymiarowości, zachowanie wariancji	Rozdzielenie niezależnych źródeł
Założenie	Składowe są ortogonalne	Składowe są statystycznie niezależne
Metoda matematyczna	Wartości i wektory własne macierzy kowariancji	Maksymalizacja niezależności składowych
Zastosowanie w EEG	Redukcja wymiarowości, wstępna analiza	Usuwanie artefaktów, separacja źródeł

2.3.5. Tworzenie modelu teoretycznego

W ramach niniejszej pracy inżynierskiej opracowano metody przetwarzania i filtrowania sygnału EEG na podstawie pracy E. Ratajczak [53] oraz A. Babayan [44]. Po uzyskaniu własnych danych EEG, planuje się udoskonalenie opracowanego teoretycznego modelu filtracji sygnału.

2.3.6. Zbieranie danych EEG

Do stworzenia modelu teoretycznego, wykorzystano dane EEG zebrane w badaniu opisanym w artykule [44]. Dane zbierano przy użyciu 64-kanalowego systemu EEG z elektrodami rozmieszczonymi zgodnie z międzynarodowym systemem 10-20 [54]. Sygnały rejestrowano z częstotliwością próbkowania 1000 Hz, a dane przetwarzano zgodnie z metodami opisanymi w artykule [44].

Po uzyskaniu danych z własnych badań, planowane jest przeprowadzenie zbierania sygnałów fal mózgowych za pomocą urządzenia Cyton firmy OpenBCI. Dane powinny być zebrane w sposób możliwie najbardziej zbliżony do sposobów zaprezentowanych w pracach, na podstawie których powstanie model teoretyczny [53][44].

2.3.7. Przetwarzanie sygnału EEG i filtracja danych

Zespół LEMON w swojej pracy opisał przebieg filtracji uzyskanego sygnału i jego pre-processingu wg poniższego schematu:

- Resampling do 250 Hz,
- Zastosowanie filtru pasmowo-przepustowego 1-45 Hz,

- Inspekcja wizualna i odrzucenie kanałów, które wykazywały niską jakość sygnału,
- Inspekcja wizualna w celu odrzucenia odcinków zapisu z dużymi zakłóceniami, np. odcinki zawierające wysokie skoki częstotliwości.
- PCA z zachowaniem komponentów, które łącznie odpowiadały za 95% całkowitej wariancji danych (zachowano co najmniej 30 komponentów)
- ICA detekcja i usunięcie artefaktów związanych z ruchem oczu, mruganiem i artefaktów pochodzących z bicia serca. Po ICA dla stanu oczu otwartych zachowano średnio 197 komponentów, a dla EC (oczy zamknięte) zachowano ich średnio 21,4 [44].

Schemat związany z filtracją i pre-processingiem danych w pracy Pani Ratajczak był znacznie bardziej rozbudowany:

- Resampling do 256 Hz,
- Zastosowanie filtru górnoprzepustowego do 1 Hz,
- Automatyczne usuwanie złych kanałów (o niskiej jakości sygnału),
- Usunięcie złych epok o wartości amplitudy wyższej niż $444\mu V$,
- Zastosowanie filtracji dolnoprzepustowej z zachowaniem częstotliwości do 70 Hz,
- Usunięcie epok o amplitudzie powyżej $222\mu V$,
- Zastosowanie filtru Notch,
- Uśrednianie (average reference),
- ICA detekcja i usunięcie artefaktów,
- Interpolacja brakujących kanałów
- Usunięcie epok o amplitudzie powyżej $111\mu V$,
- wizualna inspekcja wraz z odrzuceniem złych epok [53].

2.3.8. Porównanie metod filtracji

Tabela 2.4 przedstawia porównanie przetwarzania sygnału EEG przedstawioną w pracach [53][44].

Tabela 2.4. Porównanie przetwarzania sygnału EEG

Kroki	Badanie "A mind-brain-body dataset"[44]	Praca Pani Ratajczak[53]
Resampling	Do 250 Hz	Do 256 Hz
Filtracja	1 - 45 Hz	1 - 70 Hz
Odrzucanie złych kanałów	Poprzez inspekcję wizualną	Automatyczne
Filtr Notch	B.D.	TAK
Usuwanie złych epok	NIE	TAK (amplituda powyżej $111\mu V$)
PCA	TAK (95% wariancji)	NIE
ICA	TAK (Infomax)	TAK (Mara, Adjust)
Rekonstrukcja danych	Back-Projection po ICA	Interpolacja brakujących kanałów
Inspekcja wizualna	odrzuć złych kanałów, odcinków zapisu z dużymi zakłóceniami	Odrzucanie epok

Oba podejścia do filtracji sygnału EEG wykazują różne strategie przetwarzania sygnału, odzwierciedlające ich specyficzne cele związane z kontekstem prac badawczych.

2.3.9. Wnioski

Metoda filtracji sygnału EEG zaproponowana przez zespół LEMON [44] charakteryzuje się większą ilością inspekcji manualnej, gdzie częściej wykonywany był przegląd wizualny sygnału oraz ręczne zaznaczanie elementów zapisu. Takie podejście wymaga eksperckiego podejścia do filtracji danych i niestety utrudnia wprowadzenie automatyzację procesu filtracji np. podczas wykonywania analiz w czasie rzeczywistym. Praca E. Ratajczak [53] jest natomiast bardziej rygorystyczna i bardziej zaawansowana pod względem usuwania artefaktów i niepożądanych składników sygnału. Wyższy poziom automatyzacji zastosowanych w tej pracy narzędzi zwiększa powtarzalność wyników, zmniejsza konieczność ludzkiej interwencji, a co za tym idzie eliminuje ryzyko subiektywizmu, jakim jest obarczone ręczne usuwanie zakłóceń. Ponadto, jedynie metody w pełni automatycznie mogą być zastosowane w przetwarzaniu danych w czasie rzeczywistym.

Do budowy teoretycznego modelu filtracji, zostaną wykorzystane dostępne zbiory danych pochodzące z pracy zespołu LEMON [44], ponieważ są one dostępne zarówno jako surowy sygnał, jak i po wykonanej przez profesjonalny zespół filtracji. Pozwoli to nie tylko opracowanie własnego teoretycznego modelu filtracji, ale także na porównanie jego efektywności z wynikami uzyskanymi przez zespół LEMON. Dzięki temu będzie możliwa ocena jakości filtracji teoretycznej i określenie, czy zastosowane metody mogą być porównywalne do pracy specjalistów.

Dalsze analizy i optymalizacje związane z filtracją danych będą obejmowały dostosowanie i udoskonalenie przygotowanej, teoretycznej metodologii filtracji sygnału dla danych, uzyskanych w wyniku przeprowadzonych badań. Na podstawie analizy prac [44] i [53] powstanie hybrydowy model filtracji, który na celu będzie miał połączenie zaawansowanej automatyzacji z pracy [53] z danymi referencyjnymi z pracy [44]. Celem takiego podejścia jest uzyskanie wysokiej jakości oczyszczonego sygnału EEG, który będzie mógł być przetwarzany w dalszych etapach nad detekcją stanów uwagi.

2.4. Wydobywanie cech

Mateusz Naklicki

Wydobywanie cech to kluczowy etap przetwarzania sygnału EEG, który polega na przekształceniu surowych danych w reprezentację umożliwiającą skuteczne wykorzystanie przez algorytmy klasyfikacyjne. Surowe sygnały EEG, choć zawierają bogate informacje o aktywności mózgu, są trudne do bezpośredniego wykorzystania ze względu na ich wysoką złożoność, niską stosunek sygnału do szumu oraz wielowymiarowość [6]. Proces ekstrakcji cech umożliwia wyodrębnienie najistotniejszych informacji, które odzwierciedlają specyficzne właściwości sygnału niezbędne do realizacji celu, takiego jak klasyfikacja stanów uwagi.

Przekształcanie sygnału

Analizę sygnału można przeprowadzać w różnych domenach, co pozwala na wydobycie informacji zarówno czasowych, jak i częstotliwościowych. W domenie czasowej analizuje się podstawowe statystyki sygnału, takie jak średnia, wariancja czy współczynnik asymetrii, które odzwierciedlają zmienność i charakterystyki amplitudy. W domenie częstotliwościowej, z wykorzystaniem transformaty Fouriera lub transformaty falkowej, identyfikowane są komponenty widmowe, takie jak pasma delta, theta, alfa, beta i gamma. Szczególną uwagę zwraca się na widmową gęstość mocy (PSD), która jest szeroko stosowaną cechą w analizie EEG i pozwala na ocenę aktywności mózgu w różnych pasmach częstotliwości [55].

Redukcja wymiarowości

Ze względu na dużą liczbę potencjalnych cech, proces redukcji wymiarowości ma kluczowe znaczenie dla zwiększenia efektywności algorytmów klasyfikacyjnych. Celem tego etapu jest wyeliminowanie cech redundantnych i mało informatywnych, zachowując jednocześnie maksymalną ilość istotnych informacji. Typowe techniki redukcji wymiarowości obejmują analizę głównych składowych (PCA) czy analizę składowych niezależnych (ICA). Redukcja wymiarowości pomaga również uniknąć zjawiska „przekleństwa wymiarowości”, które występuje, gdy liczba cech znacząco wzrasta, co prowadzi do problemów takich jak rozproszenie danych [55].

Selekcja cech

Po redukcji wymiarowości następuje selekcja cech, w której identyfikowane są te cechy, które najlepiej różnicują klasy sygnału, takie jak stany relaksu i koncentracji. W tym celu można wykorzystać algorytmy takie jak analiza wariancji czy algorytmy opierające się na drzewach decyzyjnych.

Proces wydobywania cech odgrywa fundamentalną rolę w przetwarzaniu sygnałów EEG, pozwalając na przejście od złożonych, szumowych danych surowych do zredukowanego, reprezentatywnego zestawu informacji. Właściwie dobrane cechy mają znaczny wpływ na skuteczność algorytmów klasyfikacyjnych [6].

2.5. Algorytmy klasyfikujące

Krystian Nowakowski

Klasyfikacja jest jednym z kluczowych zagadnień uczenia maszynowego. Polega ono na przypisywaniu obiektów do jednej z predefiniowanych kategorii na podstawie utworzonego wcześniej modelu. Stosowana jest w różnych dziedzinach, takich jak rozpoznawanie obrazów, przetwarzanie tekstu czy diagnostyka medyczna, w tym również analiza sygnału EEG [56]. Algorytmy klasyfikujące tworzą model na podstawie dostarczonych danych treningowych, zawierających przykłady wraz z etykietą, aby nauczyć się klasyfikować nowe, nieznane dane.

Modele te są poddawane walidacji krzyżowej, w której pełny zbiór danych jest losowo dzielony na k podzbiorów, a jeden z podzbiorów jest wykorzystany do testowania klasyfikatora. Pozostałe próbki stanowią zbiór uczący [57], proces ten powtarzany jest k razy, aż wszystkie podzbiory zostaną użyte dokładnie raz do przetestowania modelu. Ogólną wydajność algorytmu szacuje się jako średnią uzyskanych k dokładności [58], gdzie dokładność to miara skuteczności, określająca procent poprawnych predykcji względem całkowitej liczby prób.

Poniżej przedstawiono kilka popularnych algorytmów klasyfikacyjnych, które posiadają zastosowanie w analizie sygnałów EEG. Każdy posiada unikalne cechy, zalety i ograniczenia, które zostaną omówione w kontekście sygnału EEG [59].

2.5.1. *K-Nearest Neighbors*

KNN (*K-Nearest Neighbors*) to algorytm nadzorowanego uczenia maszynowego używany do klasyfikacji i regresji. Zasada jego działania bazuje na założeniu, że podobne do siebie próbki będą znajdować się w sąsiedztwie [60]. Jest to metoda nadzorowana, co oznacza, że wymaga zestawu danych treningowych z oznaczonymi etykietami do nauki. KNN jest algorytmem leniwym (lazy learner), ponieważ nie buduje modelu predykcyjnego podczas fazy treningu, tylko prze-

chowuje całą bazę danych treningowych [61]. Klasyfikacja nowego punktu odbywa się w czasie rzeczywistym poprzez porównanie go z punktami treningowymi.

Działanie algorytmu można opisać następująco:

1. Algorytm przechowuje w pamięci wszystkie punkty danych wraz z ich etykietami.
2. Gdy do modelu trafia nowy punkt do klasyfikacji, obliczana jest odległość między tym punktem, a innymi w zbiorze treningowym.
3. Wybrane zostaje k najbliższych punktów-sąsiadów ze zbioru treningowego.
4. Sąsiedzi głosują nad klasyfikacją nowego punktu: najczęściej stosowaną metodą jest głosowanie większościowe, gdzie punkt jest przypisany do klasy za którą stoi większość sąsiadów.
5. Klasa, która zdobyła najwięcej głosów, zostaje przypisana do nowego punktu.

Zalety algorytmu stanowi jego prostota, brak typowego treningu modelu oraz adaptacja do nowych danych.

Problem stanowi natomiast przechowywanie całości danych w pamięci, wrażliwość na nieistotne cechy i szumy oraz brak efektywności w przestrzeniach wielowymiarowych, jako że algorytm podatny jest na tzw. *przekleństwo wymiarowości* [62].

2.5.2. Support Vector Machines

SVM (*Support Vector Machines*) również jest algorytmem nadzorowanego uczenia maszynowego, który analizuje dane na potrzeby klasyfikacji i regresji. Konceptcją całego algorytmu jest znalezienie hiperpłaszczyzny z maksymalnym marginesem w celu oddzielenia różnych klas [63]. Margines jest to odległość pomiędzy pierwszymi obiektami danych klas, które nazywane są wektorami nośnymi. Szersze marginesy mogą zwiększyć dokładności klasyfikacji [64].

W przypadku problemów nieliniowych, stosuje się funkcje jądra, które, przekształcają dane wejściowe do wielowymiarowej przestrzeni cech [65]. Wyróżnia się dwa główne typy granic decyzyjnych:

- liniowe – dane można precyzyjnie rozdzielić liniowo na charakterystyczne klasy, dla danych dwuwymiarowych to linia prosta, a dla większych wymiarów hiperpłaszczyzna [66].
- nieliniowe – gdy dane nie mogą zostać rozdzielone na dwie klasy za pomocą linii prostej, funkcja jądra przekształca je w przestrzeń cech o wyższej wymiarowości, umożliwiając ich liniowe separowanie [66].

Najpopularniejsze typy jądra to:

- jądro liniowe (linear) – najprostsza formuła, w której nie wykonuje się transformacji do wyższych wymiarów, jest stosowana w przypadku danych liniowo rozdzielanych [67]. Równanie hiperpłaszczyzny wygląda następująco $K(w, b) = w^t x + b$, gdzie w to wektor wag, który określa orientację i kierunek hiperpłaszczyzny, x prezentuje dane wejściowe, parametr b określa położenie hiperpłaszczyzny względem początku układu współrzędnych.
- jądro wielomianowe (poly) – pozwala na modelowanie zakrzywionych granic decyzyjnych poprzez podniesienie cech wejściowych do określonej potęgi [67]. Równanie opisujące funkcję jądra ma postać: $K(w, x) = (\gamma w^t x + b)^n$, gdzie γ kontroluje wpływ współczynników, a n określa stopień wielomianu
- jądro Radial Basis Function (rbf) – zwane również jądrem Gaussa, modeluje złożone granice decyzyjne, uwzględniając odległość między punktami cech w przestrzeni wejściowej. Jądro to kontroluje wpływ każdej próbki na granicę decyzyjną. Jądro opisuje wzór:

$$K(x, x') = \exp\left(-\frac{\|x - x'\|^2}{2\sigma^2}\right) \text{ gdzie } \sigma \text{ jest parametrem skalującym [67]}$$

- jądro sigmoidalne (sigmoid) – umożliwia separację klas za pomocą granic decyzyjnych w kształcie funkcji sigmoidalnej [67]. Funkcja ta dobrze uogólnia się do niezbalansowanych danych. Opisuje je następujące równanie: $K(x_i, x_j) = \tanh(\gamma x_i x_j + b)$, gdzie γ jest parametrem regulującym wpływ iloczynu skalarnego między punktami, a b wyrazem wolnym, przesuwającym granicę decyzyjną.

Działanie algorytmu przebiega następująco:

1. Jeśli dane nie są liniowo separowalne, algorytm przekształca je do wyższej wymiarowości przy użyciu jądra.
2. Algorytm iteracyjnie generuje hiperpłaszczyzny.
3. Wybiera płaszczyznę, która prezentuje największą separację lub posiada największy margines pomiędzy klasami.
4. Jeśli nie istnieje płaszczyzna z maksymalnym marginesem, algorytm dodaje karę (tzw. funkcję straty) za każdy punkt przekraczający margines.

Zaletą algorytmu SVM jest mniejsza złożoność obliczeniowa w porównaniu do algorytmów KNN oraz sztucznych sieci neuronowych. Ponadto, metoda ta posiada solidne podstawy matematyczne oraz jest łatwa do dostosowania poprzez odpowiednie parametry [68].

2.5.3. Long short-term memory

LSTM (*Long Short-Term Memory*) to rodzaj rekurencyjnej sieci neuronowej zaprojektowanej do rozwiązania problemu eksplodujących i zanikających gradientów. Klasyczne sieci rekurencyjne często zawodzą w zadaniach, gdzie czas między wejściem a sygnałami uczącymi jest długi [69]. Sieć zaproponowana przez Hochreitera i Schmidhubera została opracowana z myślą o przechowywaniu długoterminowych zależności [70]. W odróżnieniu od standardowej sieci rekurencyjnej, LSTM posiada modułową strukturę, w której każda powtarzająca się jednostka składa się z czterech warstw oddziałujących ze sobą.

Kluczowym elementem LSTM jest stan komórki pamięci, który w procesie uczenia jest aktualizowany poprzez dodawanie lub usuwanie informacji za pomocą trzech głównych bramek [71] [72]:

1. Bramka zapomnienia

Odpowiada za usuwanie nieistotnych informacji ze stanu komórki. Wejście w danym momencie x_t oraz poprzedni stan ukryty h_{t-1} są podawane do bramki, która za pomocą sigmoidalnej funkcji aktywacji ogranicza wartość wyjścia do zakresu $[0, 1]$. Wartość 0 oznacza całkowite usunięcie informacji z komórki pamięci, a 1 — jej pełne zachowanie. Aby zaktualizować stan komórki, ograniczony wektor wejścia mnożony jest przez stan komórki.

2. Bramka wejściowa

Decyduje, jakie nowe informacje będą przechowywane w komórce pamięci. Składa się z dwóch części: pierwsza warstwa sigmoidalna wybiera, które informacje zostaną zaktualizowane, natomiast druga warstwa $\tanh$ tworzy wektor kandydatów na nowe wartości. Połączone elementy dodajemy następnie do komórki, aby zaktualizować stan.

3. Bramka wyjścia

Odpowiada za filtrowanie informacji wyjściowej na podstawie zaktualizowanego stanu komórki. Najpierw warstwa sigmoidalna wybiera, które informacje mają być wyprowadzone, a następnie stan komórki przekształcony przez warstwę $\tanh$ jest mnożony przez wynik warstwy sigmoidalnej, co daje ostateczne wyjście sieci.

LSTM, jako podejście umożliwiające przechowywanie informacji długoterminowych, eliminuje problem przeuczenia (*overfitting*), który może występować w podstawowych strukturach sieci rekurencyjnych stosowanych w algorytmach głębokiego uczenia [73].

3. WARSZTAT BADAWCZY


Rozdział ten ma na celu szczegółowe omówienie narzędzi oraz metod stosowanych w ramach przeprowadzonych badań, mających na celu klasyfikację stanów uwagi na podstawie sygnałów EEG. Obejmuje on opis środowiska sprzętowego i programistycznego używanego do zbierania danych EEG oraz procedury przetwarzania sygnału i ekstrakcji cech, które umożliwiają przygotowanie danych do analizy.

3.1. Środowisko pracy

Mateusz Naklicki

3.1.1. Cyton

Do przeprowadzanie eksperymentów wykorzystano urządzenie Cyton firmy OpenBCI, przedstawione na ilustracji 3.1. Jest to płytką zaprojektowaną do rejestrowania sygnałów bioelektrycznych, takich jak EEG (elektroencefalogram), EMG (elektromiogram) oraz EKG (elektrokardiogram). Urządzenie umożliwia podłączenie do 8 kanałów z częstotliwością próbkowania 250 Hz, co pozwala na dokładną rejestrację zmienności sygnałów, zachowując szczegóły charakterystycznych dla EEG pasm. Cyton komunikuje się z komputerem bezprzewodowo za pomocą modułu radiowego RFDuino, który umożliwia transfer danych za pośrednictwem specjalnego modułu USB [74].



Rys. 3.1. Urządzenie Cyton firmy OpenBCI

Urządzenie jest kompatybilne z różnymi typami elektrod – zarówno aktywnymi, jak i pasywnymi – co umożliwia dostosowanie konfiguracji do potrzeb badawczych. Przy przeprowadzaniu eksperymentów wykorzystano elektrody pasywne Gold Cup firmy OpenBCI [75]. Na elektrody nakładano pastę przewodzącą Ten20 [76], stosowaną do mocowania elektrod bezpośrednio na



Rys. 3.2. Wygląd aplikacji OpenBCI GUI z wyświetlonym panelem do mierzenia impedancji

skórze, zapewniając stabilne umieszczenie oraz zmniejszenie impedancji między elektrodą a skórą głowy [77].

Wykorzystywane urządzenie posiadało zainstalowany firmware OpenBCI v3 w wersji v3.1.2.

3.1.2. OpenBCI GUI

OpenBCI GUI to aplikacja dostarczona przez firmę odpowiedzialną za urządzenie Cyton – OpenBCI. Umożliwia ona wizualizację, rejestrowanie oraz strumieniowanie danych z urządzeń tej firmy. Użytkownik może dostosować ustawienia sprzętowe, takie jak wzmacnienie sygnału czy wybór kanałów bezpośrednio z poziomu aplikacji. Oferuje ona także podstawowe funkcje filtrowania sygnału, co pozwala na pracę z urządzeniem od razu po wyciągnięciu z pudełka [78].

W ramach badań przeprowadzonych na potrzeby tej pracy, wykorzystano OpenBCI GUI do sprawdzania impedancji elektrod przed rozpoczęciem rejestracji sygnałów EEG. Aplikacja umożliwia ocenę impedancji dla każdego kanału, co pozwala na weryfikację jakości połączenia elektrod ze skórą. Jest to konieczne aby zapewnić dokładność rejestrowanych danych oraz zmniejszyć występowanie artefaktów. Wygląd aplikacji przedstawiono na rysunku 3.2.

Podczas eksperymentów wykorzystana została wersja aplikacji openbcigui_v5.2.2_2023-08-21_16-14-34_windows64.

3.1.3. MNE

MNE to zaawansowana biblioteka open-source przeznaczona do analizy sygnałów bioelektrycznych, takich jak EEG, szeroko stosowana w neuroinformatyce oraz badaniach biomedycznych. Biblioteka została opracowana w języku Python i oferuje szereg narzędzi do przetwarzania,

wizualizacji oraz analizy sygnałów, a więc stanowi wszechstronne środowisko do badań nad aktywnością mózgu [79].

Dzięki MNE można przeprowadzać kompleksową analizę sygnałów EEG, począwszy od filtrowania i oczyszczania danych, przez ekstrakcję cech, aż do zaawansowanych metod analizy częstotliwościowej i czasowo-częstotliwościowej. Biblioteka wspiera różne formaty danych, co pozwala na integrację z wieloma systemami akwizycji danych.

W naszej pracy biblioteka posłużyła głównie do wczytywania danych z różnych źródeł, filtrowania sygnałów EEG oraz wydobywania cech niezbędnych do klasyfikacji. Podczas badań wykorzystaliśmy bibliotekę w wersji 1.7.1 [80].

3.1.4. Brainflow

BrainFlow to biblioteka open-source pozwalająca na akwizycję i przetwarzanie sygnałów bioelektrycznych z różnych urządzeń biosensorycznych. Jej głównym celem jest ujednolicenie interfejsu programistycznego dla różnych platform sprzętowych, co ułatwia tworzenie aplikacji niezależnych od konkretnego urządzenia [81].

BrainFlow dostarcza również narzędzia do przetwarzania sygnałów, takie jak filtrowanie czy odszumianie w czasie rzeczywistym, co pozwala na efektywną obróbkę danych dla klasyfikatorów. Dodatkowo, biblioteka zawiera funkcje wspierające implementację algorytmów uczenia maszynowego, co jest szczególnie przydatne w kontekście interfejsów mózg-komputer (BCI).

W ramach przeprowadzonych badań BrainFlow został wykorzystany do integracji z płytą Cyton, umożliwiając bezpośrednią akwizycję sygnałów EEG oraz ich wstępne przetwarzanie. Użyta została biblioteka w wersji 5.13.3 [82].

3.2. Zbieranie sygnału

Mateusz Naklicki

3.2.1. Podłączanie elektrod

Proces podłączania elektrod do skóry głowy uczestnika jest kluczowym etapem, ponieważ jakość połączenia elektrod ma bezpośredni wpływ na jakość rejestrowanego sygnału. Etap ten wymaga staranności, aby zapewnić jak najniższą impedancję połączenia, minimalizując zakłócenia i artefakty.

Podłączanie rozpoczyna się od przygotowania skóry w miejscach, gdzie będą mocowane elektrody. Skóra głowy jest delikatnie oczyszczana za pomocą wacika nasączonego roztworem izopropanolu, co pomaga usunąć nadmiar tłuszczu i innych zanieczyszczeń. Następnie na miejsce montażu elektrod nakłada się niewielką ilość specjalistycznego kremu przewodzącego, jak użytej pasty Ten20 Conductive Paste, który poprawia kontakt elektrody ze skórą i zmniejsza impedancję.

Elektrody są następnie przyklejane w wyznaczone miejsca zgodnie z systemem 10-20, który zapewnia ich odpowiednie rozmieszczenie względem anatomicznych punktów referencyjnych na czaszce. W przypadku użytych elektrod typu "gold cup" konieczne jest dodatkowe ich przyciśnięcie, aby pasta przewodząca wypełniła przestrzeń między elektrodą a skórą. W późniejszych nagraniach do mocowania elektrod wykorzystano również gumki recepturki, które znacząco podniosły stabilność położenia elektrod.

3.2.2. Lokalizacja elektrod

Lokalizacja elektrod na czaszce uczestnika jest przeprowadzana zgodnie z międzynarodowym standardem rozmieszczenia elektrod EEG, znanym jako system 10-20. System ten został zaprojektowany, aby zapewnić równomierne rozmieszczenie elektrod wzdłuż powierzchni głowy, z uwzględnieniem anatomicznych punktów referencyjnych.

Konkretne punkty rozmieszczenia elektrod zostały ustalone zgodnie z następującą procedurą:

1. Zmierzono odległość między punktem nasion (dolny środek czoła) a inion (tylny środek czaszki, w okolicy potylicznej). Użyto miarę krawiecką, aby dokładnie określić odległości wzdłuż krzywizny czaszki.
2. Obwód głowy zmierzono wzdłuż linii biegnącej przez punkty referencyjne oraz pionowej osi głowy.
3. Elektrody umieszczono w odległościach równych 10% i 20% długości całkowitej wzdłuż każdej z osi głowy (poprzecznej i podłużnej).

Punkty te były zlokalizowane przy pomocy miarki krawieckiej, a następnie oznaczane gumką recepturką. Proces ten zapewnia zgodność rozmieszczenia elektrod z przyjętymi standardami i pozwala na odtwarzalność eksperymentów.

3.2.3. Weryfikacja jakości podłączenia


Weryfikacja elektrod odbywała się poprzez pomiar impedancji za pomocą aplikacji OpenBCI GUI, która posiada tryb testu impedancji. W przypadku wysokich bądź różniących się wartości między elektrodami, były one dociskane w celu poprawy kontaktu, a jeśli to nie było wystarczające, miejsce połączenia było czyszczone, a mocowanie powtarzane.

3.2.4. Stworzona aplikacja

Aplikacja stworzona przez zespół stanowi narzędzie do kompleksowej obsługi eksperymentów EEG, umożliwiającym akwizycję, analizę i klasyfikację sygnałów w czasie rzeczywistym. Umożliwia również odtwarzanie nagrań, w celu ich ponownej ewaluacji. Została napisana w Pythonie i składa się z dwóch głównych modułów, które odpowiadają za różne aspekty obsługi danych EEG.

Pierwszy moduł aplikacji przedstawiony na ilustracji 3.3 umożliwia podgląd sygnałów EEG odbieranych w czasie rzeczywistym z urządzenia Cyton. Na wykresach przedstawiane są dane z wybranych kanałów w czasie rzeczywistym, co pozwala na wizualną inspekcję jakości sygnału i identyfikację potencjalnych zakłóceń. Umożliwiona jest regulacja parametrów wyświetlania. Możliwe jest również obrazowanie PSD na wykresie. Dzięki temu modułowi operator może szybko zidentyfikować problemy, takie jak artefakty ruchowe czy zakłócenia wynikające z niedostatecznego kontaktu elektrod i na tej podstawie wstrzymać nagrywanie.

Drugi moduł aplikacji, przedstawiony na ilustracji 3.4 skupia się na obsłudze eksperymentów oraz klasyfikacji. Użytkownik może rejestrować dane z eksperymentu, oznaczając realny stan uczestnika. Interfejs pozwala operatorowi na przełączanie się między blokami eksperymentu oraz oznaczanie rozpoczęcia i zakończenia każdego bloku. Każdy start/stop jest zawiadamiany sygnałem dźwiękowym. W przypadku gdy operator zauważy nieprawidłowość w sygnale, taką jak nieustające zakłócenia, może on odrzucić aktualny blok i nagrać go ponownie. Główną funkcjo-




Rys. 3.3. Moduł aplikacji wyświetlający sygnał z urządzenia w czasie rzeczywistym

nalnością jest testowanie modeli w czasie rzeczywistym na danych z bieżącego nagrania, umożliwiając obserwację wyników klasyfikacji dla różnych konfiguracji (np. średnia kanałów vs. analiza wszystkich kanałów). Możliwe jest sterowanie parametrami dotyczącymi przetwarzania danych: oknem filtracji, częstotliwością dokonywania przewidywań czy opóźnieniem w klasyfikacji względem aktualnego sygnału ze względu na efekt krawędziowy filtrów.

Dodatkowo możliwe jest ponowne odtwarzanie wykonanych nagrań, aby powtórzyć eksperyment bądź sprawdzić skuteczność zmiany parametrów. Aplikacja stale zapisuje wyniki osiągnięte przez każdy model wraz z aktualnymi ustawieniami w celu ich późniejszej analizy.

Aplikacja posiada również dodatkowe opcje, podawane jako parametry przy uruchamianiu, co pozwala na dostosowanie działania do specyficznych potrzeb eksperymentu. Przyjmuje ona:

- Parametr kontrolujący mechanizm odrzucania próbek o wysokiej amplitudzie
- Parametr określający liczbę próbek używanych do uśredniania predykcji modelu
- Parametr ustawiający ścieżkę do pliku, który będzie używany w trybie odtwarzania sygnału
- Parametr powodujący automatyczne zamknięcie aplikacji po zakończeniu odtwarzania
- Parametr definiujący próg pewności, jaki model musi osiągnąć, aby raportować zmianę stanu.



Rys. 3.4. Moduł aplikacji wyświetlający sygnał z urządzenia w czasie rzeczywistym

3.3. Przetwarzanie sygnału

3.3.1. Filtracja sygnału

Aleksandra Sobecka

Biblioteka MNE [83] oferuje bogate narzędzia do filtracji i przygotowania sygnału. Przygotowanie w odpowiedni sposób danego materiału badawczego do dalszych analiz jest bardzo istotne i niezbędne do uzyskania w późniejszych etapach analiz miarodajnych wyników. Proces filtracji danych w głównej mierze skupiał się będzie na zapewnieniu, że wszystkie elektrody dostarczają pożądane informacje (nie są np. uszkodzone) oraz na oczyszczaniu sygnału z różnego rodzaju artefaktów.

3.3.2. Wybrane metody analizy i oczyszczania sygnału EEG w bibliotece MNE

Aleksandra Sobecka

Biblioteka MNE [83] dostarcza wiele narzędzi do obróbki i preprocessingu surowego sygnału EEG. Poniżej zostaną wymienione najistotniejsze dla niniejszej pracy:

- **Narzędzia do inspekcji wizualnej** – funkcje, dzięki którym można szczegółowo przyglądać się danym na różnych etapach analizy sygnału:
 - `raw.plot()` – funkcja do przeglądania sygnału w czasie,
 - `raw.plot_psd()` – funkcja umożliwiająca analizę częstotliwościową sygnału,
 - `raw.plot_sensors()` – umożliwia wizualne rozmieszczenie elektrod na mapie czaszki.
- **Resampling** – funkcja pozwalająca na zmianę częstotliwości próbkowania: `raw.resample()`, dzięki czemu sygnał zostanie ujednolicony dla dalszych analiz.

- **Filtry pasowo-przepustowe** – narzędzie do zastosowania filtrów pasmowo-przepustowych `raw.filter()` (bandpass filter), które pozwalają na wyeliminowanie niechcianych częstotliwości z surowego sygnału EEG.
- **Filtr Notch** – filtr stosowany do tłumienia częstotliwości związanych z zakłóceniami pochodzącymi z sieci (w Europie 50 Hz, z możliwością dodania tłumienia składowych harmonicznych): `raw.notch_filter()`. Filtr, dzięki temu, że działa w wąskim zakresie częstotliwości, skutecznie usuwa zakłócenia i nie wpływa na szersze pasmo sygnału EEG.
- **Referencja EEG** – narzędzie do ustawiania referencji sygnału `raw.set_eeg_reference()`. W dalszej analizie użyto referencji średniej (*average reference*), co pozwoliło na uzyskanie bardziej jednolitej analizy sygnałów z różnych elektrod.
- **Montowanie standardowych układów elektrod** – funkcja `make_standard_montage()` służy do ustawienia standardowego układu elektrod (*standard 10-20 system*). Dzięki temu możliwe było zachowanie spójności w analizie sygnału pochodzącego z różnych eksperymentów.
- **Podział na epoki** – narzędzie pozwalające na uzyskanie reprezentatywnych fragmentów sygnału (przy określonej długości epok), które następnie mogą być analizowane i porównywane między sobą: `mne.make_fixed_length_epochs()`.
- **Narzędzia do usuwania artefaktów serca (ECG)** – MNE zawiera funkcje, które pozwalają na automatyczne wykrywanie i usuwanie artefaktów pochodzenia sercowego z sygnału EEG. Przykładem jest funkcja `mne.preprocessing.create_ecg_epochs()`, która generuje epoki zawierające artefakty sercowe, co ułatwia ich usunięcie poprzez inne metody jak np. ICA.
- **Narzędzia do usuwania artefaktów związanych z ruchem gałek ocznych (EOG)** – Biblioteka oferuje funkcję `mne.preprocessing.create_eog_epochs()`, która identyfikuje epoki zawierające artefakty związane z ruchami gałek ocznych, co pozwala na ich późniejsze usunięcie za pomocą SSP lub ICA.
- **PCA (Principal Component Analysis)** – PCA jest stosowane w celu redukcji wymiarów danych EEG, co pomaga zmniejszyć szumy i artefakty, szczególnie w przygotowaniu do dalszego przetwarzania sygnału.
- **ICA (Independent Component Analysis)** – technika, która umożliwia rozdzielenie źródeł sygnału EEG, co pozwala na identyfikację i usunięcie komponentów artefaktowych, takich jak ruchy oczu czy bicie serca, bez utraty użytecznych informacji. Za pomocą funkcji `ica.find_bads_muscle()` możliwa jest również automatyczna identyfikacja artefaktów mięśniowych.
- **Ręczne oczyszczanie sygnału** – MNE umożliwia również ręczne oznaczanie i wykluczanie fragmentów danych zawierających zakłócenia. Można oznaczać segmenty z widocznymi artefaktami, co pozwala na ich późniejsze wykluczenie z analizy.

Podczas filtrowania danych, kluczowym elementem jest również umiejętne porównanie wykonanych filtracji. W celu oceny najlepszego sposobu wykonanej obróbki konieczne jest porównanie metod z sygnałem oryginalnym. Poniżej opisano kluczowe narzędzia, które zostały wykorzystane m. in. do oszacowania efektów filtracji i umożliwiły ich porównanie:

- **PSD** – Umożliwia obliczenie gęstości mocy spektralnej (PSD - ang. Power Spectral Density) `raw.compute_psd()`. PSD pozwala na analizę mocy sygnału w funkcji częstotliwości, co

z punktu filtracji sygnału jest istotne przy porównywaniu efektów wykonanych filtracji dla różnych zakresów częstotliwości.

- **Topomap** – Pozwala na wizualizację topograficznego rozkładu sygnału EEG na powierzchni czaszki. Jest to przydatne przy analizie przestrzennej aktywności mózgu i porównywaniu topografii sygnału przed i po filtracji: `mne.viz.plot_topomap()`
- **Porównanie sygnałów** – Funkcje pozwalające na wizualizację sygnałów `raw.plot()`: były bardzo pomocne w zobrazowaniu efektów uzyskanych po przeprowadzonej filtracji na poszczególnych kanałach.

MNE zawiera wiele narzędzi do inspekcji i oczyszczania "surowych" danych EEG z artefaktów i szumów. Dzięki funkcjom wizualizacji możliwe jest również szczegółowe porównanie efektów po zastosowaniu metod filtrujących, co może znacznie poprawić poziom decyzyjności przy wyborze najlepiej przygotowanych danych, które powinny zostać wykorzystane do dalszych analiz.

3.3.3. Agregacja sygnału EEG

Krzysztof Nowakowski

W celu umożliwienia efektywnej klasyfikacji sygnału EEG, zaproponowano cztery warianty agregacji danych. Celem tych wariantów jest uproszczenie reprezentacji sygnałów oraz zbadanie stopnia utraty istotnych informacji. Każdy z wariantów wykorzystuje różne podejścia do uśredniania kanałów i częstotliwości, co pozwala na ocenę wpływu różnych metod agregacji na skuteczność modeli klasyfikujących. Zaproponowane warianty przedstawiono poniżej:

- **Wariant 1 - Agregacja kanałów i częstotliwości.** W tym podejściu dane zbierane z wszystkich kanałów są uśredniane do jednej wartości, a wszystkie częstotliwości pozostają bez zmian. To podejście redukuje złożoność danych, zachowując szeroki zakres częstotliwości, ale może prowadzić do utraty informacji przestrzennych.
- **Wariant 2 - Agregacja kanałów i pasm częstotliwości.** W tym przypadku dane z wszystkich kanałów są uśrednione do jednej wartości, a następnie częstotliwości są grupowane zgodnie z pasmami EEG (theta, alpha, beta, gamma). Taki wariant agregacji umożliwia wyodrębnienie charakterystycznych wzorców w pasmach częstotliwościowych, które są powszechnie związane z różnymi stanami aktywności mózgu.
- **Wariant 3 - Agregacja wszystkich kanałów oraz pasm częstotliwości.** W wariantcie wykorzystywano wszystkie dostępne kanały, a dane uśredniano w ramach pasm częstotliwości. Pozwala to na zachowanie przestrzennej informacji z wielu kanałów, a jednocześnie upraszcza analizę sygnału poprzez ograniczenie liczby wymiarów w domenie częstotliwościowej.
- **Wariant 4 - Agregacja wszystkich kanałów i częstotliwości.** Wariant ten korzysta z wszystkich dostępnych danych zebranych przez elektroencefalograf, zarówno kanałów, jak i częstotliwości. Jest to najbogatsza forma agregacji, zachowująca pełne dane przestrzenne i częstotliwościowe, co może przyczynić się do uzyskania najdokładniejszych wyników klasyfikacji, ale wiąże się z większą złożonością obliczeniową.

3.4. Klasyfikacja

3.4.1. Narzędzia

Krystian Nowakowski

Do stworzenia aplikacji wykorzystano język Python, ze względu na jego popularność w środowisku uczenia maszynowego oraz kompatybilność z biblioteką MNE, kluczową w analizie sygnałów EEG. Wersja Pythona używana w projekcie to 3.11.3. W oparciu o tę wersję wybrano odpowiednie biblioteki, które umożliwiają implementację, trenowanie i walidację modeli klasyfikacyjnych, w tym modeli opartych na sieciach neuronowych.

Keras (wersja 3.4.1) to wysokopoziomowa biblioteka do budowania i trenowania modeli sieci neuronowych. Umożliwia konstrukcję modularnych komponentów z wykorzystaniem frameworków takich jak TensorFlow i PyTorch. Podstawowe struktury w Keras to `Layer` (warstwa) oraz `Model` (model), które pozwalają na łatwe budowanie wielowarstwowych sieci neuronowych [84].

Podstawową architekturą budowy modeli w Keras jest struktura `Sequential`, która umożliwia dodawanie kolejnych warstw modelu w prosty sposób. Dzięki temu budowa złożonego modelu, takiego jak LSTM, polega na dodawaniu kolejnych warstw za pomocą metody `add`.

Keras dostarcza także narzędzia zapobiegające przetrenowaniu modeli, takie jak `Dropout` oraz `EarlyStopping`. `Dropout` losowo dezaktywuje jednostki w trakcie trenowania, co zwiększa odporność modelu na przetrenowanie, a `EarlyStopping` pozwala zatrzymać proces trenowania, gdy model przestaje się uczyć [84]. W projekcie monitorowano metrykę `val_loss`, przerywając trenowanie, jeśli nie następowała poprawa przez dziesięć kolejnych epok. Keras udostępnia również metody `evaluate` oraz `predict`, które umożliwiają ocenę i predykcję wyników modeli w przyjazny sposób.

Scikit-Learn, wersja 1.5.1, jest biblioteką umożliwiającą implementację modeli uczenia maszynowego, zarówno nadzorowanego, jak i nienadzorowanego. Biblioteka ta dostarcza szeroki zestaw funkcji do oceny skuteczności modeli oraz do przetwarzania danych.

W projekcie wykorzystano `KNeighborsClassifier` do implementacji klasyfikatora KNN oraz `svm.SVC` do stworzenia modelu opartego na maszynach wektorów nośnych (SVM). Do wstępnego przetwarzania danych użyto klasy `StandardScaler`, która skaluje dane do średniej 0 i wariancji jednostkowej [57]. Standaryzacja ta pomaga poprawić efektywność modeli, ponieważ zmniejsza wpływ różnic w zakresie sygnałów EEG pomiędzy nagraniami.

Scikit-Learn dostarcza także szeroki zestaw narzędzi walidacyjnych, również narzędzia do walidacji krzyżowej, takich jak `KFold` i `cross_validate`. Wykorzystano walidację krzyżową, dzięki niej oceniono, jak dobrze modele generalizują się do danych testowych. Działanie walidacji krzyżowej zostało opisane w następującym rozdziale 2.5. Podczas prac zastosowano k równe dziesięć. Wykorzystano funkcję `train_test_split` do podziału danych na zbiory treningowe i testowe, co umożliwiło ocenę wydajności modelu na danych, których wcześniej nie widział. Do ewaluacji klasyfikatorów wykorzystano miary skuteczności, takie jak `accuracy_score` (do oceny dokładności), `confusion_matrix` (do analizy macierzy pomyłek).


Scikeras, wersja 0.13.0, to narzędzie, które umożliwia integrację modeli Keras z funkcjami Scikit-Learn. Dzięki `KerasClassifier` połączono wygodę budowy i trenowania modeli neuronowych w Keras z funkcjami oceny i walidacji dostępnymi w Scikit-Learn.

3.4.2. KNN

Krystian Nowakowski

Algorytm K-Nearest Neighbors (KNN) został wybrany jako jeden z klasyfikatorów, ze względu na swoją prostotę oraz zdolność do adaptacji nowych danych. W tej sekcji skupiono się na parametrach implementacyjnych algorytmu oraz ich wpływie na wyniki klasyfikacji. W celu optymalizacji działania KNN dla danych EEG przeprowadzono analizę parametrów, takich jak liczba sąsiadów k oraz wybór metryk odległości.

Liczba sąsiadów k – wybór tego parametru jest kluczowy dla algorytmu, na podstawie wartości k model określa, do której klasy należą dane wejściowe. Parametr ten powinien być nieparzysty aby wyeliminować niejednoznaczności [85]. W celu dobrania najlepszego parametru określono punkt nasycenia algorytmu KNN. Punkt nasycenia to wartość k , powyżej której zwiększenie ilości sąsiadów nie przynosi poprawy działania modelu. Korzystając z danych pochodzących z badania LEMON, wykreślono wykres zależności dokładności klasyfikacji modelu K najbliższych sąsiadów 3.5. Na tej podstawie wybrano k równe pięć do dalszych badań.



Rys. 3.5. Wykres zależności dokładności klasyfikacji modelu KNN od liczby sąsiadów

Metryki odległości – sposób obliczania odległości między próbkami również ma wpływ na skuteczność modelu. Zastosowano miarę euklidesową, gdzie we współrzędnych kartezjańskich odległość pomiędzy punktami definiowana jest twierdzeniem Pitagorasa, które jest następujące [86]:

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{k=1}^n (y_k - x_k)^2} \quad (3.1)$$


Do obliczenia najbliższych sąsiadów wykorzystano opcję `auto`, która dobiera najlepiej dopasowany algorytm na podstawie danych przekazanych do funkcji `fit`. W modelu wszystkie odległości posiadały jednakowe wagi.

3.4.3. SVM

Krystian Nowakowski


Kolejnym wykorzystanym algorytmem do analizy jest metoda wektorów nośnych. Algorytm ten jest popularny w problemach klasyfikacyjnych sygnałów EEG, a jego złożoność obliczeniowa jest mniejsza, niż omawianego w poprzednim podrozdziale algorytmu KNN [64]. Zaletą algorytmu jest posiadanie solidnych podstaw matematycznych oraz możliwość optymalizacji parametrów na podstawie danych wejściowych, co może wpływać na poprawność klasyfikacji. W tej sekcji przedstawiono najważniejsze parametry modelu, których modyfikacja może w znaczny sposób wpłynąć na dokładność modelu w kontekście klasyfikacji sygnału EEG.

Kluczowym elementem algorytmu SVM jest funkcja jądra, która mapuje dane wejściowe na przestrzeń cech o wyższej wymiarowości [65]. Wybór odpowiedniego typu jądra jest kluczowe w kontekście poprawności klasyfikacji. Funkcja ta wpływa na granicę klasyfikacji w problemach binarnych. Korzystając z danych LEMON przeprowadzono porównanie poszczególnych typów jądra. Wyniki tego porównania zostały przedstawione na rysunku 3.6. Analiza wyników wskazuje, że problem klasyfikacji sygnału EEG jest nieliniowy, co potwierdza niska skuteczność modelu z funkcją jądra liniowego, osiągając jedynie około 50% dokładności. Najlepsze rezultaty uzyskano z wykorzystaniem jądra RBF, gdzie dokładność przekroczyła 80%. W związku z tym tą funkcję wybrano do dalszych eksperymentów.



Rys. 3.6. Porównanie typów jądra klasyfikatora SVM

Kolejnym ważnym parametrem przy modelowaniu klasyfikatora SVM jest tzw. parametr regularyzacji oznaczany jako C . Parametr ten odpowiada za nakładanie kar za błędne klasyfikacje, wpływając na kształt granicy decyzyjnej. Wyższa wartość C prowadzi do zmniejszenia marginesu separacyjnego, co powoduje że granice pomiędzy klasami stają się węższe [87]. Węższy margi-



Rys. 3.7. Porównanie parametru regularyzacji klasyfikatora SVM

nes może zwiększyć ryzyko błędnych klasyfikacji, szczególnie dla zaszumionych danych [87]. W praktyce dąży się do uzyskania jak najszerszego marginesu, co sprawia że algorytm lepiej generalizuje strukturę danych i jest mniej podatny na przeuczenia. Przeprowadzono analizę wpływu parametru regularyzacji na wyniki klasyfikacji. Wyniki tej analizy przedstawiono na rysunku 3.7, gdzie można zauważyć wzrost dokładności modelu wraz ze wzrostem parametru regularyzacji. Do dalszych eksperymentów zastosowano wartość $C = 1000$. Zwiększenie parametru o kolejny rząd wielkości nie przynosi znaczących zysków. Również w obawie przed przetrenowaniem modelu oraz potencjalnym wpływie danych zbieranych przez zespół na sprzęcie konsumenckim, które w przypadku dużych szumów mogłoby obniżyć dokładności modelu, nie podjęto zwiększenia wartości tego parametru. Warto jednak zaznaczyć, że dalszy wzrost parametru regularyzacji może prowadzić do lepszych wyników.

Korzystając z jądra RBF, możemy wpłynąć na parametr *gamma*, który określa stopień krzywizny granicy decyzyjnej. Przy dużej wartości *gamma* obszar decyzyjny jest ograniczony do wąskiego zakresu wokół punktów, w przeciwnym wypadku, gdy *gamma* jest mała, granice decyzyjne są płynniejsze, ale może to powodować niedopasowanie modelu do danych [88]. Bazując na przeprowadzonych eksperymentach opisanych w pracy [89], stwierdzono, że przy wyborze jądra Gaussa nie zauważono poprawy skuteczności modelu przy modyfikacji parametru *gamma*. Dlatego zastosowano jego domyślną wartość. W użytej w projekcie bibliotece Scikit-Learn parametr *gamma* obliczany jest według wzoru $\gamma = 1/(n_features * X.var())$, gdzie $X.var()$ przedstawia wariancję podanych danych, a $n_features$ to liczba cech w zbiorze danych.

3.4.4. LSTM

Krystian Nowakowski

Podejście długoterminowej pamięci (LSTM), którego główną zaletą jest zdolność do identyfikowania wzorców w czasie, stanowi kolejny klasyfikator zastosowany w pracy. Dzięki selektywnemu zapamiętywaniu kluczowych informacji oraz przechowywania ich w czasie, sieć neuronowa z warstwami LSTM okazuje się bardziej efektywna niż tradycyjne rekurencyjne sieci neuronowe pozbawione tych warstw [90]. Dodatkowo podejście LSTM częściowo rozwiązuje problem nadmiernego dopasowania [73]. W tej sekcji przedstawiono szczegóły dotyczące struktury zaimplementowanej sieci LSTM.

Jednym z pierwszych wyzwań podczas projektowania sieci neuronowej jest odpowiedni dobór liczby warstw modelu. Analizując badania [91], [92], [93], można zauważyć, że często stosuje się od 3 do maksymalnie 48 warstw w klasyfikacji sygnału EEG. Celem pracy jest zaprojektowanie klasyfikatora binarnego, zdecydowano się na wykorzystanie trzech warstw LSTM, co pozwala ograniczyć ryzyko przeuczenia modelu. Na końcu modelu dodano warstwę *Dense* odpowiedzialną za generowanie końcowej klasyfikacji. Zwiększenie ilości warstw może umożliwić naukę bardziej złożonych wzorców, jak również doprowadzić do przeuczenia się modelu.

Kolejnym kluczowym aspektem w projektowaniu sieci neuronowej jest dobór odpowiedniej liczby neuronów. Liczba neuronów podobnie jak liczba warstw wpływa na zdolność modelu do generalizacji, jak i na większą potrzebę zasobów obliczeniowych. Badania [92] wykazały, że zastosowanie 64 oraz 32 neuronów w dwóch warstwach daje zadowalające wyniki w klasyfikacji sygnału EEG. W pracy dodano trzecią warstwę LSTM zawierającą 128 neuronów, aby sprawdzić czy taka konfiguracja poprawi dokładność predykcji.

Sieci neuronowe, w szczególności te posiadające dużą ilość parametrów, są podatne na przetrenowanie, zwłaszcza w sytuacji ograniczonej ilości danych treningowych [94]. Aby zwiększyć zdolność sieci neuronowej do generalizacji danych zastosowano technikę *Dropout*, która losowo wyłącza część neuronów [94]. W modelu wartość *Dropout* ustawiono na poziomie 0.3, co oznacza, że 30% neuronów wejściowych jest pomijane w każdej sekcji treningu.


W ostatniej warstwie modelu *Dense* zastosowano funkcję aktywacji *sigmoid*, która przekształca każdy element wyjściowy w liczbą rzeczywistą z zakresu [0, 1]. Takie rozwiązanie jest idealne w problemach klasyfikacji binarnej, gdzie wyjście modelu reprezentuje prawdopodobieństwo przynależności do danej klasy. Podczas kompilacji modelu oparto się na badaniu [73], które analizowało wydajność najczęściej występujących optymalizatorów. Na ich podstawie wybrano optymalizator *Adam*, który w metrykach dokładności, osiągał o około dziesięć punktów procentowych więcej niż *RMSprop* oraz *adagrad*.

Dla funkcji strat wybrano *binary_crossentropy*, która w analizach [73] charakteryzowała się najlepszymi wynikami w zadaniach klasyfikacji binarnej. W przedstawionych porównaniach różnice między modelami nie odbiegały od siebie znacząco, natomiast *binary_crossentropy* pozwalała osiągnąć najwyższą dokładność klasyfikacji. Wizualne przedstawienie zastosowanego klasyfikatora przedstawiono na rysunku 3.8, wraz z wielkością danych wejściowych i wyjściowych dla każdej z warstw.

3.4.5. Klasyfikacja w czasie rzeczywistym

Mateusz Naklicki

Klasyfikacja sygnałów EEG w czasie rzeczywistym (online) stanowi cel tej pracy. Proces ten jednak wymaga zaadresowania szeregu aspektów.



Rys. 3.8. Architektura modelu klasyfikatora bazującego na warstwach sieci LSTM.

Pierwszym elementem jest stosowane okno filtracyjne, które wpływa na jakość przetwarzania. Wykorzystano okno czasowe o stałej długości, co wymaga zebrania próbki danych o odpowiedniej długości przed możliwością dokonywania predykcji. Stosowana długość okna to 30 sekund.

Ze względu na efekt krawędziowy związany z zastosowaniem filtrów, konieczne było wprowadzenie opóźnienia przetwarzania (offsetu czasowego). Opóźnienie pozwala na minimalizację błędów wynikających z niedokładności sygnału w pobliżu granic okna analizy.

Aby zwiększyć stabilność wyników, wprowadzono mechanizm uśredniania predykcji. Decyzja modelu klasyfikacyjnego może uwzględniać wyniki wielu ostatnich predykcji. Uśrednianie to zmniejsza wpływ pojedynczych, potencjalnie błędnych decyzji, które mogą wynikać z chwilowych zakłóceń w sygnale EEG.

Wykorzystano również mechanizm progu pewności predykcji, który wymaga, aby średnia pewność modelu przekroczyła ustaloną wartość przed zmianą raportowanego stanu. Na przykład, jeśli próg został ustawiony na 0.7, model musi być pewny swojej decyzji na poziomie 70%, aby wpłynęła ona na raportowany wynik.

4. EKSPERYMENTY

4.1. *Klasyfikacja stanu oczu otwartych i zamkniętych na zbiorze danych LEMON*

4.1.1. *Cel eksperymentu*

Mateusz Naklicki

Celem niniejszego eksperymentu jest stworzenie modeli klasyfikujących stan pacjenta na podstawie sygnału EEG, analizując różnicę między stanem oczu otwartych (EO) a oczu zamkniętych (EC). Dokonanie takiej klasyfikacji umożliwi sprawdzenie, czy na podstawie sygnału EEG można precyzyjnie określić stany uwagi pacjentów. W szczególności, eksperyment ten stanowi wstęp do dalszych badań, w których porównana zostanie jakość sygnałów EEG zbieranych za pomocą urządzenia Cyton firmy OpenBCI z profesjonalnym sprzętem używanym w badaniach LEMON. Równocześnie klasyfikator, stworzony na bazie wysokiej jakości danych LEMON, posłuży do oceny jakości zebranych sygnałów i będzie punktem odniesienia dla wyników uzyskanych w kolejnych eksperymentach.

4.1.2. *Dane*

Mateusz Naklicki

Zbiór danych LEMON, który stanowi podstawę tego eksperymentu, został zebrany od 227 pacjentów w warunkach kontrolowanych. W szczególności wykorzystano elektroencefalografię (EEG) w stanie spoczynku, z użyciem profesjonalnego sprzętu: wzmacniacza BrainAmp MR Plus, połączonego z 62 aktywnymi elektrodami rozmieszczonymi według układu 10-20. Elektroda referencyjna znajdowała się w punkcie FCz, a impedancja wynosiła poniżej 5 k Ω . Nagrania sygnału EEG dokonano z częstotliwością 2500 Hz, stosując filtr środkowoprzepustowy w zakresie od 0,0015 Hz do 1 kHz.

Dane zostały zebrane w formie 16-minutowych sesji dla 216 pacjentów, gdzie sesja podzielona była na 8 bloków w stanie otwartych oczu (EO) oraz 8 bloków w stanie zamkniętych oczu (EC), przy czym każdy blok trwał 60 sekund. Nagrania rozpoczynały się od stanu zamkniętych oczu (EC), a pacjenci mieli możliwość mrugania podczas sesji EO [44].

Finalnie część nagrań została odrzucona – opublikowane zostało 203 nagrań, które następnie zostały wstępnie przetworzone. Próbkowanie zostało zmniejszone do 250 Hz, a następnie zastosowano filtr pasmowoprzepustowy w zakresie 1-45 Hz. Dalsze przetwarzanie obejmowało manualne usuwanie fragmentów z artefaktami, po czym wykonano analizę głównych składowych (PCA) w celu redukcji wymiarowości danych [95]. Ostatnim krokiem było zastosowanie analizy składowych niezależnych (ICA), aby usunąć komponenty związane z ruchami gałek ocznych, mrugnięciami oraz sygnałami związanymi z biciem serca.

4.1.3. *Filtracja i pre-processing sygnału*

Aleksandra Sobecka

W tej części opisano etapy filtrowania sygnału EEG w celu przygotowania teoretycznego modelu filtrowania, który zostanie później zastosowany do przetwarzania nagrań uzyskanych podczas własnych nagrań. Proces opiera się na połączeniu podejść zaproponowanych w pracach [44, 53], w celu otrzymania wysokiej jakości przetworzonego sygnału. Dużym udogodnie-

niem w dostępnym zbiorze danych zespołu LEMON jest możliwość pracy na oryginalnych nagraniach sygnału przed ich obróbką, a po wykonaniu teoretycznej filtracji, porównanie ich z danymi po filtracji, które również zostały przez zespół udostępnione. Pozwoliło to na ocenę skuteczności zastosowanych metod filtracji.

W ramach pracy zaproponowano model hybrydowy, który łączy najlepsze praktyki obu podejść, mając na celu minimalizację szumów i artefaktów przy jednoczesnym zachowaniu wysokiej jakości sygnału EEG. W kolejnych podrozdziałach opisano szczegółowe etapy procesu filtrowania.


Filtracja podstawowa

W celu przeprowadzenia filtracji podstawowej należało ustalić charakterystykę sygnałów zapisanych w plikach z pomiarami (sub-032301.vhdr). Korzystając z biblioteki MNE odczytano następujące informacje:

- Ilość kanałów: 62,
- Częstotliwości podczas nagrania: 2500 Hz,
- Filtr highpass: 0.0 Hz,
- Filtr lowpass: 1000.0 Hz,
- Nazwy kanałów: Fp1, Fp2, F7, F3, Fz, F4, F8, FC5, FC1, FC2, FC6, T7, C3, Cz, ...,

Ustalono również, że nagranie posiada dedykowany kanał do detekcji artefaktów związanych z ruchem oczu – VEOG.

Za pomocą funkcji `raw.plot()` utworzono wykres przebiegu sygnału przed obróbką 4.1:




Rys. 4.1. Sygnał LEMON przed filtracją

Na podstawie wcześniej wskazanych prac [44, 53], zaplanowano i przeprowadzono zestaw kroków, który na potrzeby dalszych analiz będzie nazywany w kontekście tej pracy "Filtracją podstawową". Obejmuje ona następujące kroki:

- Zmniejszenie próbkowania – resample do 250 Hz,
- Filtr pasmowo-przepustowy 1-45 Hz,
- Filtracja Notch w celu usunięcia zakłóceń sieci elektrycznej,
- Ustawienie referencji (average reference)
- Ustawienie standardowego montażu

Wykres sygnałów po przeprowadzonej filtracji podstawowej zaprezentowano na rys. 4.2. Widoczną różnicą pomiędzy wykresami sygnału przed i po filtracji jest zmniejszona ilość szumu. Na tym etapie nie zostały jednak usunięte artefakty związane z mruganiem oczami.




Rys. 4.2. Sygnał LEMON po podstawowej filtracji

W celu usunięcia artefaktów pochodzących od gałek ocznych wykorzystano dedykowaną elektrodę odpowiedzialną za detekcję artefaktów ocznych. Do celów dalszej analizy dokonano

zmiany jej nazwy z **VEOG** na **EOG**, aby możliwe było wykorzystanie gotowej funkcji z biblioteki MNE, która wymagała takiego oznaczenia elektrody.


Artefakty oczne

Korzystając z dedykowanego kanału **EOG** wykonano automatyczną detekcję artefaktów związanych z ruchem gałek ocznych. Efekt działania funkcji zaprezentowano na rys. 4.3. Funkcja wykryła 61 zdarzeń związanych ruchem gałek ocznych oraz mruganiem.




Rys. 4.3. Wykrywanie zdarzeń związanych z artefaktami ocznymi przy pomocy elektrody EOG

Dodatkowo wykryte artefakty związane z mruganiem mogą zostać usunięte za pomocą analizy ICA. Dzięki wykorzystaniu epok zawierających artefakty oczne, funkcja ICA jest w stanie automatycznie porównać i zidentyfikować te komponenty, które mają sygnały podobne do wykrytych artefaktów EOG (4.4).



Rys. 4.4. Komponent zawierający artefakty oczne

Po identyfikacji odpowiednich komponentów można usunąć artefakty związane z ruchami oczu, co prowadzi do uzyskania bardziej czystego sygnału EEG 4.5.



Rys. 4.5. Sygnał po odrzuceniu komponentu związanego z artefaktami ocznymi

Artefakty mięśniowe


Kolejnym etapem przetwarzania danych EEG LEMON, jest automatyczna detekcja artefaktów mięśniowych przy użyciu analizy ICA. Biblioteka MNE oferuje funkcję do automatycznego wykrywania tych artefaktów `ica.find_bads_muscle()`, co pozwala na łatwiejsze i bardziej obiektywne usuwanie zakłóceń mięśniowych z sygnału EEG. Usunięcie artefaktów wynikających z aktywności mięśni (np. mięśni twarzy, szyi) może znacząco wpłynąć na jakość sygnału EEG, a w szczególności w zakresie wysokich częstotliwości.

Ta funkcja analizuje każdy z komponentów niezależnych, aby znaleźć te, które mają charakterystykę podobną do aktywności mięśniowej (czyli mają wyższą energię w określonych zakresach częstotliwości). Funkcja zwraca dwie tablice:

- `muscle_indices`, czyli indeksy komponentów ICA, które zostały zidentyfikowane jako zawierające artefakty mięśniowe, oraz
- `muscle_scores`, które reprezentują stopień, w jakim dany komponent odpowiada wzorcom typowym dla artefaktów mięśniowych.


Przykładowe wyniki przedstawiono na wykresie słupkowym 4.6. Im wyższy *score* tym większe prawdopodobieństwo, że dany komponent reprezentuje artefakt mięśniowy. W tym przypadku zostały wskazane komponenty: [2, 7, 12, 13, 14, 15, 16, 17, 18, 19]. Aby dokładniej zbadać i upewnić się co do poprawności detekcji automatycznej ICA wybrane komponenty można również przedstawić w postaci topografii i ocenić czy wskazuje ona na potencjalne źródło związane z artefaktami pochodzenia mięśniowego.

Na rysunku 4.7 można dostrzec charakterystyczne dla artefaktów pochodzenia mięśniowego wysokie aktywności na obrzeżach czaszki, które są dość typowe dla mięśni czołowych, żuchwy czy skroniowych. Wzorce tego typu zazwyczaj nie mają związku z typową aktywnością mózgową.




Rys. 4.6. Wykres wartości score dla komponentów zawierających artefakty mięśniowe

Dodatkowym elementem przemawiającym za poprawną automatyczną detekcją jest również lokalna aktywność w komponentach (często punktowa) oraz wysokie amplitudy mocy sygnału [96].



Rys. 4.7. Pokazane topografie dla wytypowanych komponentów

Komponenty określone z użyciem metody ICA są na tym etapie usuwane z filtrowanego sygnału. Przykład sygnału po usunięciu artefaktów mięśniowych za pomocą opisywanej metody pokazano na rys. 4.8. Proces automatycznej detekcji i odrzucania artefaktów pochodzenia




Rys. 4.8. Sygnał po usunięciu komponentów pochodzenia mięśniowego

mięśniowego jest szczególnie przydatny, gdy przetwarzamy duże zbiory danych, ponieważ automatyzacja detekcji artefaktów pozwala na szybsze i bardziej powtarzalne przygotowanie danych do dalszych etapów analizy.

Artefakty odrzucane manualnie - ICA

Analiza ICA dekomponuje sygnał EEG na niezależne komponenty źródłowe. Każdy komponent reprezentuje potencjalnie odrębne źródło sygnału, które może być związane z aktywnością mózgową lub różnego rodzaju artefaktami. Posiadając sygnał podzielony przez ICA na komponenty można wygenerować ich topografie w celu oszacowania czy dane źródło mogło mieć pochodzenie inne niż związane z aktywnością mózgową. Mapa topograficzna komponentów pokazuje, jak rozłożona jest aktywność danego komponentu na powierzchni czaszki. Artefakty takie jak mruknięcia, aktywność mięśniowa, czy bicie serca mają charakterystyczne wzorce rozmieszczenia [96]. W omawianym zbiorze danych sygnał został podzielony na 20 komponentów (maksymalna ilość komponentów możliwych do wygenerowania to ilość dostępnych elektrod), co przedstawiono na rys. 4.9.



Rys. 4.9. Topografie komponentów

Topografie przedstawione na 4.9 pozwalają na manualne wytypowanie i usunięcie komponentów, które posiadają charakterystyczne cechy artefaktów[96]:

- **Mrugnięcia i ruchy oczu:** Te komponenty charakteryzują się wysokimi potencjałami w przedniej części czaszki - w okolicach oczu, tak jak np. na rysunku 4.5. W związku z tym, że te artefakty zostały już wcześniej zidentyfikowane i odrzucone, nie obserwujemy już ich w tym zestawie komponentów. Artefakty związane z ruchem oczu w manualnej analizie komponentów, można zidentyfikować na podstawie kilku charakterystycznych cech:
 - zmiany potencjału elektrycznego skupione są w przedniej części czaszki (w okolicach oczu),
 - moc zazwyczaj skoncentrowana jest na niskich częstotliwościach - około 5 Hz,
 - ruch oczu w pionie (najczęściej mrugnięcia) - będzie przejawiała się charakterystycznymi skokami w danych,
 - ruchy oczu w poziomie będą miały charakterystyczny kształt przypominający stopnie.
- **Artefakty mięśniowe:** Charakteryzują się one aktywnością rozłożoną na obrzeżach czaszki, o nieregularnym, często punktowym sygnale - to również zostało pokazane na rysunku 4.6. W tym przypadku także należy uznać, że większość komponentów pochodzenia mięśniowego została już usunięta z sygnału poprzez wykonanie automatycznej detekcji i odrzucenia tych artefaktów. Dla manualnej detekcji takich komponentów warto wziąć pod uwagę:
 - skoncentrowanie wysokich potencjałów na obrzeżach czaszki,
 - moc zazwyczaj skoncentrowana jest na wyższych częstotliwościach - powyżej 20 Hz,
 - mogą być dipolarne, jednak będą to sygnały dość płytkie i skoncentrowane (nie pochodzące z mózgu).
- **Zakłócenia sieciowe:** Te komponenty mogą mieć charakterystyczną sinusoidalną postać w sygnale w reprezentacji czasowej. Artefakty tego typu również nie będą tu obecne, ponieważ na etapie filtracji podstawowej został zastosowany filtr Notch w celu usunięcia zakłóceń sieci elektrycznej. Przejawia się również charakterystycznym skokowym wzrostem na częstotliwości sieci elektrycznej (np. 50 Hz) - co zostało przedstawione na rysunku 2.1.
- **Zakłócenia związane z aktywnością serca:** Są to dość charakterystyczne artefakty, przejawiające się równomierną aktywnością w obszarze niemal całej czaszki. Charakterystyczne cechy komponentu:
 - występowanie zespołu QRS,
 - moc zazwyczaj skoncentrowana jest na częstotliwości - 1 Hz,
 - często równomierne rozłożenie potencjału na topomapie głowy.Możliwa jest również detekcja artefaktów pochodzenia sercowego za pomocą dedykowanej elektrody - EOG, jednak w wybranym do badań zbiorze danych nie została ona zaaplikowana, dlatego detekcja i usunięcie tego typu artefaktu przebiegało ręcznie z użyciem biblioteki MNE.
- **Zakłócenia pochodzące od kanałów:** w przypadku częstego poruszania elektrody lub słabego kontaktu ze skórą głowy, mogą powstawać miejscowe artefakty związane z nieprawidłowym rejestrowaniem sygnału z danej elektrody. Zakłócenia tego typu charakteryzują się:
 - mocno skoncentrowaną mapą topograficzną na jednym kanale,
 - widmo zazwyczaj o charakterze $1/f$,
 - łatwo pomylić je z komponentami mięśniowymi, ale różnią się w analizie widma mocy (PSD).

- **Inne zakłócenia:** możliwe jest również występowanie artefaktów, które nie wpasowują się w żadną inną kategorię, jednak swoją charakterystyką znacznie odbiegają od aktywności, którą można by przypisać do pracy mózgu. Charakterystycznymi cechami w tym wypadku są:

- odległy numer komponentu - im odleglejszy komponent tym większe prawdopodobieństwo, że zawiera on inne zakłócenia, bardzo często zmieszane również z sygnałem mózgowym,
- topografia głowy nie mająca charakteru dipola.

W przypadku manualnego oceniania komponentów pod kątem ewentualnych artefaktów, również bardzo istotna jest znajomość charakterystyki pożądanego sygnału mózgowego:

- Bardzo często topografia ma charakter dipolowy,
- Widmo mocy maleje wraz ze wzrostem częstotliwości,
- Widmo mocy zwykle ma szczyty między 5 a 30 Hz (najczęściej przy 10 Hz - alfa - zwłaszcza podczas relaksacji z zamkniętymi oczami),
- Komponenty pochodzenia mózgowego mają lokalizację zgodną z anatomicznymi obszarami kory mózgowej, np. aktywność w obszarze potylicznym jest związana z rytmem alfa (10 Hz), który dominuje przy zamkniętych oczach,
- Brak nagłych skoków sygnału o dużych amplitudach.


Podczas manualnej analizy komponentów zostanie wykorzystane również narzędzie z biblioteki MNE [83] `label_components()`, które automatycznie przypisuje label i prawdopodobieństwo wystąpienia sygnału mózgowego lub danego artefaktu. W tym celu przeprowadzono analizę ICA z wykorzystaniem algorytmu infomax, która podzieliła dataset na 50 komponentów. Wśród nich zostały wykryte różne artefakty ze wskazaniem poziomu prawdopodobieństwa:

- Komponent 9: Etykieta: muscle artifact, Prawdopodobieństwo: 0.32
- Komponent 11: Etykieta: other, Prawdopodobieństwo: 0.48
- Komponent 22: Etykieta: other, Prawdopodobieństwo: 0.52
- Komponent 24: Etykieta: other, Prawdopodobieństwo: 0.70
- Komponent 25: Etykieta: other, Prawdopodobieństwo: 0.40
- Komponent 26: Etykieta: other, Prawdopodobieństwo: 0.77
- Komponent 30: Etykieta: muscle artifact, Prawdopodobieństwo: 0.80
- Komponent 31: Etykieta: muscle artifact, Prawdopodobieństwo: 0.96
- Komponent 32: Etykieta: muscle artifact, Prawdopodobieństwo: 0.77
- Komponent 34: Etykieta: muscle artifact, Prawdopodobieństwo: 0.76
- Komponent 37: Etykieta: other, Prawdopodobieństwo: 0.84
- Komponent 38: Etykieta: other, Prawdopodobieństwo: 0.56
- Komponent 40: Etykieta: other, Prawdopodobieństwo: 0.63
- Komponent 41: Etykieta: other, Prawdopodobieństwo: 0.89
- Komponent 42: Etykieta: muscle artifact, Prawdopodobieństwo: 0.60
- Komponent 46: Etykieta: other, Prawdopodobieństwo: 0.48
- Komponent 47: Etykieta: other, Prawdopodobieństwo: 0.97
- Komponent 48: Etykieta: other, Prawdopodobieństwo: 0.89

Gdzie


- muscle artifact - oznacza artefakty pochodzenia mięśniowego
- other - oznacza artefakty innego pochodzenia

Biorąc pod uwagę możliwość mieszania się sygnału mózgowego z sygnałami artefaktów, zdecydowano się na automatyczne odrzucenie komponentów dla których prawdopodobieństwo jest wyższe niż 70%, czyli komponenty: 24, 26, 30, 31, 32, 34, 37, 41, 47, 48.



Rys. 4.10. Automatycznie wytypowane artefakty z prawdopodobieństwem wyższym niż 70%

Po odrzuceniu komponentów sygnał prezentuje się następująco:



Rys. 4.11. Oczyszczony sygnał po usunięciu komponentów ICA(infomax)

Niewykorzystane metody w modelu teoretycznym

W wykonanym modelu teoretycznym starano się uzyskać jak najlepszy efekt przy jednocześnie jak najwyższej automatyzacji procesu, tak aby wykluczyć subiektywną rolę człowieka w tym procesie. Dlatego nie wykorzystano metody PCA, która wymagałaby oceny eksperckiej odrzucających komponentów. Nie została tu również zaimplementowana metoda odrzucenia złych kanałów - w tym przypadku z dwóch przyczyn. Pierwsza – brak skutecznej automatycznej metody, która w sposób jednoznaczny odrzucałaby złe kanały. Druga (istotniejsza) wiedza, na temat tego, że podczas eksperymentów będą dostępne jedynie 4 kanały, w związku czym usuwanie kanałów będzie czynnością niepożądaną. Pozostałe metody zawarte w pracy [53] będą wykorzystywane natomiast w dalszym rozwoju modeli filtracji.


Ocena modelu teoretycznego

W związku z tym, że do przygotowywania teoretycznej filtracji zastosowany został zbiór danych, który zawierał dane zarówno przed jak i po filtracji, możliwe było porównanie efektów opracowanego modelu teoretycznego z przefiltrowanym plikiem przygotowanym przez specjalistów z zespołu LEMON [44]. Dane będą porównywane poprzez:


- **Porównanie wizualne sygnału przed i po filtracji** - dzięki wizualnej analizie możliwe jest zidentyfikowanie zmian w charakterze sygnału (powodowanych często przez artefakty). Pozwala to też na ocenę, czy sygnał zachowuje swój pierwotny charakter i czy istotne elementy wchodzące w skład sygnału neuronalnego nie zostały przypadkiem usunięte. Efektywnie przeprowadzona filtracja na miarodajnym zbiorze danych nie powinna prowadzić do zbyt agresywnego oczyszczania sygnału, które mogłoby skutkować utratą istotnych informacji. Wizualne porównanie jest podstawowym krokiem w ocenie jakości filtracji.
- **Porównanie mocy PSD dla różnych częstotliwości** - Dzięki temu można sprawdzić, jak zmienia się energia sygnału w różnych pasmach częstotliwości. W EEG określone pasma częstotliwości (m.in. alfa, beta) są kluczowe dla interpretacji stanu mózgu. Zmiany w PSD mogą wskazywać, czy filtracja skutecznie usunęła zakłócenia (np. 50 Hz - szumy sieciowe) i czy nie wpłynęła negatywnie na interesujące częstotliwości.
- **Przedstawienie wskaźnika sygnał/szum (SNR)** - Wskaźnik sygnał/szum (SNR) ocenia, w jakim stopniu sygnał EEG jest wolny od szumu. Wyższy stosunek oznacza lepszą jakość sygnału (odsunięcie od szumu). SNR jest istotnym wskaźnikiem w EEG, gdzie niskie wartości mogą wskazywać na obecność zakłóceń lub nieefektywną filtrację. Porównanie SNR pozwala teoretycznie ocenić, czy filtracja poprawia jakość sygnału.
- **Porównanie topografii sygnału na głowie pacjenta** Topografia sygnału przedstawia przestrzenny rozkład aktywności na powierzchni czaszki. Gwałtowne zmiany w rozkładzie w EEG mogą świadczyć o błędach w przetwarzaniu sygnału. Dobra filtracja powinna eliminować artefakty bez zbyt gwałtownych zmian w aktywności (przy założeniu poprawności wykonanych badań w eksperymentach. Pod uwagę należy również wziąć rozkład elektrod oraz ich możliwą typową odpowiedź – np. dla stanu skupienia przednia część czaszki.

Na rys. 4.12 przedstawiono efekty filtracji otrzymane po przeprowadzeniu teoretycznej filtracji na zbiorze danych pochodzących z nagrania 032301. Można zauważyć niewielkie różnice na wybranych kanałach w przebiegach czasowych.

- **Porównanie wizualne sygnału przed i po filtracji:**
- **Porównanie mocy PSD dla różnych częstotliwości:** Na wykresie 4.13 można zauwa-



Rys. 4.12. Wykresy przebiegów sygnałów w czasie dla filtracji Lemon i filtracji teoretycznej dla wybranych kanałów: F3, F4 i C3




Rys. 4.13. Wykres PSD dla danych LEMON przed i po filtracji

żyć duże podobieństwo w kluczowych dla analizy zakresach częstotliwości (1-45Hz), co potwierdza zachowanie istotnych informacji w badanym sygnale.

- **Przedstawienie wskaźnika sygnał/szum (SNR):** Dla danych z filtracji teoretycznej w stosunku do danych przefiltrowanych przez [44] stosunek SNR przedstawia się następująco:
 - Zmiana SNR w paśmie delta (1-4 Hz): 1.77 dB
 - Zmiana SNR w paśmie theta (4-7 Hz): -1.40 dB
 - Zmiana SNR w paśmie alpha (8-12 Hz): -1.84 dB
 - Zmiana SNR w paśmie beta (13-30 Hz): -1.48 dB
 - Zmiana SNR w paśmie gamma (30-45 Hz): -0.56 dB

Na tej podstawie można stwierdzić, że różnice są niewielkie, mogą wynikać również z różnego sposobu implementacji algorytmów.

- **Porównanie topografii sygnału na głowie pacjenta:** Wykres na rysunku 4.14 pokazuje




Rys. 4.14. Topografie czaszki dla filtracji teoretycznej i filtracji LEMON

podobny rozkład aktywności na powierzchni czaszki bez cech gwałtownych zmian.

Analiza wyników, wykazała, że uzyskane efekty są do siebie zbliżone w kluczowych zakresach częstotliwości (1–45 Hz). Na podstawie przeprowadzonych analiz stwierdzono, że filtracja teoretyczna może być traktowana jako wiarygodna baza do dalszych analiz w modelach uczenia maszynowego, takich jak SVM, KNN czy LSTM. Dzięki temu możliwe będzie wykorzystanie opracowanego procesu filtracji w kontekście bardziej zaawansowanych badań i predykcji stanów aktywności mózgowej.

4.1.4. Eksploracja danych

Mateusz Naklicki




Rys. 4.15. Zestawienie PSD dla sygnałów EEG porównujące stany EC oraz EO

Rysunek 4.15 przedstawia analizę widmowej gęstości mocy (Power Spectral Density, PSD) dla sygnałów EEG zebranych z danych LEMON, porównując stany oczu zamkniętych oraz oczu otwartych. Na górnym wykresie widoczne jest wyraźne wzmocnienie sygnału w zakresie częstotliwości alfa (8-13 Hz), co jest charakterystyczne dla stanu relaksu i braku aktywności wzrokowej. Jest to typowy efekt, gdy oczy są zamknięte, a mózg przechodzi w stan relaksacji, co skutkuje

wzrostem aktywności fal alfa. Wzrost mocy sygnału w tym paśmie wskazuje na dominację fal alfa, co jest zgodne z literaturą dotyczącą badań EEG.


Dolny wykres przedstawia PSD dla stanu oczu otwartych. Zauważalne jest zmniejszenie mocy sygnału w zakresie fal alfa, co wynika z aktywacji układu wzrokowego oraz zwiększonej aktywności kory mózgowej związanej z przetwarzaniem bodźców zewnętrznych. Obniżona moc w paśmie alfa oraz bardziej rozproszone rozkłady mocy sygnału wskazują na większą aktywność poznawczą, typową dla stanu czuwania i zaangażowania w zadania wymagające uwagi. Wykresy potwierdzają znane zjawiska związane z aktywnością mózgową podczas stanów oczu zamkniętych (EC) i oczu otwartych (EO). Wyraźny wzrost mocy w zakresie fal alfa w stanie oczu zamkniętych i jej redukcja w stanie oczu otwartych stanowią istotny wskaźnik w klasyfikacji stanów uwagi u pacjentów. Różnice te mogą być skutecznie wykorzystane w algorytmach uczenia maszynowego do klasyfikacji, co stanowi jeden z głównych celów prowadzonego eksperymentu.



Rys. 4.16. PSD dla kanału PO8. Zaznaczono zakresy częstotliwości odpowiadające falom: Delta, Theta, Alpha, Beta i Gamma.

Rysunek 4.16 przedstawia PSD dla kanału PO8, który wykazał największe różnice między stanami oczu zamkniętych a otwartych. W paśmie alfa widoczny jest wyraźny wzrost mocy dla stanu EC, co sugeruje dominację fal alfa, typową dla relaksacji. Przeciwnie, w stanie EO moc w tym zakresie jest niższa, co wynika z aktywności mózgu podczas przetwarzania bodźców wzrokowych. Zaznaczone obszary odpowiadają różnym zakresom częstotliwości fal mózgowych, co ułatwia interpretację rozkładu mocy.

Na rysunku 4.17 przedstawiono wyniki filtracji sygnału metodami opracowanymi przez zespół, opisanymi w sekcji 4.1.3, zestawiając je z oryginalnymi metodami wykorzystanych przez specjalistów podczas badania LEMON. Różnice w wyznaczonym PSD są marginalne, co wskazuje na poprawność dokonanego przetwarzania sygnału.



Rys. 4.17. Zestawienie PSD dla oryginalnie użytych metod filtracyjnych przez badaczy LEMON oraz metod opracowanych przez zespół

4.1.5. Eksperyment

Krzystian Nowakowski

Przeprowadzono porównanie skuteczności klasyfikatorów w analizie danych pochodzących z badania LEMON. Eksperyment składał się z trzech głównych etapów:

1. Analizy wpływu redukcji liczby kanałów EEG. Zbadano, jak ograniczenie liczby kanałów wpływa na skuteczność klasyfikacji.
2. Oceniono skuteczność klasyfikatorów na danych pochodzących od jednego losowo wybranego pacjenta.
3. Porównanie skuteczności bazowej metody filtracji opracowanej przez zespół (4.1.3) z filtracją opracowaną przez naukowców wchodzących w skład zespołu LEMON.


Do oceny skuteczności modeli wykorzystano walidację krzyżową, a główną metryką ewaluacyjną była dokładność.

4.1.6. Wyniki

Krzystian Nowakowski

W celu oceny wpływu liczby kanałów na skuteczność modelu, w każdej iteracji usuwano dane z czterech najmniej znaczących kanałów dla każdego pacjenta. Kanały te wybierano na podstawie najmniejszej różnicy gęstości widmowej mocy między przypadkami z otwartymi i zamkniętymi oczami. Po usunięciu modele były ponownie trenowane. Dodatkowo dane zostały uśrednione w zakresie pasm częstotliwości. Wyniki zostały zaprezentowane na wykresie 4.18.

Analiza wykazała, że ograniczenie liczby kanałów do 12 prowadzi do wyraźnego spadku wydajności modeli. Największy spadek zaobserwowano w przypadku klasyfikatora LSTM - wyniósł on około 4 punkty procentowe. Kolejnym znaczącym spadkiem była redukcja liczby kanałów z czterech do jednego. Zespół korzysta z czterech elektrod do zbierania danych, a rezultaty uzyskane dla tego układu stanowią oczekiwane wyniki klasyfikatorów na danych zebranych przez zespół w następnym eksperymencie. Skuteczność modeli mieści się w przedziale [78%, 84%]. Jednak w przypadku LSTM spadek skuteczności przy ograniczeniu do jednego kanału wynosi aż 10 punktów procentowych. Z wykresu 4.18 można również zauważyć, że model SVM wykazuje mniejsze spadki wydajności w porównaniu do pozostałych klasyfikatorów.



Rys. 4.18. Porównanie skuteczności klasyfikatorów pod względem liczby kanałów

W kolejnym etapie eksperymentu porównano zdolność modeli do generalizacji dla danych pochodzących od jednego pacjenta. Analizie poddano zestaw danych z 56, 4 oraz 1 kanałem. Wyniki przedstawiono w tabeli 4.1, która wskazuje, że modele osiągają lepszą skuteczność na danych pochodzących od jednego pacjenta w porównaniu do większego zbioru pacjentów (przedstawionym na wykresie 4.18). Eksperyment ten miał na celu określenie oczekiwanych wyników w kolejnych eksperymentach, gdzie zespół będzie zbierał dane.

Tabela 4.1. Dokładność modeli klasyfikujących na danych pochodzących od jednego pacjenta - filtracja LEMON

Liczba kanałów	KNN	SVM	LSTM
56	0.94	0.99	1.00
4	0.86	0.90	0.90
1	0.87	0.87	0.68

Najważniejszym etapem tego eksperymentu było porównanie metody filtracji opracowanej przez zespół z filtracją stosowaną przez specjalistów z badania LEMON. Wyniki osiągnięte przez zespół przedstawiono w tabeli 4.2. Jak można zauważyć, dla danych z 4 oraz 56 kanałów różnica wyników wynosi około pięciu punktów procentowych, przy czym większe spadki dokładności zaobserwowano dla mniejszej liczby kanałów. w przypadku czterech kanałów i modelu LSTM spadek wynosi aż 18 punktów procentowych, co jest wyraźnie większą różnicą w porównaniu do innych modeli. Dla SVM spadek wyników wynosi jedynie trzy punkty procentowe i pozostaje stabilny dla wszystkich zbiorów danych. Natomiast dla modeli KNN oraz LSTM spadki dokładności przy jednym kanale są znaczne i wynoszą około 13 punktów procentowych. Obecna metoda fil-

Tabela 4.2. Dokładność modeli klasyfikujących na danych pochodzących od jednego pacjenta z wykorzystaniem filtracji opracowanej przez zespół

Liczba kanałów	KNN	SVM	LSTM
56	0.89	0.95	0.98
4	0.84	0.89	0.72
1	0.73	0.84	0.55

tracji daje zadowalające wyniki, jednak wymaga dalszych usprawnień, aby bardziej zbliżyć się do skuteczności profesjonalnej filtracji stosowanej w badaniu LEMON.

4.1.7. Wnioski

Krystian Nowakowski

Wyniki przeprowadzonych eksperymentów pozwalają wyciągnąć kilka istotnych wniosków przydatnych w kolejnych etapach pracy:

1. Zmniejszanie liczby kanałów z 56 do jednego skutkuje średnim spadkiem skuteczności modeli o około 19 punktów procentowych, co wskazuje na kluczowe znaczenie rozmiaru zestawu danych dla poprawnego działania klasyfikatorów.
2. Wyniki osiągnięte przy wykorzystaniu czterech kanałów oscylują na poziomie 81% poprawnych klasyfikacji. Jest to spadek o około 10 punktów procentowych w porównaniu z wynikami dla pełnego zestawu kanałów. Odpowiedni dobór lokalizacji pozwala zachować istotne informacje zawarte w sygnale EEG.
3. Lepsze wyniki uzyskane na danych pochodzących od jednego pacjenta, wynikają prawdopodobnie z mniejszej zmienności sygnałów, w porównaniu z większym zbiorem pacjentów. Różnice te mogą obejmować moc sygnału czy poziom szumu co utrudnia uogólnieniem klasyfikatorów.
4. Zaproponowana metoda filtracji podstawowej osiągnęła zbliżone wyniki do metodologii stosowanej w badaniu LEMON. Jednak różnice w jakości wyników wskazują na potrzebę dalszej optymalizacji.
5. Redukcja ilości danych miała największy negatywny wpływ na model LSTM, co wynika z jego charakterystyki, polegającej na analizie sekwencyjnych zależności. Ograniczenie liczby kanałów osłabia zdolność modelu do uchwycenia pełnego kontekstu czasowego w sygnałach EEG.
6. Celem zespołu w kolejnych eksperymentach jest osiągnięcie skuteczności klasyfikatorów na poziomie 80% na danych zebranych oraz opracowanych przez zespół. Realizacja tego celu będzie wymagała dalszych optymalizacji metod przetwarzania danych oraz architektur modeli.

4.1.8. Dyskusja

Krystian Nowakowski

Z uwagi na obserwowany wpływ zmniejszenia liczby kanałów na modele LSTM, przyszłe badania mogłyby rozważyć zastosowanie innych architektur sieci neuronowych, w celu poprawy zdolności modeli do uchwycenia bardziej złożonych wzorców w sygnale EEG przy zmniejszonej ilości kanałów.

4.2. **Klasyfikacja stanu oczu otwartych i zamkniętych przy użyciu urządzenia Cyton**

4.2.1. Cel eksperymentu

Mateusz Naklicki

Celem tego eksperymentu jest zbadanie możliwości replikacji wyników uzyskanych w profesjonalnym badaniu LEMON przy użyciu urządzenia Cyton, opisanego w sekcji 3.1.1, który jest

znacznie bardziej dostępny i tańszy niż sprzęt laboratoryjny. Eksperyment ten ma na celu klasyfikację stanów oczu otwartych/zamkniętych, na podstawie sygnałów EEG zebranych przy użyciu Cytona, oraz porównanie jakości wyników z danymi zgromadzonymi w badaniu LEMON. W szczególności dąży się do odpowiedzi na pytanie, czy przy pomocy sprzętu klasy konsumenckiej możliwe jest osiągnięcie podobnych wyników jak przy użyciu sprzętu laboratoryjnego. Uzyskane dane pozwolą na ocenę skuteczności zastosowania Cytona w detekcji stanów i wskażą, jakie ograniczenia mogą pojawić się przy korzystaniu z tego typu urządzeń w dalszych badaniach.

4.2.2. Zbieranie danych

Mateusz Naklicki

Elektrody umieszczono w obszarze potylicznym, wybierając lokalizacje PO3, PO4, PO7 i PO8. Wybór tych miejsc opierał się na wyznaczeniu kanałów najbardziej różnicujących badane stany na podstawie eksperymentu 4.1. Taka selekcja kanałów jest zgodna z literaturą dotyczącą charakterystyki sygnałów EEG – obszar potyliczny jest silnie związany z przetwarzaniem bodźców wzrokowych [97], co czyni go odpowiednim do badania różnic w aktywności mózgu między stanami EO i EC.

Proces zbierania danych był analogiczny do eksperymentu LEMON: składał się z 16 bloków, każdy o długości 60 sekund. W każdym bloku uczestnik pozostawał w stanie EO bądź EC. Bloki były oznaczane również zgodnie ze schematem stosowanym w oryginalnym badaniu, co ułatwiało wykorzystanie tych samych skryptów przetwarzających sygnał.

Problem stanowiła jakość sygnału, której jednym z wyznaczników jest impedancja między elektrodą a skórą głowy. W klinicznych warunkach wartość nie powinna przekraczać 5 k Ω , gdzie zespołowi w najlepszym przypadku udało się zejść do 50 k Ω , a wartość typowa wynosiła 100 k Ω .

Nagrania zostały przeprowadzone wielokrotnie na tym samym uczestniku w różnych odstępach czasu. Aby ułatwić odnoszenie się do konkretnych nagrań, będą one numerowane kolejno od 1 do 6:

- Nagranie nr 1.
Pierwsze nagranie, impedancja w zakresie 100-500 k Ω . W trakcie badania elektroda PO8 odchodziła się, w związku z czym sygnał może być dodatkowo zaszumiony.
- Nagranie nr 2.
Impedancja w zakresie 85-250 k Ω , eksperyment zakończył się na bloku nr 12 z powodu błędu w przesyłce danych z Cytona.
- Nagranie nr 3.
Impedancja w zakresie 210-370 k Ω , po zakończeniu nagrania impedancja na elektrodzie PO4 wskazywała wartość 600, najprawdopodobniej wskutek ruchów.
- Nagranie nr 4.
Impedancja w zakresie 55-84 k Ω . Do mocowania elektrod zastosowano gumki recepturki, co znacząco zwiększyło stabilność podłączenia – impedancja pod koniec badania pozostawała na tym samym poziomie. Poprawa w jakości sygnału była na tyle duża, że w każdym następnym nagraniu wykorzystywano ten sposób mocowania.
- Nagranie nr 5.
Impedancja w zakresie 50-60 k Ω .
- Nagranie nr 6.
Zmieniono położenie elektrod na pozycje C3, C4, F3, F4. Impedancja w zakresie 61-70 k Ω .


Podczas wykonywania nagrań 1, 2, 3 zespół nie był świadomy wpływu wysokiej impedancji na jakość sygnału, oraz wpływu różnic w impedancji między kanałami. Należy zwrócić uwagę na ten fakt przy analizie wyników klasyfikacji.

Po zakończeniu nagrania dane zapisano w formacie BrainVision (pliki .vhdr, .vmrk oraz .eeg), a każdy blok zapisano również jako osobną paczkę, aby zminimalizować ryzyko utraty danych w razie problemów z integralnością plików. Dane były oznaczone w sposób kompatybilny z oryginalnym badaniem LEMON, co ułatwiło dalszą analizę.

4.2.3. Eksploracja danych


Mateusz Naklicki

Dobrym zobrazowaniem pogorszenia się jakości sygnału względem danych z badania LEMON stanowi przedstawienie nieprzetworzonego sygnału EEG, który można zobaczyć na rysunku 4.19. Wykreślenie sygnału wymagało zwiększenia skali do 200 mikrowoltów, ponieważ inaczej wykres był całkowicie nieczytelny. Możemy zaobserwować jak sygnał zmienia się wraz z różnicą w impedancji: kanał PO8 charakteryzował się najmniejszą wartością wśród elektrod.




Rys. 4.19. Fragment nieprzetworzonego sygnału EEG z nagrania 1

Po zastosowaniu procedur przetwarzania sygnału, sygnał stał się bardziej czytelny, co można zauważyć na rysunku 4.20. W sekundzie 290-293 obserwujemy jeden z artefaktów, który jest często obserwowany w tym nagraniu. Podczas ręcznej analizy sygnałów z nagrania nr 1. odrzucone zostało 120 z 480 próbek 2-sekundowych, które były widocznie zaszumione. Oznacza to, że 25% sygnału zawierało znaczące zakłócenia. W przypadku reszty nagrań liczba zaszumionych próbek wynosiła kolejno: 97 (23.7%, krótsze nagranie), 36 (7.5%), 158 (32.9%), 78 (16.2%) oraz 91 (18.9%). Najczęściej obserwowanym rodzajem artefaktów podczas ręcznej analizy są artefakty wysokoczęstotliwościowe oraz wysokoamplitudowe, które trwają do kilku sekund. Tak wysoki procent próbek z artefaktami zwraca uwagę na potrzebę automatycznego wykrywania tego typu artefaktów.



Rys. 4.20. Fragment przetworzonego sygnału EEG z nagrania 1; od 283 sekundy

Aby lepiej ukazać i zrozumieć wpływ artefaktów na dalszą analizę, na rysunku 4.21 pokazana została zmiana widmowej gęstości mocy wyliczona przed i po usunięciu artefaktów z przetwarzanych danych.




Rys. 4.21. Uśrednione PSD z wszystkich kanałów przed (lewa strona) i po usunięciu artefaktów (prawa strona), nagranie nr 1

Jak można zauważyć, artefakty mają ogromny wpływ na przetwarzany sygnał. Rozpatrzenie ich przy tworzeniu klasyfikatora może być kluczowe, co rozważymy w dalszej części pracy. Dodatkowo zaobserwowano, że artefakty w ogólności są częściej obserwowane przy oczach otwartych, co wiąże się z m.in. mruganiem czy ruchami mięśni.

Jakość sygnału może zostać ukazana poprzez porównanie wykresów widmowej gęstości mocy wyliczonej z danych LEMON jak i zebranych przez zespół, co zostało przedstawione na rysunku 4.21. Możemy zauważyć znaczną różnicę w odnotowanej mocy sygnału, w szczególności spadek mocy w pasmie typowym dla oczu zamkniętych – Alfa – oraz znaczący wzrost w pasmie delta. Wzrost w pasmie delta wydaje się być artefaktem związanym z zastosowaną aparaturą –

jest obecny na każdym z nagrań niezależnie od środowiska oraz jest niezwiązany ze stanem pacjenta. Oznacza to, że jakość sygnału względem danych zebranych na sprzęcie laboratoryjnym jest bardzo pogorszona, jednak co najważniejsze: dalej widoczny jest typowy dla stanu oczu zamkniętych wzrost mocy sygnału w pasmie alfa, co znaczy, że stworzenie klasyfikatora powinno być możliwe.



Rys. 4.22. Uśrednione PSD z wszystkich kanałów, dane LEMON (lewa strona) i dane z nagrania nr 1 przy usuniętych artefaktach (prawa strona)

4.2.4. Eksperyment

Krystian Nowakowski

Przeprowadzono porównanie skuteczności klasyfikatorów na danych zebranych przez zespół. Do analizy wybrano nagrania w których nie występowały problemy z odczepieniem się elektrod oraz błędy w przesyle danych z Cyton. Eksperyment składał się z następujących etapów:

1. Porównanie jakości zebranych danych oraz ich wpływ na klasyfikatory. Dane zebrane przez zespół oraz dane pochodzące z badania LEMON zostały przetworzone w identyczny sposób aby umożliwić rzetelną ocenę działania klasyfikatorów.
2. Wpływ rozdzielania stanów podczas przeprowadzania filtracji. Porównano skuteczność filtracji wykonanej na całym nagraniu oraz filtracji oddzielnie dla jednodominutowych bloków, gdzie uczestnik znajdował się w jednym stanie oczu otwartych bądź zamkniętych.
3. Porównanie metod agregacji danych. Porównano różne metody agregacji danych opisane w rozdziale 3.3.3, aby ocenić ich wpływ na skuteczność modeli klasyfikujących.
4. Analiza czasu trwania epoki. Zbadano wpływ długości epoki na skuteczność klasyfikatorów. Rozpoczęto od epok trwających 2 sekundy, stopniowo zwiększając ich długość o 0.5 sekundy do wartości 4.5. Czas ten jest ograniczony z powodu potrzeby aproksymacji brakujących danych przy wyższych wartościach.

4.2.5. Wyniki


Krystian Nowakowski

Przeprowadzono porównanie jakości zebranych danych z eksperymentów przeprowadzonych przez zespół oraz badania LEMON. Wszystkie dane poddano identycznej filtracji, czas trwania epoki wynosił dwie sekundy. Dane z każdego kanału uśredniano do pasm częstotliwości. Eksperymenty przeprowadzono na jednym pacjencie z wykorzystaniem czterech kanałów. Dla porównania wykorzystano dane z badania LEMON, również dla 4 kanałów od jednego losowo wybranego pacjenta. Wyniki klasyfikujące dla pacjenta LEMON przedstawiono w tabeli 4.3 i osiągają poziom 90%.

Tabela 4.3. Dokładność modeli klasyfikujących na danych pochodzących od jednego pacjenta LEMON dla czterech kanałów

Liczba kanałów	KNN	SVM	LSTM
4	0.86	0.90	0.90

Wyniki uzyskane przez zespół zaprezentowano na wykresie 4.23. Jak możemy zauważyć wyniku uzyskane na danych pochodzących z badania LEMON przewyższają o około 15 punktów procentowych, wyniki uzyskane przez klasyfikatory dla poszczególnych nagrań.




Rys. 4.23. Wyniki uzyskane na danych zebranych przez zespół dla poszczególnych nagrań z filtracją całego bloku 16-minutowego.


Porównując nagrania nr 3, 4 i 5 gdzie umiejscowienie elektrod było takie samo, zauważono poprawę skuteczności modeli. Jednak zmiana umiejscowienia elektrod w miejsce z mniejszą różnicą sygnałów pomiędzy stanami oczu otwartych i zamkniętych spowodowała spadek dokładności modeli o około 10 punktów procentowych. Co więcej, różnice między modelami KNN, LSTM, SVM były niewielkie i wynosiły około 5 punktów procentowych.

Dodatkowo sprawdzono wpływ różnej metody filtracji na skuteczność klasyfikatorów. Porównano wyniki dla filtracji na całym bloku 16-minutowym oraz dla filtracji jednodominutowych próbek. Wyniki przedstawione na wykresie 4.24 wskazują, że filtracja jednodominutowa przynosi znaczące poprawy skuteczności. Modele KNN oraz SVM poprawiły swoje wyniki o 17 punktów procentowych, a model LSTM osiągnął średni wzrost skuteczności o 8 punktów procentowych, z maksymalnym wzrostem wynoszącym 15 punktów procentowych dla nagrań nr 3 i 5. Mimo to, ze względu na obawy związane z generalizacją modeli w zastosowaniach rzeczywistych, zrezygnowano z tego podejścia.

Wpływ długości epoki na skuteczność modeli również został poddany analizie. W tym celu przy wykorzystaniu filtracji 16-minutowej, wytrenowano modele dla epok o długości od 2 do 4.5 sekundy, zwiększając czas trwania o 0.5 sekundy. Wyniki przedstawiono na wykresie 4.25. Zauważono, że wydłużenie czasu trwania epoki poprawia skuteczność modeli nawet o 15 punktów procentowych. W związku z tym do dalszych eksperymentów zastosowano długość epoki równą 4.5 sekundy.




Rys. 4.24. Wyniki uzyskane na danych zebranych przez zespół dla poszczególnych nagrań z filtracją próbki jednodominutowej.



Rys. 4.25. Wpływ długości epoki na dokładność klasyfikatorów dla poszczególnych nagrań

Ostatecznie przeanalizowano wpływ różnych metod agregacji danych na skuteczność klasyfikatorów. Model wytrenowano zgodnie z czterema wariantami opisanymi w 3.3.3. Pozostały sposób przetwarzania danych pozostał bez zmian. Wyniki zaprezentowano na wykresie 4.26. Najlepsze wyniki osiągnięto dla wariantu nr 4 uwzględniającego wszystkie kanały oraz wszystkie pasma częstotliwości. Uśrednianie danych do pasm częstotliwości powoduje spadki dokładności o około 5 punktów procentowych, natomiast uśrednianie danych do jednego kanału miało mniejszy wpływ na skuteczność.



Rys. 4.26. Dokładność klasyfikatorów ze względu na agregację danych

4.2.6. Wnioski

Krystian Nowakowski

Wyniki przeprowadzonych eksperymentów pozwalają na przedstawienie kilku istotnych wniosków, przydatnych w kolejnych etapach pracy:

1. Podobna skuteczność klasyfikatorów. Ogólne wyniki poszczególnych klasyfikatorów są do siebie zbliżone. Wyniki są rozbieżne o około 5 punktów procentowych. Żaden z modeli nie wykazuje znaczącej przewagi, co wskazuje, że wybór najlepszego modelu jest uzależnione od charakterystyki danych, na których został wytrenowany.
2. Rodzaj zastosowanego okna filtracji ma istotny wpływ na skuteczność klasyfikatorów. Modele dla których dane zostały przefiltrowane w jednominutowych próbkach osiągały lepsze wyniki o 17 punktów procentowych, w porównaniu do filtracji przeprowadzonej na całym bloku 16-minutowym. Można przypuszczać, że niektóre z etapów filtracji jak np. uśrednianie, prowadzone przy większym oknie danych prowadzi do utraty subtelnych różnic w sygnale, co utrudnia klasyfikację.
3. Osiągnięte wyniki podczas filtracji jednominutowych bloków, przewyższają skuteczność klasyfikatorów trenowanych na losowo wybranym nagraniu z badania LEMON. Przefiltrowane pliki dostarczone przez naukowców były podzielone wyłącznie na dwa przypadki: oczu otwartych oraz zamkniętych. Wskazuje to, że filtracja mogła być zastosowana z podziałem na poszczególne stany w obrębie 8-minutowego nagrania, co zmniejszyło jej skuteczność w porównaniu z zastosowaną przez zespół filtracją, która miała zmniejszone okno filtracyjne do jednej minuty.
4. Wydłużenie czasu trwania epoki znacząco zwiększa skuteczność modeli. Zwiększenie długości epok z 2 do 4.5 sekundy skutkowało wzrostem dokładności nawet o 15 punktów procentowych. Modele analizując dłuższe próbki czasu mają większą możliwość uchwycenia istotnych wzorców sygnału EEG, co ułatwia poprawną klasyfikację. Na podstawie obserwa-

cji podjęto decyzję o korzystaniu do dalszych eksperymentów epok o czasie równym 4.5 sekundy .

5. Uśrednianie danych do szerokich pasm częstotliwości skutkuje znacznym spadkiem dokładności klasyfikacji stanów relaksu i skupienia. Wyniki te sugerują, że istotne informacje charakteryzujące te stany są zawarte w poszczególnych sub-pasmach. Zatem zachowanie szczegółowej struktury częstotliwościowej sygnału jest kluczowe dla skuteczności algorytmów klasyfikacyjnych. Takie podejście umożliwia lepsze uchwycenie dynamiki sygnałów EEG oraz różnic pomiędzy stanami uwagi.
6. Uśrednianie sygnałów ze wszystkich kanałów prowadzi do znacznego spadku dokładności klasyfikacji, co wskazuje na istotność zachowania topologii sygnału. Lokalizacja elektrod oraz przestrzenne zróżnicowanie aktywności mózgowej mają kluczowe znaczenie dla rozróżnienia stanów relaksu i skupienia. Wyniki podkreślają potrzebę uwzględnienia przestrzennych wzorców w analizie danych EEG, co pozwala na bardziej precyzyjne uchwycenie różnic w aktywności neuronalnej.
7. Uśrednianie kanałów ma większy wpływ na klasyfikatory niż uśrednianie częstotliwości do pasm. Spadki dokładności przy uśrednianiu do kanałów wynoszą około 5 punktów procentowych więcej niż podczas uśredniania częstotliwości. Możliwe, że różnice mocy sygnału pomiędzy półkulami mózgu podczas danego stanu pacjenta są traczone w procesie uśredniania do kanałów, co utrudnia zdolność modeli do rozróżniania stanów.
8. Wpływ impedancji podczas zbierania danych ma niewielki wpływ na analizę pojedynczych modeli. Natomiast podczas porównania uśrednionych wyników z różnych wariantów wydobycia cech, zauważono że dla nagrania nr 3, gdzie nie stosowano dodatkowej stabilizacji elektrod w postaci elastycznych gumek, skuteczność była średnio o 6 punktów procentowych niższa w porównaniu do nagrań, gdzie zastosowano to rozwiązanie.
9. Prawidłowe rozmieszczenie elektrod na czaszce znacząco wpływa na skuteczność klasyfikatorów. Umieszczenie elektrod w centralnej części czaszki, niezwiązanej z analizowanymi stanami oczu otwartych i zamkniętych, spowodowało spadek klasyfikatora nawet o 15 punktów procentowych. Spadek ten był najbardziej zauważalny w przypadku danych poddanych filtracji 16-minutowej. Obszary mózgu, które nie są odpowiedzialne za badane stany nie dostarczają istotnych cech umożliwiających poprawną klasyfikację.
10. Filtracja jednonminutowych próbek okazała się szczególnie korzystna w przypadku danych zaszumionych lub charakteryzujących się niewyraźną strukturą sygnału. Dla nagrań nr 3 i 6, gdzie zaobserwowano spadek impedancji pod koniec sesji oraz zmianę ich umiejscowienia, poprawa wyników była największa.

4.2.7. Dyskusja

Krzysztof Nowakowski, Mateusz Naklicki

Wpływ okna filtracji wymaga dalszego badania. Zmniejszenie okna może powodować zwiększenie responsywności modelu na zmianę stanu, co może być wartościowe w dynamicznym środowisku, gdzie stan ulega częstym zmianom. Połączenie krótkiego okna filtracji wraz z filtracją z podziałem na stan może przynieść duże zyski w dokładności klasyfikacji, utrzymując przy tym wysoką responsywność modelu.

Nie zaleca się stosowanie gumek recepturek podczas dłuższych sesji, ponieważ mogą one negatywnie wpływać na komfort pacjenta. Choć jest to rozwiązanie ekonomiczne i przydatne w

przypadku krótkich nagrań, jego zastosowanie w długotrwałych eksperymentach może narażać na obciążenia fizyczne pacjenta.

W przeprowadzonych badaniach zrezygnowano z trenowania modeli na jednominutowych próbkach, mimo że rozwiązanie to może przynieść obiecujące rezultaty w środowisku, w którym stan utrzymania jednego stanu jest długi (dłuższy niż stosowane okno filtracji).

4.3. Klasyfikacja stanu relaksu i skupienia przy użyciu urządzenia Cyton

4.3.1. Cel eksperymentu

Mateusz Naklicki

Celem tego eksperymentu jest stworzenie modeli klasyfikujących stany pacjenta na podstawie sygnału EEG, pozwalających na rozróżnienie pomiędzy stanem relaksu a stanem koncentracji. Klasyfikacja tych stanów umożliwia ocenę aktywności umysłowej i stanowi fundament do dalszych badań nad wpływem różnego poziomu aktywności poznawczej na sygnały EEG.

W tym eksperymencie wykorzystano zadanie wymagające dużego skupienia – uczestnik czyta odwrócone wersy z „Pana Tadeusza”, gdzie litery są zapisane od tyłu. Takie zadanie angażuje do intensywnej koncentracji i powinno pozwolić na uzyskanie sygnału EEG charakterystycznego dla tego stanu. Przeprowadzenie tego eksperymentu przy użyciu urządzenia Cyton umożliwia ocenę, jak dokładnie można odróżniać stan relaksu od koncentracji przy użyciu konsumenckiego sprzętu EEG.

W odróżnieniu od poprzednich eksperymentów, eksperyment ten bazuje na bardziej złożonym wzorcu aktywności umysłowej, a nie jedynie na różnicy pomiędzy stanem oczu otwartych i zamkniętych. Uzyskane dane pozwolą na ocenę skuteczności urządzenia Cyton w detekcji stanu umysłowego, a także dostarczą punkt odniesienia do dalszych badań nad precyzyjnym określaniem stanu relaksu i koncentracji na podstawie sygnałów EEG.

4.3.2. Zbieranie danych

Mateusz Naklicki

Elektrody zostały umieszczone w obszarze płatów czołowych, jako że jest ona częściowo odpowiedzialna za utrzymanie uwagi [98]. Pozycje elektrod w systemie 10-20 to C3, C4, F3 oraz F4.

Dane zostały zebrane w jednominutowych blokach, które oznaczają stan relaksacji bądź skupienia. Pełne nagranie składa się z 16 bloków, po 8 dla każdego ze stanów, które występują naprzemiennie. Rozpoczęcie nagrania bloku poprzedzone jest sygnałem dźwiękowym, od którego po trzech sekundach następuje zbieranie próbki danych. Taki margines ma na celu eliminację wpływu ERP wywołanego sygnałem rozpoczęcia.

Podczas eksperymentu uczestnik siedział w pozycji wyprostowanej na krześle. Podczas stanu relaksu uczestnik patrzył na określony punkt zaznaczony krzyżykiem na kartce, starając się zrelaksować, pozbyć myśli oraz prowadzić spokojny oddech. Stan skupienia osiągany był poprzez czytanie losowych wersów z książki Pana Tadeusz, w którym litery słów były wyświetlone w odwrotnym kierunku. Dla przykładu: *!owtiL onzyzcjO !ajom yt śetsej kaj :eiwordz*. Uczestnik starał się czytać w myślach tekst ze zrozumieniem, czytając tekst ponownie gdy go nie rozumiał. Uczestnik wykorzystując przycisk myszki sam sterował zmianą wersu.


Nagrania były kontynuowane na tym samym uczestniku co w poprzednim eksperymencie. Przeprowadzone zostało 5 nagrań:

- Nagranie nr 1.
Nagranie na pozycjach elektrod z poprzedniego eksperymentu (PO3, PO4, PO7 i PO8).
Impedancja w zakresie 50-59 k Ω .
- Nagranie nr 2.
Impedancja w zakresie 61-70 k Ω .
- Nagranie nr 3.
Impedancja w zakresie 43-46 k Ω .
- Nagranie nr 4.
Impedancja w zakresie 35-37 k Ω , zachowana ciągłość mocowania elektrod względem nagrania nr 2.
- Nagranie nr 5.
Impedancja w zakresie 35-40 k Ω .
- Nagranie nr 6.
Impedancja w zakresie 26-30 k Ω , zachowana ciągłość mocowania elektrod względem nagrania nr 4.

4.3.3. Filtracja i pre-processing sygnału

Aleksandra Sobecka


Na podstawie ustalonego modelu w podrozdziale 4.1.3 przeprowadzono filtrację sygnałów z otrzymanych nagrań a następnie porównano ich wyniki w odniesieniu do sygnału oryginalnego. Rozkłady mocy dla poszczególnych nagrań przedstawiono na rysunkach 4.27– 4.31.




Rys. 4.27. Porównanie PSD sygnałów z eksperymentu 2 do sygnałów bazowych

Na wykresach 4.27– 4.31. porównano sygnały opisane jako bazowe z sygnałami przefiltrowanymi filtracją teoretyczną zaproponowaną w rozdziale 4.1.3, która składa się z następujących metod:


- Resampling do 250Hz
- Filtr 1-45Hz




Rys. 4.28. Porównanie PSD sygnałów z eksperymentu 3 do sygnałów bazowych



Rys. 4.29. Porównanie PSD sygnałów z eksperymentu 4 do sygnałów bazowych



Rys. 4.30. Porównanie PSD sygnałów z eksperymentu 5 do sygnałów bazowych



Rys. 4.31. Porównanie PSD sygnałów z eksperymentu 6 do sygnałów bazowych

- Filtr Notch 50Hz
- Uśrednianie (average reference)
- Ustalenie standardowego montażu
- ICA automatycznie wykrywająca artefakty mięśniowe
- ICA Infomax z usuwaniem komponentów dla których prawdopodobieństwo artefaktu jest wyższe niż 70%

Sygnałami bazowymi są w tym przypadku sygnały niefiltrowane, ale przy zastosowaniu resamplingu do 250Hz i ustalonego standardu montażu elektrod (10-20). Celem było umożliwienie wykonania wykresów porównawczych.

Na przedstawionych wykresach można zauważyć, że filtracja teoretyczna dzięki zastosowanym metodom usuwa artefakty, przy jednoczesnym zachowaniu subtelnych zmienności mocy w sygnale EEG. Zachowanie zmian widoczne jest w zwiększeniu szczegółowości sygnału i jego widma mocy. Charakterystyczna struktura widma mocy po filtracji jest spójna we wszystkich analizowanych eksperymentach, co potwierdza skuteczność i powtarzalność zastosowanego procesu filtracji, niezależnie od badanego zestawu eksperymentalnego.

Filtracja z odrzucaniem złych epok

Na podstawie obserwacji widma sygnału zaobserwowano, że typowy sygnał charakteryzuje się mocą znajdującą się w określonym zakresie. W literaturze [99] wskazuje się, że większość istotnych sygnałów EEG mieści się w niższych wartościach amplitudy, a przekroczenie ustalonego progu może być spowodowane obecnością artefaktów, takich jak ruchy oczu, napięcie mięśniowe czy inne zakłócenia niepożądane w analizie. Takie zakłócenia wzmacniają dodatkowo sygnały rejestrowane za pomocą elektrod.

Ręczna analiza sygnału potwierdziła, że epoki przekraczające przyjęty próg wykazują charakterystyki odbiegające od oczekiwanej aktywności neuronalnej. Na tej podstawie stworzono nową wersję procesu filtracji, zawierającą dodatkowy etap usuwania tzw. złych epok. Złymi epokami nazywamy fragmenty nagrań sygnału, w których moc zarejestrowanego sygnału przekracza ustalony próg. Sygnał zgodnie z wcześniejszymi założeniami zostały podzielone epoki o długości 4,5 sekundy.

Sugerując się pracą [53] pierwotnie zastosowano metodę odrzucania epok przy wartości progowej przekraczającej $111\mu V$. Zaś w wyniku kolejnych eksperymentów i analiz, które wykonane zostały równolegle do procesu poszukiwania najlepszej metody filtracji, ustalono że można przyjąć wartość progową równą $100\mu V$. Dalsze prace w zakresie modeli predykcyjnych kontynuowano, posługując się tak ustaloną wartością.

Porównanie obydwu wartości progowych zastosowanych do odrzucania złych epok przedstawiono na rysunku 4.32. Wyniki opisanych procesów filtracji zaprezentowano jako uśrednione wartości dla wszystkich wariantów agregacji danych jakie zostały przedstawione w 3.3.3.

Porównanie efektywności filtracji w zależności od progu odrzucenia epok ($100\mu V$ i $111\mu V$) wykazało niewielką różnicę. Dlatego kontynuowano prace nad modelami predykcji i metodą filtracji, stosując zamiennie różne wartości progowe dla odrzucania epok. Model filtracji stosowany w dalszych analizach składał się z następujących kroków:

- Resampling do 250Hz
- Filtr pasmowoprzepustowy 1-45Hz
- Filtr Notch 50Hz
- Uśrednianie (average reference)

Metoda	Accuracy			Recall			Precision			F1 Score		
	knn	lstm	svm	knn	lstm	svm	knn	lstm	svm	knn	lstm	svm
Filtracja teoretyczna bez odrzucania złych epok	76%	77%	77%	75%	73%	75%	79%	83%	81%	75%	76%	76%
Filtracja teoretyczna z odrzucaniem złych epok 111uV	81%	84%	77%	79%	82%	72%	80%	82%	78%	78%	81%	73%
Filtracja teoretyczna z odrzucaniem złych epok 100uV	80%	82%	75%	81%	83%	72%	84%	84%	75%	79%	80%	71%

Rys. 4.32. Porównanie wyników filtracji dla usuwania epok o amplitudzie $100\mu V$ i $111\mu V$

- Ustalenie standardowego montażu
- ICA automatycznie wykrywająca artefakty mięśniowe
- ICA Infomax z usuwaniem komponentów dla których prawdopodobieństwo artefaktu jest wyższe niż 70%
- Odrzucanie epok o amplitudzie większej niż:
 - dla modeli zastosowanych do predykcji: $100\mu V$
 - dla modeli podczas wyznaczania najefektywniejszej filtracji: $111\mu V$

4.3.4. Eksploracja danych

Mateusz Naklicki

Na rysunku 4.33 przedstawiono zestawienie widm mocy (PSD) dla dwóch konfiguracji umiejscowienia elektrod EEG: obszaru potylicznego (lewy wykres) oraz płatów czołowych (prawy wykres). Dane zaprezentowano jako średnie wartości PSD z odchyleniem standardowym dla obu stanów – relaksu i koncentracji.

W obszarze potylicznym podczas stanu koncentracji zaobserwowano wzrost mocy w wyższych pasmach częstotliwości, w szczególności beta (13–30 Hz) i gamma (>30 Hz). Pasma te są charakterystyczne dla stanów intensywnej aktywności poznawczej, takich jak czytanie odwróconego tekstu.

W obszarze płatów czołowych dominującymi pasmami są delta (<4 Hz) i theta (4–8 Hz). Pasma theta, które jest szczególnie zauważalne w stanie relaksu, odzwierciedla głęboką relaksację i redukcję aktywności poznawczej. Podczas koncentracji w tym obszarze aktywność w pasmach delta i theta jest względnie mniejsza, co wskazuje na większą mobilizację funkcji wykonawczych i uwagi.


Średnie PSD sygnałów z wszystkich nagrań z elektrodami zamocowanymi w obszarze płatów czołowych zostało wykreślone na rysunku 4.34. W pasmach alfa (8–13 Hz), beta (13–30 Hz) i gamma (>30 Hz) gęstości widmowe dla obu stanów – relaksu i koncentracji – zaczynają się zbiegać. To sugeruje, że różnice pomiędzy stanami w płatach czołowych są bardziej wyraźne w niskich częstotliwościach (delta i theta) niż w wyższych pasmach.

Zauważono również, że moc pasm sygnału jest mniejsza o rząd wielkości w nagraniu 3 oraz 4, co może mieć fundamentalny wpływ na działanie modeli wytrenowanych na tych danych przy wykorzystaniu ich do klasyfikacji w czasie rzeczywistym.


4.3.5. Eksperyment

Krzysztof Nowakowski, Mateusz Naklicki

Zebrane nagrania podano analizie skuteczności klasyfikacji przy rozpoznawaniu stanów skupienia oraz relaksu. Zbadano skuteczność predykcji modeli offline oraz na żywo podczas podłączenia uczestnika. Eksperyment składał się z następujących etapów:



Rys. 4.33. Zestawienie PSD przy elektrodach na pozycjach PO3, PO4, PO7 i PO8: lewa strona, z elektrodami na pozycjach C3, C4, F3, F4: prawa strona. Zaznaczono odchylenie standardowe.



Rys. 4.34. Średnia PSD z wszystkich nagrań przy elektrodach mocowanych na obszarze płatów czołowych

1. Porównano jakość danych oraz ich wpływ na ocenę klasyfikatorów. Dane zebrane przez zespół zostały przetworzone w identyczny sposób jak w poprzednich eksperymentach aby ocenić działania klasyfikatorów w kontekście stanu relaksu oraz skupienia.
2. Porównano wpływ agregacji danych na ocenę klasyfikacji stanów skupienia oraz relaksacji. Porównano różne metody agregacji danych opisane w rozdziale 3.3.3, aby ocenić ich wpływ na skuteczność modeli klasyfikujących.
3. Porównano różne metody filtracji na skuteczność klasyfikatorów offline. Porównano różne kombinacje metod filtracji opisane w 2.3.
4. Sprawdzono wpływ usuwania określonych amplitud podczas uczenia oraz predykcji modeli. W tym celu eksperymentalnie dobierano amplitudę graniczną powyżej której sygnał był usuwany.

5. Wykonano łączenie danych z wielu nagrań do predykcji offline na nowym nieznanym zbiorze danych. Wytrenowano modele na wybranych nagraniach oraz sprawdzono ich skuteczność na innym nagraniu.
6. Porównano wpływ agregacji danych na predykcję na nieznanym zbiorze. Podano analizie wpływ agregacji danych na skuteczność klasyfikatorów na nieznanym wcześniej zbiorze danych.
7. Dokonano porównań ujednoliconych metod filtracji podczas uczenia modeli offline z modelami predykcyjnymi na żywo. W tym celu ujednolicono okno filtracji dla danych treningowych dla modeli offline oraz na żywo.
8. Dokonano oceny skuteczności klasyfikatorów wytrenowanych offline podczas predykcji na żywo. W tym celu wytrenowano klasyfikatory na wybranym nagraniu, a następnie poddano je ocenie podczas badania na żywo.
9. Dokonano oceny skuteczności modeli trenowanych oraz doszkalanych na żywo. Porównano skuteczność modeli trenowanych podczas badania na żywo z modelami trenowanymi offline oraz doszkalanych podczas badania na żywo.
10. Sprawdzone skuteczność uśredniania predykcji z kilku kroków czasowych podczas predykcji na żywo. Aby zapobiec nagłym skokom przewidywań modeli uśredniono wyniki klasyfikacji z kilku kroków do ostatecznej predykcji.
11. Sprawdzone wpływ wartości progu przełamania na skuteczność modelu. Próg ten określa pewność modelu konieczną do zmiany raportowanego stanu przez model.
12. Porównano podstawową i zaawansowaną metodę filtracji podczas predykcji na żywo.

4.3.6. Wyniki


Krzysztof Nowakowski, Mateusz Naklicki, Aleksandra Sobecka

Przeprowadzono porównanie jakości zebranych danych. Zebrane dane zostały poddane podstawowej filtracji oraz na bazie wcześniejszych eksperymentów wybrano wariant agregacji danych gdzie model był trenowany na wszystkich kanałach oraz wszystkich częstotliwościach. Czas trwania epoki (okna predykcji) wynosił 4.5 sekundy. Wyniki przedstawiono na wykresie 4.35.


Zauważono mniejszą skuteczność klasyfikatorów na nagraniu nr 3 oraz 4. Wynikać to może z mniejszej rzetelności przeprowadzonych badań ze strony pacjenta, spowodowane nastrojem oraz zmęczeniem. Średnia skuteczność klasyfikatorów dla tych nagrań jest niższa niż dokładność klasyfikatorów dla nagrania nr 1, gdzie zastosowano umiejscowienie elektrod PO3, PO4, PO7, PO8 stosowane przy badaniach stanu oczu otwartych oraz zamkniętych. Dla nagrań dobrej jakości zauważono najlepszą dokładność dla klasyfikatora SVM, średnie wyniki przewyższyły model LSTM o 4 punkty procentowe, a model KNN o około 7 punktów procentowych.

Sprawdzono również wpływ agregacji danych na skuteczność klasyfikatorów. Wyniki przedstawiono na wykresie 4.36. Na podstawie przeprowadzonych badań potwierdzono wyniki uzyskane w 4.2.5, gdzie stwierdzono że uśrednianie danych do pasm częstotliwości ma negatywny wpływ na skuteczność klasyfikatorów. Wyniki dla nagrania nr 2 są najbardziej równe, natomiast mimo wszystko różnice pomiędzy uśrednianiem do pasm wynosi około 3 punkty procentowe. Uśrednianie do jednego kanału powoduje spadki skuteczności klasyfikatorów o około 16 punktów procentowych, porównując nagrania o dobrej jakości sygnału.

Porównano dla każdego nagrania różne metody filtracji, które szczegółowo zostały opisane w 4.3.6. Uśrednione wyniki dla każdego z nagrań przedstawione są na wykresie 4.37. Wyniki dla filtracji nr 2, 6 oraz 8 są najwyższe. Analizując wpływ wspomnianych filtracji na poszczególnych




Rys. 4.35. Skuteczność klasyfikatorów podczas poszczególnych nagrań stanów uwagi relaksu oraz skupienia



Rys. 4.36. Dokładność klasyfikatorów ze względu na agregację danych


nagrań w przypadku nagrania nr 2 skuteczność modeli wzrasta do poziomu 90%. Wyniki te są bardzo zadowalające, zastosowanie tych filtracji może przynieść zadowalające efekty podczas klasyfikacji na żywo.

W celu ulepszenia zaawansowanej filtracji sprawdzono wpływ odrzucania sygnałów wysoko amplitudowych na skuteczność klasyfikatorów. Dobrany parametr graniczny wykorzystany w pracy [53], był on równy $111\mu V$. Eksperymentalnie dobrano inne wartości parametrów, w celu zbadania ich wpływu na klasyfikację. Badanie przeprowadzono na nagraniu nr 2 oraz zastosowano 30-sekundowe okno filtracji. Wyniki eksperymentów przedstawiono na wykresie 4.38. Zauważono



Rys. 4.37. Uśredniona skuteczność filtracji mierzona w dokładności klasyfikatorów dla wszystkich nagrań

ogólny pozytywny wpływ odrzucania sygnałów wysoko amplitudowych na skuteczność klasyfikatorów. Dla modeli KNN oraz LSTM dzięki usuwaniu amplitud wzrost skuteczności jest na poziomie 4 punktów procentowych. Dla modelu SVM wzrost jest nieznaczny na poziomie jednego punktu procentowego i występuje jedynie dla usuwania amplitud powyżej 200 μV . Dla pozostałych wartości granicznych zauważono spadek o około 3 punkty procentowe. Analizując macierze konfuzji wytrenowanych modeli, pomimo wysokiej skuteczności klasyfikatorów zauważono przeważającą ilość próbek należącej do stanu relaksu. Oznacza to, że w danych stanu skupienia występowało więcej próbek wysoko-amplitudowych. Podczas trenowania modeli należy zwrócić uwagę czy ostateczny zbiór treningowy jest zrównoważony.



Rys. 4.38. Uśredniona skuteczność klasyfikatorów dla odrzucania sygnałów powyżej danej amplitudy

W celu sprawdzenia skuteczności predykcji modele wytrenowano na danych pochodzących z nagrań nr 2, 3 oraz 4. Następnie sprawdzono je na mniejszej próbkę danych, składającej się z dwóch bloków stanu skupienia oraz stanu relaksacji. Nagranie to było wykonane na tym samym podłączeniu jak nagranie nr 4. Zestawienie wyników przedstawiono w tabeli 4.4. Spadki są drastyczne, dla modelu KNN spadek wynosi ponad 42 punkty procentowe, najmniejszy spadek zauważono dla LSTM i wyniósł 10 punktów procentowych. Wyniki te nie napawały optymizmem przed badaniem skuteczności klasyfikatorów podczas badania na żywo. Wpływ na słabe wyniki predykcji może mieć również słaba jakość zebranych danych.

Tabela 4.4. Zestawienie dokładności klasyfikatorów wytrenowanych na nagraniach nr 2, 3 oraz 4 z predykcją na danych pochodzących z innego nagrania.

Model	Zbiór treningowy	Zbiór testowy
KNN	0.79	0.37
SVM	0.78	0.60
LSTM	0.69	0.59

Analizując dane spostrzeżono, że dla modeli gdzie zastosowano uśrednianie danych do pasm częstotliwości, spadki podczas predykcji były mniejsze. Dla niektórych przypadków nastąpiła nieznaczna poprawa w zestawieniu z modelem nauczonym na danych testowych. Wyniki przedstawione są w tabeli 4.5. Dokładny opis przedstawionych wariantów znajduje się w rozdziale 3.3.3. Wariant 2 gdzie zauważono najmniejszy spadek dokładności predykcji, polega na uśrednianiu danych z wszystkich kanałów do jednego oraz do pasm częstotliwości. Spadek w tym wariantcie wyniósł 10 punktów procentowych. Dokładność klasyfikatorów dla takiej agregacji jest mniejsza, natomiast użycie takiego podejścia może przynieść najlepsze wyniki podczas predykcji na żywo. Dla wariantów gdzie brano pod uwagę wszystkie częstotliwości spadki podczas predykcji wyniosły aż 23 punkty procentowe.

Tabela 4.5. Zestawienie wpływu agregacji danych na skuteczność predykcji.

Agregacja danych	Zbiór treningowy	Zbiór testowy
Wariant 1	0.74	0.51
Wariant 2	0.62	0.52
Wariant 3	0.65	0.46
Wariant 4	0.75	0.52

Do kolejnych badań związanych z klasyfikacją stanów uwagi na żywo, podczas podłączenia pacjenta, do trenowania modeli wykorzystano dane pochodzące jedynie z nagrania nr 2. Pozostałe dwa nagrania dostępne w momencie dokonywania badań wyeliminowano z powodu podejrzenia niskiej jakości danych.

We wcześniej dokonanych badaniach wykorzystywano filtrację całego nagrania 16-minutowego, która okazała się nieskuteczna podczas predykcji na żywo: wyniki działania klasyfikatorów znajdowały się z okolicach 50% i nie były w stanie rozróżniać sygnałów (modele cały czas raportowały ten sam stan). Z tego powodu zmieniono podejście do filtrowania danych, aby dostosować modele do filtracji wykorzystywanej w aplikacji na żywo. W tym celu filtrowano każdą-30 sekundową próbkę nagrania osobno. Do analizy wybrano warianty agregacji danych, które zostały użyte w klasyfikatorach na żywo. Użyte warianty to wykorzystanie wszystkich kanałów wraz z wszystkimi częstotliwościami oraz uśrednianie kanałów z wykorzystaniem wszystkich częstotliwości. Zastosowano filtrację podstawową wraz z odrzucaniem artefaktów wysokoamplitudowych powyżej 100 μV . Zestawienie wyników dla zmian w filtracji zostało przedstawione w tabeli 4.6. Wyniki podczas

filtracji 30-sekundowej osiągają lepsze wyniki dla klasyfikatora LSTM, w pozostałych przypadkach pogorszenie wynosi 4 punkty procentowe.

Tabela 4.6. Zestawienie wpływu okna filtracji na klasyfikatory.

Model	Filtracja 16-minutowa	Filtracja 30-sekundowa
KNN	0.86	0.82
LSTM	0.85	0.91
SVM	0.88	0.84

Wyniki przedstawione w tabeli 4.7 odzwierciedlają działanie modeli w czasie rzeczywistym podczas nagrania nr 5 z wykorzystaniem podstawowej filtracji. Modele klasyfikacyjne zostały wytrenowane na danych zebranych podczas nagrania nr 2. Pozwoliło to na ocenę, jak modele radzą sobie z klasyfikacją na danych, które mogły różnić się pod względem jakości sygnału i obecności artefaktów.

Tabela 4.7. Dokładność modeli klasyfikujących sygnał na żywo podczas nagrania nr 5.

Model	Średnia kanałów	Kanały osobno
KNN	0.79	0.78
SVM	0.77	0.74
LSTM	0.81	0.78

Modele bazujące na wszystkich kanałach operowały na danych bez wcześniejszego usuwania próbek o wysokiej amplitudzie ($>100 \mu V$). Takie próbki mogły zawierać artefakty wysokoamplitudowe, co miało wpływ na ich dokładność. Modele wykorzystujące średnią kanałów były bardziej odporne na zakłócenia, dzięki czemu osiągnęły nieco lepsze wyniki.

Po nagraniu 5. dane zostały wykorzystane do ponownego wytrenowania modelu bazującego na wszystkich kanałach i powtórzono sprawdzanie dokładności modeli. W przypadku modeli KNN i SVM zaobserwowano kilkuprocentową poprawę do odpowiednio 82 i 80%. Model LSTM, przy którym zastosowano dotrenowanie modelu, zanotował pogorszenie do 76%.

Po zakończeniu nagrań, dane zostały ponownie odtworzone w aplikacji, aby sprawdzić skuteczność różnych metod przetwarzania na przestrzeni wielu nagrań.

Wyniki przedstawione w tabeli 4.8 dotyczą modeli wytrenowanych na danych z eksperymentu nr 2, z zastosowaniem odrzucania artefaktów wysokoamplitudowych ($>100 \mu V$) w danych treningowych.

Dokładność klasyfikacji w nagraniach 3 i 4 jest istotnie niższa w porównaniu do pozostałych nagrań. Jak już wcześniej wskazano, nagrania te są niższej jakości i ich charakterystyka istotnie odbiega od normy, co powoduje znaczące spadki skuteczności modeli. Z tych przyczyn w dalszej analizie skupimy się na pozostałych nagraniach.

Możemy zauważyć spadek dokładności modelu SVM bazującego na osobnym rozpatrywaniu kanałów. Należy zaznaczyć, że w scenariuszu, w którym wysokoamplitudowe artefakty nie były usuwane podczas przygotowywania danych do treningu, dokładność modelu znacząco wzrastała, osiągając wartości podobne do innych modeli.

W nagraniach 5 i 6 obserwujemy znaczący wzrost dokładności modeli, co wskazuje na poprawę jakości danych EEG, wynikającą z lepszej stabilności elektrod oraz mniejszej liczby zakłóceń. Modele oparte na średniej kanałów wykazują generalnie wyższą odporność na zakłócenia w porównaniu do modeli uwzględniających kanały indywidualnie.

Dotychczas w czasie rzeczywistym próbki sygnału były przekazywane do modelu bez względu na ich amplitudę, a więc nie uwzględniały możliwości wystąpienia artefaktów o wysokiej amplitudzie. Ignorowanie takich próbek wpłynęło nieznacznie na wyniki klasyfikatorów.

Tabela 4.8. Dokładność modeli klasyfikacyjnych w nagraniach obszaru kory czołowej

Nagranie nr 2		
Model	Średnia kanałów	Kanały osobno
KNN	0.81	0.78
LSTM	0.81	0.70
SVM	0.78	0.50
Nagranie nr 3		
Model	Średnia kanałów	Kanały osobno
KNN	0.47	0.50
LSTM	0.51	0.60
SVM	0.54	0.56
Nagranie nr 4		
Model	Średnia kanałów	Kanały osobno
KNN	0.58	0.53
LSTM	0.61	0.58
SVM	0.61	0.57
Nagranie nr 5		
Model	Średnia kanałów	Kanały osobno
KNN	0.73	0.77
LSTM	0.77	0.75
SVM	0.75	0.53
Nagranie nr 6		
Model	Średnia kanałów	Kanały osobno
KNN	0.68	0.77
LSTM	0.75	0.74
SVM	0.70	0.50

Uśrednianie odpowiedzi klasyfikatora

Zastosowane zostało uśrednianie wyników klasyfikacji dla pięciu ostatnich predykcji, co pozwoliło na bardziej stabilne określenie aktualnego stanu uczestnika. Podejście to uwzględnia ciągłość sygnałów EEG oraz redukuje wpływ pojedynczych błędnych predykcji wynikających z chwilowych zakłóceń lub artefaktów. Wyniki przedstawiono w tabeli 4.9.


Główne założenie polega na tym, że klasyfikacja oparta na zbiorze ostatnich predykcji dostarcza bardziej spójnych wyników niż pojedyncze predykcje. Dzięki temu można osiągnąć wyższą dokładność w detekcji stanów relaksu i koncentracji w czasie rzeczywistym, szczególnie gdy różnice są subtelne.

Tabela 4.9. Dokładność modeli klasyfikacyjnych z uśrednianiem 5 ostatnich predykcji

Nagranie nr 2		
Model	Średnia kanałów	Kanały osobno
KNN	0.85	0.82
LSTM	0.80	0.62
SVM	0.83	0.63
Nagranie nr 5		
Model	Średnia kanałów	Kanały osobno
KNN	0.82	0.83
LSTM	0.82	0.82
SVM	0.86	0.53
Nagranie nr 6		
Model	Średnia kanałów	Kanały osobno
KNN	0.74	0.82
LSTM	0.84	0.84
SVM	0.83	0.50

Wyniki wskazują, że zastosowanie tego sposobu przetwarzania znacząco poprawiło skuteczność modeli.

Na podstawie nagrania nr 5 zbadano jaką liczbą przewidywań wykorzystaną do obliczenia finalnej predykcji daje największą poprawę dokładności. Dane przedstawiono na wykresie 4.39. W analizie nie uwzględniono modelu SVM bazującego na osobnym rozpatrywaniu kanałów z powodu jego bardzo niskiej skuteczności w stosunku do reszty modeli.



Rys. 4.39. Dokładność modeli w zależności od liczby ostatnich przewidywań wykorzystanych do finalnego werdyktu. Nagranie 5.


Uśrednianie od 3 do 7 ostatnich przewidywań przyniosło największe korzyści w zakresie poprawy dokładności, z wyraźnym maksimum w okolicach uśredniania 5 przewidywań, gdzie średnia wartość poprawnych przewidywań podniosła się aż o 8 punktów procentowych. W przypadku nagrania nr 6 również wartość 5 przewidywań najlepiej poprawiła działanie modeli: zauważono wzrost średniej dokładności z 74% do 81%.

Wyniki dla nagrań 2, 5 i 6 zostały zestawione na wykresie 4.40.

Średnia osiągnięta dokładność również wskazuje na 5 jako optymalną liczbę uśrednianych przewidywań.

Próg przełamania

W celu dalszej poprawy jakości klasyfikacji i stabilności decyzji modeli, wprowadzono dodatkowy mechanizm w postaci progu przełamania. Mechanizm ten wymaga, aby średnia pewność przewidywania modeli przekroczyła ustalony próg, zanim nastąpi zmiana raportowanego stanu. Na przykład, dla progu przełamania wynoszącego 0.7, modele muszą osiągnąć średnią pewność przewidywania powyżej 70%, aby dokonać zmiany raportowanego stanu.



Rys. 4.40. Średnia dokładność modeli w zależności od liczby uśrednianych predykcji wśród nagrań 2, 5 i 6.

Wprowadzenie tego etapu ma na celu redukcję wpływu przypadkowych fluktuacji lub niepewnych decyzji modeli, które mogą wynikać z chwilowych zakłóceń w sygnale lub niskiej jakości danych. Mechanizm ten pozwala zwiększyć stabilność klasyfikacji, szczególnie w warunkach, gdzie różnice między stanami relaksu i koncentracji są subtelne lub dane są bardziej zaszumione.


Na kolejnych wykresach przedstawiono szczegółowe wyniki uzyskane przy różnych wartościach progu przełamania. Eksperymenty te mają na celu identyfikację optymalnego progu, który zapewni balans między stabilnością decyzji a responsywnością modeli.

Na wykresie 4.41 przedstawiono wyniki dokładności modeli w zależności od wartości tego progu. Próg przełamania równy 0,5 oznacza klasyczne działanie klasyfikatorów, co skutkuje natychmiastową zmianą raportowanego stanu przy przekroczeniu średniego wyniku na poziomie 50%. Wraz ze wzrostem progu przełamania modele wymagają wyższej pewności przewidywań, co prowadzi do zmniejszenia liczby zmian stanu, ale jednocześnie wpływa na dokładność.


Zauważono, że dla progu równego 0.5 modele osiągają najwyższą dokładność. Wartości progu w zakresie 0.55–0.65 wykazują lekkie zmniejszenie dokładności. Powyżej wartości 0.7 dokładność gwałtownie spada: mechanizm progu zaczyna zbyt mocno ograniczać możliwość zmiany stanu, prowadząc do utraty responsywności systemu na zmiany.

W przypadku nagrań 2 i 6 również zaobserwowano spadek dokładności przy stosowaniu progu przełamania, co ilustruje wykres 4.42.

Podsumowując analizę wpływu progu przełamania można stwierdzić, że mechanizm ten nie przyniósł oczekiwanych korzyści. Choć próg przełamania został wprowadzony w celu zwiększenia stabilności decyzji modeli, w kontekście tego eksperymentu skutkowało on pogorszeniem wyników klasyfikacji. Dla niskich wartości progu (np. 0.5), które de facto eliminują wpływ tego mechanizmu, modele osiągały najwyższą dokładność.



Rys. 4.41. Dokładność modeli w zależności od progu przełamania potrzebnego do zmiany raportowanego stanu. Nagranie 5.



Rys. 4.42. Średnia dokładność modeli w zależności od zastosowanego progu przełamania wśród nagrań 2, 5 i 6.

Mechanizm ten, mimo potencjalnych korzyści, okazał się nieefektywny w scenariuszu, gdzie stany relaksu i koncentracji zmieniały się w regularnych odstępach czasowych. Wyniki sugerują, że skuteczność tego mechanizmu może być silnie uzależniona od charakterystyki badania, a jego stosowanie w podobnych eksperymentach wymaga starannego przemyślenia i odpowiedniego dostosowania parametrów.

Filtracja zaawansowana

Aleksandra Sobecka

W celu zweryfikowania jakości filtracji i zoptymalizowania procesu przygotowano dodatkowe warianty filtracji, które opierają się i są rozwinięciem filtracji teoretycznej z uwzględnieniem usuwania epok oraz zachowania automatycznego charakteru modelu filtracji. Dzięki temu zminimalizowano subiektywny czynnik ludzki. Działania te mają na celu maksymalizację skuteczności procesu eliminacji artefaktów oraz poprawę parametrów jakościowych sygnału przy jednoczesnym zachowaniu informatywności nagrania EEG.

Celem wykonanych, nowych filtracji jest również lepsza jakość przetworzonego sygnału, która pozytywnie wpływa na skuteczność modeli predykcyjnych – SVM, KNN oraz LSTM. Modele te ze względu na różne podejścia do analizy danych, pozwalają na kompleksowe porównanie efektywności zastosowanych metod filtracji w kontekście klasyfikacji.

Wyniki z przedstawianych filtracji zaprezentowano jako uśrednione wartości dla wszystkich wariantów agregacji danych jakie zostały przedstawione w 3.3.3, ponieważ zakładane jest stworzenie filtracji jak najlepszej dla klasyfikacji sygnału ale jednocześnie też możliwie uniwersalnej dla różnych metod klasyfikacji.

Obniżenie progu ICA Infomax do 60% – Dla uzyskanych eksperymentów wybrana metoda ICA Infomax z progiem 70% nie wykryła żadnych komponentów do odrzucenia, ponieważ w żadnym zbiorze danych nie powstał komponent, którego prawdopodobieństwo przekroczyłoby 70%.

W związku z tym postanowiono wykonać dodatkowe dwa warianty filtracji, które mogłyby dostarczyć informacji na temat poprawności dobranego progu dla prawdopodobieństwa, że dany komponent jest artefaktem. W związku z tym obniżono próg do 60%. Taka filtracja okazała się być zbyt agresywna i usunęła wraz z wytypowanymi komponentami sygnał mózgowy, co jest dobrze widoczne poprzez spadek sprawności modeli predykcji (Tabela 4.10).

PCA – W procesie filtracji danych EEG zastosowano dodatkowy krok tj. analizę PCA, który przeprowadza redukcję wymiarowości i wyodrębnia główne komponenty sygnału EEG, bez etapu odrzucania wytypowanych komponentów. Analiza PCA została wykonana podczas procesu filtrowania jako jeden z kroków modelu:

1. Resampling do 250Hz
2. Filtr 1-45Hz
3. Filtr Notch 50Hz
4. Uśrednianie (average reference)
5. Ustalenie standardowego montażu
6. ICA automatycznie wykrywająca artefakty mięśniowe
7. PCA
8. ICA Infomax z usuwaniem komponentów dla których prawdopodobieństwo artefaktu jest wyższe niż 70%
9. Odrzucanie epok o amplitudzie większej niż $111\mu V$

Po zastosowaniu PCA zauważono znaczny wzrost w ilości odrzucanych epok, przykładowo dla danych z eksperymentu 2 odrzucono 110 epok w porównaniu do 14 epok w danych bez zastosowania PCA, mimo że próg amplitudy ($111 \mu V$) pozostał niezmieniony. Zastosowanie PCA wpłynęło na znaczną poprawę procesu odrzucania epok. Również ta filtracja osiągnęła bardzo wysokie wyniki w modelach predykcji (Tabela 4.10).

Można przypuszczać, że PCA uwypukliło subtelne artefakty i szумы w sygnale, które wcześniej nie były wykrywane. Zmiana ta pozytywnie wpłynęła na wyniki modeli predykcyjnych (SVM, KNN, LSTM), które wykazały lepszą dokładność i spójność. Wskazuje to, że krok PCA znacząco poprawił jakość danych, zwiększając ich jednorodność i eliminując wadliwe epoki, co czyni tę metodę kluczowym elementem procesu przetwarzania danych EEG w analizie.

PCA przed ICA wykrywająca artefakty mięśniowe – w celu pogłębienia analizy dotyczącej wpływu PCA na układ danych i postrzeganie ich przez współdziałające w filtracji metody, zdecydowano się na umiejscowienie PCA przed wykonaniem ICA do detekcji artefaktów mięśniowych w celu zbadania jak wpłynie na rezultaty ICA. W tym przypadku doszło do pogorszenia jakości predykcji, co pozwoliło potwierdzić wcześniejsze podejrzenia ze kluczowym elementem wpływającym na poprawę filtracji danych jest efektywne odrzucanie złych epok (Tabela 4.10).

PCA przed ICA wykrywająca artefakty mięśniowe z usuwaniem komponentów na danych sprzed PCA – zdecydowano się również na wykonanie dodatkowej filtracji, która tak jak wcześniejsza polegała na wykonaniu PCA przed ICA do detekcji artefaktów mięśniowych, z tą różnicą, że komponenty wytypowane przez ICA na zbiorze przygotowanym przez PCA są usuwane ze zbioru sprzed wykonania PCA. Metoda ta nie przyniosła tak dobrych efektów jak zastosowanie PCA przed samym usunięciem epok, i można ją uznać za porównywalną do metody z filtracji teoretycznej z usuwaniem złych epok (Tabela 4.10).

Filtracja na żywo – na podstawie wcześniejszych analiz filtracji do predykcji na żywo wybrano filtrację, która musiała spełnić dodatkowe kryterium - nie mogła być zbyt wymagająca obliczeniowo, tak żeby nie spowalniać procesu predykcji na danych napływających w czasie rzeczywistym. Wybrano metodę z PCA z której usunięto metodę ICA Infomax z progiem odrzutu przy komponentach z prawdopodobieństwem artefaktu na poziomie 70%, ponieważ ta metoda wprowadza istotne opóźnienia.

PCA z obniżeniem amplitudy do $100 \mu V$ – najwyższe wyniki zaobserwowano dla filtracji z dodatkowym etapem PCA przed usuwaniem złych epok. Biorąc po uwagę również wnioski wyciągnięte na podstawie pozostałych filtracji - na temat kluczowej roli odrzucania złych epok, zdecydowano się obniżyć próg amplitudy odrzucanych epok do $100 \mu V$. Wyniki tej filtracji uzyskały najlepsze rezultaty przedstawione na rysunku 4.10.

Podsumowanie

Na rysunku 4.43 przedstawiono zestawienie wszystkich opracowanych metod filtracji.

Wyniki dla poszczególnych metod filtracji w zależności od zastosowanego modelu przedstawia tabela 4.10. Skuteczność filtracji analizowano również z uwzględnieniem dodatkowej metryki zbiorczej tj. F1 [100]. Metryka pozwala na jednoczesną analizę wartości metryk *precision* oraz *recall*, a przez to uwzględnia wyniki metod predykcji opisane macierzą pomyłek (ang. confusion matrix). Wyniki dla poszczególnych metod filtracji niezależnie od zastosowanego modelu przedstawia wykres na rysunku 4.44.

Charakterystyka sygnału dla najlepszej metody filtracji


Na podstawie analizy wyników skuteczności metod filtracji można stwierdzić kilka charaktery-

FILTRACJA 1 Filtracja teoretyczna bez usuwania złych epok • Resample 250Hz • Filtr 1-45Hz • Filtr Notch 50Hz • Uśrednianie (avarage reference) • Montaż standardowy • ICA (mięśnie) • ICA Infomax > 70%	FILTRACJA 2 Filtracja 1 z usuwaniem złych epok (111uV) • Resample 250Hz • Filtr 1-45Hz • Filtr Notch 50Hz • Uśrednianie (avarage reference) • Montaż standardowy • ICA (mięśnie) • ICA Infomax > 70% • Usuwanie złych epok 111uV
FILTRACJA 3 Filtracja 2 z progiem ICA Infomax >60% • Resample 250Hz • Filtr 1-45Hz • Filtr Notch 50Hz • Uśrednianie (avarage reference) • Montaż standardowy • ICA (mięśnie) • ICA Infomax > 60% • Usuwanie złych epok 111uV	FILTRACJA 4 Filtracja 2 z PCA • Resample 250Hz • Filtr 1-45Hz • Filtr Notch 50Hz • Uśrednianie (avarage reference) • Montaż standardowy • ICA (mięśnie) • PCA • ICA Infomax > 70% • Usuwanie złych epok 111uV
FILTRACJA 5 Filtracja 2 z PCA przed ICA (mięśnie) • Resample 250Hz • Filtr 1-45Hz • Filtr Notch 50Hz • Uśrednianie (avarage reference) • Montaż standardowy • PCA • ICA (mięśnie) • ICA Infomax > 70% • Usuwanie złych epok 111uV	FILTRACJA 6 Filtracja 5 z usunięciem danych sprzed PCA • Resample 250Hz • Filtr 1-45Hz • Filtr Notch 50Hz • Uśrednianie (avarage reference) • Montaż standardowy • PCA • ICA (mięśnie) - dane sprzed PCA • ICA Infomax > 70% • Usuwanie złych epok 111uV
FILTRACJA 7 Filtracja 4 bez ICA Infomax dedykowana do filtracji na żywo • Resample 250Hz • Filtr 1-45Hz • Filtr Notch 50Hz • Uśrednianie (avarage reference) • Montaż standardowy • PCA • ICA (mięśnie) - dane sprzed PCA • Usuwanie złych epok 111uV	FILTRACJA 8 Filtracja 4 amplitudą odrzucania epok 100uV • Resample 250Hz • Filtr 1-45Hz • Filtr Notch 50Hz • Uśrednianie (avarage reference) • Montaż standardowy • ICA (mięśnie) • PCA • ICA Infomax > 70% • Usuwanie złych epok 100uV

Rys. 4.43. Porównanie metod zawartych dla wszystkich modeli filtracji

Tabela 4.10. Wyniki metryk poszczególnych metod filtracji w zależności od modelu


Filtr.	Accuracy			Recall			Precision			F1 Score		
	knn	lstm	svm	knn	lstm	svm	knn	lstm	svm	knn	lstm	svm
1	70%	68%	67%	66%	66%	71%	73%	66%	68%	67%	64%	67%
2	75%	79%	74%	69%	76%	70%	76%	79%	74%	69%	75%	69%
3	59%	67%	65%	52%	61%	60%	59%	63%	65%	51%	58%	58%
4	71%	77%	69%	74%	82%	73%	76%	80%	74%	73%	79%	72%
5	71%	76%	69%	74%	83%	73%	76%	79%	74%	73%	79%	72%
6	75%	79%	74%	69%	78%	70%	76%	80%	74%	69%	75%	69%
7	71%	76%	69%	74%	82%	73%	76%	80%	74%	73%	79%	72%
8	75%	78%	72%	82%	86%	78%	78%	82%	78%	79%	82%	76%



Rys. 4.44. Wyniki poszczególnych metod filtracji w zależności od modelu


stycznych cech, które mogą okazać się w przyszłości pomocne przy opracowywaniu nowych metod filtracji sygnału dla modeli predykcji do wykrywania stanu relaksacji i skupienia.

- **Wykres PSD** – wykres PSD we wszystkich eksperymentach charakteryzuje się zachowaniem wyraźnych pików w pasmach alfa i theta, które są kluczowe dla analizy stanu skupienia i relaksu.



Rys. 4.45. Przykład z eksperymentu 6, charakterystyki PSD dla najlepszej filtracji

- **Topografia czaszki** – uzyskanie dla filtracji gradienty na topomapach czaszki charakteryzują się wyraźnym podziałem między obszarami czołowymi (aktywność wyższa) a centralnymi (aktywność niższa), co może być wskaźnikiem dobrze przetworzonego sygnału EEG dla stanów skupienia i relaksacji. Zachowana jest również w większości przypadków symetria w obszarze czaszki, co również może świadczyć o poprawnie odwzorowanej aktywności mózgowej.



Rys. 4.46. Rozkład gradientów potencjałów na topomapach dla filtracji 8 dla wszystkich eksperymentów

- **SNR** – średnie wartości SNR we wszystkich pasmach wskazują na ogólną redukcję mocy sygnału, co jest typowym efektem intensywnej filtracji mającej na celu usunięcie artefaktów. Posiadając wiedzę na temat tego, że eksperymenty 3 i 4 budzą wątpliwości pod względem poprawności rejestrowania sygnałów - można dla tych eksperymentów zaobserwować znaczny spadek średniej wartości SNR:

- Eksperyment 2: Średnia zmiana SNR: -14,96 dB
- Eksperyment 3: Średnia zmiana SNR: -35,58 dB
- Eksperyment 4: Średnia zmiana SNR: -30,39 dB
- Eksperyment 5: Średnia zmiana SNR: -17,83 dB
- Eksperyment 6: Średnia zmiana SNR: -21,95 dB

Na tej podstawie można uznać, że zmniejszenie wartości SNR przy zachowaniu stabilności w szerokim zakresie pasm, może być korzystnym efektem, który warto wziąć pod uwagę przy projektowaniu i ocenie przyszłych metod filtracji.

Filtracja zaawansowana - predykcja w czasie rzeczywistym

Korzystając z modelu teoretycznego filtracji, opisanego w poprzedniej sekcji, zaimplementowano ją do działania w czasie rzeczywistym. Wyniki filtracji podstawowej z zaawansowaną porównano w tabeli 4.11.

Tabela 4.11. Zestawienie dokładności modeli klasyfikacyjnych podczas działania na żywo dla filtracji podstawowej oraz zaawansowanej. I - filtracja podstawowa, II - filtracja zaawansowana

Rodzaj filtracji	I	II	I	II	I	II
Model	Nagranie 2	Nagranie 5	Nagranie 6			
KNN (średnia kanałów)	0.85	0.84	0.82	0.73	0.74	0.56
KNN (kanały osobno)	0.82	0.85	0.83	0.73	0.82	0.56
LSTM (średnia kanałów)	0.80	0.65	0.82	0.78	0.84	0.53
LSTM (kanały osobno)	0.62	0.54	0.82	0.41	0.84	0.33
SVM (średnia kanałów)	0.83	0.50	0.86	0.50	0.83	0.81
SVM (kanały osobno)	0.63	0.50	0.53	0.50	0.50	0.53

W ogólności obserwowany jest znaczący spadek dokładności modeli. Może on wynikać z charakterystyki filtracji – w klasyfikacji na żywo okno filtracji wynosi 30 sekund, gdy filtracja zaawansowana była opracowana biorąc pod uwagę analizę pełnego nagrania.

4.3.7. Wnioski

Krzysztof Nowakowski, Mateusz Naklicki

Wyniki przeprowadzonych eksperymentów pozwalają na przedstawienie kilku istotnych wniosków przydatnych w kolejnych etapach pracy:

1. Najlepsze wyniki dla klasyfikacji stanów skupienia podczas analizy offline osiąga model SVM. Dokładność modelu jest o około 4 punkty procentowe większa niż modelu LSTM oraz 7 punktów procentowych większa niż KNN. Dla nagrań nr 2, 4 oraz 5 wyniki uzyskane przez model nie osiągają wartości poniżej 85%.
2. Pogorszenie działania klasyfikatorów dla nagrania 3 oraz 4 najprawdopodobniej spowodowany jest niską jakością danych. Wpływ na jakość danych może mieć niezauważony błąd podczas montażu elektrod na pacjencie, pomimo osiągnięcia niskich wartości impedancji na wszystkich kanałach, lub mniejszą rzetelnością wykonywanego zadania ze strony uczestnika.
3. Umieszczenie elektrod na czaszce, gdzie zauważa się mniejszą różnorodność aktywności mózgowej podczas stanów relaksu oraz skupienia, negatywnie wpływa na klasyfikatory. Wyniki uzyskane na zebranych danych z innych obszarów mózgu jest porównywalna do skuteczności modeli wytrenowanych na danych słabej jakości. Przez dane słabej jakości klasyfikatory nie rozróżniają sygnału wskazującego na dany stan.
4. Uśrednianie danych do pasm częstotliwości wpływa negatywnie na dokładność klasyfikacji, co zostało potwierdzone zarówno w przypadku stanów skupienia i relaksacji, jak i klasyfikacji stanów oczu otwartych oraz zamkniętych (szczegóły w rozdziale 4.2.6). Taki efekt może wynikać z utraty istotnych informacji w procesie uśredniania, szczególnie różnic związaną z dynamiką sygnałów EEG. Charakterystyka oraz zachowanie modeli w tych eksperymentach pozostają spójne z wcześniejszymi obserwacjami.
5. Zastosowanie zaawansowanych metod filtracji polepsza jakość sygnału, co skutkuje wzrostem skuteczności modeli. Dzięki zastosowaniu odpowiedniej filtracji sygnał nie posiada szumów oraz artefaktów, które zaburzają poprawną analizę sygnału przez klasyfikatory.
6. Usuwanie sygnału wysoko amplitudowych przynosi pozytywny efekt na skuteczność klasyfikatorów. Przy błędnie dobranej wartości granicznej może nastąpić usunięcie danych z jednego stanu, co może doprowadzić do niezbilansowanych danych i skutkować błędnymi predykcjami modeli na żywo.
7. Trenowanie modeli na danych słabej jakości, nie przynosi oczekiwanych rezultatów podczas predykcji, pomimo wykorzystania do testowania nagrań z identycznego podłączenia.

Wykorzystanie danych słabej jakości do trenowania modeli, utrudni nauczanie się cech w sygnale, co skutkuje problemami z klasyfikacją na nowym zbiorze danych.

8. Ujednolicenie okna filtracji zbioru treningowego modeli predykcyjnych, z oknem filtracji stosowanym w aplikacji na żywo jest kluczowe do osiągnięcia zadowalających wyników. Pomimo nieznacznych spadków skuteczności modeli predykcyjnych z zastosowaną filtracją 30-sekundową. W klasyfikacji na żywo modele te osiągają zadowalające rezultaty, podczas gdy modele uczone na danych z zastosowaną filtracją 16-minutową nie rozróżniały stanów.
9. Wykorzystanie uśredniania kanałów osiąga lepsze wyniki podczas predykcji na żywo. Zastosowanie takiego podejścia jest odporne na zakłócenia, dzięki czemu klasyfikacja jest dokładniejsza.
10. Uśrednienie wyników klasyfikacji do pięciu ostatnich predykcji pozwoliło na stabilne określenie aktualnego stanu. Podejście to zwiększyło uzyskiwane wyniki, dzięki redukcji wpływu pojedynczych predykcji, spowodowanych zakłóceniami sygnału.
11. Wykorzystanie mechanizmu progu przełamania, w celu zwiększenia stabilności raportowanego stanu nie przyniósł oczekiwanych korzyści. Modele osiągały najwyższą dokładność przy niskich wartościach progu, które eliminowały wpływ tego mechanizmu.
12. Skuteczność mechanizmu progu przełamania jest silnie uzależniona od charakterystyki badania. Jego zastosowanie w przyszłych eksperymentach wymaga odpowiedniego dostosowania parametrów.
13. Zastosowanie zaawansowanej filtracji podczas klasyfikacji na żywo prowadzi do obniżenia skuteczności modeli. Filtracja zaawansowana w oknie 30-sekundowym nie zawiera wystarczającej próbki danych, aby filtry zachowały się tak jak przewidywano podczas analiz pełnych nagrań.

4.3.8. Dyskusja

Krystian Nowakowski, Mateusz Naklicki

Podczas tego eksperymentu udało uzyskać się bardzo zadowalające wyniki wraz z wieloma istotnymi informacjami na temat skuteczności metod analizy danych. Zostały również ujawnione obszary wymagające dalszych badań.

Jednym z obszarów jest zbadanie wpływu lokalizacji elektrod na sygnał. Przeprowadzono podstawową analizę charakterystyk sygnału dla dwóch lokalizacji, uwidocznionych w tabeli 4.33. Wskazuje ona na znaczące różnice w widmach mocy w zależności od położenia. Przyszłe eksperymenty powinny uwzględniać alternatywne konfiguracje elektrod bądź zwiększenie ich liczby.

Kolejnym obszarem są eksperymenty z większą pulą uczestników. Wyniki obecnych badań mogą być specyficzne dla jednego uczestnika, co ogranicza możliwość ich generalizacji. Zmienność indywidualna, wynikająca z m.in. różnic w budowie anatomicznej mózgu, może wpływać na sygnał oraz skuteczność klasyfikacji. Przeprowadzenie eksperymentów na większej liczbie uczestników pozwoliłoby na ocenę stabilności uzyskanych wyników i nakierowanie na metody analizy sygnału, które byłyby bardziej zgeneralizowane.

Następną kwestią wartą dalszego badania jest dobór zadań relaksacyjnych i koncentracyjnych. Przyszłe badania mogłyby uwzględniać inne techniki takie jak medytacja prowadzona, wizualizacja czy rozwiązywanie złożonych problemów logicznych. Warte sprawdzenia jest również jak prezentuje się naturalnie zachodzące skupienie (np. podczas codziennych obowiązków) względem wywołanego w sposób eksperymentalny.

Do zbadania również pozostaje zastosowanie zaawansowanej filtracji podczas klasyfikacji na żywo, która poskutkowała w pogorszeniu wyników klasyfikacji. Jednym z głównych powodów może być ograniczenie wynikające z długości okna czasowego wykorzystywanego w czasie rzeczywistym. W przypadku okien 30-sekundowych, stosowanych w eksperymentach, ilość dostępnych próbek okazuje się niewystarczająca, aby zaawansowane filtry działały zgodnie z założeniami wypracowanymi na podstawie pełnych nagrań. Temat ten wymaga dalszej analizy w celu określenia minimalnego oraz optymalnego okna koniecznego do polepszenia jakości sygnału wykorzystując filtrację z wykorzystaniem zaawansowanych metod.

Temat powtarzalności wyników w różnych sesjach badawczych wydaje się być szczególnie ważny. Badania nad klasyfikacją stanów relaksu i skupienia wykazały istotne zależności pomiędzy jakością sygnału a skutecznością modeli klasyfikacyjnych, jednak problem zmienności wyników pozostaje otwarty. W szczególności interesująca wydaje się być kwestia nagrań 3 i 4, które to odbiegały od normy.

Każda sesja badawcza wymaga ponownego zakładania elektrod, co może prowadzić do niewielkich zmian w ich umiejscowieniu oraz różnic w impedancji połączeń. Nawet drobne różnice w położeniu elektrod mogą wpłynąć na rejestrowane widma mocy sygnału EEG, co utrudnia porównanie wyników pomiędzy sesjami. Rozwiązaniem problemu mogłoby być zastosowanie bardziej precyzyjnych systemów mocowania elektrod, takich jak czepki EEG z wbudowanymi markerami pozycji, co pozwoliłoby na odtworzenie dokładnej konfiguracji z poprzednich sesji. Interesująca w tym kontekście może być też zmienność fizjologiczna uczestnika, taka jak poziom zmęczenia, nawodnienia czy nastrój. Rejestrowanie dodatkowych parametrów, takich jak puls czy rytm serca, mogłoby dostarczyć informacji o czynnikach wpływających na zmiany w sygnale EEG pomiędzy sesjami. Również gromadzenie szczegółowych danych dla każdej sesji (np. godzina, poziom zmęczenia uczestnika, samopoczucie) mogłoby pomóc w identyfikacji i zrozumieniu źródeł zmienności pomiędzy sesjami.

Szczególnie interesujące wydają się być natomiast możliwości zastosowań opracowanych metod. Jednym z nich jest biofeedback, który może mieć użycie w terapiach osób z zaburzeniami koncentracji czy z ADHD. Pozwala on obserwować pacjentowi swoją aktywność mózgową w czasie rzeczywistym i świadomie ją regulować. Pacjent otrzymuje informacje zwrotne, np. wizualne lub dźwiękowe, które pomagają mu zwiększyć skupienie lub osiągnąć stan relaksu. Prowadzi to do nauki modyfikowania swojej aktywności mózgowej w sposób sprzyjający zwiększeniu koncentracji, redukcji stresu lub osiągnięciu głębokiego stanu relaksu.

Poza biofeedbackiem, analiza sygnałów otwiera możliwości zastosowań w interfejsach mózg-komputer (BCI), które pozwalają na kontrolowanie urządzeń za pomocą aktywności mózgowej. W kontekście tej pracy EEG może być używane do monitorowania stanu uwagi w czasie rzeczywistym w celu zapobiegania wypadkom, na przykład wśród kierowców lub operatorów maszyn, gdzie zmęczenie i utrata koncentracji mogą prowadzić do niebezpiecznych sytuacji.

5. PODSUMOWANIE

Mateusz Naklicki

Niniejsza praca inżynierska była poświęcona analizie i klasyfikacji sygnałów EEG w celu detekcji stanów uwagi. W ramach pracy udało się połączyć wiedzę z zakresu neurobiologii, inżynierii biomedycznej i informatyki, tworząc interdyscyplinarne podejście do badania wpływu stanów uwagi na sygnał EEG.

Część teoretyczna pracy dostarczyła kompleksowego przeglądu zagadnień związanych z elektroencefalografią, w tym biologicznych podstaw sygnałów EEG, ich charakterystyki oraz potencjalnych problemów, takich jak artefakty czy wpływ zakłóceń na sygnał. Szczególną uwagę poświęcono technikom przetwarzania sygnałów, takim jak analiza czasowo-częstotliwościowa oraz metody filtracji, które odegrały kluczową rolę w przygotowaniu danych do dalszej analizy.

W części badawczej zrealizowano eksperymenty, które umożliwiły zastosowanie algorytmów klasyfikujących, takich jak KNN, SVM oraz LSTM, w rozróżnianiu stanów uwagi. Wyniki eksperymentów potwierdziły skuteczność zastosowanego podejścia, osiągając dokładność klasyfikacji w czasie rzeczywistym na poziomie 74 do 86%, w zależności od stosowanego modelu 4.9. Zastosowane metody pozwoliły na identyfikację charakterystycznych cech sygnałów EEG, takich jak wzorce fal mózgowych, które były silnie skorelowane z badanymi stanami.

Podczas realizacji pracy napotkano również wyzwania, takie jak wysoka zmienność sygnałów EEG, wysoki stosunek szumu do sygnału oraz potrzeba precyzyjnego usuwania artefaktów. Rozwiązanie tych problemów wymagało zastosowania zaawansowanych technik przetwarzania danych oraz odpowiedniego doboru parametrów dla poszczególnych eksperymentów. Szczególną trudność stanowiło zapewnienie powtarzalności wyników w różnych sesjach badawczych, co podkreśla znaczenie dalszych badań nad standaryzacją stosowanych procedur.

Podsumowując, przeprowadzone badania potwierdzają, że możliwe jest osiągnięcie wysokiej dokładności klasyfikacji przy użyciu konsumenckiego sprzętu EEG, pod warunkiem zastosowania odpowiednich metod przetwarzania i analizy danych. Ostateczne wyniki eksperymentów potwierdzają, że sygnały EEG mogą być skutecznie wykorzystywane do detekcji stanów uwagi, co otwiera możliwości ich zastosowania w takich dziedzinach, jak interfejsy mózg-komputer, diagnostyka medyczna czy narzędzia wspomagające procesy uczenia się. Przyszłe badania powinny skupić się na rozszerzeniu analizy na większą grupę badawczą oraz dalszym zwiększaniu dokładności klasyfikacji.

WYKAZ LITERATURY

- [1] B. E. Swartz, "The advantages of digital over analog recording techniques," *Electroencephalography and Clinical Neurophysiology*, vol. 106, no. 2, pp. 113–117, 1998.
- [2] Augustyniak, *Elektroniczna aparatura medyczna*. Wydawnictwo AGH, Kraków, 2015.
- [3] S. Ibrahim, R. Djemal, and A. Alsuwailam, "Electroencephalography (eeg) signal processing for epilepsy and autism spectrum disorder diagnosis," *Biocybernetics and Biomedical Engineering*, vol. 38, no. 1, pp. 16–26, 2018.
- [4] L. G. W., "Attention in psychology, neuroscience, and machine learning," *Frontiers in Computational Neuroscience*, vol. 14, 2020.
- [5] Z. Q. C. H. e. a. Zhang, H., "The applied principles of eeg analysis methods in neuroscience and clinical neurology.," *Military Med Res*, 2023.
- [6] A. Chaddad, Y. Wu, R. Kateb, and A. Bouridane, "Electroencephalography signal processing: A comprehensive review and analysis of methods and techniques," *Sensors*, vol. 23, 07 2023.
- [7] P. L. Nunez and R. Srinivasan, *Electric Fields of the Brain: The neurophysics of EEG*. Oxford University Press, 01 2006.
- [8] D. V. F. Lopez-Gordo, M.A.; Sanchez-Morillo, "Dry eeg electrodes," *Sensors*, no. 14, 2014.
- [9] P. B. J. Satheesh Kumar, "Analysis of electroencephalography (eeg) signals and its categorization—a study," *Procedia Engineering*, vol. 38, pp. 2525–2536, 2012.
- [10] S. D. Beniczky, S., "Electroencephalography: basic biophysical and technological aspects important for clinical applications.," *Epileptic Disorders*, vol. 22, pp. 697–715, 2020.
- [11] H. J. Stone, J.L., "Early history of electroencephalography and establishment of the american clinical neurophysiology society.," *Journal of clinical neurophysiology : official publication of the American Electroencephalographic Society*, vol. 30, pp. 28–44, 2013.
- [12] C. P. Panteliadis, "Historical overview of electroencephalography: from antiquity to the beginning of the 21st century.," *Journal of Brain and Neurological Disorders*, 2021.
- [13] A. S. M. . A. S. N. Abo-Zahhad, M., "A new eeg acquisition protocol for biometric identification using eye blinking signals.," *International Journal of Intelligent Systems and Applications*, vol. 7, no. 6, pp. 48–54, 2015.
- [14] M. J. W. Buskila Yossi, Bellot-Saez Alba, "Generating brain waves, the power of astrocytes," *Frontiers in Neuroscience*, vol. 13, 2019.
- [15] A. A. C. Nayak, C. S., *EEG Normal Waveforms*. StatPearls Publishing, 07 2023.
- [16] T. Z. Jiang X, Bian G-B, "Removal of artifacts from eeg signals: A review.," *Sensors*, vol. 19, no. 5, p. 987, 2019.
- [17] S. J.-P. A. P. R. R. P. K. A. Khan, S.S., "A review of eeg artifact removal methods for brain-computer interface applications.," *Ingénierie des Systèmes d'Information*, vol. 29, no. 1, pp. 247–252, 2024.
- [18] D. V. MD. <https://www.learningeeg.com/artifacts#review>, (data dostępu 12.01.2022).
- [19] P. L.-B. M. e. a. Giroladini, W., "A new method to detect event-related potentials based on pearson's correlation.," *Bioinform Sys Biology*, 2016.
- [20] G. T. Steven Laureys, Melanie Boly, *The Neurology of Consciousness*. Academic Press, 2009.
- [21] Z. Z. Y. H. Z. Y. W. J. Liu Q, Yang L, "Performance, and prospect of advanced electrodes for electroencephalogram.," *Biosensors*, vol. 13, no. 1, 2023.

- [22] E. Kappenman and S. Luck, "The effects of electrode impedance on data quality and statistical significance in erp recordings," *Psychophysiology*, vol. 47, p. 888–904, 2010.
- [23] G. S. R. D. M. T. Thomas C Ferree, Phan Luu, "Scalp electrode impedance, infection risk, and eeg data quality," *Clinical Neurophysiology*, vol. 112, pp. 536–544, 2001.
- [24] D. S. D. S.-J. K. E. D. J. J. H. A. J. H. F. W. D. M. M. S. Saurabh R. Sinha, Lucy Sullivan, "American clinical neurophysiology society guideline 1: Minimum technical requirements for performing clinical electroencephalography," *Journal of Clinical Neurophysiology*, vol. 33, no. 4, p. 303–307, 2016.
- [25] M. R. H. J. F. C. Vasconcelos Beatriz, Fiedler Patrique, "The arch electrode: A novel dry electrode concept for improved wearing comfort," *Frontiers in Neuroscience*, vol. 15, 2021.
- [26] D. V. MD. <https://www.learningeeg.com/montages-and-technical-components>, (data dostępu 12.01.2022).
- [27] R. P. B. Lawrence J. Hirsch. 2010.
- [28] S. S. S. Hitten P. Zaveri, Robert B. Duckrow, "On the use of bipolar montages for time-series analysis of intracranial electroencephalograms," *Clinical Neurophysiology*, vol. 117, pp. 2102–2108, 2006.
- [29] S. P. S.-L. C. Herwig, U., "Using the international 10-20 eeg system for positioning of transcranial magnetic stimulation," *Brain Topography*, no. 2, pp. 95–99, 2003.
- [30] I. D. Valer Jurcak, Daisuke Tsuzuki, "10/20, 10/10, and 10/5 systems revisited: Their validity as relative head-surface-based positioning systems," *NeuroImage*, vol. 34, pp. 1600–1611, 2007.
- [31] J. T. S. T. J. Makeig, S., "Awareness during drowsiness: Dynamics and electrophysiological correlates.," *Canadian Journal of Experimental Psychology*, vol. 54, pp. 266–73, 2000.
- [32] W. E. Kanwisher, N., "Visual attention: Insights from brain imaging.," *Nature Reviews Neuroscience*, vol. 1, pp. 91–100, 2000.
- [33] A. Bronkhorst, "The cocktail-party problem revisited: early processing and selection of multi-talker speech.," *Atten Percept Psychophys*, vol. 77, pp. 1465–1487, 2015.
- [34] T. J. B. Miller, Earl K., *The Oxford Handbook of Attention*. Oxford Academic, 2014.
- [35] M. I. Posner and S. E. Petersen., "The attention system of the human brain.," *Annual review of neuroscience*, vol. 13, pp. 25–42, 1990.
- [36] J. D. C. Aston-Jones Gary, "An integrative theory of locus coeruleus-norepinephrine function: adaptive gain and optimal performance.," *Annual review of neuroscience*, vol. 28, pp. 403–450, 2005.
- [37] S. G. Corbetta, M., "Control of goal-directed and stimulus-driven attention in the brain.," *Nature Review of Neuroscience*, vol. 3, pp. 201–215, 2002.
- [38] G. B. Sarter M, Bruno JP, "Attentional functions of cortical cholinergic inputs: what does it mean for learning and memory?," *Neurobiology of learning and memory*, vol. 80, no. 3, pp. 245–256, 2003.
- [39] A. C. S. Foxe, John J, "The role of alpha-band brain oscillations as a sensory suppression mechanism during selective attention.," *Frontiers in psychology*, vol. 2, p. 154, 2011.
- [40] R. A. Barkley, *Attention-deficit hyperactivity disorder: A handbook for diagnosis and treatment (4th ed.* The Guilford Press., 2015.
- [41] F. D. G. I. Hamilton, J. P., "The neural foundations of major depression: Classical approaches and new frontiers," *Neurobiology of Depression.*, pp. 57–73, 2011.
- [42] L. H. S. Rabinowitz, A. R., "Cognitive sequelae of traumatic brain injury.," *The Psychiatric clinics of North America*, vol. 37, pp. 1–11, 2014.
- [43] G. Müller-Putz, R. Scherer, C. Brunner, R. Leeb, and G. Pfurtscheller, "Better than random? a closer look on bci results," *International Journal of Bioelektromagnetism*, vol. 10, pp. 52–55, 01 2008.

- [44] A. B. et al., "A mind-brain-body dataset of mri, eeg, cognition, emotion, and peripheral physiology in young and old adults," *Scientific Data*, vol. 6, 2019.
- [45] A. Oppenheim and R. Schaffer, *Digital Signal Processing*. Prentice Hall international editions, Prentice-Hall, 1975.
- [46] A. Delorme and S. Makeig, "Eeglab: an open source toolbox for analysis of single-trial eeg dynamics including independent component analysis," *Journal of Neuroscience Methods*, vol. 134, no. 1, pp. 9–21, 2004.
- [47] I. Analog Devices, *Basic Linear Design: Chapter 8 - Filters*, 2006.
- [48] Wikipedia contributors, "Discrete fourier transform." https://en.wikipedia.org/wiki/Discrete_Fourier_transform, 2024.
- [49] Wikipedia contributors, "Fourier transform." https://en.wikipedia.org/wiki/Fourier_transform, 2024.
- [50] S. Mallat, *A Wavelet Tour of Signal Processing*. San Diego, CA: Academic Press, 2nd ed., 1999.
- [51] I. T. Jolliffe, *Principal Component Analysis*. New York: Springer, 2nd ed., 2002.
- [52] A. Hyvärinen and E. Oja, "Independent component analysis: Algorithms and applications," *Neural Networks*, vol. 13, no. 4-5, pp. 411–430, 2000.
- [53] E. Ratajczak and W. Duch, "Microstate neurodynamics in hrv biofeedback," *Sensors (Basel, Switzerland)*, vol. 21, 2022.
- [54] "Report of the committee on methods of clinical examination in electroencephalography: 1957," *Electroencephalography and Clinical Neurophysiology*, vol. 10, no. 2, pp. 370–375, 1958.
- [55] F. Lotte and M. Congedo, *EEG Feature Extraction*, ch. 7, pp. 127–143. John Wiley & Sons, Ltd, 2016.
- [56] F. Lotte, M. Congedo, A. Lécuyer, L. Fabrice, and B. Arnaldi, "A review of classification algorithms for eeg-based brain-computer interfaces," *Journal of Neural Engineering*, vol. 4, 07 2007.
- [57] O. Grisel, A. Mueller, A. Gramfort, G. Louppe, T. J. Fan, P. Prettenhofer, M. Blondel, V. Niculae, J. Nothman, A. Joly, *et al.*, "scikit-learn/scikit-learn: Scikit-learn 1.4. 1. post1," *Zenodo*, 2024.
- [58] J. White and S. D. Power, "k-fold cross-validation can significantly over-estimate true classification accuracy in common eeg-based passive bci experimental designs: an empirical investigation," *Sensors*, vol. 23, no. 13, p. 6077, 2023.
- [59] F. Hashish, M. S. Sunar, H. Kolivand, F. Mohamed, and D. Mohamad, "Feature extracted classifiers based on eeg signals: A survey," *Life Science Journal*, vol. 11, pp. 364–375, 01 2014.
- [60] T. Cover and P. Hart, "Nearest neighbor pattern classification," *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967.
- [61] X. Huang, G. Jin, and W. Ruan, *K-Nearest Neighbor*, pp. 71–81. Singapore: Springer Nature Singapore, 2023.
- [62] N. Kouroukidis and G. Evangelidis, "The effects of dimensionality curse in high dimensional knn search," in *2011 15th Panhellenic Conference on Informatics*, pp. 41–45, 2011.
- [63] K. S. Bayram, M. A. Kızrak, and B. Bolat, "Classification of eeg signals by using support vector machines," in *2013 IEEE INISTA*, pp. 1–3, IEEE, 2013.
- [64] R. Palaniappan, K. Sundaraj, and S. Sundaraj, "A comparative study of the svm and k-nn machine learning algorithms for the diagnosis of respiratory pathologies using pulmonary acoustic signals," *BMC bioinformatics*, vol. 15, pp. 1–8, 2014.
- [65] M. J. Antony, B. P. Sankaralingam, R. K. Mahendran, A. A. Gardezi, M. Shafiq, J.-G. Choi, and H. Hamam, "Classification of eeg using adaptive svm classifier with csp and online recursive independent component analysis," *Sensors*, vol. 22, no. 19, p. 7596, 2022.

- [66] M. Bansal, A. Goyal, and A. Choudhary, "A comparative analysis of k-nearest neighbor, genetic, support vector machine, decision tree, and long short term memory algorithms in machine learning," *Decision Analytics Journal*, vol. 3, p. 100071, 2022.
- [67] "Demystifying support vector machines: Kernel machines." <https://mldemystified.com/posts/basics-of-ml/support-vector-machines/svm-kernel-machines/>, 2024. [data dostępu 23-11-2024].
- [68] M. Shi, C. Wang, X.-Z. Li, M.-Q. Li, L. Wang, and N.-G. Xie, "Eeg signal classification based on svm with improved squirrel search algorithm," *Biomedical Engineering/Biomedizinische Technik*, vol. 66, no. 2, pp. 137–152, 2021.
- [69] S. Hochreiter, "Untersuchungen zu dynamischen neuronalen netzen," *Diploma, Technische Universität München*, vol. 91, no. 1, p. 31, 1991.
- [70] S. Hochreiter and J. Schmidhuber, "Long short-term memory neural computation 9 (8): 1735–1780," *Search in*, 1997.
- [71] C. Olah, "Understanding lstm networks, posted on august 27 (2015)," URL: <http://colah.github.io/posts/2015-08-Understanding-LSTMs>, 2015.
- [72] A. Chugh, "Deep learning—introduction to long short term memory," *Geeks for Geeks*, 2019.
- [73] P. Nagabushanam, S. Thomas George, and S. Radha, "Eeg signal classification using lstm and improved neural network algorithms," *Soft Computing*, vol. 24, no. 13, pp. 9981–10003, 2020.
- [74] "Cyton Biosensing Board (8-channels) — shop.openbci.com." <https://shop.openbci.com/products/cyton-biosensing-board-8-channel>. [data dostępu 02-11-2024].
- [75] "Gold Cup Electrodes — shop.openbci.com." <https://shop.openbci.com/products/openbci-gold-cup-electrodes>. [data dostępu 02-11-2024].
- [76] "Ten20 Conductive Paste 8oz Jar — shop.openbci.com." <https://shop.openbci.com/products/ten20-conductive-paste-8oz-jar>. [data dostępu 02-11-2024].
- [77] A. B. Usakli, "Improvement of eeg signal acquisition: An electrical aspect for state of the art of front end," *Computational Intelligence and Neuroscience*, vol. 2010, no. 1, p. 630649, 2010.
- [78] "The OpenBCI GUI | OpenBCI Documentation — docs.openbci.com." <https://docs.openbci.com/Software/OpenBCISoftware/GUIDocs/>. [data dostępu 02-11-2024].
- [79] A. Gramfort, M. Luessi, E. Larson, D. A. Engemann, D. Strohmeier, C. Brodbeck, R. Goj, M. Jas, T. Brooks, L. Parkkonen, and M. S. Hämäläinen, "MEG and EEG data analysis with MNE-Python," *Frontiers in Neuroscience*, vol. 7, no. 267, pp. 1–13, 2013.
- [80] L. et al., "Mne-python," June 2024.
- [81] A. Parfenov, "BrainFlow — brainflow.org." <https://brainflow.org/>. [data dostępu 02-11-2024].
- [82] "Release BrainFlow 5.13.1 · brainflow-dev/brainflow — github.com." <https://github.com/brainflow-dev/brainflow/releases/tag/5.13.1>. [data dostępu 02-11-2024].
- [83] A. Gramfort, M. Luessi, E. Larson, D. A. Engemann, D. Strohmeier, C. Brodbeck, L. Parkkonen, and M. S. Hämäläinen, *MNE Python: Software for exploring, visualizing, and analyzing human neurophysiological data*, 2023.
- [84] F. Chollet *et al.*, "Keras documentation," *keras.io*, vol. 33, 2015.
- [85] A. Bablani, D. R. Edla, and S. Dodia, "Classification of eeg data using k-nearest neighbor approach for concealed information test," *Procedia computer science*, vol. 143, pp. 242–249, 2018.
- [86] N. E. M. Isa, A. Amir, M. Z. Ilyas, and M. S. Razalli, "The performance analysis of k-nearest neighbors (k-nn) algorithm for motor imagery classification based on eeg signal," in *MATEC web of conferences*, vol. 140, p. 01024, EDP Sciences, 2017.

- [87] "Support vector machine (svm) algorithm." <https://www.geeksforgeeks.org/support-vector-machine-algorithm/>. [data dostępu 24-11-2024].
- [88] "Gamma parameter in svm." <https://www.geeksforgeeks.org/gamma-parameter-in-svm/>. [data dostępu 24-11-2024].
- [89] I. S. Al-Mejibli, J. K. Alwan, and D. H. Abd, "The effect of gamma value on support vector machine performance with different kernels," *Int. J. Electr. Comput. Eng*, vol. 10, no. 5, pp. 5497–5506, 2020.
- [90] S. Kumar, A. Sharma, and T. Tsunoda, "Brain wave classification using long short-term memory network based optical predictor. sci rep 9: 9153," 2019.
- [91] T. Najafi, R. Jaafar, R. Remli, and W. A. Wan Zaidi, "A classification model of eeg signals based on rnn-lstm for diagnosing focal and generalized epilepsy," *Sensors*, vol. 22, no. 19, p. 7269, 2022.
- [92] S. Mohsen and A. G. Alharbi, "Eeg-based human emotion prediction using an lstm model," in *2021 IEEE international midwest symposium on circuits and systems (MWSCAS)*, pp. 458–461, IEEE, 2021.
- [93] A. Ting, J. Law, A. Lele, Y. Fang, and A. Raychowdhury, "A comparison of cnns and lstms for eeg signal classification," in *2022 Opportunity Research Scholars Symposium (ORSS)*, pp. 23–26, IEEE, 2022.
- [94] S. H. Khan, M. Hayat, and F. Porikli, "Regularization of deep neural networks with spectral dropout," *Neural Networks*, vol. 110, pp. 82–90, 2019.
- [95] L. Van Der Maaten, E. O. Postma, H. J. Van Den Herik, *et al.*, "Dimensionality reduction: A comparative review," *Journal of machine learning research*, vol. 10, no. 66-71, p. 13, 2009.
- [96] S. D. University of California, "Labeling of independent components." <https://labeling.ucsd.edu/tutorial/labels>. data dostępu: 2024-11-27.
- [97] P. Vijn, B. van Dijk, and H. Spekreijse, "Topography of occipital eeg-reduction upon visual stimulation," *Brain topography*, vol. 5, no. 2, p. 177—181, 1992.
- [98] A. F. Rossi, L. Pessoa, R. Desimone, and L. G. Ungerleider, "The prefrontal cortex and the executive control of attention," *Experimental Brain Research*, vol. 192, p. 489–497, Nov. 2008.
- [99] S. J. Luck, *An Introduction to the Event-Related Potential Technique*. Cambridge, MA: MIT Press, second ed., 2014.
- [100] P. Christen, D. J. Hand, and N. Kirielle, "A review of the f-measure: its history, properties, criticism, and alternatives," *ACM Computing Surveys*, vol. 56, no. 3, pp. 1–24, 2023.
- [101] N. C. of Biotechnology Information. <http://www.ncbi.nlm.nih.gov/>, (data dostępu 20.12.2012).
- [102] D. Brunet, M. M. Murray, and C. M. Michel, "Spatiotemporal analysis of multichannel eeg: Cartool," *Computational Intelligence and Neuroscience*, vol. 2011, no. 1, p. 813870, 2011.
- [103] C. M. Michel, M. M. Murray, G. Lantz, S. Gonzalez, L. Spinelli, and R. Grave de Peralta, "Eeg source imaging," *Clinical Neurophysiology*, vol. 115, no. 10, pp. 2195–2222, 2004.
- [104] J. Mattiev, J. Sajovic, G. Drevenšek, and P. Rogelj, "Assessment of model accuracy in eyes open and closed eeg data: Effect of data pre-processing and validation methods," *Bioengineering*, vol. 10, no. 1, 2023.
- [105] M. T. Knierim, M. G. Bleichner, and P. Realì, "A systematic comparison of high-end and low-cost eeg amplifiers for concealed, around-the-ear eeg recordings," *Sensors*, vol. 23, no. 9, 2023.

WYKAZ RYSUNKÓW

2.1	Artefakt pochodzący z sieci elektrycznej	12
2.2	System 10-20	14
3.1	Urządzenie Cyton firmy OpenBCI	29
3.2	Wygląd aplikacji OpenBCI GUI z wyświetlonym panelem do mierzenia impedancji	30
3.3	Moduł aplikacji wyświetlający sygnał z urządzenia w czasie rzeczywistym	33
3.4	Moduł aplikacji wyświetlający sygnał z urządzenia w czasie rzeczywistym	34
3.5	Wykres zależności dokładności klasyfikacji modelu KNN od liczby sąsiadów	38
3.6	Porównanie typów jądra klasyfikatora SVM	39
3.7	Porównanie parametru regularyzacji klasyfikatora SVM	40
3.8	Architektura modelu klasyfikatora bazującego na warstwach sieci LSTM.	42
4.1	Sygnał LEMON przed filtracją	44
4.2	Sygnał LEMON po podstawowej filtracji	45
4.3	Wykrywanie zdarzeń związanych z artefaktami ocznymi przy pomocy elektrody EOG	46
4.4	Komponent zawierający artefakty oczne	46
4.5	Sygnał po odrzuceniu komponentu związanego z artefaktami ocznymi	47
4.6	Wykres wartości score dla komponentów zawierających artefakty mięśniowe	48
4.7	Pokazane topografie dla wytypowanych komponentów	48
4.8	Sygnał po usunięciu komponentów pochodzenia mięśniowego	48
4.9	Topografie komponentów	49
4.10	Automatycznie wytypowane artefakty z prawdopodobieństwem wyższym niż 70%	52
4.11	Oczyszczony sygnał po usunięciu komponentów ICA(Infomax)	52
4.12	Wykresy przebiegów sygnałów w czasie dla filtracji Lemon i filtracji teoretycznej dla wybranych kanałów: F3, F4 i C3	54
4.13	Wykres PSD dla danych LEMON przed i po filtracji	54
4.14	Topografie czaszki dla filtracji teoretycznej i filtracji LEMON	55
4.15	Zestawienie PSD dla sygnałów EEG porównujące stany EC oraz EO	55
4.16	PSD dla kanału PO8. Zaznaczono zakresy częstotliwości odpowiadające falom: Delta, Theta, Alpha, Beta i Gamma.	56
4.17	Zestawienie PSD dla oryginalnie użytych metod filtracyjnych przez badaczy LEMON oraz metod opracowanych przez zespół	57
4.18	Porównanie skuteczności klasyfikatorów pod względem liczby kanałów	58
4.19	Fragment nieprzetworzonego sygnału EEG z nagrania 1	61
4.20	Fragment przetworzonego sygnału EEG z nagrania 1; od 283 sekundy	62
4.21	Uśrednione PSD z wszystkich kanałów przed (lewa strona) i po usunięciu artefaktów (prawa strona), nagranie nr 1	62
4.22	Uśrednione PSD z wszystkich kanałów, dane LEMON (lewa strona) i dane z nagrania nr 1 przy usuniętych artefaktach (prawa strona)	63
4.23	Wyniki uzyskane na danych zebranych przez zespół dla poszczególnych nagrań z filtracją całego bloku 16-minutowego.	64
4.24	Wyniki uzyskane na danych zebranych przez zespół dla poszczególnych nagrań z filtracją próbki jednodominutowej.	65
4.25	Wpływ długości epoki na dokładność klasyfikatorów dla poszczególnych nagrań	65
4.26	Dokładność klasyfikatorów ze względu na agregację danych	66
4.27	Porównanie PSD sygnałów z eksperymentu 2 do sygnałów bazowych	69
4.28	Porównanie PSD sygnałów z eksperymentu 3 do sygnałów bazowych	70
4.29	Porównanie PSD sygnałów z eksperymentu 4 do sygnałów bazowych	70
4.30	Porównanie PSD sygnałów z eksperymentu 5 do sygnałów bazowych	71
4.31	Porównanie PSD sygnałów z eksperymentu 6 do sygnałów bazowych	71
4.32	Porównanie wyników filtracji dla usuwania epok o amplitudzie $100\mu V$ i $111\mu V$	73

4.33 Zestawienie PSD przy elektrodach na pozycjach PO3, PO4, PO7 i PO8: lewa strona, z elektrodami na pozycjach C3, C4, F3, F4: prawa strona. Zaznaczono odchylenie standardowe.	74
4.34 Średnia PSD z wszystkich nagrań przy elektrodach mocowanych na obszarze płatów czołowych	74
4.35 Skuteczność klasyfikatorów podczas poszczególnych nagrań stanów uwagi relaksu oraz skupienia	76
4.36 Dokładność klasyfikatorów ze względu na agregację danych	76
4.37 Uśredniona skuteczność filtracji mierzona w dokładności klasyfikatorów dla wszystkich nagrań	77
4.38 Uśredniona skuteczność klasyfikatorów dla odrzucania sygnałów powyżej danej amplitudy	77
4.39 Dokładność modeli w zależności od liczby ostatnich przewidywań wykorzystanych do finalnego werdyktu. Nagranie 5.	81
4.40 Średnia dokładność modeli w zależności od liczby uśrednianych predykcji wśród nagrań 2, 5 i 6.	82
4.41 Dokładność modeli w zależności od progu przełamania potrzebnego do zmiany raportowanego stanu. Nagranie 5.	83
4.42 Średnia dokładność modeli w zależności od zastosowanego progu przełamania wśród nagrań 2, 5 i 6.	83
4.43 Porównanie metod zawartych dla wszystkich modeli filtracji	86
4.44 Wyniki poszczególnych metod filtracji w zależności od modelu	87
4.45 Przykład z eksperymentu 6, charakterystyki PSD dla najlepszej filtracji	87
4.46 Rozkład gradientów potencjałów na topomapach dla filtracji 8 dla wszystkich eksperymentów	88

WYKAZ TABEL

2.1	Klasyfikacja fal mózgowych	10
2.2	Porównanie cech transformaty Fouriera (FT) i transformaty Falkowej (WT).	20
2.3	Porównanie cech PCA i ICA.	22
2.4	Porównanie przetwarzania sygnału EEG	23
4.1	Dokładność modeli klasyfikujących na danych pochodzących od jednego pacjenta - filtracja LEMON	58
4.2	Dokładność modeli klasyfikujących na danych pochodzących od jednego pacjenta z wykorzystaniem filtracji opracowanej przez zespół	58
4.3	Dokładność modeli klasyfikujących na danych pochodzących od jednego pacjenta LEMON dla czterech kanałów	64
4.4	Zestawienie dokładności klasyfikatorów wytrenowanych na nagraniach nr 2, 3 oraz 4 z predykcją na danych pochodzących z innego nagrania.	78
4.5	Zestawienie wpływu agregacji danych na skuteczność predykcji.	78
4.6	Zestawienie wpływu okna filtracji na klasyfikatory.	79
4.7	Dokładność modeli klasyfikujących sygnał na żywo podczas nagrania nr 5.	79
4.8	Dokładność modeli klasyfikacyjnych w nagraniach obszaru kory czołowej	80
4.9	Dokładność modeli klasyfikacyjnych z uśrednianiem 5 ostatnich predykcji	80
4.10	Wyniki metryk poszczególnych metod filtracji w zależności od modelu	87
4.11	Zestawienie dokładności modeli klasyfikacyjnych podczas działania na żywo dla filtracji podstawowej oraz zaawansowanej. I - filtracja podstawowa, II - filtracja zaawansowana	89