

Imię i nazwisko studenta: Filip Krawczak
Nr albumu: 191718
Poziom kształcenia: studia pierwszego stopnia
Forma studiów: stacjonarne
Kierunek studiów: Informatyka
Profil: Architektura systemów komputerowych

Imię i nazwisko studenta: Kacper Karski
Nr albumu: 186044
Poziom kształcenia: studia pierwszego stopnia
Forma studiów: stacjonarne
Kierunek studiów: Informatyka
Profil: Bazy danych

Imię i nazwisko studenta: Damian Jankowski
Nr albumu: 188597
Poziom kształcenia: studia pierwszego stopnia
Forma studiów: stacjonarne
Kierunek studiów: Informatyka
Profil: Architektura systemów komputerowych

Imię i nazwisko studenta: Maciej Szeffler
Nr albumu: 188614
Poziom kształcenia: studia pierwszego stopnia
Forma studiów: stacjonarne
Kierunek studiów: Informatyka
Profil: Architektura systemów komputerowych

PRACA DYPLOMOWA INŻYNIERSKA

Tytuł pracy w języku polskim: Sieci neuronowe do analizy rytmu oddechowego

Tytuł pracy w języku angielskim: Neural networks for the analysis of respiratory rhythm

Opiekun pracy: dr hab. inż. Julian Szymański

STRESZCZENIE

Praca inżynierska pt. "Sieci neuronowe do analizy rytmu oddechowego" miała na celu opracowanie sieci neuronowej do analizy rytmu oddechu z prostych czujników jak akcelerometr czy tensometr. Została przygotowana dedykowana aplikacja mobilna, stanowiąca wsparcie w monitorowaniu i analizie oddechu. Kluczowym aspektem pracy było pozyskiwanie danych z czujników, ich przetwarzanie oraz analiza za pomocą modeli sieci neuronowych. Model sieci neuronowej klasyfikował rytm oddechowy na cztery klasy: wdech, retencję po wdechu, wydech oraz retencję po wydechu. Proces ten obejmował akwizycję danych z sensorów, ręczne etykietowanie próbek oraz iteracyjny proces trenowania modelu. Wyniki klasyfikacji są wizualizowane w aplikacji mobilnej w formie interaktywnego wykresu, na którym poszczególne fazy oddechu wyróżniono różnymi kolorami. W ramach pracy dokonano analizy danych oraz przeglądu literatury, obejmującego ponad 20 publikacji naukowych. Porównano siedem różnych modeli z zakresu sztucznej inteligencji, co umożliwiło optymalizację procesu trenowania oraz dostrojenia modelu. Zdecydowano się na wykorzystanie sieci neuronowej typu Gated Recurrent Unit (GRU), która charakteryzowała się wysoką skutecznością oraz niską złożonością obliczeniową. Dla poprawy jakości klasyfikacji zastosowano metodę Human-in-the-loop, angażując człowieka w roli eksperta na każdym etapie analizy, trenowania i walidacji danych. Opracowany zbiór danych treningowych zawiera ponad 2,5 godziny nagrań, które zostały ręcznie oznaczone przy pomocy dedykowanej aplikacji. Dane zbierano z wykorzystaniem dwóch akcelerometrów (iNode Nav oraz WitMotion WT901BLE) oraz tensometru (HX711). Dzięki zastosowaniu transferu etykiet (transfer labelling), oznaczone dane z jednego zbioru wykorzystywano do wspierania procesu etykietowania w innym, pokrewnym zbiorze. Aplikacja została opracowana na urządzenia mobilne z systemem Android 11 lub nowszym. Działa ona w trybie runtime, tzn. analizuje na bieżąco spływające dane z czujników i klasyfikuje je na podstawie wytrenowanego modelu. Model w tym trybie, osiągnął skuteczność na poziomie 88% dla tensometru, 77% dla akcelerometru iNode Nav oraz 80% dla akcelerometru WitMotion. Dodatkowo zastosowano specjalny tryb offline. Polega on na klasyfikacji już zebranych danych, gdzie dostępny jest pełen kontekst informacji. Uwzględnia on próbki zarówno z przeszłości, jak i przyszłości. W tym trybie osiągnięto wyższą skuteczność: 90% dla tensometru, 85% dla iNode Nav oraz 80,5% dla WitMotion. Aplikacja umożliwia także zapis danych do pliku tekstowego, co pozwala na ich dalszą analizę i przetwarzanie.

Słowa kluczowe: sieci neuronowe, aplikacja mobilna, badanie oddechu

Dziedzina nauki i techniki, zgodnie z wymogami OECD: nauki inżynierskie i techniczne, elektrotechnika, elektronika, inżynieria informatyczna

ABSTRACT

The engineering thesis entitled "Neural Networks for Respiratory Rhythm Analysis" aimed to develop a neural network for analyzing respiratory rhythm using simple sensors such as an accelerometer and a strain gauge. A dedicated mobile application was created to support the monitoring and analysis of respiration. A key aspect of the thesis was acquiring data from sensors, processing it, and analyzing it using neural network models. The neural network model classified the respiratory rhythm into four classes: inhalation, post-inhalation retention, exhalation, and post-exhalation retention. This process included data acquisition from sensors, manual labeling of samples, and an iterative model training process. The classification results were visualized in the mobile application as an interactive chart, where different phases of respiration were highlighted using distinct colors. The study included data analysis and a literature review encompassing over 20 scientific publications. Seven different artificial intelligence models were compared, enabling optimization of the training process and model fine-tuning. A Gated Recurrent Unit (GRU) neural network was selected due to its high accuracy and low computational complexity. To improve classification quality, a Human-in-the-Loop method was employed, involving human experts at every stage of analysis, training, and data validation. The developed training dataset included over 2.5 hours of recordings, manually labeled using a dedicated application. Data were collected using two accelerometers (iNode Nav and WitMotion WT901BLE) and a strain gauge (HX711). A transfer labeling method was applied, allowing labeled data from one dataset to support the labeling process in another, related dataset. The application was developed for mobile devices running Android 11 or newer. It operates in a runtime mode, analyzing incoming sensor data in real-time and classifying it using the trained model. In this mode, the model achieved an accuracy of 88% for the strain gauge, 77% for the iNode Nav accelerometer, and 80% for the WitMotion accelerometer. Additionally, an offline mode was implemented, which classifies pre-recorded data with full contextual information, considering both past and future samples. In this mode, the model achieved higher accuracy: 90% for the strain gauge, 85% for iNode Nav, and 80.5% for WitMotion. The application also allows data to be saved in a text file, enabling further analysis and processing.

Keywords: neural networks, mobile application, breath measurement

SPIS TREŚCI

Wykaz ważniejszych oznaczeń i skrótów	7
1. WSTĘP I CEL PRACY	8
1.1. Analiza oddechu (Filip Krawczak)	8
1.2. Wykorzystane urządzenia w badaniach (Filip Krawczak)	8
1.3. Sieć neuronowa (Filip Krawczak)	8
1.4. Aplikacja mobilna (Filip Krawczak)	9
1.5. Wykonane eksperymenty (Filip Krawczak)	9
2. PRZEGLĄD METOD ANALIZY ODDECHU	10
2.1. Wstęp (Filip Krawczak)	10
2.2. Analiza oddechu jako narzędzie diagnostyczne	10
2.2.1. Wstęp (Filip Krawczak)	10
2.2.2. Obecność oddechu (Filip Krawczak)	10
2.2.3. Bezdech senny (Filip Krawczak)	11
2.2.4. Zapalenie płuc (Filip Krawczak)	11
2.2.5. Wady pracy serca (Filip Krawczak)	11
2.2.6. Wysilek fizyczny (Filip Krawczak)	12
2.2.7. Stres emocjonalny (Filip Krawczak)	12
2.2.8. Dusznosci (Filip Krawczak)	12
2.2.9. Kompleksowość kontroli oddechowej (Kacper Karski)	12
2.2.10. Rytm oddechowy a funkcje poznawcze i emocjonalne (Kacper Karski)	13
2.2.11. Wartość diagnostyczna analizy rytmu oddechowego (Kacper Karski)	13
2.2.12. Potencjalne zastosowania terapeutyczne rytmu oddechowego (Kacper Karski) ...	13
2.2.13. Przyszłość badania rytmu oddechowego i potencjalne zastosowanie projektu (Kacper Karski)	14
2.3. Urządzenia do monitorowania oddechu i współpraca z innymi czujnikami	14
2.3.1. Monitorowanie oddechu z częstotliwości rytmu serca (Filip Krawczak)	14
2.3.2. Analiza dźwięków pochodzących z mikrofonu (Filip Krawczak)	15
2.3.3. Spirometr (Filip Krawczak)	16
2.3.4. Akcelerometr (Kacper Karski)	16
3. OPIS SYSTEMU	20
3.1. Wstęp (Damian Jankowski)	20
3.2. Protokół Bluetooth Low Energy (Damian Jankowski)	20
3.2.1. Serwis i charakterystyka w BLE	20
3.2.2. Przykład użycia BLE w aplikacji nRF Connect	21
3.3. Tensometr (Damian Jankowski)	22
3.3.1. Moduł BLE	23
3.4. Akcelerometr (Damian Jankowski)	25
3.4.1. iNode Nav	25
3.4.2. WitMotion WT901BLECL	27

3.5. Aplikacja mobilna (Damian Jankowski)	30
3.6. Architektura aplikacji	31
3.6.1. Ekran (Damian Jankowski)	31
3.6.2. Schemat działania aplikacji ze strony urządzenia (Maciej Szeffler)	32
3.6.3. Schemat działania aplikacji ze strony użytkownika (Filip Krawczak)	35
3.7. Repozytorium brp-app (Damian Jankowski)	36
3.8. Repozytorium brp-ml-model (Damian Jankowski)	36
3.9. Akwizycja danych (Maciej Szeffler)	38
3.10 Dane treningowe i testowe (Damian Jankowski)	42
3.11 Analiza oddechu bazująca na zmianie pochodnej (Filip Krawczak)	44
3.12 Algorytm do detekcji cykli oddechowych (Kacper Karski)	46
4. WYNIKI EKSPERYMENTÓW	48
4.1. Wstęp (Maciej Szeffler)	48
4.2. Porównanie z danymi z literatury naukowej (Kacper Karski)	48
4.3. Porównanie modeli (Maciej Szeffler)	51
4.3.1. Model z normalizacją wsadową (ang. Batch Normalization)	52
4.3.2. Sieci rekurencyjne	53
4.3.3. Sieć konwolucyjna	54
4.3.4. Końcowe wyniki	56
4.4. Proces trenowania i poprawiania modelu GRU (Kacper Karski)	59
4.5. Model offline, a model runtime (Maciej Szeffler)	61
4.6. Miara częstości oddechu (Filip Krawczak)	62
4.6.1. Weryfikacja spójności etykiet (Filip Krawczak)	63
4.6.2. Testy dokładności algorytmu do liczenia miary RR na podstawie etykiet określonych przez model runtime (Filip Krawczak)	63
4.6.3. Testy dokładności algorytmu do liczenia miary RR na podstawie etykiet określonych przez model offline (Filip Krawczak)	64
4.7. Zależność rozmiaru zbioru danych do dokładności modelu (Maciej Szeffler)	66
4.8. Human-in-the-loop (Maciej Szeffler)	68
4.9. Pomiar pochylenia (Damian Jankowski)	69
5. DYSKUSJA	73
5.1. Wnioski (Kacper Karski)	73
5.2. Dalsze możliwości rozwoju (Kacper Karski)	73
Zakres odpowiedzialności członków zespołu	74
Wykaz literatury	77
Wykaz rysunków	78
Wykaz tabel	81

WYKAZ WAŻNIEJSZYCH OZNACZEŃ I SKRÓTÓW

GRU – Gated Recurrent Unit

LSTM – Long short-term memory

CNN – Convolutional neural network

BLE – Bluetooth Low Energy

HITL – Human-in-the-loop

RR – Respiratory Rate

1. WSTĘP I CEL PRACY

Celem projektu było opracowanie sieci neuronowej do analizy rytmu oddechu z czujników takich jak akcelerometr czy tensometr. Wymagane również było zbudowanie klasyfikatora oraz aplikacji mobilnej do graficznej prezentacji danych.

1.1. Analiza oddechu (Filip Krawczak)

Analiza rytmu oddechowego ma istotne znaczenie w diagnostyce i leczeniu chorób układu oddechowego. Monitorowanie oddechu pozwala na wykrywanie nieprawidłowości, które mogą wskazywać na rozwijające się schorzenia, a nowoczesne technologie umożliwiają ciągłe monitorowanie tego parametru. Analiza danych oddechowych pozwala na wczesne identyfikowanie subtelnych zmian, co sprzyja szybkiej diagnozie i precyzyjnemu leczeniu. Ponadto, technologie te znajdują zastosowanie w terapii zaburzeń emocjonalnych, takich jak lęk czy depresja, w których regulacja rytmu oddechowego może mieć pozytywny wpływ na stan psychiczny pacjentów. Monitorowanie rytmu oddechowego wspomaga zarządzanie stresem oraz umożliwia wdrożenie efektywnych interwencji terapeutycznych.

1.2. Wykorzystane urządzenia w badaniach (Filip Krawczak)

W badaniach wykorzystano następujące urządzenia pomiarowe: tensometr HX711 oraz akcelerometry iNode Nav i WitMotion WT901BLECL. Każde z tych urządzeń pełniło określoną rolę w procesie zbierania danych, umożliwiając szczegółową analizę parametrów oddechu.

Tensometr HX711 został wykorzystany do pomiaru zmian napięcia pasa umieszczonego na klatce piersiowej badanego, w trakcie oddychania. Urządzenia tego typu służą przede wszystkim do rejestrowania odkształceń mechanicznych wywołanych działającymi siłami.

Akcelerometry iNode Nav oraz WitMotion WT901BLECL były wykorzystane do rejestracji złożonych parametrów ruchu. Urządzenie iNode Nav umożliwia pomiar przyspieszenia kąтового, natomiast WitMotion WT901BLECL, oprócz rejestracji przyspieszenia, pozwala także na pomiar prędkości kątovej oraz kątów nachylenia wbudowanym inklinometrem. Oba urządzenia są wyposażone w moduł Bluetooth Low Energy (BLE), co zapewnia bezprzewodową transmisję danych, umożliwiając ich efektywne zbieranie w czasie rzeczywistym.

Wybór tych urządzeń wynikał z ich wysokiej precyzji, niezawodności oraz zdolności do adaptacji w różnych warunkach pomiarowych. Ich zaawansowane możliwości, takie jak dokładność rejestracji parametrów i kompatybilność z technologiami bezprzewodowymi, były kluczowe dla skutecznego zbierania i analizy danych.

1.3. Sieć neuronowa (Filip Krawczak)

Jednym z celów pracy było stworzenie modelu sieci neuronowej analizującej rytm oddechu. Aby uzyskać wysoką dokładność, należało dostarczyć odpowiednią ilość danych. Były one pobierane z sensorów opisanych w rozdziale 1.2. W przypadku tensometru oraz akcelerometru WitMotion, były one dostarczane z częstotliwością 10 Hz. Akcelerometr iNode Nav charakteryzował się większą częstotliwością próbkowania wynoszącą 25 Hz, co wpłynęło na większą dokładność

pomiarów, ale jednocześnie spowodowało zwiększenie poziomu szumów w otrzymywanych danych. W celu poprawy jakości pomiarów i ich wygładzenia zastosowano średnią kroczącą, która została wdrożona dla wszystkich rodzajów sensorów. Algorytm ten liczył średnią z 5 ostatnich odczytów dla tensometru i akcelerometru WT901BLECL oraz 11 dla akcelerometru iNode Nav, co odpowiada około 0,5 sekundy pomiaru. Model analizujący oddech, został zaimplementowany tak, aby zaklasyfikować dany pomiar do jednej z czterech etykiet (wydech, retencja po wydechu, wdech, retencja po wdechu).

1.4. Aplikacja mobilna (Filip Krawczak)

W ramach projektu opracowano aplikację mobilną przeznaczoną na urządzenia z systemem Android 11 lub nowszym. Aplikacja została zaprojektowana przy użyciu technologii React Native oraz języków programowania TypeScript i Java. Program umożliwia integrację z urządzeniami pomiarowymi, ładowanie modeli predykcyjnych stanu oddechu oraz automatyczne zapisywanie danych pomiarowych w formacie tekstowym. Wykonano cztery ekrany: ekran połączeń z sensorami, ekran wykresów, ekran statystyk oddechowych oraz ekran ustawień. Główny ekran wykresów, przedstawia oddech osoby badanej. Dane, zaprezentowane jako linia ciągła, są podzielone na segmenty o różnych kolorach, odpowiadające poszczególnym fazom cyklu oddechowego. Umożliwiają one łatwiejsze rozróżnienie faz oddechowych, co wspomaga interpretację wyników analizy oddechu. Interfejs użytkownika został zaprojektowany w sposób intuicyjny, zapewniając łatwość obsługi.

1.5. Wykonane eksperymenty (Filip Krawczak)

Aby uzyskać jak najwyższą dokładność modelu, zdecydowano się na przeprowadzenie szeregu eksperymentów. Opierały się one na analizie kilku modeli z dziedziny sztucznej inteligencji i wybraniu tego, osiągającego najwyższą dokładność. Zastosowano również podejście ciągłej poprawy danych i uczestniczenia człowieka w całym cyklu treningowym, tzw. Human-in-the-loop. Porównano graficzne reprezentacje danych uzyskanych przez proste sensory, z danymi pozyskanymi przez medyczne urządzenia badające oddech. Przetestowano również tryb pomiaru kąta nachylenia inklinometrem, udostępniany przez sensor WitMotion.

2. PRZEGLĄD METOD ANALIZY ODDECHU

2.1. Wstęp (Filip Krawczak)

Oddychanie odgrywa kluczową rolę w funkcjonowaniu organizmu, umożliwiając wymianę gazową polegającą na dostarczaniu tlenu i usuwaniu dwutlenku węgla. Tlen jest niezbędny do prawidłowego funkcjonowania organizmu, a mózg zużywa średnio około 20% całkowitej ilości tlenu pobieranego przez ciało. Zgodnie z danymi National Library of Medicine, brak dostępu do tlenu przez okres około 4 minut prowadzi do wystąpienia nieodwracalnych uszkodzeń mózgu, a śmierć następuje w przedziale czasowym od 4 do 6 minut [1, 2]. Badania przeprowadzone w 1993 roku wykazały istotny związek pomiędzy ryzykiem zatrzymania krążeniowo-oddechowego, a częstotliwością oddechów wynoszącą poniżej 14 lub powyżej 24 oddechów na minutę [3]. Z tego powodu precyzyjna ocena parametrów oddechowych, w tym liczby oddechów na minutę, ma kluczowe znaczenie diagnostyczne, umożliwiając wczesne wykrywanie zaburzeń oddychania oraz niewydolności oddechowej [4]. W spoczynku prawidłowa liczba oddechów u dorosłych powinna mieścić się w przedziale 12-20 na minutę [5], przy czym wartość ta zależy od wieku pacjenta. Monitorowanie oddechu pozwala na identyfikację sytuacji, w których długość bezdechu odbiega od normy lub dochodzi do całkowitego zaniku oddechu. Wykorzystanie technologii, takich jak tensometry i akcelerometry, stanowi niezawodną i nieinwazyjną metodę oceny funkcji oddechowych. Integracja tych urządzeń z innymi systemami monitorującymi umożliwia szybkie wykrywanie zagrożeń zdrowia i życia, co jest szczególnie istotne w opiece szpitalnej.

2.2. Analiza oddechu jako narzędzie diagnostyczne

2.2.1. Wstęp (Filip Krawczak)

Monitorowanie oddechu stanowi wiarygodne narzędzie diagnostyczne, dostarczające informacji na temat bieżącego stanu zdrowia oraz potencjalnych chorób i problemów zdrowotnych. Oddychanie, choć pozornie proste w definicji, w rzeczywistości jest złożonym procesem. Nakłada się na to wiele interakcji między strukturami mózgowymi a innymi systemami organizmu. Prawidłowy rytm oddechowy jest istotny dla utrzymania homeostazy, czyli względnie stałych parametrów wewnętrznych organizmu. Analiza i monitorowanie tych parametrów mają szczególne znaczenie w diagnostyce i terapii schorzeń układu oddechowego.

2.2.2. Obecność oddechu (Filip Krawczak)

Obecność oddechu stanowi bezpośredni wskaźnik stanu zdrowia osoby badanej. Oddychanie jest podstawową funkcją organizmu, a jego zatrzymanie lub nieregularności mogą wskazywać na poważne zagrożenia zdrowotne. Urządzenia do monitorowania oddechu są wykorzystywane przez personel medyczny do identyfikacji oznak tymczasowego zatrzymania oddechu lub hipowentylacji (anormalnie powolnego lub płytkiego oddychania). W przypadkach nieprzytomności spowodowanej udarem lub urazem mózgu monitorowanie oddechu pozwala na potwierdzenie, czy organizm nadal podejmuje próbę oddychania. Ponadto, pacjenci poddawani znieczuleniu są ściśle monitorowani w celu wykrycia wszelkich zaburzeń w wzorcach oddychania, które mogą

prowadzić do hipoksji (niskiego stężenia tlenu w organizmie) i uszkodzenia organów. W każdym przypadku wykrycie nieprawidłowości oddechu jest kluczowe dla szybkiej interwencji i leczenia.

2.2.3. Bezdech senny (Filip Krawczak)

Bezdech senny jest zaburzeniem, które charakteryzuje się wielokrotnymi przerwami w oddychaniu podczas snu, zakłócając jego jakość i ciągłość. Przerwy te, zwane bezdechami, mogą trwać od kilku sekund do kilku minut i występować setki razy w nocy, często bez świadomości dotkniętego nimi człowieka. Najczęstsza forma bezdechu sennego występuje, gdy mięśnie w tylnej części gardła nadmiernie się rozluźniają, tymczasowo blokując drogi oddechowe. Centralny bezdech senny, występujący rzadziej, polega na nieprawidłowym przesyłaniu sygnałów z mózgu do mięśni kontrolujących oddychanie. Obie formy mogą prowadzić do fragmentacji snu i obniżenia poziomu tlenu, co zwiększa ryzyko niedotlenienia, udaru, a nawet śmierci, jeśli nie zaczną być leczone [6].

Monitorowanie oddechu, szczególnie w połączeniu z czujnikami mierzącymi przepływ powietrza, pozwala na wykrycie tych przerw. Obliczanie częstości oddechów oraz analiza przerw w oddychaniu stanowią kluczowe metody diagnostyczne w identyfikacji bezdechu sennego. Wiele urządzeń domowych stosuje ciągle monitorowanie przepływu powietrza i wzorców oddechowych, co umożliwia diagnozowanie bezdechu sennego, nawet w przypadku braku charakterystycznych objawów, takich jak nadmierna senność w ciągu dnia. Dzięki precyzyjnemu monitorowaniu, specjaliści mogą zlecić odpowiednie leczenie lub inne interwencje, które zapewnią stabilność oddechu przez całą noc, poprawiając jakość snu i ogólne zdrowie.

2.2.4. Zapalenie płuc (Filip Krawczak)

Zapalenie płuc jest infekcją, która powoduje gromadzenie się płynu w pęcherzykach płucnych, co utrudnia oddychanie. Infekcja może mieć charakter bakteryjny, wirusowy lub grzybiczy, a objawy zazwyczaj obejmują kaszel, gorączkę, ból w klatce piersiowej i trudności w oddychaniu. W odpowiedzi na infekcję organizm często zwiększa częstotliwość oddechów, próbując skompensować obniżoną wydolność płuc. Przyspieszony oddech jest powszechnie obserwowany u pacjentów z zapaleniem płuc, ponieważ organizm stara się zapewnić odpowiednią ilość tlenu.

Monitorowanie oddechu umożliwia wczesne wykrycie zapalenia płuc. Pacjenci z zapaleniem płuc często wykazują oznaki zwiększonego wysiłku w oddychaniu, co można zidentyfikować poprzez pomiar częstości oddechów oraz analizę wzorców płytkiego lub utrudnionego oddychania. Brak leczenia zapalenia płuc może prowadzić do poważnej niewydolności oddechowej, dlatego terminowe wykrycie za pomocą monitorowania oddechu jest kluczowe.

2.2.5. Wady pracy serca (Filip Krawczak)

Wiele chorób serca, takich jak niewydolność serca, arytmia czy choroba niedokrwienna serca, może wpływać na częstość oddechów. Choroby te często upośledzają zdolność serca do efektywnego pompowania krwi, co z kolei negatywnie wpływa na zdolność płuc do jej natlenienia. W odpowiedzi na to organizm zwiększa szybkość oddychania, w celu dostarczenia większej ilości tlenu, szczególnie podczas wysiłku fizycznego. Z tego powodu osoby z niewydolnością serca często doświadczają duszności w pozycji leżącej [7].

Osoby z wadami serca mogą doświadczać zwiększonej częstości oddechów, a choroby takie jak arytmia czy migotanie przedsionków mogą prowadzić do nieregularnych wzorców oddychania. Monitorowanie tych wzorców może wspierać specjalistów w diagnozowaniu problemów sercowych zanim wystąpią poważniejsze objawy choroby. Ponadto, obserwacja zmian w częstości

oddechów może pomóc ocenić skuteczność leków lub interwencji terapeutycznych stosowanych w leczeniu.

2.2.6. Wysiłek fizyczny (Filip Krawczak)

Podczas wysiłku fizycznego organizm naturalnie zwiększa częstość oddechów w celu zaspokojenia zwiększonych potrzeb tlenowych mięśni. Dla sportowców wzrost częstości oddechów jest normalnym zjawiskiem związanym z wydolnością fizyczną, ponieważ mięśnie wymagają większej ilości tlenu do produkcji energii podczas intensywnych aktywności. Monitorowanie częstości oddechów w trakcie ćwiczeń lub aktywności fizycznej dostarcza informacji na temat poziomu kondycji, co pozwala na optymalizację programów treningowych lub rehabilitacyjnych.

Monitorowanie oddechu podczas ćwiczeń umożliwia również wykrywanie nieprawidłowych wzorców, takich jak nadmierna duszność, co może wskazywać na problemy takie jak astma wywołana wysiłkiem. Przykładowo, osoba z niezdiagnozowaną chorobą może wykazywać oznaki nadmiernego wysiłku, takie jak szybkie oddychanie podczas umiarkowanej aktywności, co sygnalizuje konieczność przeprowadzenia dalszych badań diagnostycznych.

2.2.7. Stres emocjonalny (Filip Krawczak)

Stres emocjonalny oddziałuje na układ nerwowy, powodując przyspieszenie i spłylenie oddechu, znane jako hiperwentylacja. Krótkotrwała hiperwentylacja jest naturalną reakcją na chwilowy stres, jednak długotrwałe napięcie emocjonalne lub lęk mogą prowadzić do trwałych zmian w sposobie oddychania, co przyczynia się do rozwoju problemów, takich jak ataki paniki czy zaburzenia lękowe. Obserwacja częstości oddechu umożliwia wykrywanie i ocenianie poziomu stresu w czasie rzeczywistym, pozwalając na szybsze wdrożenie technik relaksacyjnych, takich jak ćwiczenia oddechowe, wspomagających zarządzanie stresem i zapobiegających jego negatywnym skutkom zdrowotnym [8].

2.2.8. Duszności (Filip Krawczak)

Duszności to uczucie trudności w oddychaniu, które stanowi częsty objaw wielu przewlekłych schorzeń, takich jak astma czy niewydolność serca. Może wystąpić również w wyniku nagłych wydarzeń, takich jak zator płucny czy ostry atak astmy.

Osoby doświadczające duszności często wykazują zwiększoną częstość oddechów, szczególnie w odpowiedzi na wysiłek fizyczny lub w spoczynku. Jeśli duszności nasilają się w nocy lub podczas leżenia na płasko, może to wskazywać na zaostrzenie objawów choroby. Ciągłe monitorowanie oddechu umożliwia wczesne wykrycie oznak zagrożenia, co pozwala na skuteczniejsze zarządzanie objawami, dostosowywanie leczenia oraz szybszą interwencję w razie potrzeby.

2.2.9. Kompleksowość kontroli oddechowej (Kacper Karski)

Względnie prosty proces, którym jest oddychanie, tak naprawdę wymaga skoordynowanej pracy wielu struktur nerwowych, które umożliwiają precyzyjne dostosowanie każdego oddechu do aktualnych potrzeb metabolicznych organizmu. Na czele tego układu znajduje się kompleks preBötzingera (preBötC), który, jak wykazały badania [9], odgrywa kluczową rolę w generowaniu rytmu oddechowego. Neurony tego kompleksu, dzięki synchronizacji swoich aktywności pozwalają nie tylko na utrzymanie stabilności oddychania, ale również na elastyczne dostosowywanie rytmu do zmian fizjologicznych, takich jak wysiłek fizyczny, stan emocjonalny czy zmiany poziomu gazów we krwi.

Mechanizm „burstlets”, który umożliwia preBötC generowanie niewielkich, zsynchronizowanych impulsów, przekształcających się w pełne „wybuchy” aktywności neuronów, odpowiada za skurcz mięśni oddechowych. Mechanizm ten jest kluczowy dla adaptacji układu oddechowego, który musi odpowiadać zarówno na bieżące potrzeby metaboliczne, jak i na współistniejące procesy, takie jak kaszel czy połykanie.

2.2.10. Rytm oddechowy a funkcje poznawcze i emocjonalne (Kacper Karski)

Rytm oddechowy ma także wpływ na funkcje poznawcze i emocjonalne. Badania wskazują, że odpowiednia modulacja rytmu oddechowego może wspierać stan psychiczny człowieka. Autorzy artykułu [10] opisali, że techniki oddechowe, takie jak medytacja, mogą skutecznie obniżać poziom stresu, lęku oraz poprawiać koncentrację i funkcje poznawcze. Podczas ich wykonywania zmienia się aktywność fal mózgowych (theta i delta), związanych z relaksacją i skupieniem uwagi. Dodatkowo, badania [11] wykazały, że wdechy przez nos zwiększają reakcję emocjonalną organizmu na bodźce, szczególnie w sytuacjach zagrożenia. Zależność ta sugeruje, że rytm oddechowy można regulować, aby kontrolować stany emocjonalne, co stwarza potencjalne możliwości terapeutyczne w leczeniu zaburzeń emocjonalnych. Ponadto techniki, takie jak oddychanie przeponowe, mogą wspierać terapię lęku i depresji, ponieważ ich stosowanie wpływa na aktywność neuronów w obszarach mózgu, odpowiedzialnych za emocje, takich jak ciało migdałowate.

2.2.11. Wartość diagnostyczna analizy rytmu oddechowego (Kacper Karski)

Monitorowanie rytmu oddechowego ma duży potencjał diagnostyczny, zwłaszcza w przypadku chorób układu oddechowego, takich jak astma, przewlekła obturacyjna choroba płuc (POChP) czy bezdech senny. Badania [12] wykazały, że pacjenci z astmą, szczególnie w fazie niekontrolowanej, czyli wtedy, gdy objawy choroby nie są skutecznie łagodzone przez leczenie lub stan zdrowia wymyka się spod kontroli, prezentują charakterystyczne zmiany w rytmie oddechowym. Analiza zmienności interwałów między oddechami (IBI) oraz zmienności objętości płuc (LV) stanowią wskaźniki pozwalające na rozróżnienie postaci kontrolowanej i niekontrolowanej astmy. W badaniach tych stosuje się metody analityczne, takie jak detrended fluctuation analysis (DFA) czy największe wykładniki Lapunowa (LLE), co pozwala na precyzyjne monitorowanie i przewidywanie zaostrzeń choroby. Jest to istotne z perspektywy zapobiegania powikłaniom, takim jak nadciśnienie tętnicze czy choroby sercowo-naczyniowe.

2.2.12. Potencjalne zastosowania terapeutyczne rytmu oddechowego (Kacper Karski)

Znajomość dynamiki rytmu oddechowego znajduje zastosowanie w terapii i profilaktyce zdrowotnej. Techniki oddechowe, takie jak oddychanie przeponowe, mogą być wykorzystywane do redukcji stresu, poprawy funkcji poznawczych oraz wspierania leczenia stanów lękowych. Badania [13] oraz [14] wykazały, że kontrola głębokości i szybkości oddychania, wpływa na układ autonomiczny, obniżając aktywność układu współczulnego i zwiększając aktywność przywspółczulną. W efekcie obserwuje się obniżenie ciśnienia krwi, poprawę nastroju oraz redukcję objawów lękowych i depresyjnych. Techniki oddechowe wspierają także terapię przewlekłych chorób układu oddechowego, takich jak astma. Regularne monitorowanie rytmu oddechowego może pomóc pacjentom w zarządzaniu objawami oraz w przewidywaniu zaostrzeń choroby. Co więcej, badania sugerują, że codzienna praktyka tych technik poprawia wentylację, wspierając terapię farmakologiczną i pomagając pacjentom lepiej kontrolować chorobę.

2.2.13. Przyszłość badania rytmu oddechowego i potencjalne zastosowanie projektu (Kacper Karski)

Postęp technologiczny w zakresie monitorowania rytmu oddechowego stwarza coraz większe możliwości precyzyjnego i wygodnego śledzenia parametrów zdrowotnych. Projekt oparty na sieciach neuronowych może stanowić przydatne narzędzie do analizy stanu oddechu w czasie rzeczywistym. System ten, dzięki zastosowaniu odpowiednio dobranych modeli, jest w stanie analizować zmienność rytmu oddechowego i dostosowywać się do różnych stanów fizjologicznych użytkownika. System mógłby być potencjalnie zintegrowany z bardziej zaawansowanymi sensorami lub technologiami, takimi jak respiratory inductive plethysmography (RIP), co zwiększyłoby jego precyzję. Dzięki tej elastyczności projekt może znaleźć zastosowanie zarówno w warunkach szpitalnych, jak i domowych, umożliwiając monitorowanie stanu zdrowia bez konieczności przeprowadzania bardziej inwazyjnych badań. Integracja z algorytmami sztucznej inteligencji mogłaby umożliwić automatyczne wykrywanie nieprawidłowości w rytmie oddechowym, takich jak bezdech senny czy zaostrzenia astmy, co potencjalnie mogłoby wspierać użytkowników i opiekunów zdrowotnych w codziennym monitorowaniu oddechu.

2.3. Urządzenia do monitorowania oddechu i współpraca z innymi czujnikami

Zakłócenia procesu oddychania, takie jak bezdech, niedodma czy hiperwentylacja, mogą prowadzić do poważnych konsekwencji zdrowotnych, co czyni monitorowanie oddechu kluczowym elementem diagnostyki i terapii. W warunkach klinicznych, takich jak oddziały intensywnej terapii, pacjenci często są podłączeni do urządzeń monitorujących, jednak takie podejście bywa niepraktyczne w środowisku domowym czy podczas rehabilitacji.

Tradycyjne metody monitorowania oddechu, takie jak spirometria, pneumotachografia czy pletyzmografia, dostarczają precyzyjnych danych, lecz są z natury inwazyjne lub wymagają stosowania specjalistycznego sprzętu, który może ograniczać ruch pacjenta. W ostatnich latach obserwuje się rosnące zainteresowanie technologiami opartymi na czujnikach inercyjnych, takich jak akcelerometry. Czujniki te, umieszczone na klatce piersiowej i brzuchu, mogą rejestrować ruchy ciała związane z oddychaniem w sposób nieinwazyjny, co stanowi obiecującą alternatywę dla klasycznych metod.

2.3.1. Monitorowanie oddechu z częstotliwości rytmu serca (Filip Krawczak)

Przykład zastosowania integracji urządzeń monitorujących oddech i częstotliwość rytmu serca przedstawiono w pracy [6]. Opracowany Zautomatyzowany System Wykrywania Obturacyjnego Bezdechu Sennego (Automated System for OSA Detection – ASOSAD) wykorzystuje zmienność rytmu serca (HRV) oraz zmienność rytmu oddechu (RRV) jako dane wejściowe. System umożliwia nieinwazyjne wykrywanie epizodów bezdechu sennego na podstawie analizy wzorców sygnałów sercowych i oddechowych.

W badaniu przeanalizowano dane pochodzące od dwóch grup:

- 17 osób zdrowych,
- 15 osób zdiagnozowanych z obturacyjnym bezdechem sennym.

Do klasyfikacji epizodów bezdechu sennego zastosowano klasyfikator maszyn wektorów nośnych (SVM). Analiza cech HRV i RRV w fazie REM snu pozwoliła na osiągnięcie początkowej dokładności klasyfikacji na poziomie 80%. Dalsza optymalizacja wyboru cech doprowadziła do poprawy wyników. Wykazano, że analiza czasowych cech HRV przyczyniła się do wzrostu

dokładności o 10%, co wskazuje na istotność danych o zmienności rytmu serca w diagnostyce OSA. Szczegółowe wyniki modelu przedstawiono w tabeli 2.1.

ASOSAD with Time domain HRV features as input			
Kernel	Classification accuracy (%)	Sensitivity (%)	Specificity (%)
Linear	40	60	20
Polynomial	90	80	100
ASOSAD with Time domain RRV features as input			
Linear	80	100	60
Polynomial	50	40	60
ASOSAD with Frequency domain HRV features as input			
Linear	40	40	40
Polynomial	40	80	0
ASOSAD with Frequency domain RRV features as input			
Linear	60	40	80
Polynomial	40	80	0

Rys. 2.1. Dokładności klasyfikatora SVM (źródło [6])

W badaniu zastosowano również metodę fuzji decyzji, polegającą na przypisaniu różnych wag cechom HRV i RRV w celu zwiększenia niezawodności systemu. Przypisane wagi zostały przedstawione w tabeli 2.2. Metoda ta umożliwiła osiągnięcie bezbłędnego wykrywania epizodów bezdechu sennego, co wskazuje na potencjał integracji monitorowania częstotliwości rytmu serca oraz oddechu w poprawie czułości i dokładności systemów zautomatyzowanego monitorowania stanu zdrowia.

Kernel	Weight applied to the TD HRV system	Weight applied to the TD RRV system	Classification accuracy (%)
Linear	0.81	0.19	100

Rys. 2.2. Wartości wag przypisane cechom HRV i RRV (źródło [6])

System ASOSAD stanowi przykład efektywnej integracji zmienności rytmu serca (HRV) i zmienności rytmu oddechu (RRV) w diagnostyce zdrowotnej, szczególnie w obszarze wykrywania obturacyjnego bezdechu sennego. Zastosowane technologie wykazują znaczący potencjał w kontekście rozwoju urządzeń noszonych przy ciele badanego, które umożliwiają ciągłe monitorowanie parametrów zdrowotnych.

2.3.2. Analiza dźwięków pochodzących z mikrofonu (Filip Krawczak)

W artykule [15] przedstawiono zastosowanie nowoczesnych technik sztucznej inteligencji w diagnostyce chorób układu oddechowego. Analiza dźwięków, takich jak kaszel, zmiany w głosie czy świsty, została wskazana jako potencjalne źródło cyfrowych biomarkerów umożliwiających wykrywanie chorób płuc. Wykorzystanie algorytmów uczenia maszynowego pozwala na precyzyjną identyfikację objawów schorzeń, w tym astmy i infekcji wirusowych.

Jednym z kluczowych przykładów jest detekcja kaszlu w środowiskach o wysokim poziomie hałasu, który może zakłócać analizę dźwiękową. W badaniach uwzględniono zbiory danych gromadzone w zróżnicowanych warunkach akustycznych, co umożliwiło opracowanie modeli zdolnych do rozpoznawania kaszlu z wysoką dokładnością, nawet w obecności szumów tła. Analiza dźwięków oddechowych, takich jak świsty, odgrywa istotną rolę w identyfikacji problemów związanych z układem oddechowym. Właściwe rozpoznanie wzorców dźwiękowych umożliwia wykrywanie wczesnych symptomów chorób oddechowych.

W artykule omówiono również dostępne publiczne bazy danych wspierające rozwój systemów diagnostycznych. Zawierają one próbki dźwięków, takich jak kaszel, szmery oddechowe oraz zmiany w tonie głosu, które mogą być wykorzystane w monitorowaniu stanu zdrowia pacjentów z zaburzeniami oddechowymi.

2.3.3. Spirometr (Filip Krawczak)

Spirometria to jedno z kluczowych badań wykorzystywanych do oceny funkcji płuc oraz monitorowania chorób układu oddechowego, w tym astmy i przewlekłej obturacyjnej choroby płuc (POChP). W pracy Office Spirometry: Indications and Interpretation [16] podkreślono znaczenie tego badania w pomiarze parametrów, takich jak natężona objętość wydechu, czyli objętość powietrza wydychana z płuc w czasie pierwszej sekundy maksymalnie natężonego wydechu (FEV1), natężona pojemność życiowa (FVC), czyli największa objętość powietrza, jaką można wydychać z płuc podczas maksymalnego, szybkiego wydechu oraz wskaźnik FEV1/FVC.

Badanie spirometryczne cechuje się prostotą wykonania oraz nieinwazyjnym charakterem, dostarczając jednocześnie precyzyjnych informacji diagnostycznych. Obniżenie wartości FEV1 oraz stosunku FEV1/FVC wskazuje na obecność ograniczeń przepływu powietrza w drogach oddechowych, charakterystycznych dla chorób obturacyjnych, takich jak POChP. W przypadku astmy spirometria pozwala na ocenę odwracalności obturacji po zastosowaniu leków rozszerzających oskrzela.

Zastosowanie spirometrii obejmuje również ocenę skuteczności leczenia farmakologicznego. Zgodnie z wytycznymi, wzrost wartości FEV1 o co najmniej 12% oraz po podaniu 200 ml leku rozszerzającego oskrzela jest wskaźnikiem poprawy funkcji płuc u pacjentów z astmą. W przypadku POChP podobne zmiany są zwykle mniej wyraźne.

Regularne pomiary spirometryczne umożliwiają wczesne wykrycie pogorszenia stanu zdrowia, co pozwala na szybsze wdrożenie skutecznej terapii. Przenośne wersje spirometrów umożliwiają wykonywanie badań w warunkach domowych, co stanowi istotne udogodnienie dla pacjentów z ograniczoną mobilnością.

Spirometry są fundamentalnym narzędziem w profilaktyce oraz monitorowaniu chorób układu oddechowego. Łącząc precyzję pomiarów z łatwą dostępnością, stanowią nieodzowny element współczesnej diagnostyki pulmonologicznej.

2.3.4. Akcelerometr (Kacper Karski)

Analiza oddechu może być przeprowadzona na wiele różnych sposobów. Jednym z nich jest wykorzystanie akcelerometrów tak jak przedstawiono w badaniu opisanym w artykule [17]. Zaprezentowano w nim, że akcelerometry mogą być skutecznie wykorzystywane do monitorowania oddechu w sposób nieinwazyjny. Przedstawione wyniki są bardzo ważne dla prowadzonych badań, ponieważ poruszają podobną tematykę. Artykuł potwierdza, że akcelerometry są dobrym rozwiązaniem do mierzenia parametrów oddechowych bez użycia skomplikowanego sprzętu. Wnioski

i opisane metody mogą być przydatne do rozwijania technologii, które ułatwią monitorowanie oddechu, szczególnie w domowych warunkach lub w telemedycynie.

Cel badania

Głównym celem badania było określenie optymalnej liczby oraz rozmieszczenia akcelero-metrów na ciele pacjenta w celu dokładnej estymacji przebiegu oddechowego. Autorzy chcieli określić, jakie lokalizacje czujników dostarczają najbardziej wiarygodnych danych oraz jak redukcja liczby czujników wpływa na jakość wyników. Takie podejście miało na celu opracowanie prostego, a jednocześnie precyzyjnego systemu monitorowania, który mógłby być zastosowany w różnych warunkach klinicznych i pozaklinicznych.

Badanie obejmowało również analizę możliwości separacji sygnałów oddechowych od zakłóceń przy użyciu algorytmów przetwarzania danych, takich jak analiza niezależnych komponentów (ICA). To kluczowy aspekt w warunkach rzeczywistych, gdzie ruchy ciała, wibracje czy zmiany postawy pacjenta mogą znacząco wpływać na jakość pomiarów.

Metodyka


Badanie przeprowadzono na grupie 30 zdrowych uczestników, co pozwoliło na uzyskanie wiarygodnych danych w kontrolowanych warunkach. Każdy z uczestników został wyposażony w 10 akcelero-metrów rozmieszczonych na klatce piersiowej oraz brzuchu. Wybrane lokalizacje obejmowały zarówno centralne, jak i boczne obszary ciała, umożliwiając ocenę wpływu różnych pozycji na jakość sygnału.

Eksperyment przeprowadzano w trzech pozycjach ciała: leżącej, siedzącej i stojącej. Dane zebrane z akcelero-metrów porównywano z wynikami referencyjnej metody pneumotachografii, która mierzy przepływ powietrza przez drogi oddechowe, dostarczając bardzo precyzyjnych wyników.

Zastosowano zaawansowane algorytmy analizy danych, w tym analizę niezależnych komponentów (ICA), w celu separacji sygnałów oddechowych od zakłóceń. Algorytmy te umożliwiły usunięcie wpływu ruchów ciała i innych artefaktów, co jest szczególnie istotne w warunkach klinicznych.

Lokalizacja czujników

Wyniki badania wykazały, że rozmieszczenie czujników ma kluczowe znaczenie dla jakości estymacji przebiegu oddechowego. Szczególnie istotne były lokalizacje po prawej stronie klatki piersiowej, oznaczone na rysunku 2.3 numerami 1, 4 oraz 7, co można tłumaczyć większą objętością prawego płuca w porównaniu z lewym. Dane z tych lokalizacji były bardziej stabilne i dokładne w porównaniu z czujnikami umieszczonymi w innych obszarach.



Rys. 2.3. Optymalne rozmieszczenie sensorów zaproponowane przez autorów artykułu (źródło [17])

Liczba czujników

Analiza pokazała, że dane z zaledwie czterech strategicznie rozmieszczonych czujników są wystarczające do uzyskania dokładnych wyników. Optymalizacja liczby czujników może znacząco zmniejszyć koszty i złożoność systemu, jednocześnie zachowując jego dokładność.

Separacja sygnałów

Zastosowanie Independent Component Analysis (ICA) pozwoliło na skuteczne wyodrębnienie sygnałów oddechowych z danych surowych, eliminując wpływ zakłóceń takich jak ruchy ciała czy wibracje. Analiza ICA polega na dekompozycji sygnału na komponenty statystycznie niezależne, co umożliwia separację różnych źródeł sygnału, nawet jeśli są one nałożone na siebie w danych surowych. W praktyce oznacza to, że algorytmy ICA identyfikują i wyodrębniają komponenty pochodzące od różnych źródeł (np. sygnały oddechowe, szumy), wykorzystując różnice w ich statystycznych właściwościach, takich jak niezależność lub różny rozkład czasowy. Algorytmy te okazały się szczególnie przydatne w pozycjach stojącej i siedzącej, gdzie zakłócenia były bardziej intensywne.

Znaczenie wyników

Wyniki badania wskazują na możliwość praktycznego zastosowania akcelerometrów w monitorowaniu oddechu, zwłaszcza w warunkach, gdzie tradycyjne metody pomiarowe są niewygodne lub niepraktyczne. Technologia ta może znaleźć zastosowanie w monitorowaniu bezdechu sennego, przewlekłych chorób płuc czy w rehabilitacji. Ponadto, niewielki rozmiar i lekkość akcelerometrów umożliwiają ich integrację z odzieżą medyczną, co czyni je idealnym rozwiązaniem dla zastosowań domowych i w telemedycynie.

Podsumowanie

Wyniki opisane w artykule [17] ukazują potencjał wykorzystania akcelerometrów w monitorowaniu oddechu. Choć przedstawione badanie koncentruje się na rozmieszczeniu czujników i optymalizacji liczby akcelerometrów, niniejsza praca wyróżnia się podejściem do analizy danych

oraz zastosowaniem zaawansowanych metod uczenia maszynowego. Różnice te podkreślają unikalność projektu i jego wartość w rozwijaniu nowych technologii w monitorowaniu procesów oddechowych.

Podczas gdy badanie w artykule ogranicza się do wykorzystania akcelerometrów, projekt ten obejmuje zastosowanie zarówno akcelerometrów, jak i tensometrów. Tensometry, dzięki swojej wysokiej czułości na odkształcenia mechaniczne, rejestrują zmiany obwodu klatki piersiowej związane z cyklem oddechowym. Ich połączenie z akcelerometrami pozwala na uzyskanie bardziej wszechstronnych danych, które precyzyjnie opisują ruchy klatki piersiowej i brzucha.

Zastosowanie dwóch rodzajów czujników zwiększa odporność systemu na potencjalne zakłócenia. Na przykład w sytuacjach, gdy sygnał z akcelerometrów jest zakłócony przez nagłe ruchy ciała, tensometry mogą dostarczyć wiarygodnych danych, które uzupełniają analizę. W praktyce takie podejście pozwala na lepsze odwzorowanie przebiegu oddechu nawet w dynamicznych warunkach.

Jednym z najistotniejszych elementów pracy jest ręczna analiza danych w początkowym etapie, opisana w rozdziale 3.10. Dane z czujników są poddawane ocenie, co pozwala na lepsze zrozumienie ich charakterystyki oraz identyfikację cech kluczowych dla analizy oddechu. Etap ten umożliwia wyselekcjonowanie istotnych wzorców oraz wyeliminowanie potencjalnych zakłóceń przed dalszym przetwarzaniem danych.

Ręczna analiza różni się od metod zastosowanych w artykule, gdzie dane były automatycznie przetwarzane za pomocą klasycznych algorytmów, jak analiza niezależnych komponentów (ICA). Podejście prezentowane w projekcie pozwala na dokładne zrozumienie dynamiki sygnałów w kontekście ruchów oddechowych, co stanowi solidną podstawę do kolejnego kroku, jakim jest trenowanie sieci neuronowej. Dzięki temu system staje się bardziej precyzyjny i dostosowany do różnorodnych warunków pomiarowych.

Kluczowym elementem odróżniającym niniejszą pracę od badań opisanych w artykule jest wykorzystanie sieci neuronowej, opisanej w rozdziale 3.12. Pełni ona rolę narzędzia, które uczy się samodzielnie aby analizować dane z czujników na podstawie wzorców zidentyfikowanych w procesie manualnej analizy. Sieć jest trenowana na rzeczywistych danych, co pozwala na efektywne rozpoznawanie i interpretację sygnałów związanych z oddechem.

Takie podejście eliminuje potrzebę ręcznego przetwarzania danych w późniejszych etapach, co znacząco zwiększa efektywność systemu. W przeciwieństwie do artykułu, gdzie zastosowano z góry zdefiniowane algorytmy, projekt opiera się na zdolności sieci neuronowej do adaptacji. Dzięki temu system może być używany w różnych scenariuszach, takich jak monitorowanie pacjentów w stanie spoczynku, podczas aktywności fizycznej czy w zmiennych warunkach środowiskowych.


Projekt ten różni się od badań opisanych w artykule zarówno pod względem stosowanych technologii, jak i metod analizy. Podczas gdy artykuł skupia się na analizie optymalnego rozmieszczenia akcelerometrów, projekt koncentruje się na stworzeniu kompleksowego systemu, który nie tylko zbiera dane, ale również interpretuje je i przetwarza w sposób autonomiczny.

Wartość tego rozwiązania wynika z jego zdolności do automatycznego rozpoznawania wzorców w danych, co pozwala na zastosowanie w warunkach rzeczywistych. W sytuacjach, gdzie dane są zakłócone, sieć neuronowa ma zdolność do „uczenia się” rozpoznawania oddechu na podstawie wielu różnych źródeł danych (akcelerometry i tensometry). To czyni system bardziej odpornym na błędy pomiarowe i lepiej dostosowanym do potrzeb pacjentów.

3. OPIS SYSTEMU

3.1. Wstęp (Damian Jankowski)

System rozwijania i treningu modeli sieci neuronowych składał się z dwóch etapów. W pierwszym z nich wybierano w aplikacji mobilnej sensory, by umożliwić przesył danych. Podczas pomiaru oddechu dane z sensorów były zbierane i zapisywane na urządzeniu mobilnym, na którym zainstalowano aplikację. Podczas drugiego etapu nagrane dane przesyłano na komputer lub inne urządzenie o wystarczającej mocy obliczeniowej, gdzie dokonywano etykietowania, wstępnej filtracji oraz odrzucania zaszumionych danych. Następnie trenowano różne modele sieci neuronowych. Wytrenowane modele ładowano z powrotem do aplikacji, umożliwiając predykcję aktualnej fazy oddechu nagrywającego. Poszczególne etapy zostały zaprezentowane na rysunku 3.1.



Rys. 3.1. Schemat systemu (źródło własne)

Opis architektury aplikacji, jak również użytych sensorów do pomiarów znajduje się w dalszej części pracy.

3.2. Protokół Bluetooth Low Energy (Damian Jankowski)

Bluetooth Low Energy (BLE) to wersja protokołu Bluetooth, zaprojektowana specjalnie z myślą o aplikacjach wymagających niskiego poboru energii i transmisji danych na niewielkie odległości. Jest powszechnie stosowany w urządzeniach przenośnych, takich jak czujniki medyczne, zegarki sportowe czy urządzenia IoT (Internet of Things), które wymagają długotrwałej pracy na małych bateriach. BLE różni się od tradycyjnego Bluetooth przede wszystkim tym, że wykorzystuje mniej energii przy jednoczesnym utrzymaniu niskich opóźnień w przesyłaniu danych.

3.2.1. Serwis i charakterystyka w BLE


W architekturze BLE, komunikacja opiera się na strukturze złożonej z serwisów (*services*) i charakterystyk (*characteristics*). Zgodnie z artykułem [18] każde urządzenie BLE może udostępniać jeden lub więcej serwisów, z których każdy zawiera różne charakterystyki, przechowujące dane pomiarowe lub ustawienia.

- **Serwis** – Serwis to grupa funkcji oferowanych przez urządzenie BLE, które zwykle dotyczą określonej funkcji lub działania, np. monitorowania siły, pomiaru tętna czy przesyłania danych z czujnika temperatury. Każdy serwis jest identyfikowany przez unikalny identyfikator UUID (Universally Unique Identifier).


- **Charakterystyka** – Charakterystyka to pojedyncza, najmniejsza jednostka danych, która umożliwia odczyt lub zapis informacji w urządzeniu BLE. Każda charakterystyka jest również identyfikowana przez UUID i może zawierać różne atrybuty, takie jak możliwość odczytu lub zapisu danych (oznaczane jako R lub W) oraz opcje subskrypcji, dzięki czemu urządzenie klienckie może otrzymywać powiadomienia o zmianach wartości.

3.2.2. Przykład użycia BLE w aplikacji nRF Connect

Do monitorowania komunikacji z sensorami i przeglądania ich serwisów i charakterystyk użyto aplikacji nRF Connect for Mobile dostępnej w sklepie Google Play [19]. Dzięki niej można połączyć się z urządzeniem BLE, przeglądać dostępne serwisy oraz sprawdzić wartości charakterystyk. Na rysunkach 3.2 oraz 3.3 przedstawiono przykładowe informacje dotyczące akcelometru iNode.



Rys. 3.2. Wynik skanowania w aplikacji, widoczny sensor iNode (źródło własne)





Rys. 3.3. Szczegóły wybranego serwisu i charakterystyki. Widoczna 13-bajtowa ramka surowych danych (źródło własne)

3.3. Tensometr (Damian Jankowski)

Tensometr HX711 przedstawiony na rysunkach 3.4 oraz 3.6 zbudowany jest w układzie pełnego mostka Wheatstone'a. Mierzy zmiany napięcia wynikające z naprężenia paska umieszczonego wokół klatki piersiowej. Tensometr ma wymiary 80x13x13mm i maksymalną obciążalność 2kg. Wyjściowe napięcie proporcjonalne do siły jest wzmacniane przez układ HX711, który dostarcza sygnał o konfigurowalnym wzmocnieniu (64 lub 128). Dane są przetwarzane z częstotliwością próbkowania 10Hz (domyślnie) lub 80Hz, w zależności od konfiguracji, a następnie przesyłane bezprzewodowo do urządzeń mobilnych za pomocą mikrokontrolera ESP32, który działa jako moduł Bluetooth Low Energy (BLE).

Tensometr został zbudowany w ramach pracy magisterskiej Dariusza Biernackiego [20], której celem była analiza oddechu człowieka przy użyciu mobilnych czujników. Praca obejmuje przegląd literatury dotyczącej monitorowania częstotliwości oddechu oraz zastosowań czujników w kontekście hospitalizacji i sportu.



Rys. 3.4. Tensometr HX711 (źródło własne)

3.3.1. Moduł BLE

Do komunikacji z tensometrem za pomocą technologii Bluetooth Low Energy, użyto mikrokontrolera ESP32 widocznego na rysunkach 3.5 oraz 3.6. Moduł BLE został zaprogramowany przy użyciu biblioteki `arduino-esp32`, jak opisano w pracy [20]. Proces komunikacji opierał się na wymianie danych zgodnie ze standardem BLE, w szczególności z użyciem zdefiniowanego UUID usługi oraz charakterystyki tensometru przedstawionych w listingu 3.1.

```
1 const TENS_SERVICE_UUID = "6e400001-b5a3-f393-e0a9-e50e24dcca9e";
2 const TENS_CHARACTERISTIC_UUID = "6e400003-b5a3-f393-e0aa9-e50e24dcca9e";
```

Listing 3.1: UUID usługi oraz charakterystyki BLE dla tensometru
(źródło własne: `brp-app/src/screens/ConnectScreen.tsx`)



Rys. 3.5. Moduł BLE tensometru (źródło własne)




Rys. 3.6. Tensometr HX711 podłączony do mikrokontrolera ESP32 (źródło własne)

3.4. Akcelerometr (Damian Jankowski)

3.4.1. iNode Nav

iNode Nav widoczny na rysunku 3.7 to bezprzewodowy sensor monitorujący ruch i pole magnetyczne, wyposażony w rejestrator oraz 14-bitowy czujnik ruchu i 3-osiowy akcelerometr. Dzięki komunikacji za pomocą Bluetooth Low Energy, przesyła dane w czasie rzeczywistym do urządzeń końcowych, np. smartfonów.



Rys. 3.7. Akcelerometr iNode Nav (źródło własne)

Aby urządzenie mogło rozpocząć rejestrowanie danych, najpierw trzeba ustawić tryb pracy, częstotliwość notyfikacji i rodzaj przesyłanych danych. W przypadku tego konkretnego modelu, możliwe ustawienia zapisuje się na dwóch bajtach do UUID_ACC_CHARACTERISTIC. Sposób zapisu poszczególnych bajtów oraz adresy UUID urządzenia przedstawione zostały w tabelach 3.1, 3.2 oraz 3.3.

04710c44-c624-de89-c1bc-4396089d1886	UUID_ACC_SERVICE	
04710c43-4c62-4de8-9c1b-c439689d1886	UUID_ACC_CHARACTERISTIC	RW
0x2901		
0x2902	UUID_CLIENT_CONFIG	W

Tabela 3.1. Adresy UUID serwisów oraz charakterystyk dla iNode (źródło [21])

b_7	b_6	b_5	b_4	b_3	b_2	b_1	b_0
	0	0	1	1.5625 Hz			
	0	1	0	3.25 Hz			
	0	1	1	6.25 Hz			
	1	0	0	25 Hz			
	1	0	1	50 Hz			
0	AC (tylko składowa zmienna z akcelerometru)						
1	DC (składowa zmienna i składowa stała z akcelerometru)						

Tabela 3.2. Możliwe ustawienia czujnika iNode Nav. Bajt 1 (źródło [21])

b_7	b_6	b_5	b_4	b_3	b_2	b_1	b_0
				0	0	dane z akcelerometru i magnetometru	
				0	1	tylko dane z akcelerometru	
				1	0	tylko dane z magnetometru	
				1	1	dane z akcelerometru i magnetometru	
			0	wysyłaj każdą próbkę			
			1	wysyłaj co drugą próbkę			
			(częstotliwość notyfikacji będzie dwa razy mniejsza od ustawionej)				

Tabela 3.3. Możliwe ustawienia czujnika iNode Nav. Bajt 2 (źródło [21], z wprowadzoną poprawką w związku z błędem w dokumentacji producenta)

Podczas nagrywania danych, sensor ten pracował w ustawieniu 0xc0, 0x04, tj. częstotliwość wysyłania 25 razy na sekundę oraz tryb *tylko dane z akcelerometru*. W tym trybie urządzenie wysyła dane przez tzw. notyfikacje w paczkach po 7 bajtów przedstawionych w tabeli 3.4.

ACC_X	ACC_X	ACC_Y	ACC_Y	ACC_Z	ACC_Z	PACKET
LSB	MSB	LSB	MSB	LSB	MSB	NUMBER

Tabela 3.4. Ramka danych wysyłana przez sensor iNode w trybie *tylko dane z akcelerometru* (źródło [21])

gdzie:

- ACC_X, ACC_Y, ACC_Z - Wartości przyspieszenia w jednostkach $1/16000 \text{ m/s}^2$ w poszczególnych osiach XYZ
- PACKET NUMBER - Numer pakietu, który jest zwiększany o jeden (lub o dwa, jeśli wybrano wysyłanie co drugiej próbki danych) przy każdym jego wysłaniu przez sensor

Sieci neuronowe oraz aplikacja mobilna zostały zaprojektowane w taki sposób, aby na wejściu przyjmować wartość równą sumie wartości bezwzględnych trzech składowych osi XYZ. Proces ten został przedstawiony w listingu 3.2. Takie podejście pozwala na redukcję wymiarowości danych wejściowych, co upraszcza działanie modeli i zmniejsza ich złożoność obliczeniową. Suma bezwzględna składowych XYZ stanowi miarę całkowitej aktywności ruchowej niezależnej od kierunku, co jest szczególnie użyteczne w kontekście analizy ruchu.

```

1 const computeNodeValue = (data: { value: Iterable<number> }) => {
2   const bytes = new Int8Array(data.value);
3
4   const axL = bytes[0];
5   const axH = bytes[1];
6   const ayL = bytes[2];
7   const ayH = bytes[3];
8   const azL = bytes[4];
9   const azH = bytes[5];
10
11  const ax = (axH * 256 + axL) / 16000.0;
12  const ay = (ayH * 256 + ayL) / 16000.0;
13  const az = (azH * 256 + azL) / 16000.0;
14
15  const sumAcc = Math.abs(ax + ay + az);
16
17  return sumAcc;
18 };

```

Listing 3.2: Kod konwertujący poszczególne bajty notyfikacji z sensora na wartości przyspieszenia
(źródło własne: `brp-app/src/screens/ConnectScreen.tsx`)

3.4.2. WitMotion WT901BLECL

Czujnik WitMotion WT901BLECL przedstawiony na rysunku 3.8 to urządzenie Bluetooth 5.0 wyposażone w szereg sensorów, które umożliwiają pomiar przyspieszenia, prędkości kątowej, kąta oraz pola magnetycznego. Dzięki solidnej obudowie i kompaktowym rozmiarom idealnie nadaje się do zastosowań przemysłowych, takich jak monitorowanie stanu maszyn oraz predykcyjne utrzymanie ruchu. Urządzenie można skonfigurować do wielu różnych zastosowań, umożliwiając interpretację danych za pomocą algorytmów i filtracji Kalmana.

Oferuje on następujące parametry:

1. Akcelerometr:

- Zakres: $\pm 16g$
- Rozdzielczość: $0.0005, g/LSB$

2. Żyroskop:

- Zakres: $\pm 2000^\circ/s$
- Rozdzielczość: $0.061^\circ/s/LSB$

3. Inklinometr:

- Zakres dla osi X i Z: $\pm 180^\circ$
- Zakres dla osi Y: $\pm 90^\circ$
- Dokładność nachylenia: 0.2° przy prędkości kątowej $\pm 2000^\circ/s$
- Rozdzielczość: 0.0055° (przy urządzeniu umieszczonym poziomo)



Rys. 3.8. Akcelerometr WitMotion WT901BLECL (źródło własne)

Ustawienia i tryby pracy czujnika

Domyślnie sensor wysyła dane z częstotliwością 10 Hz. Aby to zmienić, użytkownik może wysłać ramkę konfiguracyjną, widoczną w tabelach 3.6 oraz 3.7. Podobnie jak w przypadku sensora iNode, do tego celu potrzebne są adresy rejestrów do komunikacji, przedstawione w tabeli 3.5.

0000ffe5-0000-1000-8000-00805f9a34fb	UUID_ACC_SERVICE	
0000ffe4-0000-1000-8000-00805f9a34fb	UUID_ACC_CHARACTERISTIC	R
0000ffe9-0000-1000-8000-00805f9a34fb	UUID_ACC_CHARACTERISTIC_WRITE	W

Tabela 3.5. Adresy UUID serwisów oraz charakterystyk dla WitMotion (źródło [22])

Ramka konfiguracyjna częstotliwości wysyłania danych

B_4	B_3	B_2	B_1	B_0
FF	AA	03	RATE	00

Tabela 3.6. Struktura ramki sensora WitMotion (źródło [22])

RATE	Częstotliwość
0x01	0,1 Hz
0x02	0,5 Hz
0x03	1 Hz
0x04	2 Hz
0x05	5 Hz
0x06	10 Hz (domyślnie)
0x07	20 Hz
0x08	50 Hz
0x09	100 Hz
0x0A	200 Hz

Tabela 3.7. Możliwe ustawienie częstotliwości wysyłania danych dla sensora WitMotion (źródło [22])

Ramka konfiguracyjna częstotliwości wysyłania danych określa, jak często dane są przesyłane z modułu. Parametr RATE definiuje częstotliwość przesyłania w hercach (Hz), z domyślną wartością ustawioną na 10 Hz. W zależności od zastosowania, użytkownik może zmienić częstotliwość przesyłania na wartości od 0,1 Hz do 200 Hz, wybierając odpowiednią wartość RATE.

Format danych

Moduł wysyła dane z domyślnym ustawieniem flagi 0x61, obejmującym dane dotyczące kąta, prędkości kątowej oraz przyspieszenia. Aby wysłać dane dotyczące pola magnetycznego, konieczne jest ustawienie flagi 0x71 oraz wysłanie odpowiedniej instrukcji rejestrowej. Moduł przesyła do 20 bajtów danych za pomocą Bluetooth w formacie przedstawionym w tabeli 3.8.

Bajt	Dane	Opis
B_0	0x55	Nagłówek pakietu
B_1	0x61	Flaga
B_2	axL	Przyspieszenie w osi X
B_3	axH	
B_4	ayL	Przyspieszenie w osi Y
B_5	ayH	
B_6	azL	Przyspieszenie w osi Z
B_7	azH	
B_8	wxL	Prędkość kątowa w osi X
B_9	wxH	
B_{10}	wyL	Prędkość kątowa w osi Y
B_{11}	wyH	
B_{12}	wzL	Prędkość kątowa w osi Z
B_{13}	wzH	
B_{14}	RollL	Kąt w osi X
B_{15}	RollH	
B_{16}	PitchL	Kąt w osi Y
B_{17}	PitchH	
B_{18}	YawL	Kąt w osi Z
B_{19}	YawH	

Tabela 3.8. Format pakietu danych dla czujnika WitMotion (źródło [22])

Poniżej przedstawiono przykłady konwersji danych dla jednej z osi współrzędnych.

Metoda obliczania przyspieszenia:

$$a_x = \frac{(a_{xH} \cdot 256) + a_{xL}}{32768} \cdot 16g \quad (g = \text{przyspieszenie ziemskie, } 9,8 \text{ m/s}^2)$$

Metoda obliczania prędkości kątowej:

$$\omega_x = \frac{(w_{xH} \cdot 256) + w_{xL}}{32768} \cdot 2000 \quad (^\circ/\text{s})$$

Metoda obliczania kąta:

$$\text{Roll (oś X)} = \frac{(\text{Roll}_H \cdot 256) + \text{Roll}_L}{32768} \cdot 180 \quad (^\circ)$$

3.5. Aplikacja mobilna (Damian Jankowski)

Aplikacja na Androida, została stworzona z wykorzystaniem technologii React Native oraz języków Typescript i Java. Modele predykcji stanu oddechu są ładowane wraz ze startem aplikacji z plików w formacie .tftlite (format dostosowany do mikroprocesorów, telefonów ze względnie niską wydajnością).

Dodatkową funkcjonalnością jest automatyczny zapis wszystkich pomiarów w formacie tekstowym. W trakcie pomiaru, tworzone są pliki w folderze „Pobrane” na telefonie użytkownika, a w nich zapisywane są kolejne wartości z sensorów wraz z aktualnym czasem.


Kod odpowiedzialny za obsługę sieci neuronowych został napisany w języku Java, ponieważ framework React Native nie zapewnia odpowiedniego wsparcia do pracy z TensorFlow. Java wczytuje gotowy model sieci neuronowej i wykorzystuje go do prognozowania stanu oddechu, co umożliwia wykonywanie obliczeń związanych z predykcją w aplikacji.

3.6. Architektura aplikacji


3.6.1. Ekrany (Damian Jankowski)

Dla użytkownika udostępniono 4 ekrany, jak pokazano na rysunkach 3.9 i 3.10:

- ekran połączenia, w którym można wybrać odpowiedni sensor (wspierane są urządzenia: tensometr HX711, akcelerometr iNode Nav oraz akcelerometr WT901BLECL);
- ekran wykresów, w którym można rozpocząć pomiar lub w przypadku braku dostępnych sensorów, uruchomić wersję demonstracyjną;
- ekran statystyk, w którym dostępne są dane dotyczące oddechu, takie jak liczba oddechów czy ich częstotliwość;
- ekran ustawień, w którym można przełączyć domyślny model predykcyjny na inny.




(a)




(b)

Rys. 3.9. Wygląd aplikacji. Ekran połączenia a) oraz ekran wykresów b). (źródło własne)




(a)



(b)

Rys. 3.10. Wygląd aplikacji. Ekran statystyk a) oraz ekran ustawień b). (źródło własne)

3.6.2. Schemat działania aplikacji ze strony urządzenia (Maciej Szeffler)




Rys. 3.11. Diagram sekwencji struktury aplikacji (źródło własne)

Opis poszczególnych funkcji przedstawionych na diagramie 3.11:

1. *handleAndroidPermissions*: funkcja, która na podstawie aktualnego systemu oraz wersji API systemu Android, wymaga określonych uprawnień do prawidłowego działania. Po uruchomieniu aplikacji, funkcja asynchronicznie pyta użytkownika o uprawnienia:
 - `BLUETOOTH_SCAN` - umożliwia skanowanie urządzeń przez protokół bluetooth;
 - `BLUETOOTH_CONNECT` - umożliwia na łączenie się z urządzeniami;
 - `ACCESS_FINE_LOCATION` - umożliwia udostępnienie lokalizacji użytkownika za pomocą WIFI + GPS. Jest to uprawnienie wymagane przez system Android w wersji API < 31;
 - `READ_EXTERNAL_STORAGE` - umożliwia odczyt plików z urządzenia użytkownika. Jest to uprawnienie wymagane do odczytywania plików tekstowych z pomiarami w wersji demonstracyjnej;
 - `WRITE_EXTERNAL_STORAGE` - umożliwia zapis plików na urządzeniu użytkownika. Jest to uprawnienie wymagane do zapisywania pełnych pomiarów na urządzeniu użytkownika.
2. *startScan*: funkcja umożliwiająca rozpoczęcie skanowania urządzeń bluetooth w otoczeniu użytkownika. Używana biblioteka to `react-native-ble-manager`. Każde urządzenie bluetooth posiada numer UUID, będący odpowiednikiem numeru seryjnego.

3. *setPeripherals*: po znalezieniu urządzeń, funkcja dodaje je do listy znanych sensorów w otoczeniu.
4. *retrieveConnected*: funkcja, po wyszukaniu urządzenia, wyświetla tylko te, które należą do predefiniowanej listy 3 urządzeń i ich charakterystyk: iNode Nav, WitMotion WT901BLECL, Tensometr HX711. Urządzenia te są przygotowane do połączenia.
5. *connectPeripheral*: funkcja wywoływana, gdy użytkownik kliknie na dane urządzenie z prezentowanej listy w celu połączenia. Każde urządzenie BLE (Bluetooth Low Energy) podzielone jest na charakterystyki oraz serwisy. Każda charakterystyka może posiadać wiele serwisów. Funkcja, po otrzymaniu urządzenia, wyszukuje dostępne charakterystyki i serwisy. Łącząc się z urządzeniem, wysyła komunikat o konfiguracji działania urządzenia (np. format danych, częstotliwość ich otrzymywania). Następnie rozpoczyna notyfikację odpowiedniego serwisu przechowującego dane pomiarowe, co polega na zasubskrybowaniu odpowiedniego kanału i ciągłym przetwarzaniu otrzymanych danych.
6. *computeTensometerValue* oraz *computeAccelerometerValue*: po rozpoczęciu notyfikacji, wszystkie otrzymywane dane są przesyłane w bajtach i dekodowane na format liczbowy. Dekodowanie danych dla tensometru oparte jest na dokumentacji [20], a dla akcelerometrów na dokumentacjach [22] oraz [21].
7. *setTensPoints* oraz *setAccPoints*: funkcje te ustawiają notyfikowane dane z odpowiednich czujników (tensometru lub akcelerometru), które następnie są przesyłane do dalszego przetwarzania.
8. *movingAverage*: funkcja stosuje algorytm średniej kroczącej na otrzymanych danych, w celu ich wygładzenia. Krok algorytmu zależy od wykorzystywanego sensoru. W przypadku tensometru i akcelerometru WitMotion krok wynosi 5, co odpowiada pomiarowi 0,5 sekundy przy częstotliwości 10Hz. W przypadku akcelerometru iNode Nav krok wynosi 11, co odpowiada około 0,5 sekundy przy częstotliwości 25Hz. Algorytm bierze pod uwagę dane z określonego kroku i wygładza je względem ich średniej.
9. *normalize*: funkcja normalizuje dane do przedziału $<-1, 1>$. W przypadku pomiarów na różnych badanych, dane zwracane przez sensory charakteryzują się dużymi nierównościami. Normalizacja zapobiega nienormalywnym danym, tworząc z nich zuniwersalizowane przypadki testowe.
10. *predictData*: funkcja, na podstawie otrzymanych danych, zwraca predykcję modelu. Model przypisuje próbki do jednej z 4 kategorii przedstawionych w tabeli 3.9. Każdy model otrzymuje inną liczbę próbek. Dla tensometru i akcelerometru WitMotion jest to 5 próbek pomiarowych i 1 próbka oznaczająca amplitudę. Dla akcelerometru iNode Nav jest to 11 próbek pomiarowych i 1 próbka oznaczająca amplitudę. Na podstawie otrzymanej kategorii, fragment dla tych próbek jest kolorowany w celu łatwiejszej wizualizacji.
11. *loadModel* oraz *loadAccModel*: funkcje te wykonują żądanie do kodu natywnego w Javie w celu załadowania nowego modelu predykcyjnego. Proces polega na usunięciu starego modelu z pamięci i zastąpieniu go nowym, w zależności od wyboru użytkownika (dla tensometru lub akcelerometru).

3.6.3. Schemat działania aplikacji ze strony użytkownika (Filip Krawczak)



Rys. 3.12. Diagram przepływu aplikacji z punktu widzenia użytkownika (źródło własne)

Opis poszczególnych etapów na podstawie diagramu 3.12:

1. Użytkownik inicjuje działanie aplikacji, która w pierwszej kolejności wymaga uzyskania zgody na aktywację modułu Bluetooth. W przypadku urządzeń pracujących na systemie Android w wersji niższej niż 11, aplikacja dodatkowo żąda uprawnień do dostępu do lokalizacji. Udzielenie zgody na wymagane uprawnienia jest niezbędne do dalszego działania aplikacji.
2. Po uruchomieniu aplikacji, ładowany jest domyślny model sieci neuronowej, którym jest model GRU
3. Użytkownik ma możliwość przejścia do sekcji "SETTINGS", gdzie może zmienić domyślnie załadowany model GRU na inny, spośród dostępnych modeli. Po dokonaniu zmiany, wybrany model jest wskazywany na interfejsie użytkownika za pomocą zielonego tła.
4. W sekcji "CONNECT" użytkownik może aktywować funkcję "Scan Bluetooth", inicjując proces wyszukiwania dostępnych urządzeń Bluetooth, które mogą być sparowane z aplikacją.
5. Wyniki skanowania wyświetlane są w sekcji "CONNECT", gdzie użytkownik może wybrać urządzenie docelowe do połączenia. W przypadku pomyślnego nawiązania połączenia, tło wybranego urządzenia zmienia kolor na zielony.
6. Po ustanowieniu prawidłowego połączenia z urządzeniem, użytkownik przechodzi do sekcji "CHARTS" i aktywuje proces pomiaru, naciskając przycisk "START". Dane pomiarowe są następnie wizualizowane w postaci wykresu.
7. W lewym górnym rogu interfejsu użytkownika wyświetlany jest czas trwania pomiaru, natomiast w prawym górnym rogu prezentowana jest liczba wykrytych cykli oddechowych.
8. Funkcja "STOP" umożliwia zatrzymanie procesu pomiarowego, natomiast przycisk "RESET" pozwala na wyczyszczenie wykresu i zresetowanie wyników.
9. Przy użyciu przycisku "DEMO" użytkownik może uruchomić symulację pomiaru, bez konieczności łączenia się z urządzeniami zewnętrznymi. W takim przypadku dane pomiarowe są odczytywane z wbudowanego pliku dołączonego do aplikacji.
10. Zarówno w trakcie pomiaru, jak i po jego zakończeniu, użytkownik może przejść do sekcji "STATISTICS", gdzie prezentowane są obliczenia statystyczne, takie jak średnia liczba oddechów na minutę oraz całkowita liczba wykrytych oddechów zarejestrowanych podczas pomiaru.

3.7. Repozytorium *brp-app* (Damian Jankowski)

W tym repozytorium znajdują się pliki źródłowe aplikacji mobilnej [23], które zostały stworzone z wykorzystaniem frameworka React Native w wersji 0.74.3 oraz Node.js w wersji 18. Aplikacja jest zaprojektowana do działania na urządzeniach z systemem Android w wersji 11 lub wyższej. Poniżej znajduje się szczegółowy opis struktury repozytorium oraz roli poszczególnych folderów i plików w aplikacji.

- `android/` – folder zawierający pliki niezbędne do budowania aplikacji na system Android. Szczególną uwagę należy zwrócić na:
 - `android/app/src/main/assets` – znajduje się tutaj folder z wytrenowanymi modelami w formacie `tflite`, które są wykorzystywane przez aplikację do przetwarzania danych.
 - `android/app/src/main/java/com/brpapp/` – folder z kodem aplikacji w języku natywnym w Javie, który odpowiada za wczytywanie modeli przy starcie aplikacji oraz integrację z systemem Android.
- `src/` – folder zawierający pliki źródłowe aplikacji, napisane w języku TypeScript przy użyciu frameworka React Native. Folder ten zawiera logikę aplikacji, zarządzanie stanem oraz komponenty interfejsu użytkownika.
- `src/screens/` – folder z plikami źródłowymi odpowiadającymi za poszczególne ekrany aplikacji. W szczególności:
 - `src/screens/ChartsScreen.tsx` – ekran odpowiedzialny za odbieranie danych z urządzeń, przetwarzanie ich przez model oraz generowanie wykresów. Ekran ten jest również odpowiedzialny za tworzenie nagrań do pliku tekstowego.
 - `src/screens/ConnectScreen.tsx` – ekran służący do łączenia się z urządzeniami Bluetooth (BLE). W przypadku rozszerzenia wsparcia dla innych sensorów, konieczne będzie uzyskanie adresów charakterystyk i serwisów urządzenia BLE, nazwy urządzenia, a następnie dodanie algorytmu do odczytu surowych danych bajtowych oraz ich konwersji na odpowiednie wartości.
 - `src/screens/SettingsScreen.tsx` – ekran ustawień, na którym można wybrać aktualnie używany model sieci neuronowej. Obecnie dostępne modele to LSTM oraz GRU.
 - `src/screens/StatisticScreen.tsx` – ekran, na którym można przeglądać statystyki dotyczące liczby wykonanych cykli oddechowych oraz ich średnią liczbę na minutę.

3.8. Repozytorium *brp-ml-model* (Damian Jankowski)

Wykorzystywany w repozytorium kod [24] oparty jest na Pythonie w wersji 3.11 oraz bibliotece TensorFlow w wersji 2.15.0. Poniżej przedstawiono szczegóły struktury repozytorium oraz funkcje wybranych skryptów.


- `data/` – folder zawierający zbiory danych pochodzących z sensorów. Dane są zorganizowane w podfoldery, rozdzielając je na dane surowe i otagowane. Dane surowe można wstępnie zaklasyfikować za pomocą dostępnych skryptów w folderze `scripts`.
- `graphs/` – folder przechowujący grafiki generowane przy użyciu biblioteki `matplotlib`.
- `models/` – folder zawierający pliki źródłowe modeli, w tym definicje ich warstw oraz funkcji trenowania. Aby dodać nowy model sieci neuronowej, należy utworzyć klasę dziedziczącą po jednej z dostępnych abstrakcji: `AbstractModel` lub `SequentialModel`.

- `AbstractModel` – umożliwia tworzenie modeli z bardziej zaawansowaną logiką i strukturą, wymagających ręcznej implementacji metod trenowania i ewaluacji.
- `SequentialModel` – ułatwia definiowanie modeli opartych na sekwencyjnej strukturze warstw, dostosowanych do standardowych przypadków użycia.
- `notebooks/` – folder, w którym znajdują się pliki Jupyter Notebook, umożliwiające analizę i wizualizację danych w sposób interaktywny.
- `scripts/` – folder zawierający różne skrypty pomocnicze, przydatne do przetwarzania danych, ich klasyfikacji oraz wizualizacji. Szczegółowy opis wybranych skryptów znajduje się poniżej:
 - `categorise_automatically.py` – skrypt, który automatycznie etykietuje dane surowe na podstawie obliczeń pochodnych.
 - `categorise_by_model.py` – umożliwia wstępną klasyfikację danych przy użyciu już wytrenowanego modelu.
 - `convert_timestamps.py` – skrypt konwertujący dane czasowe z oryginalnych jednostek na kolejne sekundy pomiaru.
 - `labelling.py` – narzędzie do ręcznej korekty etykiet danych. Umożliwia równoczesne etykietowanie danych pochodzących z tensometru oraz akcelerometru. Użytkownik może poruszać się po wykresach przy użyciu strzałek w lewo i prawo, co przesuwa okno czasowe. Po wciśnięciu klawisza `M` (multiple) aktywowany jest tryb wielokrotnego wyboru, a kliknięcie na daną próbkę otwiera okno wyboru etykiety. Przykładowe okno wyboru klasyfikacji jest przedstawione na rysunku 3.13, a widok skryptu z zaznaczeniem przedziału czasowego można zobaczyć na rysunku 3.14.
 - `load_data.py` – zawiera przydatne funkcje do zapisu i odczytu danych, a także do przygotowania danych do trenowania modeli.
 - `normalization.py` – implementuje algorytmy normalizacji oraz średniej kroczącej dla danych wejściowych.
 - `plot.py` – funkcje umożliwiające tworzenie wykresów.
 - `transfer_labels.py` – zawiera funkcje do przenoszenia etykiet z jednego zbioru danych do drugiego.
- `main.py` – główny skrypt zawierający logikę trenowania modeli, pozwalający na wskazanie modelu do treningu oraz zbioru danych, na którym model będzie trenowany.

Aby przeprowadzić wstępne przetwarzanie danych, użytkownik może umieścić swoje dane w odpowiednich folderach w katalogu `data`. Następnie należy uruchomić skrypt `categorise_automatically.py` lub `categorise_by_model.py`, który dokona wstępnej klasyfikacji. Wynik tej klasyfikacji może zostać zweryfikowany i poprawiony za pomocą skryptu `labelling.py`. Widok interfejsu skryptu `labelling.py`, z możliwością zaznaczania przedziałów czasowych i wyboru odpowiednich etykiet, przedstawiono na rysunkach 3.13 i 3.14.



Rys. 3.13. Okienko wyboru zmiany klasyfikacji przedziału (źródło własne)



Rys. 3.14. Skrypt do ręcznej klasyfikacji danych z widocznym zaznaczeniem przedziału czasu do etykietowania (źródło własne)

Dane przygotowane i skorygowane przez użytkownika można przekształcić na format wymagany do trenowania modeli za pomocą funkcji `prepare_data_for_training()` w skrypcie `load_data.py`. Wybrany model, znajdujący się w folderze `models`, może być następnie trenowany i testowany na tych danych, co pozwoli uzyskać dokładność klasyfikacji wyświetlaną po zakończeniu procesu.


3.9. Akwizycja danych (Maciej Szeffler)

Aplikację skonfigurowano w sposób umożliwiający przechowywanie maksymalnie 300 próbek, co odpowiada 30 sekundom pomiaru w 10 Hz. Każda próbka była rejestrowana co 0,1 sekundy, co zapewniało częstotliwość 10 Hz dla tensometru oraz akcelerometru WitMotion. W przypadku akcelerometru iNode Nav, próbki dostarczano co 0,04 sekundy, co odpowiadało częstotliwości 25 Hz.


Zebrane dane zostały następnie przetworzone w celu przeprowadzenia analizy i klasyfikacji. Pierwszym etapem przetwarzania była normalizacja, która umożliwiła skalowanie wartości do zakresu od -1 do 1 w przesuwanym oknie o kroku 150 próbek dla urządzeń działających w częstotliwości 10 Hz oraz 375 próbek dla urządzeń działających w częstotliwości 25 Hz. Krok ten wynikał z okna czasowego widocznego dla użytkownika, wynoszącego 15 sekund. Procedura ta okazała się niezbędna do zapewnienia spójności i porównywalności danych.

Kolejnym etapem było zastosowanie średniej kroczącej. Algorytm ten oblicza średnią wartość z określonej liczby ostatnich próbek w sekwencji danych (zwanych krokiem), przesuwając okno obliczeniowe o jedną próbkę przy każdej iteracji. Dzięki temu eliminuje krótkoterminowe fluktuacje i uwydatnia długoterminowe trendy w danych. W przypadku tensometru i akcelerometru

WitMotion zastosowano krok w wysokości 5, natomiast dla akcelerometru iNode Nav krok wyniósł 11. Przetworzone w ten sposób dane zostały również przedstawione na wykresach w aplikacji mobilnej, zapewniając ich czytelną i ujednoliconą wizualizację.




(a)




(b)

Rys. 3.15. Nagrany fragment wdechu z bezdechem (a) przed przetworzeniem średnią kroczącą oraz normalizacją (b) po przetworzeniu średnią kroczącą oraz normalizacją (źródło własne)

Wykresy 3.15 przedstawiają wybrany fragment zestawu danych uzyskanego podczas pomiaru wdechu z bezdechem przy użyciu tensometru. Zastosowanie średniej kroczącej umożliwiło wygładzenie występujących szumów, tak jak jest to widoczne na 3.15b.



(a)



(b)

Rys. 3.16. Nagrany fragment hiperwentylacji (a) przed przetworzeniem średnią kroczącą oraz normalizacją (b) po przetworzeniu średnią kroczącą oraz normalizacją (źródło własne)

Wykresy 3.16 prezentują wybrany fragment zestawu danych zarejestrowanego podczas pomiaru hiperwentylacji przy użyciu akcelerometru. Analogicznie jak w poprzednim przypadku, średnia krocząca została wykorzystana do redukcji ewentualnych szumów, tak jak jest to widoczne na 3.16b.

Ze względu na charakterystykę wykorzystanych sensorów, w sytuacji, gdy w określonym zakresie czasowym wartości próbek wzrastały, klasyfikowano je jako wdech; dla próbek malejących jako wydech. Niewielkie zmiany wartości próbek interpretowano jako bezdech po wdechu lub bezdech po wydechu (retencję). Do wstępnej klasyfikacji wykorzystano algorytm pochodnej, której dokładny opis znajduje się w rozdziale 3.11. W procesie analizy, każdemu z tych stanów przypisano odpowiednią wartość liczbową, zaprezentowaną w tabeli 3.9.

Tabela 3.9. Liczbowa reprezentacja stanów (źródło własne)

Stan	Reprezentacja
Wydech	0
Retencja po wydechu	1
Wdech	2
Retencja po wdechu	3
Szum	999

Dla fragmentów danych zawierających znaczące zakłócenia uniemożliwiające ich wykorzystanie w procesie treningu przygotowano osobną klasę. Fragmentom tym przypisano wartość klasy 999, a próbki należące do tej klasy zostały wykluczone ze zbioru treningowego.

Kolejnym etapem było przygotowanie danych treningowych. W tym celu przeprowadzono ponad 150 minut pomiarów różnych faz oddechu w wielu konfiguracjach: 80 minut z użyciem tensometru, 45 minut z akcelerometrem iNode Nav oraz 25 minut z akcelerometrem WitMotion. Poszczególne zbiory danych treningowych dla tensometru, zaprezentowano w tabeli 3.10. Dodatkowo opracowano dwa pięciominutowe zbiory testowe, które zawierały wszystkie konfiguracje występujące w zbiorze treningowym. Przykładowy rozkład zbioru testowego, został przedstawiony w tabeli 3.11. Jako cechę opisującą aktualne stadium oddechu zastosowano amplitudę, która została wykorzystana w dalszym procesie trenowania sieci neuronowych. Następnie dane poddano filtrowaniu oraz klasyfikacji zgodnie z wcześniej opisanym schematem.


Rodzaj oddechu	Czas pomiaru [s]	Ilość cykli oddechu
Kaszel	268	151
Oddech płytki	438	260
Oddech wolny	438	51
Bezdech i wdech	274	33
Bezdech i wydech	275	35
Wdech i zatrzymanie	425	41
Wydech i zatrzymanie	423	37
Hiperwentylacja	272	300
Zwykły oddech	384	71
Zbiór od mężczyzny w wieku 50+	602	136
Zbiór od kobiety w wieku 50+	603	205
Dodatkowy zbiór wdech i zatrzymanie	598	52

Tabela 3.10. Poszczególne rodzaje i rozmiary danych tensometru w procesie trenowania modeli (źródło własne)


Rodzaj oddechu	Czas pomiaru [s]	Ilość cykli oddechu
Kaszel	30	14
Oddech płytki	30	17
Oddech wolny	30	4
Bezdech i wdech	30	4
Bezdech i wydech	30	3
Wdech i zatrzymanie	30	4
Wydech i zatrzymanie	30	4
Hiperwentylacja	30	23
Zwykły oddech	60	20

Tabela 3.11. Poszczególne rodzaje i rozmiary danych w procesie testowania modeli (źródło własne)

3.10. Dane treningowe i testowe (Damian Jankowski)



(a)



(b)


Rys. 3.17. Surowe dane z tensometru (a) i akcelerometru (b) z podziałem na stany oddechu (źródło własne)

Do trenowania modeli przygotowano zbiory danych przedstawione na rysunku 3.17, które były wstępnie zaklasyfikowane używając pochodnej, a następnie poprawione ręcznie używając autorskiej aplikacji. Każdy zbiór danych jest podzielony na pliki tekstowe, z których każdy zawiera konkretne rodzaje wzorców oddechowych, takie jak hiperwentylacja, wolne oddychanie, zatrzymanie oddechu i inne. Pliki są zorganizowane w sposób ułatwiający trenowanie modeli z różnymi scenariuszami oddechowymi.

W każdym zbiorze danych wiersze zawierają znormalizowane wartości, wraz z oznaczeniem typu oddechu i upływającym czasem w sekundach od początku pomiaru, oddzielnymi przecinkami. Warto zauważyć, że wartość typu oddechu odpowiadają tym widocznym w tabeli 3.9.

Eksperyment klasyfikacji skupiał się na szczegółowej analizie danych oddechowych, uzyskanych z użyciem czujników tensometrycznych (HX711) oraz akcelerometrów (iNode Nav, WitMotion). W ramach tego eksperymentu zastosowano następującą metodologię do gromadzenia i przetwarzania danych:

1. W pierwszej kolejności, dane były zbierane za pomocą aplikacji mobilnej, która umożliwiała połączenie z czujnikami i przechowywanie otrzymanych danych. Tensometr HX711 podłączony do mikrokontrolera ESP32 oraz akcelerometr WitMotion, umożliwiały przesyłanie próbek z częstotliwością 10 Hz. Akcelerometr iNode Nav wysyłał dane z częstotliwością 25 Hz.
2. Dane były zbierane od trzech testerów: 22-letniego zdrowego i fizycznie aktywnego mężczyzny oraz dwóch 55-letnich zdrowych, ale nieaktywnych fizycznie osób (jednego mężczyzny i jednej kobiety), a ich wartości oscylowały w zakresie od 500 000 do 900 000. Po zebraniu surowych danych, przeprowadzono normalizację do zakresu (-1,1) w oknie składającym się z 150 próbek dla tensometru i akcelerometru WitMotion oraz oknie składającym się z 375 próbek dla urządzenia iNode Nav, co odpowiadało 15 sekundom pomiaru.
3. Wstępna klasyfikacja faz oddechu odbywała się poprzez analizę zmiany znaku pochodnej sygnału. Wartości pochodnej w zakresie +/- 0,0079 wskazywały na zatrzymanie oddechu i przypisanie do stanu zatrzymanie po wdechu lub zatrzymanie po wydechu, natomiast wartości powyżej 0,0079 oznaczały wdech, a wartości poniżej -0,0079 - wydech. Proces wyznaczania tej wartości przedstawiono w rozdziale 3.11.
4. Przystąpiono do szkolenia modelu sieci neuronowej, wykorzystując powiązane zbiory danych z poprzednich etapów. Każdemu stanowi oddechowemu przypisano określoną wartość numeryczną, co zostało przedstawione w tabeli 3.9.
5. Przeprowadzono ręczną weryfikację i korektę w celu uzyskania ostatecznych etykiet danych. W tym celu użyta została dedykowana aplikacja przedstawiona na rysunku 3.18, która wyświetla szeregi czasowe danych, oznaczone kolorem odpowiadającym określonej klasie. Aplikacja umożliwia zmianę przypisań, wybierając kolor dla określonego zakresu czasu. Procedura polegała na tym, że jedna osoba zajmowała się etykietowaniem danych, a druga osoba je walidowała, co miało na celu zapewnienie jak najwyższej dokładności procesu.



Rys. 3.18. Autorska aplikacja do etykietowania danych (źródło własne)

3.11. Analiza oddechu bazująca na zmianie pochodnej (Filip Krawczak)


Monitorowanie oddechu oparte na analizie zmian pochodnej funkcji, stanowi metodę umożliwiającą podstawowe określenie cykli oddechowych poprzez analizę szybkości zmian sygnałów generowanych przez czujnik mierzący ruchy klatki piersiowej. Technika ta charakteryzuje się prostotą oraz szybkością działania, co pozwala na wykrywanie kolejnych cykli oddechowych w warunkach ograniczonych zasobów obliczeniowych, gdzie zastosowanie bardziej zaawansowanych metod analizy nie jest możliwe. Każdy cykl oddechu składa się z fazy wdechu, wydechu oraz retencji. W idealnych warunkach pochodna podczas wdechu będzie dodatnia, podczas wydechu ujemna, a w czasie retencji będzie zbliżona do zera. Takie warunki są nieosiągalne w rzeczywistości między innymi ze względu na błędy pomiarowe urządzenia, a także na szumy spowodowane pracą mięśni klatki piersiowej czy biciem serca. Aby zminimalizować wpływ szumów i zwiększenie dokładności klasyfikacji oddechu ustalane są granice możliwych wahań wartości współczynnika kierunkowego sygnału. Odpowiednie dostosowanie tego parametru pozwala na zignorowanie niewielkich szumów występujących między innymi podczas retencji. W ramach sprawdzenia dokładności takiego rozwiązania, został napisany skrypt w języku Python, który klasyfikuje kolejne cykle oddechu na podstawie zmiany pochodnej funkcji, której wartości są wyznaczane na podstawie 0,5 sekundy ostatniego pomiaru z sensorów. Jako dane wejściowe, otrzymał nagrany wcześniej zbiór testowy danych oraz ten sam zbiór testowy z prawidłowymi etykietami rodzaju oddechu. Do pozyskiwania danych użyto akcelerometru iNode Nav, który charakteryzuje się wysoką czułością i potrafi wychwycić nawet najmniejsze zmiany w przyspieszeniu. Jednak wraz z jego dużą precyzją pojawia się także podatność na szumy. Na podstawie tych danych skrypt określił granice

możliwych wahań pochodnej funkcji opisującej oddech, jak pokazano w tabeli 3.12. Dzięki tym granicom udało się rozróżnić fazy oddechowe: jeśli zmiana pochodnej przekroczy określoną wartość parametru, jest to sygnał wydechu, w przypadku wartości mieszczących się w wyznaczonym przedziale mówimy o retencji, a gdy pochodna przekroczy granicę w przeciwnym kierunku, mamy do czynienia z wdechem.

Faza oddechowa	Zakres wartości pochodnej
Wydech	$(-\infty, -0,0079)$
Retencja	$\langle -0,0079, +0,0079 \rangle$
Wdech	$(+0,0079, +\infty)$

Tabela 3.12. Podział faz oddechowych na podstawie zbiorów wartości pochodnej funkcji (źródło własne)

Najlepsza uzyskana dokładność klasyfikacji oddechu, oparta wyłącznie na analizie tych zmian, wyniosła 54,56%.



Rys. 3.19. Porównanie rezultatu klasyfikacji oddechu bazując na zmianie pochodnej z wzorcową klasyfikacją (źródło własne)

Na podstawie wykresu 3.19 można zauważyć, że analiza oddechu oparta o zmianę wartości pochodnej nie sprawdza się dobrze dla danych zasumionych. Dynamiczne wdechy i wydechy są w większości prawidłowo klasyfikowane, jednak fazy retencji oraz powolne oddechy są często błędnie rozpoznawane. Znacznie utrudnia to obliczenie ilości oddechów na minutę (RR - Respiratory Rate), co jest istotną informacją w kontekście oceny stanu zdrowia osoby badanej. Metoda oparta na pochodnej ma jednak pewne zalety, jak niska złożoność obliczeniowa, dzięki czemu może działać na mniej wydajnych urządzeniach. Pochodna osiąga również wysokie wyniki w przypadku hiperwentylacji, która charakteryzuje się dynamicznymi wdechami i wydechami, bez

faz retencji. Mimo tych korzyści, na podstawie uzyskanych wyników eksperymentu zrezygnowano z dalszej analizy oddechu opierając się o zmianę wartości pochodnej.

3.12. Algorytm do detekcji cykli oddechowych (Kacper Karski)

Ze względu na niewystarczające wyniki pochodnej, zdecydowano się na zaimplementowanie zaawansowanego algorytmu do detekcji cykli oddechowych. Opracowany system został zaprojektowany w celu rozpoznawania stanu oddechu w czasie rzeczywistym, co ma kluczowe znaczenie dla monitorowania zdrowia i kondycji fizycznej osób badanych. Głównym etapem było dobranie odpowiedniej architektury sieci neuronowej, co okazało się decydujące dla uzyskania wysokiej dokładności klasyfikacji. Wstępne eksperymenty przeprowadzono z wykorzystaniem modeli takich jak dynamiczna regresja liniowa oraz maszyny wektorów nośnych (SVM – Support Vector Machines). Modele te nie spełniły wymagań dokładnościowych ze względu na ich ograniczoną zdolność do uchwycenia subtelnych zmian w sekwencyjnych danych oddechowych, w których kluczowe są relacje czasowe.

Po przeprowadzeniu szczegółowej analizy 4.3, wybrano model sieci neuronowej oparty na strukturze Gated Recurrent Unit (GRU), czyli rekurencyjnej jednostce o bramkowanej strukturze, która wykazuje wysoką dokładność w modelowaniu szeregów czasowych. Sieci GRU, jako wariant rekurencyjnych sieci neuronowych (RNN), są zdolne do przechowywania informacji o wcześniejszych stanach, co jest kluczowe w analizie danych sekwencyjnych. W porównaniu z sieciami LSTM (Long Short-Term Memory), model GRU charakteryzuje się prostszą architekturą, co czyni go bardziej efektywnym obliczeniowo, szczególnie w aplikacjach czasu rzeczywistego.

Zaimplementowany model GRU składał się z trzech kolejnych warstw, każda z odpowiednio dobraną funkcją aktywacji. W pierwszej warstwie zastosowano funkcję ReLU (Rectified Linear Unit), co pozwoliło przeciwdziałać problemowi zanikania gradientów. Druga warstwa wykorzystwała funkcję tangensa hiperbolicznego (tanh), umożliwiając bardziej precyzyjne odwzorowanie zmienności sygnału. Ostatnia warstwa, oparta na funkcji softmax, odpowiadała za klasyfikację końcową, przypisując prawdopodobieństwo do każdego z możliwych stanów oddechu.


Dane przygotowane na wcześniejszych etapach zostały podzielone na zestawy treningowe i walidacyjne. Model był trenowany przez 50 epok, co pozwoliło na systematyczne zwiększanie dokładności klasyfikacji przy jednoczesnym monitorowaniu ryzyka przeuczenia. Każda iteracja szkoleniowa obejmowała zestawy składające się z 500 próbek, co umożliwiło efektywne uśrednianie wag oraz redukcję potencjalnych błędów.

Do optymalizacji modelu zastosowano algorytm Adaptive Moment Estimation (ADAM), który łączy zalety metod Adagrad i RMSProp.

Adagrad (Adaptive Gradient Algorithm) dostosowuje tempo uczenia się dla każdej cechy w zależności od jej częstości. Rzadziej występujące cechy mają wyższe tempo uczenia, a częściej występujące – niższe, co sprawia, że model lepiej radzi sobie z rzadkimi danymi. Jednak z czasem tempo uczenia może zbyt szybko spadać, co może utrudniać dalszy trening.

RMSProp (Root Mean Square Propagation) rozwiązuje ten problem, stosując wygładzanie gradientów i utrzymując stabilność tempa uczenia. Dzięki temu jest bardziej efektywny w przypadku danych sekwencyjnych i pozwala uniknąć spadku tempa uczenia.

ADAM umożliwia dynamiczną adaptację tempa uczenia dla każdej wagi, co przyspiesza proces nauki i zapewnia stabilność wyników, szczególnie w przypadku dużych zbiorów danych sekwencyjnych.



Rys. 3.20. Diagram sieci Gated Recurrent Unit. Wartości w warstwach Dense i GRU, oznaczają wymiar wyjściowych danych. W przypadku warstwy Dropout, jest to procentowa liczba przypadkowo odrzucanych próbek (źródło własne)

Całość kodu architektury zaprezentowanej na diagramie 3.20, została zaimplementowana z wykorzystaniem biblioteki `tensorflow`, dedykowanej tworzeniu i trenowaniu sieci neuronowych.

4. WYNIKI EKSPERYMENTÓW

4.1. Wstęp (Maciej Szeffler)

W celu wyboru najbardziej optymalnego podejścia do rozwiązania problemu rozpoznawania oddechu, przeprowadzono szereg testów mających na celu poprawę jakości modelu. Pracę rozpoczęto od przetestowania różnych modeli, aby wyłonić ten o największym potencjale rozwojowym. Uwzględniono kilka najpopularniejszych metod uczenia maszynowego, w tym zarówno proste modele, takie jak regresja logistyczna oraz te bardziej złożone, jak sieci neuronowe.


Na podstawie dostępnych danych treningowych przeanalizowano optymalną wielkość zbioru oraz potrzebę jego dalszego rozwijania. Dodatkowo zastosowano znaną metodykę Human-in-the-Loop, umożliwiającą ciągłe doskonalenie modeli poprzez integrację eksperckiej oceny człowieka. Wdrożenie tego podejścia znacząco poprawiło dokładność klasyfikacji modelu.

W końcowym etapie podjęto decyzję o zbadaniu trybu pomiaru pochylenia akcelerometru. Choć funkcja ta nie jest dostępna we wszystkich typach akcelerometrów, została uznana za potencjalnie innowacyjne podejście do pozyskiwania danych rytmu oddechu.


4.2. Porównanie z danymi z literatury naukowej (Kacper Karski)

Dane zebrane podczas pracy zostały zestawione z wynikami prezentowanymi w literaturze naukowej, gdzie analizę parametrów oddechowych prowadzono z wykorzystaniem zaawansowanych systemów pomiarowych lub większą ilością akcelerometrów. Celem porównania jest ocena efektywności zastosowania nieskomplikowanych technologii, takich jak tensometr i akcelerometr, w zestawieniu z bardziej zaawansowanymi i kosztownymi urządzeniami diagnostycznymi, pod kątem ich przydatności i precyzji w analizie danych.

W literaturze naukowej analiza parametrów oddechowych często opiera się na zaawansowanych systemach pomiarowych, takich jak profesjonalne spirometry, pletyzmografy czy precyzyjne sensory piezoelektryczne. Urządzenia te charakteryzują się wysoką rozdzielczością, szerokim zakresem pomiarowym oraz możliwością rejestrowania wielu parametrów oddechowych w czasie rzeczywistym. Przykładowo, w pracy [25] przedstawiono wyniki analizy rytmu oddechowego z wykorzystaniem sieci centrycznych na ciele, gdzie badano zmienność amplitudy oraz częstotliwości oddechu w różnych stanach fizjologicznych. W artykule [12] dane pobierane były za pomocą pletyzmografu, czyli urządzenia medycznego służącego do pomiaru zmian objętości ciała lub jego części, które zachodzą w wyniku przepływu krwi, oddychania lub innych procesów fizjologicznych. Pletyzmograf jest powszechnie stosowany w diagnostyce układu oddechowego oraz krążeniowego, umożliwiając precyzyjne monitorowanie parametrów fizjologicznych, jednak jest to sprzęt kosztowny, dostępny głównie w wyspecjalizowanych placówkach medycznych.




Rys. 4.1. Surowe dane pobrane przez twórców artykułu (źródło [25])



Rys. 4.2. Surowe dane pobrane za pomocą pletyzmografu (źródło [12])

Surowe dane przedstawione na rysunkach 4.1 i 4.2 wykazują dużą zgodność z danymi zarejestrowanymi podczas realizacji projektu, przedstawionymi na rysunku 3.17. Pomimo braku zastosowania filtrów w tych przypadkach, można zauważyć wyraźnie regularne cykle oddechowe, zmienność amplitudy oraz częstotliwości.




Rys. 4.3. Szacowanie częstości oddechów za pomocą metody obliczania cyklu oddechowego opartej na wykrywaniu szczytów. (a) W przypadku wolnego oddechu. (b) W normalnym oddychaniu. (c) W przypadku szybkiego oddechu. (źródło [25])

Wyniki uzyskane podczas realizacji projektu, przedstawione na rysunkach 4.10 i 4.11, mimo że opierają się na danych pochodzących ze stosunkowo nieskomplikowanych czujników, wykazują zaskakująco wysoką zgodność z wynikami prezentowanymi w literaturze naukowej (rysunek 4.3). Zgodność ta została osiągnięta pomimo różnic w metodach zbierania, przetwarzania i prezentacji danych. Analiza wykresów wskazuje, że tensometr umieszczony na klatce piersiowej z powodzeniem rejestruje zmiany mechaniczne towarzyszące ruchom oddechowym, a dane z akcelerometru uzupełniają informację o dynamice i kierunku ruchu klatki piersiowej.


Co istotne, zastosowane czujniki są znacznie prostsze, a ich koszt i dostępność przewyższają zaawansowane technologie stosowane w badaniach naukowych. Mimo tej różnicy, jakość zebranych danych okazała się wystarczająca do przeprowadzenia analizy, co stanowi ważny punkt odniesienia w kontekście przyszłych zastosowań takich systemów w warunkach codziennych. Wskazuje to na możliwość wykorzystania tanich i nieskomplikowanych technologii w badaniach oddechu, co otwiera drogę do tworzenia mobilnych i dostępnych rozwiązań diagnostycznych, potencjalnie użytecznych w monitorowaniu zdrowia w domu.

4.3. Porównanie modeli (Maciej Szeffler)

Aby wybrać najlepszy model, przetestowano wiele wariantów różnych modeli sztucznej inteligencji, w tym kolejno: Random Forest (RF), Support Vector Machine (SVM), Logistic Regression (LR), Batch Normalization (BN), Gated Recurrent Unit (GRU), Long Short-Term Memory (LSTM) oraz 1D Convolutional Neural Network (Conv1D). Wszystkie testy, były przeprowadzane na modelu runtime, z zastosowaniem normalizacji oraz wygładzania za pomocą algorytmu średniej kroczącej. Modele były trenowane na 50 epokach, w paczkach po 500 próbek każda. Wyniki testów są przedstawione na poniższych rysunkach 4.4 i 4.5.



Rys. 4.4. Wyniki różnych modeli trenowanych na zbiorze treningowym z tensometru (źródło własne)



Rys. 4.5. Wyniki różnych modeli trenowanych na zbiorze treningowym z akcelerometru iNode Nav (źródło własne)

Warto zwrócić uwagę na prosty model regresji logistycznej. W przypadku tensometru okazał się on być jednym z najmniej skutecznych, natomiast w przypadku akcelerometru był najdokładniejszy. Różnice te wynikają głównie z rozmiaru danych w obu sensorach oraz architektury regresji logistycznej. W przypadku akcelerometru iNode Nav, gdzie dostarczane jest 11 próbek do uczenia, występuje znacznie większa złożoność, co pozwala modelowi na łatwiejsze dopasowanie się do wzorca.


Aby dokładniej zrozumieć działanie poszczególnych modeli, podjęto decyzję o przeprowadzeniu głębszej analizy najskuteczniejszych modeli, dostosowując je odpowiednio do specyfiki problemu. Wzięto pod uwagę model z normalizacją wsadową (87,61% dla tensometru, 76,78% dla akcelerometru iNode Nav), model GRU (88,39% dla tensometru, 77,37% dla akcelerometru

iNode Nav), model LSTM (87,38% dla tensometru, 76,65% dla akcelerometru iNode Nav), model sieci konwolucyjnych 1D (87,65% dla tensometru, 77,37% dla akcelerometru iNode Nav).

4.3.1. Model z normalizacją wsadową (ang. Batch Normalization)

Bardzo popularną techniką w trakcie trenowania różnych modeli neuronowych, jest normalizacja danych do określonego zakresu. W trakcie treningu modelu, w kolejnych warstwach, następuje zmiana rozkładu danych wejściowych (np. średnia). Polega to na tym, że na danych w każdej warstwie dokonywane są przekształcenia wynikające z funkcji aktywacji oraz wag. Zmiany rozkładu w początkowych warstwach mogą znacząco wpływać na późniejsze warstwy, co prowadzi do dłuższego czasu uczenia modelu, ze względu na ciągłe dostosowywanie się sieci do nowego rozkładu. Dodatkowo może to powodować problemy związane z generalizacją danych i niższą stabilnością. Problem ten rozwiązuje model z normalizacją wsadową.


Jak opisują autorzy pracy [26], modele z normalizacją wsadową zrewolucjonizowały podejście do uczenia głębokiego. Jest to technika stosowana w sieciach neuronowych, mająca na celu poprawę dokładności i szybkości uczenia. Polega ona na normalizacji danych wejściowych dostarczanych do każdej warstwy poprzez ich standaryzowanie, a następnie przeskalowywanie i przesuwanie. Warstwy normalizacji wsadowej zostały zastosowane bezpośrednio przed funkcjami aktywacji kolejnych warstw, tak jak zaprezentowano to na diagramie 4.6.



Rys. 4.6. Diagram sieci wykorzystującej normalizację wsadową. Wartości w warstwach Dense, oznaczają wymiar wyjściowych danych (źródło własne)


Wyniki

Proces testowania modelu przeprowadzono na podstawie średniego wyniku dokładności uzyskanego z 20 pętli treningowych. Model wykorzystujący batch normalization uzyskał średni wynik na poziomie 87,6%. Jest to spowodowane dużymi wahaniami dokładności modelu, które mieściły się w zakresie 85% - 90%. Rysunek 4.7 przedstawia historię wyników tego modelu.



Rys. 4.7. Przykładowy wykres historii uczenia modeli tensometru z normalizacją wsadową. (źródło własne)

Dla porównania, model nie wykorzystujący normalizacji wsadowej osiągnął średnią dokładność na poziomie 88,4%. W tym przypadku wahania dokładności były znacznie mniejsze. Dodatkowo, czas treningu był mniejszy o średnio 10%. Rysunek 4.8 przedstawia historię wyników tego modelu.



Rys. 4.8. Przykładowy wykres historii uczenia modeli tensometru bez normalizacji wsadowej. (źródło własne)

Modele wykorzystujące normalizację wsadową, szczególnie w kontekście uczenia głębokiego, miały na celu znaczące przyspieszenie procesu uczenia oraz poprawę wydajności. W przedstawionym rozwiązaniu nie zaobserwowano poprawy dokładności modelu. Wynikało to z kilku czynników. Po pierwsze, zastosowana sieć składała się jedynie z trzech warstw, co okazało się zbyt małą liczbą, aby dostrzec różnice w czasie treningu czy dokładności modelu. Modele w uczeniu głębokim, często obejmują nawet kilkaset warstw. Jednocześnie, w przypadku tak prostego problemu, stosowanie bardziej skomplikowanej sieci okazało się niepotrzebne. Po drugie, liczba próbek, wynosząca około 50 000 prostych danych numerycznych z jednym hiperparametrem, amplitudą, była zbyt mała, by model mógł w pełni wykorzystać potencjał normalizacji wsadowej.

4.3.2. Sieci rekurencyjne

Standardowe sieci neuronowe (ang. feedforward neural network) polegają na wykorzystaniu danych, które przepływają w jednym kierunku. Najprostszy schemat polega na dostarczeniu

danych na warstwę wejściową. Następnie dane te są przekazywane do warstw ukrytych, a na samym końcu do warstwy wyjściowej, która generuje wynik. Warstwy ukryte są odpowiedzialne za modyfikowanie przepływających danych i dostosowywanie wag. Taka sieć nie ma możliwości pamiętania poprzednich stanów.

W problemie rozpoznawania stanów oddechów, bardzo przydatna jest informacja o poprzednich stanach oraz kontekst takiej informacji. W takich przypadkach idealnym zastosowaniem jest sieć rekurencyjna (RNN - Recurrent Neural Network). Jest to rodzaj sieci neuronowej, w której informacja płynie nie tylko w jednym kierunku do kolejnych warstw, ale wraca także do poprzednich za pomocą mechanizmu propagacji wstecznej (ang. backpropagation). Warstwy ukryte w takiej sieci pełnią rolę komórek rekurencyjnych, zdolnych zapamiętywać wewnętrzny stan, który jest aktualizowany. Taka komórka jest w stanie przechowywać informację o poprzednich krokach. Mechanizm propagacji wstecznej minimalizuje błąd pomiędzy predykcjami sieci a oczekiwanymi wynikami i polega na aktualizacji wag w kolejnych etapach.

W opisywanej pracy skupiono się na dwóch odmianach sieci rekurencyjnych, opisanych również przez autorów badania [27].

- **Long Short-Term Memory (LSTM)**: Jest to sieć neuronowa, zdolna do przechowywania dłuższych sekwencji danych. Jest to bardziej złożona sieć, posiadająca trzy bramki: input, forget, output. Pozwalają one na przechowywanie informacji o stanach lub zapominanie o nich. Charakteryzuje się ona większą złożonością, a co za tym idzie dłuższym czasem uczenia. Takie sieci dobrze współpracują z dużymi zbiorami danych, w których dostępna jest wysoka liczba parametrów. W przypadku małego zbioru, są one szczególnie narażone na przetrenowanie.
- **Gated Recurrent Unit (GRU)**: Jest to uproszczona sieć typu LSTM. Posiada jedynie dwie bramki: update, reset. Bramka update odpowiedzialna jest za kontrolę nad pamiętaniem ilości poprzednich stanów, a bramka reset za zapominanie poprzednich stanów. Dzięki mniejszej liczbie bramek, ma ona większą efektywność obliczeniową i jest szybsza od sieci typu LSTM. Dzięki zastosowaniu mniejszej ilości bramek, jest mniej podatna na przetrenowanie w małych zbiorach danych z niewielką ilością parametrów.

Dla tensometru, podczas treningu sieci LSTM, uzyskano średni wynik na poziomie około 87%. W przypadku sieci GRU, średni wynik wyniósł około 88%. Dla akcelerometru nie zauważono znaczących różnic pomiędzy wynikami uzyskanymi przy użyciu obu sieci.

4.3.3. Sieć konwolucyjna

W ramach dodatkowego eksperymentu, zdecydowano się na zastosowanie sieci konwolucyjnej. Jest to sieć głównie wykorzystywana w przypadku rozpoznawania obrazów, dźwięków czy wideo. Wykorzystuje ona operację konwolucji, czyli przekształceń macierzowych fragmentów danych tak aby wydobyć z nich konkretne informacje.


Sieci konwolucyjne operują na kernelach, zwanych również filtrami. Są to macierze zawierające dane. Rozróżniane są trzy główne kategorie sieci konwolucyjnych.

1. Sieć konwolucyjna 1D - Dane wejściowe dostarczane do takiej sieci, składają się z jednowymiarowego wektora. Powinny zawierać konkretną sekwencję, jak stan oddechu. W takiej sieci, operacja konwolucji, przesuwając filtr wzdłuż jednej osi danych. Taki rodzaj sieci jest szczególnie przydatny do klasyfikacji danych sekwencyjnych w kontekście.

2. Sieć konwolucyjna 2D - Dane wejściowe dostarczane do takiej sieci, składają się z siatki, np. obrazy. Operacja konwolucji, przesuwając filtr po obu dostępnych osiach. Wykorzystywana jest do rozpoznawania obrazów i klatek wideo.
3. Sieć konwolucyjna 3D - Dane wejściowe dostarczane do takiej sieci, składają się z macierzy, np. trójwymiarowe obrazy czy wideo. Operacja konwolucji, przesuwając filtr po trzech dostępnych osiach. Wykorzystywana jest do rozpoznawania filmów wideo, gdzie trzecim wymiarem może być czas.

Ze względu na charakter wykorzystywanych danych, które można przedstawić jako jednowymiarowe wektory, zdecydowano się na eksperymenty z siecią konwolucyjną 1D. Autor artykułu [28] opisuje podstawową architekturę takiej sieci, która składa się z:

1. **Warstwa konwolucyjna:** Podstawowa warstwa, zawierająca wyuczone filtry. Odpowiadają one za ekstrakcję określonych cech, umożliwiających rozróżnienie od siebie segmentów danych. Wartości w filtrach są dobierane i optymalizowane w trakcie treningu sieci. Kluczowe jest kilka hiperparametrów dobieranych w tej warstwie.
 - a) Rozmiar jądra (ang. kernel size) - jest to hiperparametr odpowiedzialny za zdefiniowanie rozmiaru filtra i odnosi się do wymiarów okna, które jest przesuwane nad danymi wejściowymi.
 - b) Wypełnienie (ang. padding) - podobnie jak w przypadku programowania stron internetowych, padding odnosi się do pojęcia wypełnienia obszaru poza danymi wyjściowymi. Przykładowo, jeśli dane wejściowe są rozmiaru 9x9, a dane wyjściowe rozmiaru 5x5, padding umożliwia dodanie obramowania wokół danych wyjściowych, tak aby otrzymać taki sam rozmiar jak dane wejściowe. Odbывается to za pomocą dodania dodatkowych wag na krawędziach z wartością zero.
 - c) Kroki (ang. strides) - określa liczbę, o jaką jądro, powinno zostać przesunięte po danych wejściowych.
2. **Warstwy poolingowe:** W przypadku korzystania z sieci konwolucyjnych, dane w określonych segmentach mogą się powtarzać. Oznacza to, że takie informacje są zbędne i niepotrzebnie wydłużają proces treningu sieci. Dzięki zastosowaniu warstw pooling, można takie dane połączyć. Przykładem jest warstwa MaxPooling, która powoduje połączenie kilku próbek danych w jedną, za pomocą funkcji maksimum.
3. **Warstwy aktywacji:** Warstwy aktywacji są konieczną cechą treningu wszystkich sieci neuronowych, wprowadzającą do treningu nieliniowość. Jednym z przykładów funkcji aktywacji jest ReLU (Rectified Linear Activation), którą można zdefiniować jako $ReLU(x) = \max(0, x)$. Sieć została przygotowana, tak jak na poniższym diagramie 4.9.




Rys. 4.9. Diagram jednowymiarowej sieci konwolucyjnej. Wartości w warstwach, oznaczają wymiar wyjściowych danych (źródło własne)

Warto wspomnieć o warstwie flatten, która odpowiada za spłaszczanie wyników wyjściowych z warstwy konwolucyjnej, do wejścia kolejnej warstwy, do postaci jednowymiarowego wektora.


Na przykładzie tej sieci zaobserwowano ponad 75% przyspieszenie prędkości uczenia modelu. Jednocześnie proces uczenia modelu okazał się bardzo stabilny, a jego dokładność była nieznacznie gorsza od modelu GRU. Dzięki temu, taka architektura mogła zostać wykorzystana do wstępnego, szybkiego wytrenowania modelu oraz rozpoznania problemów w etykietach danych. Następnie dane te mogły zostać poprawione i po prawidłowej klasyfikacji przesłane do bardziej czasochłonnego modelu GRU.

4.3.4. Końcowe wyniki

Bazując na wynikach tensometru i biorąc pod uwagę niewielkie różnice, a także prostotę w implementacji, zdecydowano się na model Gated Recurrent Unit. Na tej podstawie, w celu uproszczenia implementacji użycia modelu w kodzie natywnym Java, dla akcelerometrów podjęto decyzję o zastosowaniu tych samych modeli.



Rys. 4.10. Wyniki klasyfikacji danych z tensometru wraz z historią uczenia modelu GRUModel. Na danych testowych osiągnął dokładność 88.06%. (źródło własne)



Rys. 4.11. Wyniki klasyfikacji danych z akcelerometru iNode Nav wraz z historią uczenia modelu GRUModel. Na danych testowych osiągnął dokładność 77.24%. (źródło własne)

Ocena modelu klasyfikacyjnego opartego na sieci GRU (Gated Recurrent Unit) została przeprowadzona w kilku kluczowych etapach, mających na celu obiektywne określenie jego dokładności.


Po pierwsze, nowe dane wejściowe zostały przetworzone przez wytrenowaną sieć GRU, będącą rodzajem sieci rekurencyjnych. Dane te obejmowały różne formy oddechu, takie jak bezdech, hiperwentylacja czy wdechy/wydechy po bezdechu, które wymagały uwzględnienia kontekstu i zależności między elementami sekwencji. Po przetworzeniu danych przez sieć GRU, wyniki klasyfikacji zostały zapisane. Te wyniki to klasy przypisane do poszczególnych danych wejściowych przez model.

Następnie, uzyskane wyniki klasyfikacji zostały porównane z wynikami zaklasyfikowanymi ręcznie (wzorcowymi). Porównanie to polegało na sprawdzeniu, w jakim stopniu automatyczne klasyfikacje modelu pokrywały się z ręcznymi odpowiednikami. Ostatecznie, wynik procentowy poprawności porównania określał dokładność modelu.

Dokładność modelu klasyfikacyjnego, wynosząca 88,06% i 77,24%, pokazana na rysunkach 4.10 i 4.11, wynikała głównie z kilku czynników związanych z charakterem danych i specyfiką zadania.


Istotnym czynnikiem była obecność punktów krytycznych w pobliżu bezdechu. W kontekście analizy danych oddechowych, bezdech stanowił kluczowy moment, który był trudny do jednoznacznego zidentyfikowania. Złożoność i subtelność sygnałów w okolicach bezdechu sprawiały, że nawet niewielkie różnice w interpretacji mogły prowadzić do znaczących rozbieżności między wynikami modelu a ręczną klasyfikacją. Te punkty krytyczne charakteryzowały się podobnymi fragmentami, które były trudne do uchwycenia przez algorytmy uczenia maszynowego. Przykładowo początek wydechu wyglądał identycznie jak początek retencji po wdechu.

Należy zauważyć, że ocena klasyfikacji, w której widoczny jest pełen kontekst informacji, jest dużo prostsza dla użytkownika niż dla modelu, który miał dostęp jedynie do 5 próbek. Przykładowo, w tak zdefiniowanym problemie, model musiał zdecydować, co nastąpi między 29.5 a 30 sekundą.




Rys. 4.12. Przykładowy problem, przed którym stoi model (źródło własne)

Jak można zauważyć na rysunku 4.12, bez dodatkowego kontekstu, taka decyzja jest nie-możliwa nawet dla człowieka. Nie byłby on w stanie podjąć decyzji, czy ten fragment to retencja po wdechu, czy już początek wydechu. Podkreśla to istotę użycia modeli sztucznej inteligencji w poprawnej klasyfikacji oddechu.



Rys. 4.13. Wynik modelu tensometru wytrenowanego tylko na zbiorze 'wdech i zatrzymanie'. (źródło własne)

Zaobserwowano istotną poprawę wyników modelu tensometru w fazie retencji po wdechu po przeszkoleniu modelu wyłącznie na zbiorze danych "wdech i zatrzymanie". Model prawidłowo sklasyfikował większą fazę retencji po wdechu, natomiast w ogólności osiągnął dużo niższą dokładność (81,44%) niż model wytrenowany na całym zbiorze. Rysunek 4.13 przedstawia te wyniki.



Rys. 4.14. Liczba próbek z konkretnymi etykietami w zbiorze. Etykiety wynikają z tabeli 3.9 (źródło własne)

Obserwację tę potwierdza wykres 4.14, który wskazuje na relatywnie niską liczbę próbek zaklasyfikowanych jako retencja po wdechu w porównaniu do pozostałych etykiet klasyfikacyjnych. Świadczy to o nierównowadze w rozkładzie danych w zbiorze treningowym, co negatywnie wpłynęło na dokładność modelu w identyfikacji tej specyficznej fazy oddechu.

4.4. Proces trenowania i poprawiania modelu GRU (Kacper Karski)

Wszystkie oznaczone próbki w zbiorach danych zostały poddane ręcznej weryfikacji, a nieprawidłowe etykiety skorygowano w celu zapewnienia najwyższej jakości danych wejściowych. Szczególną uwagę zwrócono na dokładność walidacji danych w zestawie testowym, który obejmował różnorodne stany oddechowe, jak:

- 60 sekund normalnego, głębokiego oddychania,
- 30 sekund płytkiego oddychania,
- 30 sekund wdechu z zatrzymaniem oddechu,
- 30 sekund wydechu z zatrzymaniem oddechu,
- 30 sekund bardzo wolnego oddychania,
- 30 sekund hiperwentylacji,
- 30 sekund kaszlu,
- 30 sekund wdechu z pauzą (badany rozpoczął wdech, zatrzymał się w połowie oddechu, a następnie kontynuował),
- 30 sekund wydechu z pauzą (badany rozpoczął wydech, zatrzymał się w połowie, a następnie kontynuował).

Liczba próbek dla każdego rodzaju oddechu w zbiorze testowym została przedstawiona w tabeli 3.11.

Dane zostały podzielone na odpowiednie sekwencje: po 5 próbek dla tensometru i akcelerometru WitMotion oraz 11 próbek dla akcelerometru iNode Nav. W przypadku tensometru każda sekwencja składała się z 5 próbek, a etykieta była przypisywana do pierwszej próbki w sekwencji. Model Gated Recurrent Unit (GRU) trenowano przez 50 epok z rozmiarem wsadu wynoszącym 500 i testowano na zestawie danych niewykorzystanym wcześniej w procesie uczenia.


Po każdej sesji szkoleniowej wyniki zwracane przez model dla zestawu testowego były ręcznie analizowane. Wykorzystano w tym celu interaktywne wykresy, na których górna część ekranu przedstawiała przewidywane wartości, a dolna rzeczywiste wartości z zestawu testowego widoczne na rysunkach 4.10 i 4.11. Punkty danych zostały oznaczone zgodnie z ich klasami, co umożliwiło łatwą identyfikację momentów, w których model popełniał błędy. W takich przypadkach zarejestrowano dodatkowe próbki reprezentujące problematyczne stany, które następnie oznakowano w sposób opisany wcześniej.

Do walidacji danych wykorzystano klasyfikator z czterema etykietami odpowiadającymi różnym stanom oddechowym. Im większa zgodność etykiet w przewidywanych danych z rzeczywistymi wartościami z ręcznie oznaczonego zestawu testowego, tym wyższy był uzyskany wynik dokładności modelu. Osiągnięte wyniki to:

- 88,06% dokładności dla modelu opartego na danych z tensometru,
- 77,24% dokładności dla modelu opartego na danych z akcelerometru iNode Nav.

Proces klasyfikacji i oceny wyników dla różnych typów oddechów opierał się na ręcznej walidacji danych, treningu modelu GRU oraz szczegółowej analizie jego wydajności.

1. Dane zostały odpowiednio podzielone na sekwencje, z etykietą przypisaną na podstawie pierwszej próbki w każdej sekwencji. Przygotowane dane zostały wykorzystane do trenowania modelu GRU, który był trenowany na sekwencjach, których wcześniej nie widział, co miało na celu zwiększenie obiektywności wyników oraz zapobieganie przeuczeniu.
2. Ręczna walidacja oznaczonych próbek zapewniła wysoką jakość danych wejściowych. Szczególną uwagę zwrócono na zestaw testowy, który zawierał różnorodne typy oddechów, takie jak głębokie oddychanie, płytkie oddychanie oraz warianty przerw w oddychaniu. Dokładność walidacji danych była na bieżąco monitorowana.
3. Po każdej sesji treningowej wyniki przewidywane przez model były ręcznie przeglądane i analizowane na interaktywnych wykresach, co umożliwiło identyfikację momentów, w których klasyfikacja stanów oddechowych napotykała trudności. Wyniki klasyfikacji były mierzone poprzez porównanie etykiet przewidywanych przez model z ręcznie oznakowanymi etykietami z zestawu testowego.
4. Dodatkowe testy wydajności modelu GRU z różną liczbą epok wykazały, że zmiana tego parametru nie miała znaczącego wpływu na dokładność, co sugeruje, że model osiągnął swoje optimum w wybranej liczbie epok, jak przedstawiono na rysunku 4.15. Zdecydowano się na liczbę 100 epok, ponieważ dla większej liczby zaobserwowano, że współczynnik pomiędzy czasem trwania obliczeń a wzrostem dokładności modelu był niewielki. Oznacza to, że zwiększanie liczby epok powyżej tego poziomu nie przynosiło znaczących korzyści w dokładności, a jednocześnie znacząco wydłużało czas treningu.




Rys. 4.15. Dokładność modelu w zależności od liczby epok (źródło własne)

4.5. Model offline, a model runtime (Maciej Szeffler)


Model runtime, jak sama nazwa wskazuje, musi działać w czasie rzeczywistym. W wyniku tego, model został ograniczony do pewnego okna czasowego, co powoduje, że może on zobaczyć jedynie próbki znajdujące się w przeszłości.

Model offline pozbawiony jest tych ograniczeń. Został on zaprojektowany w taki sposób, że zamiast jedynie kontekstu kolejnych próbek, bierze pod uwagę znacznie szersze okno czasowe, a także to, co wydarzy się w przyszłości. Zasada działania polega na przygotowaniu trzykrotnie większego kontekstu niż model runtime (czyli 15 próbek dla tensometru i akcelerometru WitMotion oraz 33 próbki dla akcelerometru iNode Nav). Następnie etykieta takiego zbioru jest dobierana na podstawie próbki środkowej z wybranej sekwencji. Dzięki temu model otrzymuje dane do nauki, w których aktualny stan jest poprzedzony próbkami przeszłymi, a następnie próbkami przyszłymi.



Rys. 4.16. Wyniki klasyfikacji danych z tensometru. Na rysunku a) widoczny jest model działający w trybie runtime. Na rysunku b) model działający w trybie offline. (źródło własne)

Rysunek 4.16 przedstawia porównanie modeli tensometru runtime vs offline. W trybie runtime, osiągnął on dokładność na poziomie 88,11%, natomiast w trybie offline 90,19%. Zauważono około 2% wzrost dokładności modelu i jednocześnie dające lepsze rezultaty w fazach retencji po wdechu.



Rys. 4.17. Wyniki klasyfikacji danych z akcelerometru iNode Nav. Na rysunku a) widoczny jest model działający w trybie runtime, a więc działający w trybie runtime. Na rysunku b) model działający w trybie offline. (źródło własne)

Rysunek 4.17 przedstawia porównanie modeli akcelerometru iNode Nav runtime i offline. Zauważono znaczący wzrost dokładności modelu o prawie 8%.

Można stwierdzić duży potencjał w modelu offline. W momencie zakończenia pomiaru przez użytkownika, taki model może zostać wykorzystany, aby poprawić wszystkie dane, które zostały wcześniej błędnie zaklasyfikowane.

4.6. Miara częstości oddechu (Filip Krawczak)

Podstawowa miara dokładności, uwzględniała szumy w porównywanych próbkach. Zdecydowano się na stworzenie miary częstości oddechu, która wyeliminuje taki problem. Algorytm liczenia częstości oddechów (RR - respiratory rate) wykorzystuje przewidywania dostarczane przez model sieci neuronowej. Model klasyfikuje każdy stan oddechowy jako "wdech", "wydech", "retencja po wdechu" lub "retencja po wydechu", generując sekwencję przewidywań na podstawie

danych w czasie rzeczywistym. Ta sekwencja jest następnie przetwarzana przez algorytm liczenia oddechów, który identyfikuje pełne oddechy w celu obliczenia częstości oddechów. Liczba oddechów wykrytych przez algorytm w trakcie badania jest prezentowana na głównym ekranie wykresów, natomiast wartość miary częstości oddechu jest udostępniana użytkownikowi na ekranie statystyk.

Pełny oddech definiowany jest jako cykl rozpoczynający się od wdechu, a kończący na wydechu.

1. **Wdech** - Oznacza początek nowego cyklu oddechowego.
2. **Stany przejściowe** - Mogą pojawić się między wdechem, a wydechem, uwzględniając drobne zmiany lub przerwy w wzorcu oddechowym.
3. **Wydech** - Kończy cykl i sygnalizuje zakończenie pojedynczego oddechu.

Ze względu na brak 100% dokładności modelu, w danych mogą pojawiać się nieprawidłowe lub sprzeczne przewidywania. Pojedyncza etykieta oznaczająca wydech może zostać błędnie zidentyfikowana w trakcie fazy wdechu. Gdyby algorytm uwzględniał oddech na podstawie pojedynczej próbki danych wskazującej na wydech, mogłoby to prowadzić do błędnego naliczania oddechów w sytuacjach, w których cykl oddechowy faktycznie nie został zakończony.

4.6.1. Weryfikacja spójności etykiet (Filip Krawczak)

W celu zwiększenia precyzji algorytmu oraz ograniczenia wpływu potencjalnych zakłóceń w przewidywaniach modelu, przeprowadzono eksperymenty mające na celu określenie optymalnej liczby kolejnych etykiet wymaganych do potwierdzenia wdechu i wydechu. Analizowane były różne scenariusze, zakładając minimalną liczbę powtarzających się etykiet, od jednej do sześciu z rzędu. Celem testów było znalezienie ustawienia, które pozwoliłoby osiągnąć jak najwyższą dokładność w liczeniu oddechów, uwzględniając dwa istotne czynniki:


- **Eliminacja nadliczania oddechów** - sytuacja, w której algorytm błędnie rozpoznaje oddech, mimo że cykl oddechowy nie został zakończony.
- **Zapobieganie pomijaniu oddechów** - przypadki, w których algorytm nie rozpoznaje prawidłowego oddechu z powodu zbyt rygorystycznych wymagań dla uznania cyklu oddechowego za pełny.

4.6.2. Testy dokładności algorytmu do liczenia miary RR na podstawie etykiet określonych przez model runtime (Filip Krawczak)

Tabela 4.1 oraz wykres 4.18 przedstawia dokładności algorytmu liczenia pełnych cykli oddechu w zależności od rodzaju sensora oraz liczby próbek wykorzystywanych do analizy.

Tabela 4.1. Dokładność algorytmu w zależności od ilości próbek i sensora (źródło własne)

Sensor	Liczba etykiet z rzędu					
	1	2	3	4	5	6
Akcelerometr WitMotion	0.00%	47.58%	62.90%	79.03%	90.83%	96.49%
Akcelerometr iNode Nav	34.68%	65.32%	83.87%	89.52%	91.67%	94.74%
Tensometr	92.00%	99.00%	92.63%	100.00%	97.30%	92.86%



Rys. 4.18. Dokładność liczenia oddechów od liczby próbek w trybie runtime (źródło własne)

Na podstawie testów ustalono następujące wnioski.

1. Jednokrotne wystąpienie etykiety szczególnie w przypadku analizowania danych pochodzących z akcelerometrów jest nie wystarczające, aby stwierdzić rozpoczęcie, bądź zakończenie cyklu oddechowego. Dane akcelerometru charakteryzują się wysoką czułością, co przekłada się również na duże szумы oraz zakłócenia danych, które błędnie analizowane przez algorytm częstości oddechu.
2. Dwukrotne powtórzenie etykiety jako kryterium rozpoznania cyklu oddechu zwiększyło dokładność naliczania liczby oddechów u wszystkich urządzeń. Tensometr osiągnął wynik 99%, co potwierdza wysoką dokładność modelu, stabilność danych oraz brak potrzeby analizowania większej ilości danych, aby prawidłowo rozpoznać etap cyklu oddechu.
3. Zobrazowanie danych z tabeli 4.1 na wykresie 4.18 umożliwia łatwe zaobserwowanie trendu wzrostowego dokładności naliczania częstości oddechu w zależności od liczby próbek do analizy w przypadku danych pochodzących z akcelerometrów.
4. Pięć lub sześć kolejnych etykiet okazało się najbardziej optymalnymi rozwiązaniami - zapewniają wysoką dokładność oraz znacznie zmniejszają liczbę błędnych detekcji. W przypadku analizowania danych z tensometru przy sześciu kolejnych etykietach występuje zwiększona liczba pomijanych oddechów, co jest szczególnie widoczne w przypadku hiperwentylacji.


Ostatecznie przyjęto, że wymóg pięciu kolejnych etykiet będzie stosowany w algorytmie jako optymalne rozwiązanie, łączące wysoką dokładność liczenia oddechów z odpornością na błędy i nieprzewidywalne zakłócenia w danych.

4.6.3. Testy dokładności algorytmu do liczenia miary RR na podstawie etykiet określonych przez model offline (Filip Krawczak)

Przeprowadzono również testy, w których oceniano dokładność algorytmu do liczenia częstości oddechu na podstawie etykiet określonych przez model w trybie offline. Dzięki temu model lepiej identyfikuje etapy cyklu oddechowego, co jest szczególnie istotne w przypadku danych pochodzących z akcelerometrów.

Tabela 4.2. Dokładność algorytmu w zależności od liczby próbek i sensora w trybie offline (źródło własne)

Sensor	Liczba etykiet z rzędu					
	1	2	3	4	5	6
Akcelerometr WitMotion	47.58%	66.13%	80.65%	90.32%	91.67%	99.12%
Akcelerometr iNode Nav	42.74%	69.35%	83.06%	90.32%	94.17%	95.61%
Tensometr	91.00%	100.00%	90.53%	94.94%	91.89%	90.00%




Rys. 4.19. Dokładność liczenia oddechów od liczby próbek w trybie offline (źródło własne)

Wyniki przeprowadzonych testów, zawarte w tabeli 4.2 oraz na wykresie 4.19 pozwalają na wyciągnięcie kilku istotnych wniosków.


1. Już przy czterech próbkach algorytm osiąga dokładność około 90% dla wszystkich sensorów, co zapewnia zadowalające rezultaty jednocześnie zapobiegając pomijaniu oddechów z powodu zbyt rygorystycznych wymagań dla uznania cyklu za pełny.
2. Zaobserwowano spadek dokładności algorytmu dla tensometru wraz ze wzrostem liczby analizowanych etykiet, co sugeruje, że algorytm zaczyna pomijać niektóre oddechy.
3. Model offline osiąga lepsze rezultaty model runtime. Warto jednak zauważyć, że mimo wyższej dokładności, czas przetwarzania danych w modelu offline jest dłuższy, co może stanowić ograniczenia w aplikacjach wymagających natychmiastowej analizy danych
4. W przypadku danych zawierających duże zakłócenia i szумы, takie jak dane pochodzące z akcelerometrów powinno się uwzględnić większą liczbę etykiet do analizy przed podjęciem decyzji o naliczeniu pełnego cyklu oddechu. Większa liczba próbek pozwala na lepszą filtrację zakłóceń, co zwiększa stabilność wyników.

4.7. Zależność rozmiaru zbioru danych do dokładności modelu (Maciej Szeffler)



Rys. 4.20. Wykres jakości klasyfikacji tensometru dla różnych rozmiarów danych treningowych. 100% danych oznacza 48000 próbek (źródło własne)


Wyniki, przedstawione na rysunku 4.20 dla danych z tensometru, wskazują na trend w zmianach dokładności modelu w zależności od ilości danych treningowych. Dla małego zbioru danych, stanowiącego zaledwie 1% całkowitej ilości, dokładność modelu przekroczyła 50% dla tensometru, co stanowi wynik znaczący, biorąc pod uwagę ograniczoną ilość informacji do nauki. Przy dalszym zwiększaniu zbioru danych dokładność wzrasta. Jednakże, przekazanie większych rozmiarów zbioru danych przyniosło niewielki, pomijalny wzrost dokładności, utrzymując się na stabilnym poziomie. Ta obserwacja sugeruje, że model GRU osiągnął nasycenie informacyjne przy około połowie całkowitej dostępnej ilości danych.




Rys. 4.21. Wykres jakości klasyfikacji akcelerometru iNode Nav dla różnych rozmiarów danych treningowych. 100% danych oznacza 67000 próbek (źródło własne)

W przypadku rysunku 4.21 zaobserwowano interesującą zależność. Dokładność modelu wzrastała wraz ze wzrostem rozmiaru zbioru danych treningowych, osiągając maksimum przy wykorzystaniu 75% dostępnych danych. Jednak dla pełnego zbioru danych zaobserwowano spadek dokładności, co można przypisać zjawisku przetrenowania modelu. Aby zaradzić temu problemowi, jednym z możliwych rozwiązań jest zastosowanie warstwy Dropout. W bibliotece TensorFlow warstwa ta umożliwia wprowadzenie losowego odrzucenia określonego procenta jednostek w trakcie treningu, co zapobiega nadmiernemu dopasowaniu modelu i poprawia jego uogólnienie na nowe dane.


Dzięki zastosowaniu takiej warstwy, udało się zwiększyć dokładność do 77,90%.



Rys. 4.22. Wykres pomyłek klas dla tensometru GRUModel dla 1% danych wejściowych (źródło własne)



Rys. 4.23. Wykres pomyłek klas dla tensometru GRUModel dla 50% danych wejściowych (źródło własne)



Rys. 4.24. Wykres pomyłek klas dla tensometru GRUModel dla 100% danych wejściowych (źródło własne)

Rys. 4.22, 4.23, 4.24 przedstawiają macierze konfuzji dla różnej liczby danych wejściowych. Jedynie znaczące różnice zostały zaobserwowane między 1% rozmiarem danych wejściowych a pozostałymi. Szczególnie widoczne jest to dla klasy "wydech", gdzie model bardzo często klasyfikował ten typ jako bezdech po wydechu.

Różnice w przypadku 50% a 100% rozmiaru danych wejściowych były niewielkie. Wynikały one z samej jakości danych, a nie ich rozmiaru.

4.8. Human-in-the-loop (Maciej Szeffler)

W trakcie trwania pracy, stosowano podejście zwany Human-in-the-loop. Jest to pojęcie związane z procesem trenowania modeli sztucznej inteligencji. Człowiek w takim cyklu pełni rolę eksperta, który dostarcza model nowymi poprawionymi danymi. Jak opisują autorzy w artykule [29], podejście Human-in-the-loop ma bardzo szerokie zastosowanie. Człowiek może brać udział w każdym procesie związanym z trenowaniem modeli.


1. Wydobycie danych. W przypadku opisywanej pracy, było to zebranie danych z urządzeń na przykładowych osobach badanych.
2. Oczyszczanie danych. Ten proces był szczególnie zauważalny w przypadku pracy z danymi z akcelerometru. Sensor ten wprowadzał duże szумы oraz przekłamanie. W tym celu niektóre dane zostały usunięte ze zbiorów.
3. Etykietowanie danych. Jak wspomniano już wcześniej, dane pobrane z urządzeń były we wstępnych etapach etykietowane przez zmianę pochodnej, natomiast w końcowej fazie wszystko było przeglądane przez człowieka i ewentualnie poprawiane.
4. Trenowanie modeli. Przetestowano różne kombinacje parametrów, samych modeli czy warstw w tych modelach.

Samo pojęcie "loop" w kontekście tego terminu oznacza iteracyjność. Przykładowo akwizycja danych nie odbyła się raz, a była sukcesywnie stosowana przez cały czas trwania pracy. Również etykietowanie danych wymagało kilkukrotnego przeglądania i ewentualnego poprawiania błędnie zaklasyfikowanych danych.

Bardzo ważnym etapem była obserwacja kluczowych momentów, w których model osiągał najniższą dokładność. W szczególności zwrócono uwagę na momenty retencji po wdechu, jak pokazano na wykresie 4.13. Zdecydowano się przeprowadzić następujące czynności:

1. Model został wytrenowany podstawowymi danymi, używanymi w standardowym procesie uczenia;
2. Następnie, na podstawie predykcji modeli, w cykl wkraczał człowiek, którego zadaniem była ocena podjętych przez model decyzji, aby poprawić ewentualne błędy;
3. Zgrupowane błędnie zaklasyfikowane dane, zostały poprawione oraz ponownie umieszczone w zbiorze treningowym.

Podczas długotrwałych testów, zauważono znaczącą poprawę zastosowania takiego podejścia dla modelu akcelerometru. W przypadku tensometru, zaobserwowano wzrost dokładności o około 1 p.p. Dla akcelerometru iNode Nav wzrost wyniósł około 10 p.p.




Rys. 4.25. Porównanie modelu a) przed wykorzystaniem procesu Human-in-the-loop b) po wykorzystaniu procesu Human-in-the-loop (źródło własne)


Rysunek 4.25 przedstawia porównanie zastosowania procesu HITL w modelu runtime dla danych uzyskanych z akcelerometru iNode Nav. Prace rozpoczęto ze dokładnością modelu wynoszącą 66,23%, a zakończono na 76,81%. Eksperyment ten podkreślił, jak ważne jest ciągle poprawianie danych. Bez żadnych modyfikacji modelu, udało się uzyskać wynik o ponad 10 p.p. wyższy. Zastosowano ponad 20 iteracji HITL, a z każdą z nich, obserwowano kolejne poprawy dokładności.

4.9. Pomiar pochylenia (Damian Jankowski)

W momencie wprowadzenia nowego sensora WitMotion postanowiono sprawdzić jego dokładność zarówno w modelu w trybie runtime, jak i offline. Sensor ten umożliwia zbieranie danych z wbudowanego czujnika — inklinometru, który mierzy odchylenia w stopniach od trzech osi współrzędnych, oznaczone jako *pitch*, *roll* oraz *yaw*, przedstawione na rysunku 4.26. Dane z inklinometru okazały się bardziej odporne na szumy, wykazując przewagę szczególnie podczas analizy wolnych oddechów, gdzie dane z akcelerometru były nadmiernie zaszumione, co zilustrowano na rysunku 4.27.




Rys. 4.26. Układ współrzędnych x, y, z oraz wizualizacja kątów obrotu: *pitch*, *roll*, *yaw*.




Rys. 4.27. Porównanie znormalizowanych danych z dwóch czujników sensora WitMotion: akcelerometru (rys. 4.27a) oraz inklinometru (rys. 4.27b), uzyskanych z tego samego pomiaru jednej fazy oddechu (źródło własne)

Przygotowano zestaw treningowy składający się z 25 minut nagrania różnych rodzajów oddechu. Następnie próbkom ręcznie przypisano etykiety i je zwalidowano, wykorzystując proces HITL w kilku iteracjach. Dane były nagrywane podobnie jak w przypadku tensometru, w częstotliwości 10 Hz.



Rys. 4.28. Model akcelometru WitMotion GRU runtime. (źródło własne)

Rysunek 4.28 przedstawia dokładność modelu w trybie runtime. Osiągnął wynik powyżej 80%, przewyższając akcelometr iPhone pomimo wykorzystania mniejszej ilości danych (25 Hz w porównaniu do 10 Hz).



Rys. 4.29. Model akcelometru WitMotion GRU offline. (źródło własne)

Rysunek 4.29 przedstawia wyniki modelu w trybie offline. W porównaniu do trybu runtime nie wykazano znaczących różnic w dokładności. Wyniki pozostają zbliżone, jednak zauważono korelację pomiędzy częstotliwością próbkowania a dokładnością modelu. Zarówno tensometr, jak i akcelometr WitMotion, przesyłające dane z częstotliwością 10 Hz, wykazały niewielki wzrost dokładności w modelu offline.

Przeprowadzone testy wykazały, że sensor WitMotion, dzięki wykorzystaniu danych z in-klinometru, charakteryzuje się większą odpornością na szumy w porównaniu do akcelometru. Analiza zarówno w trybie runtime, jak i offline wykazała zbliżoną dokładność modeli, przekraczającą 80%. Mimo mniejszej częstotliwości próbkowania (10 Hz), model GRU dla WitMotion osiągnął wyższe wyniki niż akcelometr iPhone Nav, operujący na częstotliwości 25 Hz.

Ostatecznie wyniki potwierdzają, że inklinometr zintegrowany z sensorem WitMotion stanowi skuteczne narzędzie do analizy sygnałów oddechu, szczególnie w przypadku wolnych oddechów, gdzie odporność na szumy ma kluczowe znaczenie.

5. DYSKUSJA

5.1. Wnioski (Kacper Karski)

Założone cele projektu zostały w pełni zrealizowane, a osiągnięte wyniki w niektórych obszarach wykazały wysoką skuteczność i innowacyjność. Świadczy to o solidnym wykonaniu oraz dużym potencjale opracowanego rozwiązania. Stworzony system nie tylko spełnia założone wymagania funkcjonalne, lecz także otwiera szerokie możliwości rozbudowy i dalszego rozwoju w przyszłości.

Wykazano możliwość skutecznej analizy rytmu oddechowego przy wykorzystaniu nieskomplikowanych czujników, takich jak tensometr czy akcelerometr. Pomimo ich kompaktowych rozmiarów i relatywnie niskiego kosztu, są w stanie dostarczać dane wysokiej jakości, co umożliwia precyzyjną ocenę rytmu oddechowego. Dzięki temu czujniki te mogą stanowić atrakcyjną alternatywę dla bardziej zaawansowanych i kosztownych urządzeń diagnostycznych, szczególnie w zastosowaniach wymagających mobilności lub niskich kosztów implementacji.

Pokazano, że zaangażowanie człowieka w cały proces związany z cyklem nagrywania, poprawiania danych oraz trenowania modelu przynosi znaczące korzyści. Mimo braku dodania nowych próbek do zbioru, udało się znacząco poprawić dokładność modelu.

Zauważono, że ograniczenia związane z analizą oddechu w trybie runtime nie występują w trybie offline. W trybie offline poprawa dokładności była uzależniona wyłącznie od jakości i ilości danych, a nie od zmiennych warunków zewnętrznych. Kluczowym powodem lepszych wyników w tym trybie był czas. Dzięki temu, że tryb offline miał dostęp do większego kontekstu i nie musiał przetwarzać danych w czasie rzeczywistym, analiza mogła być dokładniejsza, a model lepiej dopasowany do danych. Brak konieczności działania w czasie rzeczywistym pozwolił na uzyskanie lepszych rezultatów, co ma istotne znaczenie dla dalszego rozwoju projektu.

Warto również podkreślić, że efektywna analiza rytmu oddechowego za pomocą opracowanego systemu nie wymaga dużych ilości danych treningowych, co zostało wykazane w rozdziale 4.7. Wyniki sugerują, że nawet przy wykorzystaniu części dostępnych danych możliwe jest osiągnięcie wysokiej dokładności modeli predykcyjnych. Taka cecha jest szczególnie istotna w zastosowaniach, gdzie dostęp do dużych zbiorów danych może być ograniczony, na przykład w warunkach klinicznych lub w przypadku nowych aplikacji, dla których dane są dopiero zbierane. Dzięki temu rozwiązanie może być szybciej wdrażane i adaptowane do różnych scenariuszy.

Realizacja projektu pozwoliła osiągnąć wszystkie założone cele, a wyniki wskazują na wysoki potencjał opracowanego rozwiązania. Uzyskane rezultaty stanowią solidną podstawę do dalszego rozwoju systemu. Dzięki szczegółowej analizie literatury, wysokiej jakości zbiorowi danych oraz efektywnym modelom sztucznej inteligencji, projekt stanowi obiecującą bazę dla przyszłych zaawansowanych aplikacji wspierających diagnostykę medyczną i monitorowanie zdrowia.

5.2. Dalsze możliwości rozwoju (Kacper Karski)

Dalszy rozwój projektu może obejmować zwiększenie liczby uczestników badań do co najmniej 30 osób, co pozwoli na poprawę uniwersalności modeli. Wprowadzenie dynamicznych danych rejestrowanych w różnych pozycjach ciała oraz podczas aktywności fizycznych mogłoby

znacząco rozszerzyć zakres zastosowań aplikacji. Ponadto, dalsze ulepszanie architektury modeli poprzez dodanie dodatkowych warstw lub zastosowanie rozwiązania end-to-end może zwiększyć efektywność systemu dzięki automatyzacji procesów przetwarzania danych.

Interesującym kierunkiem w kontekście zastosowań medycznych, może być opracowanie prototypu koszulki, wyposażonej w wbudowane sensory rozmieszczone na klatce piersiowej. Takie rozwiązanie, umożliwiłoby analizę ruchu klatki piersiowej w czasie rzeczywistym oraz stworzenie trójwymiarowego modelu wspierającego diagnostykę schorzeń, jak astma czy zaburzenia kardiologiczne.

Kolejnym etapem rozwoju systemu mogłoby być zwiększenie liczby i różnorodności sensorów. Przykładowo integracja mikrofonu, pozwoliłaby na analizę dźwięków oddechu, co mogłoby dostarczyć dodatkowych informacji diagnostycznych, takich jak wykrywanie świstów oddechowych czy zmian charakterystycznych dla schorzeń płuc.

ZAKRES ODPOWIEDZIALNOŚCI CZŁONKÓW ZESPOŁU

Damian Jankowski

- Opracowanie instrukcji (plików readme) do instalacji i uruchomienia aplikacji mobilnej oraz skryptów do treningu sieci neuronowych
- Stworzenie funkcjonalności służącej do zapisywania danych z czujników do pliku
- Przeorganizowanie repozytorium brp-model i brp-app
- Umożliwienie połączenia kilku sensorów (iNode, WitMotion) jednocześnie z aplikacją mobilną
- Przygotowanie ekranu aplikacji mobilnej, dotyczącej zarządzania połączeniami z sensorami
- Zaktualizowanie aplikacji mobilnej do nowszych wersji systemu Android
- Debugowanie i dbanie o poprawne działanie aplikacji
- Nagrywanie danych treningowych i testowych
- Opracowanie części pracy inżynierskiej dotyczącej sensorów, ich działania oraz metod łączenia ich z aplikacją
- Dodanie etykiet czasowych podczas nagrywania danych w celu późniejszej ich analizy
- Ręczna klasyfikacja danych

Kacper Karski

- Analiza surowych danych otrzymanych z sensorów
- Opracowanie wstępnego etykietowania danych na podstawie algorytmu opartego na pochodnej
- Przygotowanie 7 modeli z różnych dziedzin sztucznej inteligencji
- Testowanie dokładności poszczególnych modeli
- Przygotowanie części pracy inżynierskiej dotyczącej aktualnie dostępnych rozwiązań na podstawie analizy artykułów naukowych
- Ręczna klasyfikacja danych

Filip Krawczak

- Stworzenie widoku ekranu wykresu i statystyk użytkownika
- Dodanie obliczania częstości oddechu wraz z przygotowaniem części widoku
- Dodanie czwartego klasyfikatora do danych i podział etykiety bezdech, na bezdech po wdechu oraz bezdech po wydechu
- Testowanie jakości i ponowne trenowanie modeli na nowych danych z czwartym klasyfikatorem
- Przygotowanie części pracy inżynierskiej dotyczącej dokumentacji repozytorium brp-ml-model
- Opracowanie części związanej z analizą i monitorowaniem oddechu na podstawie aktualnych badań
- Ręczna klasyfikacja danych

Maciej Szeffler

- Kierowanie zespołem i komunikacja z promotorem
- Stworzenie wstępnej wersji aplikacji
- Integracja wytrenowanych modeli z aplikacją mobilną
- Testowanie jakości i ponowne trenowanie modeli na poprawionych danych
- Przygotowanie funkcjonalności wersji deweloperskiej nie wymagającej połączenia z sensorami
- Stworzenie skryptu do ręcznego etykietowania danych
- Przygotowanie danych do trenowania modeli w trybie "transfer labelling"
- Opracowanie rozwiązania modelu offline
- Zintegrowanie aplikacji mobilnej, tak aby umożliwiała wyświetlanie czterech klasyfikatorów
- Opracowanie części pracy inżynierskiej dotyczącej eksperymentów wykonywanych przez cały okres trwania pracy
- Ręczna klasyfikacja danych

WYKAZ LITERATURY

- [1] MedlinePlus. *CPR - adult and child after onset of puberty*. Bethesda (MD): National Library of Medicine (US), 2023. Dostęp przez Internet: <https://medlineplus.gov/ency/article/000013.htm> [dostęp: 2024-11-04].
- [2] Larson J., Drew K.L., Folkow L.P., Milton S.L., Park T.J. "No oxygen? No problem! Intrinsic brain tolerance to hypoxia in vertebrates." *J Exp Biol.*, 2014, vol. 217, nr 7, s. 1024–1039. doi: <https://doi.org/10.1242/jeb.085381>.
- [3] Fieselmann J.F., Hendryx M.S., Helms C.M., Wakefield D.S. "Respiratory rate predicts cardiopulmonary arrest for internal medicine inpatients." *J Gen Intern Med.*, 1993, vol. 8, nr 7, s. 354–360. doi: 10.1007/BF02600071.
- [4] Nicolò A., Massaroni C., Schena E., Sacchetti M. "The importance of respiratory rate monitoring: From healthcare to sport and exercise." *Sensors*, 2020, vol. 20, nr 6396.
- [5] Cretikos M.A., Bellomo R., Hillman K., Chen J., Finfer S., Flabouris A. "Respiratory rate: The neglected vital sign." *Med. J. Aust.*, 2008, vol. 188, s. 657–659.
- [6] Prabha A., Trivedi A., Kumar A.A., Kumar C.S. "Automated system for obstructive sleep apnea detection using heart rate variability and respiratory rate variability." *Proc. 2017 Int. Conf. on Advances in Computing, Communications and Informatics (ICACCI)*, 2017, s. 1303–1307. doi: 10.1109/ICACCI.2017.8126021.
- [7] T. Cross, C. Kim, B. Johnson, S. Lalande, "The interactions between respiratory and cardiovascular systems in systolic heart failure", *Journal of Applied Physiology*, vol. 128, no. 1, p. 214-224, 2020. <https://doi.org/10.1152/japplphysiol.00113.2019>.
- [8] Banushi, B.; Brendle, M.; Ragnhildstveit, A.; Murphy, T.; Moore, C.; Egberts, J.; Robison, R. Breathwork Interventions for Adults with Clinically Diagnosed Anxiety Disorders: A Scoping Review. *Brain Sci.* 2023, 13, 256. <https://doi.org/10.3390/brainsci13020256>
- [9] Ashhad S., Kam K., Del Negro C.A., Feldman J.L. "Breathing Rhythm and Pattern and Their Influence on Emotion." *Annual Review of Neuroscience*, 2022, vol. 45, s. 223–247. doi: <https://doi.org/10.1146/annurev-neuro-090121-014424>.
- [10] Lavretsky H., Feldman J.L. "Precision Medicine for Breath-Focused Mind-Body Therapies for Stress and Anxiety: Are We Ready Yet?" *Global Advances in Health and Medicine*, 2021, vol. 10. doi: <https://doi.org/10.1177/2164956120986129>.
- [11] Zelano C., Jiang H., Zhou G., Arora N., Schuele S., Rosenow J., Gottfried J.A. "Nasal Respiration Entrain Human Limbic Oscillations and Modulates Cognitive Function." *Journal of Neuroscience*, 2016, vol. 36, no. 49, s. 12448–12467. doi: <https://doi.org/10.1523/JNEUROSCI.2586-16.2016>.
- [12] Raoufy M.R., Ghafari T., Darooei R., Nazari M., Mahdavian S.A., et al. "Classification of Asthma Based on Nonlinear Analysis of Breathing Pattern." *PLOS ONE*, 2016, vol. 11, no. 1, e0147976. doi: <https://doi.org/10.1371/journal.pone.0147976>.
- [13] Brown R.P., Gerbarg P.L. "Sudarshan Kriya Yogic Breathing in the Treatment of Stress, Anxiety, and Depression: Part I—Neurophysiologic Model." *Journal of Alternative and Complementary Medicine*, 2005, vol. 11, no. 1, s. 189–201. doi: <https://doi.org/10.1089/acm.2005.11.189>.

- [14] Zaccaro A., Piarulli A., Laurino M., Garbella E., Menicucci D., Neri B., Gemignani A. "How Breath-Control Can Change Your Life: A Systematic Review on Psycho-Physiological Correlates of Slow Breathing." *Frontiers in Human Neuroscience*, 2018, vol. 12. doi: <https://doi.org/10.3389/fnhum.2018.00353>.
- [15] Kapetanidis, P.; Kalioras, F.; Tsakonas, C.; Tzamalīs, P.; Kontogiannis, G.; Karamanidou, T.; Stavropoulos, T.G.; Nikolettseas, S. Respiratory Diseases Diagnosis Using Audio Analysis and Artificial Intelligence: A Systematic Review. *Sensors* 2024, 24, 1173. <https://doi.org/10.3390/s24041173>
- [16] Langan RC, Goodbred AJ. Office Spirometry: Indications and Interpretation. *Am Fam Physician*. 2020 Mar 15;101(6):362-368. PMID: 32163256.
- [17] Siqueira A., Spirandeli A.F., Moraes R., Zarzoso V. "Respiratory Waveform Estimation From Multiple Accelerometers: An Optimal Sensor Number and Placement Analysis." *IEEE Journal of Biomedical and Health Informatics*, 2019, vol. 23, no. 4, s. 1507–1515. doi: <https://doi.org/10.1109/JBHI.2018.2867727>.
- [18] Woolley M. "A Developer's Guide to Bluetooth Technology." Dostęp przez Internet: <https://www.bluetooth.com/blog/a-developers-guide-to-bluetooth/> [dostęp: 2024-11-04].
- [19] Nordic Semiconductor ASA. *Aplikacja nRF Connect for Mobile*. Dostęp przez Internet: <https://play.google.com/store/apps/details?id=no.nordicsemi.android.mcp> [dostęp: 2024-11-04].
- [20] Biernacki D. *Analiza oddechu z użyciem czujników*. Praca magisterska.
- [21] iNode. *Notyfikacje w iNode Nav* Dostęp przez Internet: <https://support.elsat.com.pl/dl.php?fid=823> (login: inode, hasło puste) [dostęp: 2024-11-18].
- [22] WitMotion. *Bluetooth AHRS IMU sensor | WT901BLECL*. WitMotion Shenzhen Co., Ltd. Dostęp przez Internet: https://cdn.robotshop.com/rbm/f83835f4-5e29-4ee0-9cc2-e49300031503/b/bf5c1f59-3b36-40a4-a5f0-e5a0eea52565/a8cd29da_wt901blecl-datasheet.pdf [dostęp: 2024-11-18].
- [23] GitHub. *Repozytorium brp-app*. Dostęp przez Internet: <https://github.com/Breatherzy/brp-app> [dostęp: 2024-11-04].
- [24] GitHub. *Repozytorium brp-ml-model*. Dostęp przez Internet: <https://github.com/Breatherzy/brp-ml-model> [dostęp: 2024-11-04].
- [25] Fan D., Ren A., Zhao N., Yang X., Zhang Z., Shah S.A., Hu F., Abbasi Q.H. "Breathing Rhythm Analysis in Body Centric Networks." *IEEE Access*, 2018, vol. 6, s. 32507–32513. doi: <https://doi.org/10.1109/ACCESS.2018.2846605>.
- [26] Santurkar S., Tsipras D., Ilyas A., Madry A. "How Does Batch Normalization Help Optimization?" *Advances in Neural Information Processing Systems*, 2018, vol. 31. Dostęp przez Internet: https://proceedings.neurips.cc/paper_files/paper/2018/file/905056c1ac1dad141560467e0a99e1cf-Paper.pdf [dostęp: 2024-11-04].
- [27] Nosouhian S., Nosouhian F., Khoshouei A.K. "A Review of Recurrent Neural Network Architecture for Sequence Learning: Comparison between LSTM and GRU." *Preprints*, 2021. doi: <https://doi.org/10.20944/preprints202107.0252.v1>.
- [28] Maczur M. *Jak działają sieci konwolucyjne*. Dostęp przez Internet: <https://mirosławmamczur.pl/jak-dzialaja-konwolucyjne-sieci-neuronowe-cnn/> [dostęp: 2024-11-04].
- [29] Chai C., Li G. "Human-in-the-loop Techniques in Machine Learning." *IEEE Data Eng. Bull.*, 2020, vol. 43, nr 3, s. 37–52.

WYKAZ RYSUNKÓW

2.1	Dokładności klasyfikatora SVM (źródło [6])	15
2.2	Wartości wag przypisane cechom HRV i RRV (źródło [6])	15
2.3	Optymalne rozmieszczenie sensorów zaproponowane przez autorów artykułu (źródło [17])	18
3.1	Schemat systemu (źródło własne)	20
3.2	Wynik skanowania w aplikacji, widoczny sensor iNode (źródło własne)	21
3.3	Szczegóły wybranego serwisu i charakterystyki. Widoczna 13-bajtowa ramka surowych danych (źródło własne)	22
3.4	Tensometr HX711 (źródło własne)	23
3.5	Moduł BLE tensometru (źródło własne)	24
3.6	Tensometr HX711 podłączony do mikrokontrolera ESP32 (źródło własne)	24
3.7	Akcelerometr iNode Nav (źródło własne)	25
3.8	Akcelerometr WitMotion WT901BLECL (źródło własne)	28
3.9	Wygląd aplikacji. Ekran połączenia a) oraz ekran wykresów b). (źródło własne)	31
3.10	Wygląd aplikacji. Ekran statystyk a) oraz ekran ustawień b). (źródło własne)	32
3.11	Diagram sekwencji struktury aplikacji (źródło własne)	33
3.12	Diagram przepływu aplikacji z punktu widzenia użytkownika (źródło własne)	35
3.13	Okienko wyboru zmiany klasyfikacji przedziału (źródło własne)	37
3.14	Skrypt do ręcznej klasyfikacji danych z widocznym zaznaczeniem przedziału czasu do etykietowania (źródło własne)	38
3.15	Nagrany fragment wdechu z bezdechem (a) przed przetworzeniem średnią kroczącą oraz normalizacją (b) po przetworzeniu średnią kroczącą oraz normalizacją (źródło własne)	39
3.16	Nagrany fragment hiperwentylacji (a) przed przetworzeniem średnią kroczącą oraz normalizacją (b) po przetworzeniu średnią kroczącą oraz normalizacją (źródło własne)	40
3.17	Surowe dane z tensometru (a) i akcelerometru (b) z podziałem na stany oddechu (źródło własne)	42
3.18	Autorska aplikacja do etykietowania danych (źródło własne)	44
3.19	Porównanie rezultatu klasyfikacji oddechu bazując na zmianie pochodnej z wzorcową klasyfikacją (źródło własne)	45
3.20	Diagram sieci Gated Recurrent Unit. Wartości w warstwach Dense i GRU, oznaczają wymiar wyjściowych danych. W przypadku warstwy Dropout, jest to procentowa liczba przypadkowo odrzucanych próbek (źródło własne)	47
4.1	Surowe dane pobrane przez twórców artykułu (źródło [25])	49
4.2	Surowe dane pobrane za pomocą pletyzmografu (źródło [12])	49
4.3	Szacowanie częstości oddechów za pomocą metody obliczania cyklu oddechowego opartej na wykrywaniu szczytów. (a) W przypadku wolnego oddechu. (b) W normalnym oddychaniu. (c) W przypadku szybkiego oddechu. (źródło [25])	50
4.4	Wyniki różnych modeli trenowanych na zbiorze treningowym z tensometru (źródło własne)	51
4.5	Wyniki różnych modeli trenowanych na zbiorze treningowym z akcelerometru iNode Nav (źródło własne)	51
4.6	Diagram sieci wykorzystującej normalizację wsadową. Wartości w warstwach Dense, oznaczają wymiar wyjściowych danych (źródło własne)	52
4.7	Przykładowy wykres historii uczenia modeli tensometru z normalizacją wsadową. (źródło własne)	53
4.8	Przykładowy wykres historii uczenia modeli tensometru bez normalizacji wsadowej. (źródło własne)	53
4.9	Diagram jednowymiarowej sieci konwolucyjnej. Wartości w warstwach, oznaczają wymiar wyjściowych danych (źródło własne)	56

4.10 Wyniki klasyfikacji danych z tensometru wraz z historią uczenia modelu GRUModel. Na danych testowych osiągnął dokładność 88.06%. (źródło własne)	56
4.11 Wyniki klasyfikacji danych z akcelerometru iNode Nav wraz z historią uczenia modelu GRUModel. Na danych testowych osiągnął dokładność 77.24%. (źródło własne)	57
4.12 Przykładowy problem, przed którym stoi model (źródło własne)	58
4.13 Wynik modelu tensometru wytrenowanego tylko na zbiorze 'wdech i zatrzymanie'. (źródło własne)	58
4.14 Liczba próbek z konkretnymi etykietami w zbiorze. Etykiety wynikają z tabeli 3.9 (źródło własne)	59
4.15 Dokładność modelu w zależności od liczby epok (źródło własne)	61
4.16 Wyniki klasyfikacji danych z tensometru. Na rysunku a) widoczny jest model działający w trybie runtime. Na rysunku b) model działający w trybie offline. (źródło własne)	62
4.17 Wyniki klasyfikacji danych z akcelerometru iNode Nav. Na rysunku a) widoczny jest model runtime, a więc działający w trybie runtime. Na rysunku b) model działający w trybie offline. (źródło własne)	62
4.18 Dokładność liczenia oddechów od liczby próbek w trybie runtime (źródło własne)	64
4.19 Dokładność liczenia oddechów od liczby próbek w trybie offline (źródło własne)	65
4.20 Wykres jakości klasyfikacji tensometru dla różnych rozmiarów danych treningowych. 100% danych oznacza 48000 próbek (źródło własne)	66
4.21 Wykres jakości klasyfikacji akcelerometru iNode Nav dla różnych rozmiarów danych treningowych. 100% danych oznacza 67000 próbek (źródło własne)	66
4.22 Wykres pomyłek klas dla tensometru GRUModel dla 1% danych wejściowych (źródło własne)	67
4.23 Wykres pomyłek klas dla tensometru GRUModel dla 50% danych wejściowych (źródło własne)	67
4.24 Wykres pomyłek klas dla tensometru GRUModel dla 100% danych wejściowych (źródło własne)	68
4.25 Porównanie modelu a) przed wykorzystaniem procesu Human-in-the-loop b) po wykorzystaniu procesu Human-in-the-loop (źródło własne)	69
4.26 Układ współrzędnych x, y, z oraz wizualizacja kątów obrotu: <i>pitch, roll, yaw</i> .	70
4.27 Porównanie znormalizowanych danych z dwóch czujników sensora WitMotion: akcelerometru (rys. 4.27a) oraz inklinometru (rys. 4.27b), uzyskanych z tego samego pomiaru jednej fazy oddechu (źródło własne)	70
4.28 Model akcelerometru WitMotion GRU runtime. (źródło własne)	71
4.29 Model akcelerometru WitMotion GRU offline. (źródło własne)	71

WYKAZ TABEL

3.1	Adresy UUID serwisów oraz charakterystyk dla iNode (źródło [21])	26
3.2	Możliwe ustawienia czujnika iNode Nav. Bajt 1 (źródło [21])	26
3.3	Możliwe ustawienia czujnika iNode Nav. Bajt 2 (źródło [21], z wprowadzoną poprawką w związku z błędem w dokumentacji producenta)	26
3.4	Ramka danych wysyłana przez sensor iNode w trybie <i>tylko dane z akcelerometru</i> (źródło [21])	26
3.5	Adresy UUID serwisów oraz charakterystyk dla WitMotion (źródło [22])	28
3.6	Struktura ramki sensora WitMotion (źródło [22])	28
3.7	Możliwe ustawienie częstotliwości wysyłania danych dla sensora WitMotion (źródło [22])	29
3.8	Format pakietu danych dla czujnika WitMotion (źródło [22])	30
3.9	Liczbowa reprezentacja stanów (źródło własne)	41
3.10	Poszczególne rodzaje i rozmiary danych tensometru w procesie trenowania modeli (źródło własne)	41
3.11	Poszczególne rodzaje i rozmiary danych w procesie testowania modeli (źródło własne)	41
3.12	Podział faz oddechowych na podstawie zbiorów wartości pochodnej funkcji (źródło własne)	45
4.1	Dokładność algorytmu w zależności od ilości próbek i sensora (źródło własne)	63
4.2	Dokładność algorytmu w zależności od liczby próbek i sensora w trybie offline (źródło własne)	65